

# M54: Analyse numérique matricielle (cours)

Bernhard Beckermann

Laboratoire Painlevé, Université de Lille, France  
Bernhard.Beckermann@univ-lille.fr

29/08/2021



## Motivations (et bref contenu) de ce cours

L'analyse numérique matricielle sert pour...

- une simulation en aérodynamique (d'un avion, d'une voiture, ...)
- la Conception Assistée par Ordinateur d'une pièce mécanique (un moteur, une prothèse, ...)
- les techniques de compression de données (photos, big data,...)
- le fonctionnement d'un moteur de recherche (Google, ...)

Ces thèmes sont évoqués plus en détail dans d'autres modules de maths applis, mais comme brique de base on doit

- trouver un/plusieurs/tous les éléments propres d'une matrice  $A$  de grande taille
- trouver  $x \in \mathbb{R}^n$  solution de  $Ax = b$  dans un sens à préciser (aux moindres carrés).

Nos challenges :

- montrer l'existence, l'unicité des objets en question (outil : normes matricielles)
- trouver des méthodes efficaces de résolution, en passant par des factorisations (svd, LU, QR, etc) de  $A$ , en tenant compte d'une forme particulière de  $A$
- comprendre l'impact des erreurs sur les données  $A, b$
- comprendre l'effet de la précision finie sur ordinateur...



## Table de matières

- 1 Notions et Rappels
- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice  $A$  ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR



## Bibliographie (Lilliad)

- 1 Allaire, G. et Kaber, S.M. Algèbre linéaire numérique. Ellipses, 2002.
- 2 Amodei, L. et Dedieu, J.P. Analyse numérique matricielle. Dunod, 2008.
- 3 Brezinski, C. et Redivo-Zaglia, M. Méthodes numériques directes de l'algèbre matricielle. Ellipses, 2004.
- 4 Ciarlet, P.G. Introduction à l'analyse numérique matricielle et à l'optimisation. Masson, 1988.
- 5 Filbet, F. Analyse numérique. Algorithmique et étude mathématique. Dunod, 2009.
- 6 Lascaux, P. et Théodor, R. Analyse numérique matricielle appliquée à l'art de l'ingénieur. Seconde édition, Tome 1, Masson, 1993.
- 7 Lascaux, P. et Théodor, R. Analyse numérique matricielle appliquée à l'art de l'ingénieur. Seconde édition, Tome 2, Masson, 1993.
- 8 Quarteroni, A. et Saleri, F. Calcul Scientifique. Cours, exercices corrigés et illustrations en MATLAB et Octave. Springer, 2006.
- 9 Schatzman, M. Analyse numérique : Une approche mathématique. Dunod, 2004.



## La précision finie sur ordinateur

Un nombre machine est un nombre en virgule flottante (en bases 2, 16 ou ici 10) avec une mantisse et un exposant de taille limitée. Étant donné un nombre  $\alpha$  réel, l'ordinateur stocke alors le nombre machine  $\text{float}(\alpha)$ , avec

$$|\alpha - \text{float}(\alpha)| \leq \epsilon |\alpha|$$

avec la précision machine  $\epsilon \approx 10^{-8}$  (resp.  $10^{-16}$ ) en simple précision (resp. double précision).

Un bon modèle pour comprendre l'erreur sur ordinateur d'une opération élémentaire entre deux nombres machines  $\alpha, \beta$  est

$$\alpha \otimes \beta = \text{float}(\alpha \times \beta), \quad \otimes \in \{+, -, \cdot, /\}.$$

Il reste à savoir comment ces "petites" erreurs s'accumulent ?

### Exemple 0.1

Calculer  $\beta = (2 + \alpha) - \alpha$  sur ordinateur en double précision pour  $\alpha = 10^{20}$  donne  $\tilde{\beta} = 0$ , avec une erreur relative  $|\tilde{\beta} - \beta|/|\beta| = 1$  (de 100%).

On vient de rencontrer un exemple de **cancellation** : l'erreur relative augmente fortement si on forme la différence de deux nombres de taille comparable et de même signe. La cancellation n'apparaît pas pour d'autres opérations arithmétiques élémentaires.



## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice  $A$  ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR



## Notions de base : matrices/vecteurs

- $\mathbb{K} \in \{\mathbb{R}, \mathbb{C}\}$  corps des nombres réels ou complexes ;
- $\mathcal{M}_{m,n}(\mathbb{K})$  l'ensemble des matrices à  $m$  lignes et  $n$  colonnes (de type/taille/format  $(m, n)$ ) à éléments dans  $\mathbb{K}$ . Convention : une matrice  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  est notée en majuscules, avec élément  $a_{i,j}$  à la position ligne  $i \in \{1, \dots, m\}$  et colonne  $j \in \{1, \dots, n\}$ . On note par  $0_{m,n} = 0$  la matrice comportant que des éléments 0 (la taille de 0 étant clair du contexte).
- $\mathcal{M}_m(\mathbb{K}) = \mathcal{M}_{m,m}(\mathbb{K})$  l'ensemble des matrices carrées d'ordre  $m$ . On note par  $I_m = I$  la matrice identité.
- $\mathbb{K}^m$  ensemble des vecteurs (colonne), parfois identifiés avec les matrices colonnes  $\mathcal{M}_{m,1}(\mathbb{K})$ . Convention : un vecteur  $x$  est noté en minuscules, avec élément  $x_j$  à la position  $j$  (et des scalaires avec des lettres grecs).
- Transposée  $A^T \in \mathcal{M}_{n,m}(\mathbb{K})$  de  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  avec éléments  $(A^T)_{i,j} = a_{j,i}$ .
- Adjointe  $A^* \in \mathcal{M}_{n,m}(\mathbb{K})$  avec éléments  $(A^*)_{i,j} = \overline{a_{j,i}}$ .
- Produit scalaire entre deux vecteurs  $x, y \in \mathbb{C}^n$  :  $(y, x) = x^* y = \sum_{j=1}^n \bar{x}_j y_j$ .
- Norme euclidienne induite  $\|x\|_2 = \sqrt{(x, x)}$ .
- Inégalité de Cauchy-Schwarz :  $|(x, y)| \leq \|x\|_2 \|y\|_2$ .
- Base canonique  $\{e_1, \dots, e_n\}$  du  $\mathbb{K}^n$  (colonnes de  $I_n$ ), base orthonormée du  $\mathbb{K}^n$ .
- Image  $\text{Im}(A) = \{Ax : x \in \mathbb{K}^n\}$ , le rang  $\text{rang}(A) = \dim \text{Im}(A)$  et noyau  $\ker(A) = \{x \in \mathbb{K}^n : Ax = 0\}$  d'une matrice  $A \in \mathcal{M}_{m,n}(\mathbb{K})$ .
- Pour  $K \subset \mathbb{K}^n$  sous-espace vectoriel : complément orthogonal  $K^\perp = \{y \in \mathbb{K}^n : \forall x \in K, (x, y) = 0\}$ .

## Notions de base : Quelques matrices particulières

### Définition 1.1

Une matrice  $A \in \mathcal{M}_n(\mathbb{K})$  est dite

- **inversible** s'il existe  $B \in \mathcal{M}_n(\mathbb{K})$  avec  $BA = I$  (ou  $AB = I$ ). Dans ce cas,  $B$  est unique, dite inverse de  $A$ , et notée  $A^{-1}$ ;
- **symétrique** (resp. **hermitienne**) si  $A^T = A$  (resp.  $A = A^*$ );
- **orthogonale** (resp. **unitaire**) si  $A^T A = I$  (resp.  $A^* A = I$ );
- **normale** si  $AA^* = A^* A$ ;
- **semi-définie positive** si  $\forall x \in \mathbb{K}^n, (Ax, x) \geq 0$ ;
- **définie positive** si elle est semi-définie positive, et  $(Ax, x) = 0$  implique  $x = 0$  ;
- **diagonale** si  $a_{j,k} = 0$  pour  $j \neq k$  ;
- **triangulaire supérieure** (resp. **inférieure**) si  $a_{j,k} = 0$  pour  $j > k$  (resp.  $j < k$ ).
- **similaire à  $B \in \mathcal{M}_n(\mathbb{K})$**  s'il existe une matrice inversible  $S$  avec  $B = S^{-1}AS$ . Elle est dit **diagonalisable** si elle est similaire à une matrice diagonale.

## Notions de base : valeurs propres

### Définition 1.2

$\lambda \in \mathbb{C}$  est dit **valeur propre** de  $A \in \mathcal{M}_n(\mathbb{K})$  s'il existe  $x \in \mathbb{C}^n \setminus \{0\}$  dit **vecteur propre** de sorte que  $Ax = \lambda x$ .

Le couple  $(\lambda, x)$  est dit **élément propre** de  $A$ .

On note par  $\text{Sp}(A)$  dit **spectre** l'ensemble des valeurs propres de  $A$ , et par  $\chi_A(\lambda) = \det(A - \lambda I)$  le **polynôme caractéristique** de  $A$ .

### Lemme 1.3

$\text{Sp}(A)$  est l'ensemble des racines de  $\chi_A$ . Par conséquent,  $A$  admet au moins une valeur propre, et au plus  $n$ .

### Définition 1.4

On appelle **rayon spectral** de  $A \in \mathcal{M}_n(\mathbb{K})$  la quantité  $\rho(A) = \max\{|\lambda| : \lambda \in \text{Sp}(A)\}$ .

### Théorème 1.5 (Matrices diagonalisables)

- Il existe une matrice non diagonalisable.
- $A \in \mathcal{M}_n(\mathbb{K})$  est diagonalisable avec  $B = S^{-1}AS$  diagonale ssi  $A$  admet une base de vecteurs donnée par les colonnes de  $S$ , avec valeurs propres associées sur la diagonale de  $B$ .
- Si  $A \in \mathcal{M}_n(\mathbb{K})$  admet  $n$  valeurs propres distinctes alors  $A$  est diagonalisable.

## Notions de base : Normes vectorielles

### Définition 1.6

Soit  $E$  un espace vectoriel sur le corps  $\mathbb{K}$ . Une application  $E \ni x \mapsto \|x\| \in \mathbb{R}$  est dite norme si

- 1) positivité et séparation       $\forall x \in E, \|x\| \geq 0, (\|x\| = 0 \text{ssi } x = 0)$ ;
- 2) homogénéité       $\forall x \in E, \forall \alpha \in \mathbb{K} : \|\alpha x\| = |\alpha| \|x\|$ ;
- 3) inégalité triangulaire       $\forall x, y \in E : \|x + y\| \leq \|x\| + \|y\|$ .

Dans ce cas,  $E$  muni de la norme  $\|\cdot\|$  est dit espace normé.

### Exemple 1.7

Pour un entier  $n \geq 2$ ,  $\mathbb{K} = \mathbb{R}$ ,  $E = \mathbb{K}^n$  on peut définir trois **normes vectorielles usuelles**

$$\|x\|_2 = \sqrt{\sum_{j=1}^n |x_j|^2}, \quad \|x\|_1 = \sum_{j=1}^n |x_j|, \quad \|x\|_\infty = \max_{j=1, \dots, n} |x_j|.$$

Ces formules donnent également des normes dans le cas  $\mathbb{K} = \mathbb{C}$ .

## Notions de base : des révisions

- 1 Revoir opérations sur les matrices : addition (terme par terme) et multiplication (si dimensions sont compatibles), multiplication d'une matrice avec un scalaire. En général  $AB \neq BA$ . On ne divise pas par des matrices ! Une matrice inversible doit être carrée !
- 2  $\mathbb{K}^n$  est un espace vectoriel sur  $\mathbb{K}$ ,  $\mathcal{M}_{m,n}(\mathbb{K})$  aussi.
- 3  $\mathbb{K}^n$  muni avec  $\|\cdot\|_p$  pour  $p \in \{1, 2, \infty\}$  est un espace normé.
- 4 Rappel sous-espace vectoriel, combinaison linéaire, système libre (=linéairement indépendant), système génératrice, dimension, base d'un espace vectoriel. Base orthonormée. Construction.
- 5 Tout système libre de  $k < n$  vecteurs du  $\mathbb{K}^n$  peut se compléter pour former une base du  $\mathbb{K}^n$ .
- 6  $(AB)^* = B^* A^*$ , de même pour la transposée (et l'inverse si cela existe).  $\det(AB) = \det(A) \det(B)$ .
- 7 Si  $A \in \mathcal{M}_{m,n}(\mathbb{K})$ ,  $b \in \mathbb{K}^m$ , le système  $Ax = b$  admet une solution  $y$  si  $b \in \text{Im}(A)$ . Dans ce cas, l'ensemble des solutions est donné par  $y + \text{Ker}(A)$ .
- 8  $A \in \mathcal{M}_n(\mathbb{K})$  est inversible ssi  $\det(A) \neq 0$  ssi  $\exists B \in \mathcal{M}_n(\mathbb{K})$  avec  $AB = I$  (ou  $BA = I$ ).
- 9 le déterminant d'une matrice triangulaire  $A$  se calcule en prenant le produit des éléments sur la diagonale.
- 10  $\det(A^{-1}) = 1/\det(A)$ ,  $\det(A^T) = \det(A)$ ,  $(A^*)^{-1} = (A^{-1})^*$ .
- 11 Pour  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  :  $\text{rang}(A) + \dim(\text{ker}(A)) = n$ .  $\text{rang}(A) = \text{rang}(A^*)$ . Pour tout  $K \subset \mathbb{K}^n$  sous-espace vectoriel :  $(K^\perp)^\perp = K$ .  $\text{ker}(A)^\perp = \text{Im}(A^*)$ .



## Applications et Révisions

- 2 La factorisation de Schur et la SVD
- 3 Matrices matrice de  $A^*$  et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle de la décomposition LU
- 6 Comment exploiter une structure dans la matrice  $A$  ?
- 7 Le problème des racines carrees et la décomposition QR
- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode GF



## La factorisation de Schur et ses conséquences

Théorème 2.1 (Factorisation de Schur)

Pour tout  $A \in \mathcal{M}_n(\mathbb{C})$  il existe  $U \in \mathcal{M}_n(\mathbb{C})$  unitaire et  $T \in \mathcal{M}_n(\mathbb{C})$  de sorte que  $T = U^*AU$ .

Si  $A$  est normale alors  $T$  est diagonale.

Corollaire 2.2 (Diagonalisation d'une matrice hermitienne)

Soit  $A \in \mathcal{M}_n(\mathbb{C})$  hermitienne. Alors il existe  $U \in \mathcal{M}_n(\mathbb{C})$  unitaire de sorte que la matrice  $D = U^*AU$  est diagonale et composée des valeurs propres de  $A$ .  
Si  $A \in \mathcal{M}_n(\mathbb{R})$  alors aussi  $U, D \in \mathcal{M}_n(\mathbb{R})$ .

Nous déduisons qu'une matrice hermitienne admet une base orthonormée de vecteurs propres.



## Décomposition en valeurs singulières (1)

Soit  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  une matrice rectangulaire.

Lemme 2.3

Pour toute matrice  $A \in \mathcal{M}_{m,n}(\mathbb{K})$ , les valeurs propres de  $A^*A$  sont réelles et  $\geq 0$ .

Lemme 2.4

Soient  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  et  $B \in \mathcal{M}_{n,m}(\mathbb{K})$ , alors les valeurs propres non nulles de  $AB$  et de  $BA$  sont les mêmes (comptant multiplicité).

Définition 2.5 (Valeurs singulières d'une matrice)

Les valeurs singulières  $\mu_1 \geq \mu_2 \geq \dots \geq \mu_n$  d'une matrice  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  sont les racines carrées positives ou nulles des valeurs propres de  $A^*A$ .

Théorème 2.6 (Valeurs singulières d'une matrice normale)

Les valeurs singulières d'une matrice normale  $A \in \mathcal{M}_n(\mathbb{K})$  sont les modules de ses valeurs propres.



## Décomposition en valeurs singulières (2)

Théorème 2.7 (Décomposition en valeurs singulières, SVD)

Soit  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  avec  $r$  valeurs singulières positives. Alors il existe  $U \in \mathcal{M}_m(\mathbb{K})$  et  $V \in \mathcal{M}_n(\mathbb{K})$  toutes les deux unitaires et  $\Sigma \in \mathcal{M}_{m,n}(\mathbb{K})$  "diagonale" tel que

$$A = U\Sigma V^*, \quad \Sigma = \begin{bmatrix} \tilde{\Sigma} & 0 \\ 0 & 0 \end{bmatrix}$$

avec  $\tilde{\Sigma} = \text{diag}(\mu_1, \mu_2, \dots, \mu_r)$ , où  $\mu_1 \geq \dots \geq \mu_r > 0$ . En particulier,  
 $\text{rank}(A) = r \leq \min(m, n)$ .

Remarques 2.8 (Schéma de calcul de la svd)

- Calculer les éléments propres  $(\mu_j^2, v_j)$  de  $A^* A$  avec  $\mu_1 \geq \dots \geq \mu_r > \mu_{r+1} = \dots = \mu_n = 0$  et  $\{v_1, \dots, v_n\}$  base orthonormée du  $\mathbb{K}^n$  ;
- Calculer  $u_j = Av_j / \mu_j$  pour  $j = 1, \dots, r$ , ainsi que  $\{u_{r+1}, \dots, u_m\}$  base orthonormée de  $\ker(A^*) = \ker(AA^*)$  ;
- Poser  $U = (u_1, \dots, u_m)$ ,  $V = (v_1, \dots, v_n)$ ,  $\Sigma$  comme avant.

NB : Pour se ramener de  $n > m$  à  $n \leq m$ , on peut calculer la svd  $A^* = V\Sigma^* U^*$ .

On conclut que si  $A$  est réelle alors aussi  $U$  et  $V$  peuvent être réelles.



### SVD (3) : approcher $A$ par une matrice de faible rang

Si on mesure la distance entre deux matrices de même taille par la norme spectrale  $\|\cdot\|_2$  discutée au chapitre suivant, on montrera aux TD le résultat important suivant.

Théorème 2.9 (Théorème de Eckhart-Young)

Pour  $k \in \{0, \dots, \min(m, n)\}$  la matrice de rang  $\leq k$  la plus proche de  $A$  est donnée par

$$B = U \begin{bmatrix} \text{diag}(\mu_1, \dots, \mu_k) & 0 \\ 0 & 0 \end{bmatrix} V^* = \sum_{j=1}^k u_j \mu_j v_j^*,$$

de distance donnée par  $\mu_{k+1}$ .

Pour calculer  $B$  il suffit alors de connaître seulement  $k$  éléments propres de  $A^* A$ . Stocker  $B$  au lieu de  $A$  nécessitera alors  $(m+n)k$  emplacements mémoires au lieu de  $mn$ , ce qui peut signifier un large gain, en particulier dans le contexte de l'ACP en big data où  $k = 2$ .

On verra en TP un exemple de compression d'images (un élément d'une matrice correspond au niveau gris du pixel associé).

1

2 La toute sur une Schur et la SVD

3 Normes matricielles et conditionnement

4 Resolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss

5 Interprétation matricielle : la décomposition LU

6 Comment exploiter une structure dans la matrice  $A$  ?

7 Le problème des moindres carrés et la décomposition QR

8 Calcul de la décomposition QR par Householder et Givens

9 Calcul numérique de valeurs propres

10 La méthode de la puissance

11 La méthode QR



### Normes matricielles et normes compatibles

Définition 3.1 (norme matricielles)

On se donne pour tout entier  $n \geq 1$  une norme vectorielle  $\|\cdot\|$  sur  $\mathbb{K}^n$ . Une norme  $\|\cdot\|$  sur  $\mathcal{M}_{m,n}(\mathbb{K})$  est dite

- compatible avec la norme vectorielle  $\|\cdot\|$  si

$$\forall A \in \mathcal{M}_{m,n}(\mathbb{K}) \forall x \in \mathbb{K}^n : \|Ax\| \leq \|A\| \|x\|.$$

- sous-multiplicative ou norme matricielle si

$$\forall A \in \mathcal{M}_{m,n}(\mathbb{K}) \forall B \in \mathcal{M}_{n,\ell}(\mathbb{K}) : \|AB\| \leq \|A\| \|B\|.$$

Exemple 3.2 (norme de Frobenius aussi dite norme de Schur)

L'expression

$$\|A\|_F = \sqrt{\sum_{j=1}^m \sum_{k=1}^n |a_{j,k}|^2} = \sqrt{\text{trace}(A^* A)}$$

donne une norme matricielle sur  $\mathcal{M}_{m,n}(\mathbb{K})$  qui est compatible avec la norme vectorielle euclidienne  $\|\cdot\|_2$ .

Lemme 3.3

A toute norme matricielle  $\|\cdot\|$  on peut associer une norme vectorielle qui lui soit compatible. En particulier,  $\|A\| \geq \rho(A)$  pour tout  $A \in \mathcal{M}_n(\mathbb{K})$ .



## Normes subordonnées

**Théorème 3.4 (norme subordonnée)**

On se donne pour tout entier  $n \geq 1$  une norme vectorielle  $\|\cdot\|$  sur  $\mathbb{K}^n$ , et

$A \in \mathcal{M}_{m,n}(\mathbb{K})$ . L'expression

$$\|A\| := \max_{x \in \mathbb{K}^n, \|x\|=1} \|Ax\|$$

donne bien une norme matricielle compatible avec la norme vectorielle  $\|\cdot\|$  dite **norme matricielle subordonnée à la norme vectorielle**  $\|\cdot\|$ .

Pour toute norme matricielle subordonnée,  $\|I_n\| = 1$ . Pour la norme de Schur,  $\|I_n\|_S = \sqrt{n}$ , elle n'est alors pas subordonnée.

**Définition 3.5 (normes subordonnées usuelles)**

Pour nos normes vectoriels usuels  $\|\cdot\|_p$ ,  $p = 1, 2, \infty$ , on note par  $\|A\|_p$  aussi la norme matricielle subordonnée. La norme matricielle  $\|\cdot\|_2$  est aussi appelée **norme spectrale**.

**Théorème 3.6 (formules pour les normes subordonnées usuels)**

Pour  $A \in \mathcal{M}_{m,n}(\mathbb{K})$  nous avons  $\|A\|_2 = \sqrt{\rho(A^* A)}$  (la plus grande valeur singulière), et

$$\|A\|_1 = \max_{k=1, \dots, n} \sum_{j=1}^m |a_{j,k}|, \quad \|A\|_\infty = \max_{j=1, \dots, m} \sum_{k=1}^n |a_{j,k}|.$$

## Propriétés des normes et du rayon spectral

**Corollaire 3.7 (propriétés de la norme spectrale)**

- a) Soit  $A \in \mathcal{M}_{m,n}(\mathbb{K})$ , alors  $\|A^*\|_2 = \|A\|_2$ .
- b) Soit  $A \in \mathcal{M}_n(\mathbb{K})$  une matrice hermitienne, alors  $\|A\|_2 = \rho(A)$ .
- c) Soient  $U \in \mathcal{M}_m(\mathbb{K})$ ,  $V \in \mathcal{M}_n(\mathbb{K})$  unitaires et  $A \in \mathcal{M}_{m,n}(\mathbb{K})$ , alors  $\|UAV\|_2 = \|A\|_2$ .

Peut-on être plus précis dans l'inégalité  $\|A\| \geq \rho(A)$  du lemme 3.3 ?

**Théorème 3.8 (théorème de Gelfant)**

Soient  $A \in \mathcal{M}_n(\mathbb{K})$ , et  $\epsilon > 0$ . Alors on peut construire une norme matricielle subordonnée  $\|\cdot\|_*$  avec  $\|A\|_*$  avec  $\|A\|_* \leq \rho(A) + \epsilon$ .

En particulier, pour toute norme matricielle  $\|\cdot\|$  et tout  $A \in \mathcal{M}_n(\mathbb{K})$ ,

$$\lim_{k \rightarrow \infty} \|A^k\|^{1/k} = \rho(A).$$

**Théorème 3.9 (série de von Neumann)**

Pour tout  $E \in \mathcal{M}_n(\mathbb{K})$ , la série  $\sum_{k=0}^{\infty} E^k$  converge ssi  $\rho(E) < 1$ . Dans ce cas,  $I - E$  est inversible, et la limite de la série est donnée par  $(I - E)^{-1}$ .

Si de plus  $\|E\| < 1$  pour une norme matricielle alors

$$\|(I - E)^{-1} - I\| \leq \|E\|/(1 - \|E\|).$$

## Conditionnement : motivation.

Dans la suite de ce cours on note par  $\|\cdot\|$  une norme vectorielle et la norme matricielle subordonnée (pour les normes usuelles on ajoute un indice  $p \in \{1, 2, \infty\}$ ).

Les erreurs de représentation de nombres machines, mais aussi des erreurs de mesure font que, au lieu de résoudre un système  $Ax = b$  pour  $A \in \mathcal{M}_n(\mathbb{K})$  et  $b \in \mathbb{K}^n$  donné, on résout plutôt sur ordinateur le système perturbé  $(A + \Delta A)(x + \Delta x) = b + \Delta b$ , et on se demande si la solution obtenue  $x + \Delta x$  est proche de la solution désirée  $x$ .

**Exemple 3.10**

On obtient des solutions  $x = (-4, 4)^T$ ,  $x + \Delta x = (0.5, 1)^T$  assez éloignées pour les données "proches"

$$A = \begin{bmatrix} 4.2186 & 6.3279 \\ 3.1415 & 4.7123 \end{bmatrix}, b = \begin{bmatrix} 8.4372 \\ 6.2832 \end{bmatrix}, A + \Delta A = \begin{bmatrix} 4.2188 & 6.3279 \\ 3.1416 & 4.7124 \end{bmatrix}, b + \Delta b = \begin{bmatrix} 8.4373 \\ 6.2832 \end{bmatrix}$$

**Lemme 3.11 (pire amplification des erreurs relatives)**

$$\|A\| \|A^{-1}\| = \sup_{b, \Delta b} \left\{ \frac{\|\Delta x\|}{\|x\|} / \frac{\|\Delta b\|}{\|b\|} : Ax = b, A(x + \Delta x) = b + \Delta b \right\}.$$



## Définition et propriétés du conditionnement

**Définition 3.12 (conditionnement)**

Pour  $A \in \mathcal{M}_n(\mathbb{K})$  on définit le conditionnement  $\text{cond}(A) = \|A\| \|A^{-1}\|$ , en particulier  $\text{cond}_p(A) = \|A\|_p \|A^{-1}\|_p$  pour  $p \in \{1, 2, \infty\}$ .

**Lemme 3.13 (propriétés du conditionnement)**

Soit  $A \in \mathcal{M}_n(\mathbb{K})$  inversible, alors

- a)  $\text{cond}(A) \geq 1$  ;
- b)  $\forall \lambda \in \mathbb{K} \setminus \{0\}$  :  $\text{cond}(\lambda A) = \text{cond}(A)$  ;
- c)  $\text{cond}(A^{-1}) = \text{cond}(A)$  ;
- d)  $\text{cond}_2(A) = \mu_1/\mu_n$  rapport entre plus grande et plus petite valeur singulière ;
- e)  $\text{cond}_2(A) = 1$  pour  $A$  unitaire.

On dira que  $A$  est bien (resp. mal) conditionné si  $\text{cond}(A) \approx 1$  (resp.  $\text{cond}(A) \gg 1$ ).

**Corollaire 3.14 (distance aux matrices non inversibles)**

Pour toute matrice  $A \in \mathcal{M}_n(\mathbb{K})$  inversible

$$\frac{1}{\text{cond}_2(A)} = \min \left\{ \frac{\|A - B\|_2}{\|A\|_2} : B \in \mathcal{M}_n(\mathbb{K}) \text{ non inversible.} \right\}$$



## Estimations d'erreur pour systèmes perturbés

### Théorème 3.15

Soient  $A, \Delta A \in M_n(\mathbb{K})$  avec  $A$  inversible et  $\|A^{-1}\Delta A\| < 1$ . Avec  $b, \Delta b \in \mathbb{K}^n$ ,  $b \neq 0$ , on considère les deux systèmes

$$\begin{cases} Ax = b \\ (A + \Delta A)(x + \Delta x) = b + \Delta b \end{cases}$$

Alors

$$\frac{\|\Delta x\|}{\|x\|} \leq \frac{\text{cond}(A)}{1 - \|A^{-1}\Delta A\|} \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right).$$

### Remarques 3.16

Comme  $\|A^{-1}\Delta A\| \leq \text{cond}(A)\|\Delta A\|/\|A\|$ , nous concluons que le système perturbé admet une solution proche de celle de  $Ax = b$  tant que

$$\text{cond}(A) \left( \frac{\|\Delta A\|}{\|A\|} + \frac{\|\Delta b\|}{\|b\|} \right) \ll 1.$$



### 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice  $A$  ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR



### Notions et Rappels

### Factorisation de Schur et la SVD

### Normes matricielles et conditionnement

1) Ryt dos  
2) Pseudo  
3) Logique  $\rightarrow A: Fu$

Futurwo

### 4 Résolution de systèmes linéaires $Ax = b$ par l'élimination de Gauss

### 5 Interprétation matricielle : la décomposition LU

### 6 Comment exploiter une structure dans la matrice $A$ ?

### 7 Le problème des moindres carrés et la décomposition QR

### 8 Calcul de la décomposition QR par Householder et Givens

### 9 Calcul numérique de valeurs propres

### 10 La méthode de la puissance

### 11 La méthode QR



### 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice  $A$  ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR



## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice A ?

## 7 Le problème des moindres carrés et la décomposition QR

- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR

1

## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss

## 5 Interprétation matricielle : la décomposition LU

- 6 Comment exploiter une structure dans la matrice A ?

## 7 Le problème des moindres carrés et la décomposition QR

- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR

2

## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss
- 5 Interprétation matricielle : la décomposition LU
- 6 Comment exploiter une structure dans la matrice A ?

## 7 Le problème des moindres carrés et la décomposition QR

- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR

3

## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss

## 5 Interprétation matricielle : la décomposition LU

- 6 Comment exploiter une structure dans la matrice A ?

## 7 Le problème des moindres carrés et la décomposition QR

- 8 Calcul de la décomposition QR par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR

4

## 1 Notions et Rappels

2 La factorisation de Schur et la SVD

3 Normes matricielles et conditionnement

4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss

5 La décomposition matricielle : la décomposition LU

6 Comment exploiter une structure dans la matrice A?

7 Calcul de la décomposition QR

8 Le problème des moindres carrés et la décomposition QR

9 Calcul numérique de valeurs propres

10 La méthode de la puissance

11 La méthode QR



## 1 Notions et Rappels

2 La factorisation de Schur et la SVD

3 Normes matricielles et conditionnement

4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss et décomposition LU

5 L'algorithme de Gauss sur ordinateur

6 Comment exploiter une structure dans la matrice A?

7 Le problème des moindres carrés et la décomposition QR

8 Calcul de la décomposition QR pleine par Householder et Givens

9 Calcul numérique de valeurs propres

10 La méthode de la puissance

11 La méthode QR



## Déjà vu avant : l'élimination de Gauss

Dans les trois chapitres suivants nous souhaitons résoudre un système à  $n$  inconnues  $x_1, \dots, x_n$  et  $n$  équations

$$i = 1, 2, \dots, n : \boxed{a_{i,1}x_1 + a_{i,2}x_2 + \dots + a_{i,n}x_n = b_i},$$

qui peut s'écrire comme  $\boxed{Ax = b}$ , avec  $A \in M_n(\mathbb{K})$  supposée inversible, et  $b \in \mathbb{K}^n$  donnés. L'hypothèse sur  $A$  donne l'existence et unicité de notre inconnue  $x$ .

Algorithme 4.1 (élimination de Gauss avec pivotage naturel)

**Idée :** Avec  $A = A^{(1)}$ ,  $b = b^{(1)}$ , transformer pour  $k = 1, 2, \dots, n - 1$  le système  $A^{(k)}x = b^{(k)}$  en un système  $A^{(k+1)}x = b^{(k+1)}$  équivalent, en créant dans  $A^{(k+1)}$  des zéros en colonne  $k$  en dessous de la diagonale.

**Objectif :** Résoudre le système plus simple  $A^{(n)}x = b^{(n)}$  avec  $A^{(n)}$  triangulaire supérieure par une remontée.

pour  $k = 1, \dots, n - 1$

on suppose l'hypothèse de pivotage naturel que pivot  $a_{k,k}^{(k)} \neq 0$   
pour  $i = k + 1, \dots, n$

calculer multiplicateur  $\ell_{i,k} = a_{i,k}^{(k)} / a_{k,k}^{(k)}$   
soustraire  $\ell_{i,k}$  fois la  $k^{\text{ème}}$  équation (ligne pivot) de la  $i^{\text{ème}}$  équation



## Un exemple et (à droite) un nouveau schéma de calcul

Exemple 4.2 (un exemple  $3 \times 3$ )

		$A^{(k)}$	$b^{(k)}$
$k = 1$	$4x_1 + 8x_2 + 12x_3 = 4$	/	$\boxed{4} \quad 8 \quad 12 \quad 4$
	$3x_1 + 8x_2 + 13x_3 = 5$	/	$3 \quad 8 \quad 13 \quad 5$
	$2x_1 + 9x_2 + 18x_3 = 11$	/	$2 \quad 9 \quad 18 \quad 11$
$k = 2$	$4x_1 + 8x_2 + 12x_3 = 4$	/	$4 \quad 8 \quad 12 \quad 4$
	$0x_1 + 2x_2 + 4x_3 = 2$	$\ell_{2,1} = 3/4$	$0 \quad \boxed{2} \quad 4 \quad 2$
	$0x_1 + 5x_2 + 12x_3 = 9$	$\ell_{3,1} = 2/4$	$0 \quad 5 \quad 12 \quad 9$
$k = 3$	$4x_1 + 8x_2 + 12x_3 = 4$	/	$4 \quad 8 \quad 12 \quad 4$
	$0x_1 + 2x_2 + 4x_3 = 2$	/	$0 \quad 2 \quad 4 \quad 2$
	$0x_1 + 0x_2 + 2x_3 = 4$	$\ell_{3,2} = 5/2$	$0 \quad 0 \quad 2 \quad 4$

- Les pivots sont encadrés par des rectangles, ils sont bien non nuls ;
- les premières  $k$  lignes de  $[A^{(k)}, b^{(k)}]$  et  $[A^{(k+1)}, b^{(k+1)}]$  sont identiques ;
- on note bien que  $A^{(3)}$  est triangulaire supérieure ;
- le système  $A^{(3)}x = b^{(3)}$  peut être résolu par une remontée :
  - par la troisième équation :  $x_3 = 4/2 = 2$ ,
  - par la deuxième équation :  $x_2 = (2 - 4x_3)/2 = -3$ ,
  - par la première équation :  $x_1 = (4 - 8x_2 - 12x_3)/4 = 1$ .

## La décomposition LU : existence et unicité

Définition 4.5 (définition d'une décomposition LU)

On dira que  $A \in \mathcal{M}_n(\mathbb{K})$  admet une décomposition LU si  $A = LU$  avec  $L \in \mathcal{M}_n(\mathbb{K})$  triangulaire inférieure à diagonale unité, et  $U \in \mathcal{M}_n(\mathbb{K})$  triangulaire supérieure.

Théorème 4.6 (unicité)

Soit  $A \in \mathcal{M}_n(\mathbb{K})$  inversible. Alors une décomposition LU est unique.

Théorème 4.7 (existence)

Soit  $A \in \mathcal{M}_n(\mathbb{K})$  inversible. Alors nous avons équivalence entre

- $A$  admet une décomposition LU ;
- pour  $k = 1, 2, \dots, n-1$ , la sous-matrice principale  $[A]_k$  composée des premières  $k$  lignes et colonnes de  $A$  est inversible ;
- l'hypothèse de pivotage naturel est valable :  $a_{k,k}^{(k)} \neq 0$  pour  $k = 1, \dots, n-1$ .

Dans ce cas,  $U = A^{(n)}$  est donné dans le lemme 4.3, et  $L$  dans le lemme 4.4.

Remarques 4.8 (utilité d'une décomposition LU)

- $Ax = b$  revient à résoudre  $Ly = b$  (par descente) et  $Ux = b$  (par remontée).
- Calcul efficace de  $\det(A)$  et l'inverse  $A^{-1}$  (voir TD) etc...

## Forme de $A^{(k)}$ dans le cas général.

Lemme 4.3 (une étape d'élimination)

Sous l'hypothèse de pivotage naturel, nous avons  $A^{(k+1)} = L^{(k)}A^{(k)}$  et  $b^{(k+1)} = L^{(k)}b^{(k)}$  pour  $k = 1, \dots, n-1$ , avec  $L^{(k)}$ ,  $A^{(k)}$  et  $b^{(k)}$  ayant la forme

$$\begin{array}{ccccccccc|ccccc|c}
1 & 0 & \cdots & \cdots & \cdots & 0 & a_{1,1}^{(1)} & \cdots & a_{1,k}^{(1)} & \cdots & a_{1,n}^{(1)} & b^{(1)} \\
0 & 1 & 0 & & & \vdots & 0 & a_{2,2}^{(2)} & \cdots & a_{2,k}^{(2)} & \cdots & a_{2,n}^{(2)} & b^{(2)} \\
\vdots & 0 & 1 & 0 & & \vdots & \ddots & \ddots & \ddots & \vdots & \vdots & \vdots & \vdots \\
\vdots & \vdots & -\ell_{k+1,k} & 1 & \ddots & \vdots & 0 & \cdots & 0 & a_{k,k}^{(k)} & \cdots & a_{k,n}^{(k)} & b^{(k)} \\
\vdots & \vdots & \vdots & 0 & \ddots & \vdots & 0 & \cdots & 0 & a_{k+1,k}^{(k)} & \cdots & a_{k+1,n}^{(k)} & b_{k+1}^{(k)} \\
\vdots & \vdots \\
0 & 0 & -\ell_{n,k} & 0 & \cdots & 0 & 0 & \cdots & 0 & a_{n,k}^{(k)} & \cdots & a_{n,n}^{(k)} & b_n^{(k)}
\end{array}$$

En particulier  $A^{(n)}$  est triangulaire supérieure.

Lemme 4.4

$$L := (L^{(1)})^{-1}(L^{(2)})^{-1} \cdots (L^{(n-1)})^{-1} = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ \ell_{2,1} & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ \ell_{n,1} & \cdots & \ell_{n,n-1} & 1 \end{bmatrix}$$

## Pivotage partiel

Si l'hypothèse de pivotage naturel n'est pas valable, il faudra envisager de permutez avant chaque étape d'élimination. Voici une stratégie dite pivotage partiel.

Algorithme 4.9 (élimination de Gauss avec pivotage partiel)

Pour  $k = 1, \dots, n-1$

Chercher l'indice  $\pi_k$  du plus grand élément en module parmi les  $a_{i,k}^{(k)}$ ,  $i = k, \dots, n$ .  
Permuter l'équation d'indice  $k$  et l'équation d'indice  $\pi_k$ .  
Pour  $i = k+1, \dots, n$

Calculer multiplicateur  $\ell_{i,k} = a_{i,k}^{(k)} / a_{k,k}^{(k)}$

Soustraire  $\ell_{i,k}$  fois la  $k^{\text{ème}}$  équation (ligne pivot) de la  $i^{\text{ème}}$  équation

On notera par  $P^{(k)} \in \mathcal{M}_n(\mathbb{R})$  la matrice de transposition qui échange deux éléments d'indice  $k$  et  $\pi_k$ , et laisse les autres composantes invariantes.  $P^{(k)}$  est obtenu en remplaçant les colonnes d'indice  $k$  et  $\pi_k$  de l'identité  $I_n$  par  $e_{\pi_k}$  et  $e_k$ , respectivement. Les formules dans le lemme 4.3 prennent alors la forme  $A^{(k+1)} = L^{(k)}P^{(k)}A^{(k)}$  et  $b^{(k+1)} = L^{(k)}P^{(k)}b^{(k)}$  pour  $k = 1, \dots, n-1$ .

Théorème 4.10 (factorisation LU et pivotage partiel)

Soit  $A \in \mathcal{M}_n(\mathbb{K})$  une matrice inversible. Alors la matrice  $A$  admet une décomposition LU à permutation près, c'est-à-dire  $PA = LU$ , où  $P = P^{(n-1)} \cdots P^{(1)}$  est une matrice de permutation, et  $L$ ,  $U$  sont comme avant à condition que l'on permute simultanément tous les multiplicateurs avec les équations.

$PA = LU$

## 1 Notions et Rappels

- 2 La factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss et décomposition LU
- 5 L'algorithme de Gauss sur ordinateur
- 6 Comment exploiter une structure dans la matrice  $A$ ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR pleine par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR



Navigation icons: back, forward, search, etc.

## Stockage sur place et vectorisation

### Remarques 5.1 (stockage sur place)

Une fois  $a_{i,j}^{(k)}$  calculé, on n'a plus besoin de  $a_{i,j}^{(k)}$  et on stockera  $a_{i,j}^{(k+1)}$  à sa place, de même pour le second membre qui peut être considéré comme une colonne supplémentaire de  $A$ . Cela revient à supprimer l'indice  $(k)$  dans l'algorithme, mais pour plus de clarté on va se servir d'un tableau  $M \in \mathcal{M}_{n,n+1}(\mathbb{K})$  initialisé par  $M = [A, b]$  pour le stockage sur place.

On stockera aussi  $\ell_{i,k}$  à la position  $(i, k)$  de  $M$  (à la place d'un zéro dans  $A^{(k+1)}$ ).

### Remarques 5.2 (vectorisation)

Avec des listes indiquant les indices ligne et colonne des sous-matrices, les formules d'élimination de Gauss

$$\forall i, j > k : \quad \ell_{i,k} = \frac{a_{i,k}^{(k)}}{a_{k,k}^{(k)}}, \quad a_{i,j}^{(k+1)} = a_{i,j}^{(k)} - \ell_{i,k} a_{k,j}^{(k)}, \quad b_i^{(k+1)} = b_i^{(k)} - \ell_{i,k} b_k^{(k)},$$

deviennent les formules vectorisées  $M[k+1:n, k] = M[k+1:n, k]/M[k, k]$ , et pour  $i \in [k+1:n]$

$$M[i, k+1:n+1] = M[i, k+1:n+1] - M[i, k] * M[k, k+1:n+1].$$

Ces formules vectorisées sont plus rapides à exécuter sous python.



Navigation icons: back, forward, search, etc.

## Triangulation de Gauss

### Algorithme 5.3 (Triangulation de Gauss et descente, pivotage partiel)

```

Initialiser  $M = [A, b]$ ,  $n = \text{ordre de } A$ .
Pour  $k = 1, 2, \dots, n-1$ 
    Chercher  $\pi_k \in [k:n]$  tel que  $|M[\pi_k, k]| = \max(|M[k:n, k]|)$ 
    Permuter les lignes  $k$  et  $\pi_k$  de  $M$ 
     $M[k+1:n, k] = M[k+1:n, k] / M[k, k]$ 
    Pour  $i = k+1, \dots, n$ 
         $M[i, k+1:n+1] = M[i, k+1:n+1] - M[i, k] * M[k, k+1:n+1]$ 

```

On pourrait supprimer aussi la boucle  $i$  en calculant directement  
 $M[k+1:n, k+1:n+1] = M[k+1:n, k+1:n+1] - M[k+1:n, k] * M[k, k+1:n+1]$ .

Avec  $M$  (et le tableau  $\pi$ ) en sortie, nous obtenons la factorisation  $PA = LU$  et  $Lb^{(n)} = Pb$ , avec la matrice de permutation  $P$  comme avant, et

$$L = \begin{bmatrix} 1 & 0 & \cdots & 0 \\ m_{2,1} & 1 & \ddots & \vdots \\ \vdots & \ddots & \ddots & 0 \\ m_{n,1} & \cdots & m_{n,n-1} & 1 \end{bmatrix}, \quad U = \begin{bmatrix} m_{1,1} & m_{1,2} & \cdots & m_{1,n} \\ 0 & m_{2,2} & \cdots & m_{2,n} \\ \vdots & \ddots & \ddots & \vdots \\ 0 & \cdots & 0 & m_{n,n} \end{bmatrix}, \quad b^{(n)} = \begin{bmatrix} m_{1,n+1} \\ m_{2,n+1} \\ \vdots \\ m_{n,n+1} \end{bmatrix},$$

Navigation icons: back, forward, search, etc.

## Remontée et complexité

### Algorithme 5.4 (Remontée pour trouver solution de $Ax = b$ )

```

Initialiser  $M$  sortie de l'algorithme 5.3,  $n = \text{nombre de lignes de } M$ ,  $x = 0 \in \mathbb{R}^n$ .
Pour  $i \in \text{range}(n-1, -1, -1)$  # veut dire,  $i=n-1, n-2, \dots, 0$ 
     $x(i) = (M(i, n) - M[i, i+1:n] * x(i+1:n)) / M[i, i]$ 

```

### Théorème 5.5 (complexité de l'algorithme de Gauss)

Les algorithmes 5.3 et 5.4 nécessitent  $\mathcal{O}(n^2)$  espaces mémoire.

La triangulation 5.3 nécessite  $\frac{2}{3}n^3 + O(n^2)$  opérations élémentaires, et la remontée 5.4 nécessite  $n^2 + O(n)$  opérations élémentaires.

### Démonstration.

Commençons à compter le nombre d'opérations pour la remontée

$$\sum_{i=1}^{n-1} \left( \underbrace{2}_{\substack{\text{division et soustraction} \\ \text{produit scalaire}}} + \underbrace{(2(n-1-i)-1)}_{\substack{\text{produit scalaire}}} \right) = n^2 + O(n),$$

et pour la triangulation

$$\sum_{k=1}^{n-1} \left( \underbrace{n-k-1}_{\substack{\text{divisions} \\ \text{produits et soustractions}}} + \underbrace{2(n-1-k)(n-k)}_{\substack{\text{produits et soustractions}}} \right) = 2 \sum_{\ell=0}^{n-1} \ell^2 + O(n^2) = \frac{2}{3}n^3 + O(n^2).$$

Navigation icons: back, forward, search, etc.

## L'algorithme de Gauss en précision finie.

Théorème 5.6 (sans preuve)

Soient  $\hat{L}$ ,  $\hat{U}$ ,  $\hat{P}$  calculés sur ordinateur avec précision machine  $\epsilon$ , alors

$$\|\hat{P}A - \hat{L}\hat{U}\|_\infty \leq 2\epsilon n^2 \gamma(A),$$

avec le facteur de grossissement  $\gamma(A) = \max_{i,j,k} |A_{i,j}^{(k)}|$ .

- Sans pivotage,  $\gamma(A)$  peut être arbitrairement plus grand que  $\|A\|_\infty$ .
- Dans le cas de pivotage partiel,  $\gamma(A) \leq 2^{n-1} \|A\|_\infty$  (voir TD).
- Si  $A$  est hermitienne définie positive alors  $\gamma(A) \leq \|A\|_\infty$ .

Exemple 5.7

Avec pivotage naturel,  $\delta > 0$  "petit", et arithmétique exacte

$$A = \begin{bmatrix} \delta & 1 \\ 1 & 1 \end{bmatrix} = LU, \quad L = \begin{bmatrix} 1 & 0 \\ 1/\delta & 1 \end{bmatrix}, \quad U = \begin{bmatrix} \delta & 1 \\ 0 & 1 - 1/\delta \end{bmatrix}.$$

et en précision finie, pivotage naturel,  $\delta \ll \epsilon$ ,

$$\hat{L} = L, \quad \hat{U} = \begin{bmatrix} \delta & 1 \\ 0 & -1/\delta \end{bmatrix}, \quad \hat{P} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}, \quad \|\hat{P}A - \hat{L}\hat{U}\|_\infty = 1.$$

Et avec pivotage partiel ?

## 1 Notions et Rappels

- 2 Factorisation de Schur et la SVD
- 3 Normes matricielles et conditionnement
- 4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss et la décomposition LU
- 5 L'algorithme de Gauss sur ordinateur
- 6 Comment exploiter une structure dans la matrice  $A$ ?
- 7 Le problème des moindres carrés et la décomposition QR
- 8 Calcul de la décomposition QR pleine par Householder et Givens
- 9 Calcul numérique de valeurs propres
- 10 La méthode de la puissance
- 11 La méthode QR

## Exploiter la symétrie

Théorème 6.1 (décomposition de Crout)

Si  $A \in M_n(\mathbb{K})$  inversible et hermitienne admet une décomposition  $A = LU$ , alors elle admet aussi une unique décomposition  $A = LDL^*$  avec  $D$  diagonale et réelle.

Théorème 6.2 (décomposition de Cholesky)

Si  $A \in M_n(\mathbb{K})$  est hermitienne définie positive alors elle admet une unique décomposition  $A = CC^*$  avec  $C$  triangulaire inférieure ayant des éléments diagonaux  $> 0$ .

Remarques 6.3

Comment calculer des telles décompositions si on sait qu'elles existent ? Prenons le cas de la décomposition de Crout, où les inconnues sont les éléments de  $L$  sous la diagonale (il y a des 1 sur la diagonale et les 0 au dessus de la diagonale), ainsi que les éléments de  $D$  sur la diagonale. Alors pour  $1 \leq j \leq n$  on obtient terme par terme

$$a_{i,j} = \sum_{k=1}^j \ell_{i,k} d_{k,k} \overline{\ell_{j,k}}, \quad \ell_{i,i} = \ell_{j,j} = 1.$$

En parcourant  $(i,j) = (1,1), (2,1), \dots, (n,1), (2,2), (3,2), \dots, (n,2), \dots, (n,n)$  on peut résoudre pour la seule inconnue  $d_{i,i}$  si  $i = j$ , et  $\ell_{i,j}$  si  $i > j$  (car les autres quantités dans notre formule ont été déjà calculées avant).

On conclut que cette méthode nécessite  $n^3/3 + O(n^2)$  opérations arithmétiques, la moitié de ce que l'on avait trouvé pour la triangulation de Gauss.

Calculer la factorisation de Cholesky

## Exploiter des 0 dans A

Après tout, le but de l'élimination de Gauss est de créer des zéros dans  $A$ . Ne peut-on pas réduire la complexité si  $A$  contient déjà beaucoup de zéros, par exemple  $A$  est une matrice tridiagonale, c'est-à-dire,  $a_{i,j} = 0$  pour  $|i-j| > 1$  ?

Théorème 6.4 (théorème du front)

Soit  $A \in M_n(\mathbb{K})$  inversible admettant une décomposition  $A = LU$ . Notons par

$$\text{front}(A) = (j(1), j(2), \dots, j(n)),$$

avec  $j(i)$  l'indice colonne du premier élément non nul dans la ligne  $i$  de  $A$ . Alors  $\text{front}(L) = \text{front}(A)$  et  $\text{front}(U^T) = \text{front}(A^T)$ .

Démonstration.

Technique similaire à la remarque 6.3. □

Exemple 6.5

Soit  $A$  une matrice tridiagonale irréductible, c'est-à-dire,  $a_{i,j} = 0$  pour  $|i-j| > 1$  et  $a_{i,j} \neq 0$  pour  $|i-j| = 1$ . Alors  $\text{front}(A) = \text{front}(A^T) = (1, 1, 2, 3, \dots, n-1)$ .

Par conséquent,  $\text{front}(L) = (1, 1, 2, 3, \dots, n-1)$  et  $L$  est une matrice bidiagonale inférieure à diagonale unité. Aussi  $\text{front}(U^T) = (1, 1, 2, 3, \dots, n-1)$  et  $U$  est une matrice bidiagonale supérieure.

On conclut que le calcul de  $L$  et  $U$  nécessite  $O(n)$  opérations arithmétiques, bien moins que ce que l'on avait trouvé pour la triangulation de Gauss. □

## 1 Notions et Rappels

### 2 La factorisation de Schur et la SVD

### 3 Normes matricielles et conditionnement

### 4 Résolution de systèmes linéaires $Ax = b$ par l'élimination de Gauss et décomposition LU

### 5 L'algorithme de Gauss sur ordinateur

### 6 Comment exploiter une structure dans la matrice A ?

### 7 Le problème des moindres carrés et la décomposition QR

### 8 Calcul de la décomposition QR pleine par Householder et Givens

### 9 Calcul numérique de valeurs propres

### 10 La méthode de la puissance

### 11 La méthode QR



## Position du problème des moindres carrés

Dans les 2 chapitres suivants on considérera seulement  $\mathbb{K} = \mathbb{R}$ , et on se donne  $A \in \mathcal{M}_{m,n}(\mathbb{R})$  avec  $\text{rank}(A) = n \leq m$ , et  $b \in \mathbb{R}^m$ .

Définition 7.1 (le problème des moindres carrés)

Trouver  $x \in \mathbb{R}^n$  de sorte que  $\|Ax - b\|_2 \leq \|Ax - b\|_2$  pour tout  $x \in \mathbb{R}^n$ .

Exemple 7.2 (la droite de régression)

En physique ou en statistique on se pose le problème comment faire passer au mieux une droite par un nuage de  $m \geq 2$  points  $\{(t_j, b_j)^T \in \mathbb{R}^2 : j = 1, \dots, m\}$ , que l'on suppose non alignés sur une droite verticale. On cherche alors une droite de la forme  $g(t) = x_1 + x_2 t$  avec abscisse  $x_1 \in \mathbb{R}$  et pente  $x_2 \in \mathbb{R}$  de sorte que, avec la distance des valeurs  $\delta_j = g(t_j) - b_j$  en  $t_j$ , la quantité

$$\sum_{j=1}^m \delta_j^2 = \|Ax - b\|_2^2, \quad \text{avec } A = \begin{bmatrix} 1 & t_1 \\ 1 & t_2 \\ \vdots & \vdots \\ 1 & t_m \end{bmatrix}, \quad b = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{bmatrix}, \quad x = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix},$$

soit la plus petite possible. Notons que  $\text{rank}(A) = 2$  par hypothèse sur le nuage de points. En TD/TP, on cherchera à faire passer des fonctions plus compliquées par un nuage de points.



## L'existence et l'unicité d'une solution

**Théorème 7.3** (solution d'un problème de moindres carrés)

*L'unique solution  $\underline{x}$  du problème des moindres carrés est l'unique solution  $\underline{x}$  du système des équations normales  $A^T A \underline{x} = A^T b$ .*

Nous donnons une preuve algébrique, alternativement on pourrait donner une preuve analytique en calculant les points annulant le gradient de  $\mathbb{R}^n \ni f(\underline{x}) = \|A\underline{x} - b\|_2^2$  et déterminer la nature du Hessian.

**Définition 7.4** (décomposition QR (pleine ou économique))

*On dira que  $A = QR$  est une décomposition QR (pleine) si*

$$Q \in \mathcal{M}_m(\mathbb{R}) \text{ orthogonale}, \quad R = \begin{bmatrix} \tilde{R} \\ 0_{m-n,n} \end{bmatrix} \in \mathcal{M}_{m,n}(\mathbb{R}),$$

avec  $\tilde{R} \in \mathcal{M}_n(\mathbb{R})$  triangulaire supérieure à diagonale  $> 0$ .

*On dira que  $A = \tilde{Q}\tilde{R}$  est une décomposition QR économique si  $\tilde{Q} \in \mathcal{M}_{m,n}(\mathbb{R})$  avec  $\tilde{Q}^T \tilde{Q} = I_n$  ( $\tilde{Q}$  est à colonnes orthonormées), et  $\tilde{R}$  comme avant.*

**Lemme 7.5**

*Il existe une et une seule décomposition QR économique  $A = \tilde{Q}\tilde{R}$ .*

**Remarques 7.6**

*Dans la définition 7.4, on doit prendre comme  $\tilde{Q}$  la matrice formée par les premières  $n$  colonnes de  $Q$ . Par contre, les autres colonnes de  $Q$  ne sont pas uniques.*

## Résolution par décomposition QR économique

**Corollaire 7.7**

*La solution  $\underline{x}$  du problème des moindres carrés est l'unique solution  $\underline{x}$  du système  $\tilde{R}\underline{x} = \tilde{Q}^T b$ , avec  $A = \tilde{Q}\tilde{R}$  une décomposition QR économique.*

**Remarques 7.8**

*Le passage par une décomposition QR économique est préférable à la résolution du système des équations normales car*

$$\text{cond}_2(A^T A) = \text{cond}_2(\tilde{R}^T \tilde{R}) = (\text{cond}_2(\tilde{R}))^2 \gg \text{cond}_2(\tilde{R})$$

*Si  $\text{cond}_2(\tilde{R})$  est encore trop élevé, on cherche à régulariser, par exemple par une méthode de Tichonov où on cherche à minimiser  $x \mapsto \|Ax - b\|_2^2 + \lambda \|x\|_2^2$  pour un  $\lambda > 0$  approprié. Alternativement, on cherche à approcher d'abord  $A$  par une matrice de rang plus faible, parfois par des heuristiques comme la décomposition QR avec pivotage des colonnes, ou par des techniques inspirées par la SVD et le théorème de Eckhart-Young.*

## L'algorithme de Gram-Schmidt

Avec l'hypothèse habituelle  $\text{rank}(A) = n$ , notre décomposition QR économique  $A = \tilde{Q}\tilde{R}$  implique que  $\text{Im}(A) = \text{Im}(\tilde{Q})$ , autrement dit, les colonnes  $q_1, \dots, q_n \in \mathbb{R}^m$  de  $\tilde{Q}$  forment une base orthonormée de l'espace engendré par les colonnes (libres)  $a_1, \dots, a_n \in \mathbb{R}^m$  de  $A$ . Une telle base orthonormée est construite par l'algo de Gram-Schmidt vu en deuxième année.

**Algorithme 7.9** (décomposition QR économique par Gram-Schmidt)

**Objectif :** Avec  $A = (a_1, \dots, a_n)$ , construire  $\tilde{Q} = (q_1, \dots, q_n)$  à colonnes  $q_j$  orthonormées, ainsi que les éléments non nuls de  $\tilde{R}$  d'une décomposition QR économique  $A = \tilde{Q}\tilde{R}$ .

Pour  $k = 1, \dots, n$  faire

poser  $y = a_k$

pour  $j = 1, \dots, k-1$  faire

$\tilde{r}_{j,k} = (q_j, y), \quad y = y - r_{j,k} q_j$  (rendre  $y$  orthogonal à  $q_j$ )

$\tilde{r}_{k,k} = \|y\|_2 > 0$ , normaliser  $q_k = y/\tilde{r}_{k,k}$ .

## Remarques 7.10

a) Pour  $k$  fixe, on doit calculer  $k$  produits scalaire et  $k-1$  combinaisons linéaires dans  $\mathbb{R}^m$ , donc en total un nombre d'opérations arithmétique de  $\sum_k (4km) + \mathcal{O}(n) = 2mn^2 + \mathcal{O}(mn) (+n$  racines).

b) Attention, même si  $\tilde{r}_{k,k} \neq 0$ , il peut être petit... en fait  $|\tilde{r}_{k,k}|/\|\tilde{R}\|_2 \geq 1/\text{cond}_2(\tilde{R})$ .

c) Un autre ordre du même calcul donnant lieu à l'**algo de Gram-Schmidt modifié** permet en précision finie de diminuer la perte d'orthogonalité  $\|I_n - \tilde{Q}^T \tilde{Q}\|_2$ : on pose  $q_j = a_j$  pour  $j = 1, \dots, n$  et, pour  $k = 1, \dots, n$ , on normalise  $q_k$  et on rend  $q_{k+1}, \dots, q_n$  orthogonal à  $q_k$ .

1 Notions et Rappels

2 La factorisation de Schur et la SVD

3 Normes matricielles et conditionnement

4 Résolution de systèmes linéaires  $Ax = b$  par l'élimination de Gauss et décomposition LU

5 L'algo de Gauss sur ordinateur

6 Comment exploiter une structure dans la matrice  $A$  ?

7 Le problème des moindres carrés et la décomposition QR

8 Calcul de la décomposition QR pleine par Householder et Givens

9 Calcul numérique de valeurs propres

10 La méthode de la puissance

11 La méthode QR

On suppose pour un instant que, pour tout  $m \geq 2$  et  $y \in \mathbb{R}^m$  il existe une matrice orthogonale  $H(y) \in \mathcal{M}_m(\mathbb{R})$  de sorte que  $H(y)y$  est un multiple du premier vecteur canonique  $e_1$  dans  $\mathbb{R}^m$ . Ces matrices seront construites par la suite.

**Théorème 8.1** (une étape d'élimination dans une factorisation QR pleine)  
Avec des matrices orthogonales  $H^{(k)}$  comme ci-dessous, nous posons  $A^{(1)} = A$  et  $A^{(k+1)} = H^{(k)}A^{(k)}$  pour  $k = 1, \dots, n-1$ . Alors  $A^{(k)}$  aura la forme

$$y^{(k)} = \begin{bmatrix} a_{1,k}^{(k)} \\ a_{2,k}^{(k)} \\ \vdots \\ a_{m,k}^{(k)} \end{bmatrix}, \quad H^{(k)} = \left[ \begin{array}{c|c} I_{k-1} & 0 \\ \hline 0 & H(y^{(k)}) \end{array} \right], \quad A^{(k)} = \begin{bmatrix} a_{1,1}^{(k)} & \cdots & a_{1,k}^{(k)} & \cdots & a_{1,n}^{(k)} \\ 0 & a_{2,2}^{(k)} & \cdots & a_{1,k}^{(k)} & \cdots & a_{2,n}^{(k)} \\ \vdots & \ddots & \ddots & \vdots & & \vdots \\ 0 & \cdots & 0 & a_{k,k}^{(k)} & \cdots & a_{k,n}^{(k)} \\ \vdots & & & \vdots & & \vdots \\ 0 & \cdots & 0 & a_{m,k}^{(k)} & \cdots & a_{m,n}^{(k)} \end{bmatrix}.$$

En particulier, avec une matrice  $E = \text{diag}(\pm 1, \dots, \pm 1) \in \mathcal{M}_m(\mathbb{R})$  appropriée,  $R = EA^{(n)} \in \mathcal{M}_{m,n}(\mathbb{R})$  et  $Q^T = EH^{(n-1)} \dots H^{(1)}$  nous obtenons la décomposition QR pleine  $A = QR$ .

**NB :** les premières  $k-1$  lignes dans  $A^{(k)}$  et  $A^{(k+1)}$  sont les mêmes (possibilité de stockage sur place).

## Matrices de Householder

### Définition 8.2

Étant donné  $w \in \mathbb{R}^m \setminus \{0\}$ , la matrice de Householder  $H = H_w$  est définie par

$$H = I_m - \frac{ww^T}{w^Tw}$$

**Attention :**  $w^Tw \in \mathbb{R}$  mais  $ww^T \in \mathcal{M}_m(\mathbb{R})$ .

**Lemme 8.3** (propriétés d'une matrice de Householder)

Une matrice de Householder est symétrique et orthogonale.  $H$  représente une matrice de symétrie par rapport au hyperplan  $\{x \in \mathbb{R}^m : (x, w) = 0\}$ .

**Lemme 8.4** (élimination avec une matrice de Householder)

Soit  $y \in \mathbb{R}^m \setminus \{0\}$ , et  $\alpha = -\|y\|_2$  si  $y_1 > 0$ , et  $\alpha = \|y\|_2$  si  $y_1 \leq 0$ . Alors le vecteur

$$w = y - \alpha e_1 \quad \text{avec} \quad w^Tw = 2\alpha(\alpha - y_1)$$

est de sorte que la matrice de Householder  $H = H_w$  vérifie  $Hy = \alpha e_1$ .

**Remarques 8.5** (Calcul efficace d'un produit de  $H_w$  avec un vecteur)

Un produit entre la matrice de Householder  $H_w$  et  $x \in \mathbb{R}^m$  peut être implémenté par les formules  $\beta = 2(w^Tx)/(w^Tw)$  et  $Hx = x - \beta w$ , en  $4m + O(1)$  opérations arithmétiques (si on ne compte pas la norme).

Une combinaison de 8.1–8.5 donne l'algorithme suivant où on stocke sur place les matrices  $A^{(k)}$ , ainsi dans  $H$  les produits partiels  $H^{(k)} \dots H^{(1)}$ . Ici on néglige  $E$ .

**Algorithme 8.6** (décomp. QR pleine  $A = QR$  avec algo de Householder)

**Objectif :** calculer  $H = Q^T$  et  $R = A^{(n)}$  (dans  $A$ )

Poser  $(m, n) = \text{taille de } A$ ,  $H = I_m$

Pour  $k = 1, \dots, n-1$  faire

# créer zéros en colonne  $k$  par le lemme 8.4,  $y = y^{(k)}$

poser  $y = A[k:m, k]$ ,  $\alpha = \text{signe}(y_1)\|y\|$ ,  $\gamma = 1/(\alpha(\alpha - y_1))$ ,  $w = y - \alpha e_1$

poser  $A[k, k] = \alpha$ ,  $A[k+1:m, k] = 0$

# produit rapide  $H^{(k)}A^{(k)}$  par les remarques 8.5

poser  $\beta = \gamma w^T A[k:m, k+1:n]$ ,  $A[k:m, k+1:n] = A[k:m, k+1:n] - w\beta$

# produit rapide  $H^{(k)}H$  par les remarques 8.5

poser  $\beta = \gamma w^T H[k:m, k:m]$ ,

poser  $H[k:m, k:m] = H[k:m, k:m] - w\beta$

**Lemme 8.7** (complexité pour l'algorithme de Householder)

Pour  $k$  fixe :  $2(m-k) + O(1)$  OA pour le calcul de  $w$  et sa norme,

$4(n-k)(m-k) + O(m)$  OA pour  $A$ , et  $4(m-k)^2 + O(m)$  OA pour  $H$ . En total  $m(m-k)$  OA pour  $H$ .

$$\underbrace{\frac{4n^3}{3} + 2(m-n)n^2}_{\text{calcul de } R} + \underbrace{\frac{4n^3}{3} + 4(m-n)mn + O(mn)}_{\text{calcul de } Q} \text{ OA} + n \text{ racines.}$$

## Simplifications

**Remarques 8.8** (résolution d'un problème de moindres carrés)

Si on veut juste résoudre notre problème de moindres carrés, on n'a pas besoin de  $Q$  mais de  $R$  et de  $b^{(n)} = Q^*b$ . Ceci peut se calculer par les formules  $b^{(1)} = b$ , et  $b^{(k+1)} = H^{(k)}b^{(k)}$  pour  $k = 1, \dots, n-1$  (ou dans une colonne supplémentaire de  $A$ ).

**Remarques 8.9** (simplifications pour le cas Hessenberg)

Si  $m = n$  et  $A$  est une matrice de Hessenberg, c'est-à-dire,  $a_{j,k} = 0$  pour  $j > k+1$ , on peut réduire la complexité en montrant par récurrence sur  $k$  que toutes les matrices  $A^{(k)}$  dans le théorème 8.1 ont une forme Hessenberg. En particulier, seulement les deux premières composantes des vecteurs  $y = y^{(k)}$  et  $w$  dans l'algorithme 8.6 sont non-nulles. Ceci implique que la matrice  $H^{(k)}$  est l'identité  $I_m$  dont on a changé les éléments aux quatre positions  $(k-1:k, k-1:k)$ , et donc  $Q$  est aussi de forme Hessenberg. Un examen plus fin permet de réduire la complexité à  $O(n^2)$  OA pour obtenir une décomposition QR de  $A$ .

**Remarques 8.10** (simplifications pour le cas d'une matrice tridiagonale)

Si de plus  $A$  est une matrice tridiagonale, c'est-à-dire, aussi  $a_{j,k} = 0$  pour  $k > j+1$ , en se basant sur l'étude précédente on peut montrer que  $A^{(k)}$  contient au plus trois éléments non nuls par ligne, en ligne  $i$  aux positions  $(i, i:i+2)$  si  $i \leq k$ , et aux positions  $(i, i-1:i+1)$  si  $i > k$ . En particulier, les éléments non nuls de  $R$  se trouvent sur la diagonale principale, et sur la première et deuxième super-diagonale, c'est-à-dire,  $r_{j,k} = 0$  pour  $j > k$  et pour  $k > j+2$ . Un examen plus fin permet de réduire la complexité à  $O(n)$  OA pour obtenir une décomposition QR de  $A$ .

## Les rotations de Givens

Toute variante de construction de matrices orthogonales annulant une partie d'un vecteur (voir avant le théorème 8.1) donnera lieu à une variante de l'algorithme de Householder.

Exemple 8.11 (Une rotation dans  $\mathbb{R}^2$ )

Pour tout  $y = [y_1, y_2]^T \in \mathbb{R}$  il existe un angle  $\varphi$  de sorte que

$$Gy = \begin{bmatrix} \|y\|_2 \\ 0 \end{bmatrix}, \quad G = G(\varphi) = \begin{bmatrix} \cos(\varphi) & -\sin(\varphi) \\ \sin(\varphi) & \cos(\varphi) \end{bmatrix}.$$

Définition 8.12 (définition d'une rotation de Givens)

Étant donné  $1 \leq i < j \leq m$ , une **rotation de Givens**  $G^{(i,j)} = G^{(i,j)}(\varphi) \in \mathcal{M}_m(\mathbb{R})$  est obtenue en partant de l'identité  $I_m$ , où on remplace la sous-matrice à indices lignes/colonnes  $i$  et  $j$  par une rotation  $G(\varphi)$  comme avant.

Remarques 8.13

Notons que tout produit de rotations de Givens est une matrice orthogonale, et que la multiplication  $G^{(i,j)}B$  avec  $B \in \mathcal{M}_{m,n}(\mathbb{R})$  est facile à implémenter (en  $6n + \mathcal{O}(1)$  OE) car seulement les lignes  $i$  et  $j$  de  $B$  changent.



## Créer des zéros avec les rotations de Givens

Etant donné  $y \in \mathbb{R}^m$ , on peut trouver des angles de sorte que

$$G^{(1,2)} \dots G^{(m-2,m-1)} G^{(m-1,m)} y = \|y\| e_1,$$

le facteur  $G^{(m-1,m)}$  créant un zéro à la dernière position, le facteur  $G^{(m-2,m-1)}$  créant un zéro à l'avant-dernière position (et laisse invariant le zéro à la dernière position) etc.

D'autres ordres de rotations de Givens sont imaginables, surtout si  $y$  comporte déjà beaucoup de zéros. Par exemple, si  $y_3 = \dots = y_m = 0$  (voir le cas Hessenberg discuté avant), alors un produit  $G^{(1,2)}y = \|y\|e_1$  suffit.

L'algorithme décrit dans le théorème 8.1 pour trouver une décomposition  $QR$  avec  $Q = (Q^{(n)})^T$  et  $R = A^{(n)}$  aura alors la forme suivante : on initialise  $Q^{(1)} = I_m$ ,  $A^{(1)} = A$ , et on calcule pour  $k = 1, \dots, n-1$

$$\begin{aligned} A^{(k+1)} &= G^{(k,k+1)}(\varphi^{(k,k+1)}) \dots G^{(m-1,m)}(\varphi^{(m-1,m)}) A^{(k)}, \\ Q^{(k+1)} &= G^{(k,k+1)}(\varphi^{(k,k+1)}) \dots G^{(m-1,m)}(\varphi^{(m-1,m)}) Q^{(k)}, \end{aligned}$$

avec  $\varphi^{(i-1,i)}$  pour  $i = k+1, \dots, m$  choisi pour produire un zéro à la position  $(i, k)$ . D'une manière similaire on montre :

Corollaire 8.14

Pour tout  $A \in \mathcal{M}_n(\mathbb{R})$  il existe une matrice  $Q \in \mathcal{M}_n(\mathbb{R})$  orthogonale (produit de  $(n-1)(n-2)/2$  rotations de Givens) de sorte que  $Q^T A Q$  soit une matrice de Hessenberg, en complexité  $O(n^3)$ .

Ce résultat est à comparer avec la décomposition de Schur qui est plus coûteuse car elle nécessite le calcul d'éléments propres.

