

Statistiques

(C1) La démarche statistique à t le M de Bernoulli

I / Introduction

- bcp de données à analyser (med, météo, finance)
- diff types de stat: → stat descriptives: visualisat' données (moy, variance, histogr)
- maths, probas → stat inférentielles: tirer de l'info sur données.
- stat décisionnelles: poser qd à la vue données (tests)

→ Probab VS Stat: En proba, on étudie qd de Ω dt n cont' la loi.
En stat, on dispose de données (ou observs) qu'on modélise

- On cherche des infos sur cette loi inconnue
- Modéliser, estimer, tester

II / Modélisat'

• Des observs:

n observs x_1, \dots, x_n (@ n réponses à sondage ζ_{son})
On les modélise à réaliser de Ω

$$X_1(\omega) = x_1, \dots, X_n(\omega) = x_n. (@ x_i = \begin{cases} 1 & \text{si oui} \\ 0 & \text{si non} \end{cases})$$

x_i est à valeur ds {0,1} dc suit une loi de Bernoulli

• Une famille de probabilités:

On suppose que les $(X_i)_{1 \leq i \leq n}$ st déf sur un espace probabilisable (Ω, \mathcal{F}) (& mesurables) & on munit (Ω, \mathcal{F}) d'une famille de probabilités $(P_\theta)_{\theta \in \Theta}$.

→ $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ modèle statistique

@ $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in [0,1]})$, θ représente la proba inconnue de voter "oui"


tq $X_i \sim \text{Bern}(\theta)$ sous P_θ ie $\begin{cases} P_\theta(X_i=1)=\theta \\ P_\theta(X_i=0)=1-\theta \end{cases}$

- loi des observs: Pour avoir la loi des observs (X_1, \dots, X_n) la loi seule des X_i ne suffit pas.

→ Plurius modélisat' (sondage)

On n'intervroge pas $2x$ mme personne. (tirage sans remise): pas indép entre réponses.
Les $(X_i)_{1 \leq i \leq n}$ ne st pas indépendantes, si on pose $S_n = \sum_{i=1}^n X_i$

On sait que Ω^N N électeurs $S_n = \text{card } \{(1 \leq i \leq n, X_i=1)\}$



$S_n \sim \text{Hypergéométrique}(n, N, \theta)$

RQ Cela permet d'avoir la loi de (X_1, \dots, X_n) (car les info contenues ds S_n).

Soit $(x_1, \dots, x_n) \in \{0,1\}^n$, $k = \sum_{i=1}^n x_i$.
Calculer $P_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n) | S_n = k)$ $\forall k \in \{0, \dots, n\}$

• RQ loi hypergéométrique → loi binomiale: $\lim_{N \rightarrow \infty} P_\theta(S_n=k) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$

• 2^e modélisat': On fait à si on interrogait les individus indépendamment des autres (tirage à remise), ce q permet de appr les $(X_i)_{1 \leq i \leq n}$ indépend
 $X_i \sim \text{Bern}(\theta)$ & l'indépde. RQ: $P_\theta(S_n=k) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$
 $S_n \sim \text{Bin}(n, \theta)$ sous P_θ .

Cel: Modèle statistiq - $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ st tel que on observe un

- m-échantillon $(x_1, \dots, x_n) \rightarrow n$ @ iid (indép & identiq distribués)
- Observat's: Réalisat's du m-échantillons (données) (x_1, \dots, x_n) & $x_i = X_i(\omega)$, $\omega \in \Omega$

RQ $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ est xaract' explicite!

• Sondage: $\Omega = \{0,1\}^n$, $\mathcal{F} = \mathcal{P}(\Omega)$, $P_\theta(\{(w_1, \dots, w_n)\}) = \prod_{i=1}^n \theta^{w_i} (1-\theta)^{1-w_i}$
ens des m-uplets à val' de 10,15: tous les m-ens: $= \begin{cases} \theta & \text{si } w_i = 1 \\ 1-\theta & \text{si } w_i = 0 \end{cases}, \theta \in [0,1]$

$w = (w_1, \dots, w_n) \in \{0,1\}^n$ ne reprsentent pas m individus interrogés
⇒ $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in [0,1]})$ modèle statistiq.

$$\forall i \quad w = (w_1, \dots, w_n) \in \Omega$$

$$X_i(w) = X_i(w_1, \dots, w_n) = w_i, \text{ renfin que}$$

$$\mathbb{P}_\theta(X_i=1) = \theta = 1 - \mathbb{P}_\theta(X_i=0)$$

$$\begin{aligned} \text{car } \mathbb{P}_\theta(X_i=1) &= \mathbb{P}_\theta(\{w \in \Omega : X_i(w)=1\}) \\ &= \mathbb{P}_\theta(\{w = (w_1, \dots, w_n) \in \Omega : w_i=1\}) \\ &= \sum_{\substack{(w_1, \dots, w_n) \in \Omega, \\ w_i=1}} \mathbb{P}_\theta(\{(w_1, \dots, w_n)\}). \end{aligned}$$

Rq Vers l'infini (non Ω) qd on fait tendre $n \rightarrow \infty$,

$\Omega = \{0, 1\}^{\mathbb{N}}$, $f^\theta = ?$, \mathbb{P}_θ sur (Ω, \mathcal{F}) pt c'est constant de telle sorte qu'elle coïncide de la proba.

$\Rightarrow (\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in [0,1]})$ 2e un m-échantillon (X_1, \dots, X_m) tq $X_i \sim \text{Bern}(\theta)$ $1 \leq i \leq n$ est appelé modèle de Bernoulli.

III / Estimation & intervalles de confiance

Q3: Une fois le modèle posé $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ & (x_1, \dots, x_m) le m-échantillon. Comment obtenir de l'information sur le paramètre θ inconnu θ de l'observat de (x_1, \dots, x_m) .

→ Estimation ponctuelle de θ à fourchette de marge d'erreur.

$$@ (ex) \quad m=10, \quad 1100 \pm 100000.$$

$$\Omega = \{0, 1\}^{10}, \quad \mathcal{F} = \mathcal{P}(\Omega),$$

$$\mathbb{P}_\theta(\{(w_1, \dots, w_{10})\}) = \theta^{\sum_{i=1}^{10} w_i} (1-\theta)^{10 - \sum_{i=1}^{10} w_i}$$

$$X_i(w_1, \dots, w_n) = w_i, \quad \mathbb{P}_\theta(X_i=1) = \theta.$$

On a envie d'estimer θ par $\frac{3}{10}$.

Marge d'erreur ?

④ Estimation:

① Un estimat^r de θ est f measurable de (X_1, \dots, X_m) qd ne dépend pas de θ .

i.e. Un estimateur $\hat{\theta}_m$ de θ est @ de la forme $\hat{\theta}_m = \varphi_m(x_1, \dots, x_m)$ où φ est measurable. \mathbb{P}_θ f measurable $f : (\mathcal{E}_1, \mathcal{F}_1) \rightarrow (\mathcal{E}_2, \mathcal{F}_2)$ & $B \in \mathcal{F}_2, f^{-1}(B) \in \mathcal{F}_1$.

Idée : Trouver des estimat^rs de θ "pas trop loin" de θ .

$$@ \quad \hat{\theta}_{10} = \frac{\sum_{i=1}^{10} X_i}{10}, \quad \hat{\theta}_{10}(w) = \frac{3}{10}$$

$$\text{② } \mathbb{P}_\theta((X_1, \dots, X_m) = (1, 1, 0, 0, 1, 0, 0, 0, 0, 0)) = \theta^3 (1-\theta)^7 = f(\theta)$$

$\hat{\theta}_{10}(w) = \frac{3}{10}$ est le paramètre θ q maximise $\theta \mapsto \mathbb{P}_\theta((x_1, \dots, x_m) = (1, 1, 0, 0, 1, 0, 0, 0, 0, 0))$ sur $[0,1]$ (calcul de $f'(\theta)$).

→ $\hat{\theta}_{10}$ est le paramètre le plus vraisemblable.

Généralisation

$(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in [0,1]}), \quad x_1, \dots, x_m$ iid Bern (θ) sous \mathbb{P}_θ . $\forall \theta \in [0,1], \quad \forall (x_1, \dots, x_m) \in \{0, 1\}^m$

$$\begin{aligned} V(\theta, x_1, \dots, x_m) &= \mathbb{P}_\theta((X_1, \dots, X_m) = (x_1, \dots, x_m)) \\ &= \theta^{\sum_{i=1}^m x_i} (1-\theta)^{n - \sum_{i=1}^m x_i} \end{aligned}$$

$V(\theta, x_1, \dots, x_m)$ est la f de vraisemblance (vraisemblance du param. θ à la vue de l'observat (x_1, \dots, x_m)).

$$\ln(V(\theta, x_1, \dots, x_m)) = \sum_{i=1}^m x_i \ln \theta + (n - \sum_{i=1}^m x_i) \ln(1-\theta)$$

$$\begin{aligned} \psi(\theta) &= \frac{\sum_{i=1}^m x_i}{\theta} - \frac{n - \sum_{i=1}^m x_i}{1-\theta} \Leftrightarrow \psi(\theta) = 0 \Leftrightarrow \frac{\sum x_i}{\theta} = \frac{n - \sum x_i}{1-\theta} \\ &\Leftrightarrow (1-\theta) \sum x_i = \theta(n - \sum x_i) \end{aligned}$$

θ	0	$\frac{\sum x_i}{m}$	1
$\psi(\theta)$	0	$\frac{\sum x_i}{m}$	0
ψ	+	0	-

$$\Leftrightarrow \theta = \frac{\sum x_i}{m}$$

→ L'estimateur du maximum de vraisemblance est

$$\hat{\theta}_m = \arg \max_{\theta \in [0, 1]} V(\theta, X_1, \dots, X_m) = \frac{1}{n} \sum_{i=1}^n X_i$$

$$\Leftrightarrow V(\theta, X_1, \dots, X_m) \leq V(\hat{\theta}_m, X_1, \dots, X_m)$$

$$\forall \theta \in [0, 1]$$

$\frac{1}{n} \sum_{i=1}^n X_i$ est appelé moyenne empirique des $(X_i)_{1 \leq i \leq m}$

notée \bar{X}_m .

→ Pk cet estimateur ?

* estimateur qui maximise la vraisemblance : le paramètre le plus vraisemblable à la vue des observations X_1, \dots, X_m .

* il a de bonnes pptés :

$$\underbrace{E_\theta(\bar{X}_m)}_{\text{espérance sous } P_\theta} = E_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n} E_\theta\left(\sum_{i=1}^n X_i\right)$$

espérance sous P_θ

par linéarité de l'espérance.

Comme $X_i \sim \text{Bern}(\theta)$ sous P_θ . $E_\theta(X_i) = \theta \quad \forall i \in \{1, \dots, n\}$

$$\Rightarrow E_\theta(\bar{X}_m) = \theta.$$

On dit que \bar{X}_m est un estimateur sans biais de θ .

• On a envie de dire que "plus n est grand plus \bar{X}_m se rapproche de θ ".

Comment évaluer la convergence de \bar{X}_m vers θ .

* évaluer $P_\theta(|\bar{X}_m - \theta| \geq \varepsilon)$

① Bien-aimé - Chebichev

$$P_\theta(|\bar{X}_m - \theta| \geq \varepsilon) \leq \frac{\theta(1-\theta)}{n \varepsilon^2} \leq \frac{1}{4n \varepsilon^2}$$

② Moments d'ordre 4

$$P_\theta(|\bar{X}_m - \theta| \geq \varepsilon) \leq \frac{1}{4n^2 \varepsilon^4}$$

③ Hoeffding

$$P_\theta(|\bar{X}_m - \theta| \geq \varepsilon) \leq 2e^{-2n\varepsilon^2}$$

pour lui
non bornée


④ Pour une généralisation :

* ⑤ valable pour ⑥ de carré intégrable

* ⑦ valable pour ⑧ bornées.

$\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P_\theta(|\bar{X}_m - \theta| \geq \varepsilon) = 0$,
on dit que \bar{X}_m ⑨ vers θ sous P_θ , $\theta \in [0, 1]$

$$\bar{X}_m \xrightarrow[m \rightarrow \infty]{\text{prob}} \theta$$



- * (C) simple ? $\bar{X}_n(\omega) \xrightarrow[n \rightarrow \infty]{} \theta \quad \forall \omega \in \Omega$ Se traduit en termes d'événements :
 $\Omega = \{0, 1\}^{\mathbb{N}^*}$ (infini non-dénombrable)
 \mathcal{F}, \mathbb{P} tq $E_i = "pile au i^{e} lancer"$
 $P_\theta(E_i) = \theta$. et les $(E_i)_{i \in \mathbb{N}^*}$ st indépendants.
- $X_i(\omega) = \omega_i$ si $\omega = (\omega_m)_{m \in \mathbb{N}^*} \in \Omega$
(resultat du i^{e} lancer)
- $P_\theta(X_i=1) = P_\theta(E_i) = \theta = 1 - P_\theta(X_i=0)$
- $X_i \sim \text{Bernoulli}(\theta)$ sous P_θ et les $(X_i)_{i \in \mathbb{N}^*}$ st indépendantes
- $\bar{X}_n(\omega) \xrightarrow[n \rightarrow \infty]{} \theta$ n'est pas vraie $\forall \omega \in \Omega$
- $\begin{array}{ll} \text{@ } \omega = (0, \dots, 0, \dots) & \bar{X}_n(\omega) = 0 \\ \omega = (1, \dots, 1, \dots) & \bar{X}_n(\omega) = 1 \end{array} \quad \forall n \in \mathbb{N}$
- $\exists \Omega' \in \mathcal{F}$ tq $P_\theta(\Omega') = 1, \forall \omega \in \Omega', \bar{X}_n(\omega) \xrightarrow[n \rightarrow \infty]{} \theta$.
- $\Omega' = \{\omega \in \Omega, \lim_{n \rightarrow \infty} \bar{X}_n(\omega) = \theta\}$
- $\lim_{n \rightarrow \infty} \bar{X}_n(\omega) = \theta, \quad \forall \epsilon > 0, \exists m \in \mathbb{N}^*, \forall p \geq m, |X_p(\omega) - \theta| \leq \epsilon$.
- $A_p(\epsilon) = \{\omega \in \Omega, |\bar{X}_p(\omega) - \theta| \leq \epsilon\} = \{|\bar{X}_p - \theta| \leq \epsilon\}$
- $\rightarrow \omega \in \Omega'$ si $\forall \epsilon > 0 \exists m \in \mathbb{N}^* \forall p \geq m, \omega \in A_p(\epsilon)$
- $\forall \epsilon > 0, \omega \in \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\epsilon)$
- $\omega \in \bigcap_{\epsilon > 0} \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\epsilon)$
- RQ: On se ramène à une intersection dénombrable en mq $\bigcap_{\epsilon > 0} A(\epsilon) = \bigcap_{m \in \mathbb{N}^*} A\left(\frac{1}{m}\right)$.
- En notant $A(\epsilon) = \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\epsilon)$.
- On va mq que $P_\theta(\Omega'^c) = 0$.
- $\Omega'^c = \bigcup_{\epsilon > 0} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\epsilon)$
- $\Omega'^c = \bigcup_{m \in \mathbb{N}^*} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c\left(\frac{1}{m}\right)$.

(4)

(6)

$$\text{On montre } P_\theta \left(\bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon) \right) = 0 \quad \forall \varepsilon > 0.$$

$$P_\theta(A_p^c(\varepsilon)) = P_\theta(|\bar{x}_p - \theta| > \varepsilon) \leq 2e^{-2p\varepsilon^2} \xrightarrow[m \rightarrow \infty]{} 0$$

$B_m(\varepsilon) = \bigcup_{p \geq m} A_p^c(\varepsilon)$, la suite $(B_m(\varepsilon))$ est ↘ :

$$B_{m+1}(\varepsilon) \subset B_m(\varepsilon) = A_m^c(\varepsilon) \cup B_{m+1}(\varepsilon)$$

$$\Rightarrow P_\theta \left(\bigcap_{m \in \mathbb{N}^*} B_m(\varepsilon) \right) = \lim_{m \rightarrow \infty} P_\theta(B_m(\varepsilon))$$

$$P_\theta(B_m(\varepsilon)) = P_\theta \left(\bigcup_{p \geq m} A_p^c(\varepsilon) \right) \leq \sum_{p=m}^{\infty} P_\theta(A_p^c(\varepsilon))$$

Hoeffding : $P_\theta(B_m(\varepsilon)) \leq \sum_{p=m}^{\infty} 2e^{-2p\varepsilon^2} \leq 2 \frac{e^{-2m\varepsilon^2}}{1-e^{-2\varepsilon^2}}$

reste d'une série convergente, $\lim_{n \rightarrow \infty} P_\theta(B_n(\varepsilon)) = 0$.

$$\Rightarrow \text{On a montré que } \forall \varepsilon > 0, \quad P_\theta \left(\bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon) \right) = 0$$

$$\Omega'^c = \bigcup_{m \in \mathbb{N}^*} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon)$$

$$P_\theta(\Omega'^c) \leq \sum_{m \in \mathbb{N}^*} P_\theta \left(\bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon) \right) \Rightarrow P_\theta(\Omega') = 1.$$

⑥ $\exists \Omega' \in \mathcal{F}^\omega, \quad P_\theta(\Omega') = 1$,
 $w \in \Omega', \quad \lim_{m \rightarrow \infty} \bar{x}_m(w) = \theta$.

On dit que \bar{x}_m ⑦ presque sûrement vers θ .

⑧ si \bar{x}_m ⑦ presque sûrement vers θ alors
 \bar{x}_m ⑦ en probabilité et la ⑧ en proba
implique ⑨ ce presque sûre (p.s.) à la condition
suffisante que $\left[\sum_{m \in \mathbb{N}} P_\theta(|\bar{x}_m - \theta| > \varepsilon) < \infty \right]$

• Risque quadratique

$$\begin{aligned} \mathbb{E}_\theta[(\bar{x}_m - \theta)^2] &= \text{Var}_\theta(\bar{x}_m) = \text{Var}_\theta \left(\frac{1}{m} \sum x_i \right) \\ &= \frac{1}{m^2} \text{Var}_\theta(\sum x_i) = \frac{1}{m^2} \sum \text{Var}_\theta(x_i) \\ \text{car les } (x_i) \text{ indép.} \quad &= \frac{1}{m^2} m\theta(1-\theta) = \frac{\theta(1-\theta)}{m} \end{aligned}$$


2) Intervalles de confiance

Un IDC est un intervalle aléatoire duquel se trouve le vrai paramètre inconnu de grande proba.

④ Soit $\alpha \in [0,1]$, un intervalle de confiance de niveau de confiance $1-\alpha$ est un intervalle aléatoire \hat{I}_m en f de X_1, \dots, X_n (indépendant de θ) tq $P_\theta(\hat{I}_m \ni \theta) \geq 1-\alpha$

Général: Inégalité de Concentration (BT au Hoeffding)

② Modèle de Bernoulli



$$\text{ex7} \quad \bar{X}_{10}(w) = \frac{3}{10}.$$

$$\boxed{\text{BT}} \quad P_\theta(|\bar{X}_m - \theta| > \varepsilon) \leq \frac{1}{4n\varepsilon^2}$$

$$\Leftrightarrow P_\theta(\theta \notin [\bar{X}_m - \varepsilon, \bar{X}_m + \varepsilon]) \leq \frac{1}{4n\varepsilon^2}$$

Il suffit de prendre $\varepsilon = \varepsilon(\alpha, n)$ tq

$$tq \quad \frac{1}{4n\varepsilon^2} \leq \alpha, \quad \varepsilon \leq \sqrt{\frac{1}{4n\alpha}}$$

$$\hat{I}_m = \left[\bar{X}_m - \frac{1}{2\sqrt{n\alpha}}, \bar{X}_m + \frac{1}{2\sqrt{n\alpha}} \right] \cap [0,1].$$

$$P_\theta(\theta \in \hat{I}_m) \geq 1-\alpha.$$

$$\boxed{\text{Hoeffding}} \quad P_\theta(|\bar{X}_m - \theta| > \varepsilon) \leq 2e^{-2n\varepsilon^2}.$$

Il suffit de prendre $\varepsilon = \varepsilon(\alpha, n)$ tq

$$2e^{-2n\varepsilon^2} \leq \alpha \Leftrightarrow \varepsilon \geq \sqrt{\frac{1}{2n} \ln \frac{\alpha}{2}}$$

$$\hat{J}_m = \left[\bar{X}_m - \sqrt{\frac{1}{2n} \ln \frac{\alpha}{2}}, \bar{X}_m + \sqrt{\frac{1}{2n} \ln \frac{\alpha}{2}} \right] \cap [0,1].$$

③ $\alpha = 10\%$

Intervalle de confiance de niveau 90% , $\alpha = 10\%$

$$\bar{X}_{10}(w) = \frac{3}{10}, \quad \hat{I}_{10\%} = [0; 0.8], \quad \hat{J}_{10\%} = [0; 0.687].$$

$$\boxed{\text{BT}}: \frac{1}{2\sqrt{n\alpha}} = \frac{1}{20} = 0.05, \quad \boxed{\text{H}}: \sqrt{\frac{1}{2n} \ln \frac{\alpha}{2}} = 0.0387$$

fourchette de 3,9%

⑥

⑥

RQ: Pas optimal si \hat{I}_n^a est un intervalle, de confiance de niveau $1-\alpha$ alors tout

$\hat{J}_n^a \supset \hat{I}_n^a$ est aussi un intervalle de confiance $1-\alpha$.

E_2 = celle que le trait n'est pas meilleur alors qu'en réalité il l'est.

Soit: On retrouve le trait.

Cela ne permet pas minimiser les erreurs & on priviliege une: E_1 .

Oriente le choix (dissymétrique) des hypothèses

H_0 : hypothèse nulle (hypothèse défaut)

H_1 : hypothèse alternative

Le test de H_0 contre H_1 est construit de telle sorte que la prob. de se tromper quand on conclut H_1 est fixée et contrôlée.

$m=10$ → On observe 3 piles sur 10 : peut-on conclure que la pièce est fausse?

2 chaines possibles, potentiellement, on peut se tromper

H_0 : "le traitement n'est pas meilleur"

H_1 : "le traitement est meilleur"

E_1 : Conclure H_1 alors qu'en réalité c'est H_0 .

choix dissymétrique, dépend de la vérité. @ confinement
"l'épidémie reprend"
"l'épidémie ne reprend pas!"

Chaque décision a des conséquences \neq très graves.

@ "le traitement est meilleur" ou "le trait n'est pas meilleur".

2 erreurs possibles
 E_1 = celle que le trait est meilleur alors que ce n'est pas le cas.
Consequence: traiter l'ins des patients le à un traitement qui n'est pas bon.

Point de vue des médecins:

H_0 : "l'épidémie reprend".

H_1 : "l'épidémie ne reprend pas".

Pt de vue économiq:

H_0 : "l'épidémie ne reprend pas"

H_1 : "l'épidémie reprend".

→ traducto des hypothèses sur f du param. θ : hypothèses posent une question sur la loi (ou son paramètre) inconnue.

Exemple médicament

H_0 : "le trait n'est pas meilleur" $\theta \leq \theta_0$	$(\theta = \theta_0)$	H_1 : "le nouveau trait est meilleur" $\theta > \theta_0$
θ_0 proba de guérison de l'ancien trait ^t (connue)		
θ — — — — — (inconnue)		

3) Construction du test

@ médicament, on veut tester $H_0: \theta \leq \theta_0$

contre $H_1: \theta > \theta_0$, à la vue de l'observat X_1, \dots, X_n .
(les résultats de n patients au nouveau trait).

, X_1, \dots, X_n iid Bern (θ)

$X_i = \begin{cases} 1 & \text{si le } i^{\text{e}} \text{ patient guéri} \\ 0 & \text{sinon} \end{cases} \quad 1 \leq i \leq n$

θ inconn., on a estimateur \bar{X}_n

θ_0 connu \Rightarrow Comment conclure H_1 ?

↳ Réponse "naïve" si $\bar{X}_n > \theta_0$.

(Pb) On veut contrôler la proba de se tromper.

P_{H_0} ("conclure H_1 ")

Enonc:

$$\sup_{\theta \leq \theta_0} P_{\theta}(\bar{X}_n \geq \theta_0) = P_{\theta_0}(\bar{X}_n \geq \theta_0) \quad (\text{dans le cas de la loi binomiale})$$

$$= P_{\theta_0}\left(\sum_{i=1}^n X_i \geq n\theta_0\right) \quad (\text{suite})$$

car la médiane d'une Din (n, θ_0) est $\lfloor n\theta_0 \rfloor$ ou $\lfloor n\theta_0 + 1 \rfloor$

→ On se donne une marge d'erreurs $\alpha \in]0, 1[$ appelé niveau de test. Et on choisit un seuil t_α

tg on conduit H_1 si $\bar{X}_n \geq t_\alpha$ (\bar{X}_n suffisamment grande que θ_0) de telle sorte que $\sup_{\theta \leq \theta_0} P_{\theta}(\bar{X}_n \geq t_\alpha) \leq \alpha$

$R_{\theta_0}^\alpha = \{\bar{X}_n \geq t_\alpha\} = \text{zone de rejet.}$ (lorsqu'on est en dehors de cette zone on rejette H_0 & on conduit H_1).

Règle de décision

Si on observe $X_m(w) \geq t_\alpha$ alors on rejette H_0
(à une erreur contrôlée $\leq \alpha$).

sinon on ne rejette pas H_0 (mais l'erreur n'est pas contrôlée).

Généralisation

$$(\mathcal{Q}, \mathbb{P}_\theta^*(P_\theta))_{\theta \in \Theta} \quad (\mathbb{P}) = \mathbb{I}_0 + \mathbb{E} \text{ (Bernoulli)}$$

X_1, \dots, X_n iid Bern(θ)

$$\mathbb{B}_0 \subset \mathbb{Q}^-, \mathbb{B}_1 \subset \mathbb{Q}, \mathbb{B}_0 \cap \mathbb{B}_1 = \emptyset.$$

④ Construire un test de H_0 contre H_1 au niveau α ,
c'est construire une zone de rejet (f de X_1, \dots, X_n , à) \mathbb{R}_m^α .
tq $\sup_{\theta \in \mathbb{B}_0} \mathbb{P}_\theta(\mathbb{R}_m^\alpha) \leq \alpha$.

Règle de décision q en décale :

- si $w \in \mathbb{R}_m^\alpha$ alors on conduit H_1 .
- si $w \notin \mathbb{R}_m^\alpha$ alors on ne rejette pas H_0 .

⑤

Vocabulaire

• taille du test : $\sup_{\theta \in \mathbb{B}_0} \mathbb{P}_\theta(\mathbb{R}_m^\alpha)$.

• Erreur de première espèce (E_1) : conclure H_1 à tort

• Erreur de seconde espèce (E_2) : conclure H_0 à tort.

si $\theta \in \mathbb{B}_1$, $\beta(\theta) = \mathbb{P}_\theta(\mathbb{R}_m^\alpha)^c$
erreur de seconde espèce on $\theta \in \mathbb{B}_1$.

Proba de conclure H_0 à tort $\sup_{\theta \in \mathbb{B}_1} \mathbb{P}_\theta(\mathbb{R}_m^\alpha)^c$.

• Puissance du test : proba de conclure H_1 à raison.

si $\theta \in \mathbb{B}_1$ $\pi(\theta) = \mathbb{P}_\theta(\mathbb{R}_m^\alpha) = 1 - \beta(\theta)$.
Plus la puissance est grande meilleure est le test
f puissance $\mathbb{B}_1 \rightarrow \mathbb{R}$

$$\theta \mapsto \mathbb{P}_\theta(\mathbb{R}_m^\alpha)$$

Test convergent

si $\forall \theta \in \mathbb{B}_1$, $\lim_{n \rightarrow \infty} \mathbb{P}_\theta(\mathbb{R}_m^\alpha) = 1$.

Test sans biais

si $\forall \theta \in \mathbb{B}_1 \quad \pi(\theta) > \alpha$,

ie $\forall \theta \in \mathbb{B}_1, 1 - \beta(\theta) > \alpha \Leftrightarrow \beta(\theta) < 1 - \alpha$

Erreur de seconde espèce. $\Leftrightarrow \beta = \sup_{\theta \in \mathbb{B}_1} \beta(\theta) \leq 1 - \alpha$

Point de vue des médecins.

► Hypothèse simple: si \textcircled{H}_0 ou \textcircled{H}_1 sont vraies → test de \textcircled{H}_0 : "rouge non dominant" $\theta = \frac{1}{4}$
 réduits à un singeur:

• $H_0: \theta = \theta_0$ contre $H_1: \theta = \theta_1$
 (test unilatéral)

- $H_0: \theta = \theta_0$ contre $H_1: \theta \neq \theta_0$ (test bilatéral)
Hypothèse multiple nulle.

4) Exemples

► Hypothèses simples fléurs

Croisement entre "fleurs rouges & fleurs blanches".
Gène dominant?

→ si le rouge est dominant alors la proba d'obtenir une fleur rouge est $\frac{3}{4}$.

→ silicon probe $\frac{1}{a}$.

On obtient sur n croissons le nbr \ln de FR

$X_n \sim \text{Bin}(n, \theta)$ où θ est la proba d'obtenir une fleur R à l'issu du tirage (inconnue)

- test de H_0 : "rouge non dominant" $\theta = 1/4$
 H_1 : "rouge dominant" $\theta = 3/4$.

t_2 $\frac{s_n}{n} = \hat{\theta}_n$

$R_n^d = \{ \hat{\theta}_n > t_2 \}$

Pour construire un test de niveau α de H_0 :

$\theta = \frac{1}{4}$ contre H_1 : $\theta = \frac{3}{4}$. On construit une zone de rejet

$$R_m^2 = \left\{ \frac{s_n}{n} \geq t_2 \right\} = \left\{ s_n \geq t_2 n \right\} \text{ an } t_2 \text{ reelle:}$$

$$\underbrace{P_{1/4}(S_n \geq k_2)}_{\text{for some } k_2} \leq 2.$$


$$k_d = \min \{ k \in \{0, \dots, m\} : P_{Y_k} (S_n > k) \leq \alpha \}$$

$m=8$, soit de 8 sous f_0 et sous f_{l-1}

k	$P_{1/4}(S_8 = k)$	$P_{3/4}(S_8 = k) / P_{1/4}(S_8 > k)$
0	0.01	
1	26.70	-
2	31.15	89.85
3	20.77	
4	8.65	
5	2.31	
6	0.37	
7	0.04	
8	—	0.

\rightarrow sous H_0 : $S_8 \sim \text{Bin}(8, \frac{1}{4})$, $x \mapsto P_{\frac{1}{4}}^x (S_8 \leq x)$

\rightarrow sous H_1 : $S_8 \sim \text{Bin}(8, \frac{3}{4})$, $x \mapsto P_{\frac{3}{4}}^x (S_8 \leq x)$



(R9) Une variable aléatoire X est dite stochastiquement plus grande qu'une (R10) Y si $\forall n \in \mathbb{N}$: $F_X(x) \leq F_Y(x)$ (où F_X et F_Y sont des fr de répartition X & Y).

$$k_\alpha = \min \{ k \in \{0, \dots, 8\} \mid P_{\frac{1}{4}}^x (S_8 \geq k) \leq \alpha \}$$

$$\alpha = 5\%$$

$$\alpha_{10\%} = 5$$

$$\alpha_{15\%} = 4$$

$$\alpha_{5\%} = 5$$

$$\alpha_{10\%} = 5$$

$$\alpha_{15\%} = 4$$

taux de test 2,72%

(M)

au niveau 5%, si on observe $S_8(\omega) > 5$ alors on conclut H_1 ($\theta = \frac{3}{4}$).

$R_{\alpha}^{5\%} = \{S_8 > 5\}$ sinon on ne rejette pas H_0 .



$$\{S_8 > 5\} = \{\bar{X}_8 > \frac{5}{8}\}$$

taux du test: 2,72%.

erreur de 2^{nde} espèce: $P_{\frac{1}{4}}(S_8 \leq 4) = 11,37\%$.

pouissance: $P_{\frac{3}{4}}(S_8 \geq 5) = 88,63\%$.

R9: Si on fixe le niveau: $\alpha = 2\%$, $R_2 = \{S_8 > 6\}$
la puissance $\Rightarrow \Leftrightarrow$ l'erreur de 2^{nde} espèce \uparrow .

α -valeur du test: On a observé $S_8(\omega) = 7$.

$$\alpha\text{-valeur } P_{\frac{1}{4}}(S_8 \geq 7) = \alpha(7)$$

$$\alpha(7) \leq 5\% \Leftrightarrow \omega \in R_5^{5\%}$$

On observe $S_8(\omega) = 7 \Rightarrow \alpha(7) = P_{\frac{1}{4}}(S_8 \geq 7) = 0,049$.

$\alpha(7) \leq 5\% \Rightarrow$ on rejette H_0 au niveau 5% ($\frac{\alpha(7)}{\alpha} = \frac{0,049}{0,02} = 2,45$)

Point de vue des méthodes

Hypothèses multiples

medicament, $(\mathcal{Q}, \mathcal{F}^t, P_\theta)_{\theta \in \mathcal{I}_0, \mathcal{L}}$

X_1, \dots, X_n iid $\text{Bin}(\theta)$, $S_m = \sum_{i=1}^m X_i$

$H_0: \theta \leq \theta_0$ contre $H_1: \theta > \theta_0$

$\mathcal{D}_0 = [\theta_0, \theta_0]$ & $\mathcal{D}_1 = [\theta_0, +\infty[$,



Zone de rejet du test de niveau α .

$$k \text{ tel que } \sup_{\theta \leq \theta_0} P_\theta(S_m \geq k) \leq \alpha$$

$$k_\alpha = \min\{k\}$$

$$\text{Gr} \sup_{\theta \leq \theta_0} P_\theta(S_m \geq k) = P_{\theta_0}(S_m \geq k)$$

$$\Rightarrow k_\alpha = \min\{k \in \mathbb{N}: P_{\theta_0}(S_m \geq k) \leq \alpha\}$$

Première: si $S_m \sim \text{Bin}(n, \theta)$ sous P_θ alors
(k fixé) $\theta \mapsto P_\theta(S_m \geq k)$ est ↑ si $\theta \mapsto$.

2 possibles:

$$f(\theta) = P_\theta(S_m \geq k) = \sum_{i=k}^m \binom{n}{i} \theta^i (1-\theta)^{n-i}$$

On dérive & on mq $f'(\theta) \geq 0$.


* simulaθ: comment simuler une loi binomiale? $P_\theta(S_m \geq k)$

soit U une rv uniforme sur $[0, 1]$

$$P(U \in [a, b]) = b-a \text{ si } [a, b] \subset [0, 1]$$

Transformer U en une loi de Bernoulli

$$X = \mathbf{1}_{\{U \leq \theta\}}, P(X=1) = P(U \leq \theta) = \theta, P(X=0) = 1-\theta$$



$S_m (\theta, \mathcal{D}_1)$ U_1, \dots, U_m : rv iid $\text{Bern}(\theta)$.

$$S_m(\theta) = \sum_{i=1}^m \mathbf{1}_{\{U_i \leq \theta\}}$$

On si $\theta \leq \theta'$ alors $S_m(\theta) \leq S_m(\theta')$

$$\text{d'où } \{S_m(\theta) \geq k\} \subset \{S_m(\theta') \geq k\}$$

$$\Rightarrow P(S_n(\theta) \geq k) \leq P(S_n(\theta_0) \geq k)$$

et $\theta \mapsto P(S_n(\theta) \geq k)$ est ↗.

$$k_\alpha^1 = \max \{k \in \{0, \dots, n\} : P_{\theta_0}(S_n \leq k) \leq \frac{\alpha}{2}\}$$

$$k_\alpha^2 = \min \{k \in \{0, \dots, n\} : P_{\theta_0}(S_n \geq k) \leq \frac{\alpha}{2}\}.$$

Comment déterminer k_α ?

↳ peu adéquat ou impossible Koeffeling

↳ à l'aide du théorème central limite (si on peut voir M61)


⑨ Sur E_1 & E_2 :

$$E_1 = \sup_{\theta \neq \theta_0} P_{\theta}(S_n \geq k_\alpha) = P_{\theta_0}(S_n \geq k_\alpha)$$

$$E_2 = \sup_{\theta > \theta_0} P_{\theta}(S_n \leq k_\alpha) = P_{\theta_0}(S_n \leq k_\alpha) \quad \boxed{E_1 + E_2 = 1}$$

• Test bilatéral:

$H_0: \theta = \theta_0$ contre $H_1: \theta \neq \theta_0 \rightarrow \theta_0 = \{\theta_0\}$
 $\rightarrow \theta_1 =]0, \theta_0[\cup]\theta_0, 1[$.



$$R_\alpha = \{S_n \leq k_\alpha^1\} \cup \{S_n \geq k_\alpha^2\}$$

$$\text{et } k_\alpha^1 \text{ & } k_\alpha^2 \quad P_{\theta}(\{S_n \leq k_\alpha^1\} \cup \{S_n \geq k_\alpha^2\}) \leq 2\alpha$$

Chap II : Généralité

I / Modéliser

- Modèle statistiq: $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ où (Ω, \mathcal{F}) est un espace probabilisable.
- $(\mathbb{P}_\theta)_{\theta \in \Theta}$ une famille de probabilités sur cet espace.

→ Θ espace des paramètres, ici on suppose $\Theta \subset \mathbb{R}^d$
 \Rightarrow statistiq non paramétrique.

- Observat: (X_1, \dots, X_m) un m -échantillon de loi \mathbb{P}_θ sous \mathbb{P}_0 (loi commune des $(X_i)_{1 \leq i \leq m}$)
 ici on considère des v.a iid sinon $X = (X_1, \dots, X_m)$ une seule observat à val \mathbb{R}^m ds \mathbb{R}^m .

\Rightarrow objectif:

- ▷ estima θ sous $g(\theta)$
- ▷ tester

\Rightarrow outil: la vraisemblance.

II / La vraisemblance

① Lois discrètes

soit \mathbb{P}_0 la loi de X_1 sous \mathbb{P}_0 , qd l'on appelle discrète. soit $\mathbb{P}_0(X \in \mathcal{K}) = 1$ au plus dénombr.

a) 3 exemples

* capture - recapture

OB: estimer la populat (les poissons) ds le lac Taille N inconnue.

Demande: → capture: on en pêche 50 poissons auxquels on fait une marque et on les remet ds le lac.

→ recapture: On en pêche 50 avec ramie et on compte le nbr de Poissons marqués.

Modélisat: $p = \frac{50}{N}$: proba de pêcher un poisson marqué
 $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \Theta})$ X_1, \dots, X_{50} iid

$$X_i = \begin{cases} 1 & \text{si le } i^{\text{e}} \text{ poisson pêché est marqué} \\ 0 & \text{sinon} \end{cases}$$

$$\hat{\theta}_{50} = \sum_{i=1}^{50} X_i, \quad S_{50}(i_0) = 4.$$

14

Tome 2
Statistique

$$P_p(S_{50}=4) = \binom{4}{50} p^4 (1-p)^{50}$$

Idée pour estimer p : choisir $\hat{p}(w)$ qui maximise p ,
 $p \in [0,1]$; $P_p(S_{50}=4)$.

On dérivant on $p \in [0,1]$;

$$\hat{p}(w) = \operatorname{argmax}_{p \in [0,1]} P_p(S_{50}=4) = \frac{4}{50} = \frac{S_{50}(w)}{50}$$

Ce qui correspond à une estimation de N :

$$\hat{N}(w) = \frac{20}{\hat{p}(w)} = 250.$$

Plus généralement, si on observe $S_{50}(w)=s$

alors $\operatorname{argmax}_{p \in [0,1]} L(p, s) = \frac{s}{50}$.

où $L(p, s) = P_p(S_{50}=s) = \binom{s}{50} p^s (1-p)^{50-s}$

$$\hat{p} = \frac{s}{50} \quad \text{et} \quad \hat{N} = \frac{1000}{s}$$

loi géométrique: On modélise le nbr de cycles
 ayant de tomber encerclée par une loi géométrique,
 si θ est proba de tomber encerclée un mois
 donné. Si X est la variable égale au nbr de
 cycles pour tomber encerclée.

$$P_\theta(X=k) = \theta(1-\theta)^{k-1}, \quad k \in \mathbb{N}^*$$

On observe les données suivantes sur $n=100$ femmes
 $m=100$ femmes

nbr cycles	1	2	3	4	5	6	7	8	9	10	11	12	>12
nbr fr	29	16	17	4	3	9	4	5	1	1	1	3	7

On ne dispose pas des données individuelles $(X_i)_{1 \leq i \leq 100}$
 mais de $(N_k)_{1 \leq k \leq 13}$

$$N_k = \sum_{i=1}^{100} \mathbf{1}_{\{X_i=k\}} \quad 1 \leq k \leq 12$$

$$N_{13} = \sum_{i=1}^{100} \mathbf{1}_{\{X_i>12\}}$$

Comment estimer θ ?

$$\rightarrow P_\theta(X_1=1) = \theta$$

$$\hat{\theta}_1 = \frac{1}{100} \sum_{i=1}^{100} \mathbf{1}_{\{X_i=1\}}$$

$\hat{\theta}_1$ est un estimateur
 sans biais de θ

$$\mathbb{E}_\theta(\hat{\theta}_1) = \frac{1}{100} \sum_{i=1}^{\infty} P_\theta(X_i=1) = \theta$$

$$\frac{1}{m} \sum_{i=1}^m \mathbf{1}_{\{X_i=1\}} \xrightarrow[m \rightarrow \infty]{P_\theta \text{ ps}} \theta$$

$$\hat{\theta}_1(w) = \frac{99}{100}$$

Defaut: N'utilise pas tous les données

$$\rightarrow E_\theta(X_1) = \frac{1}{\theta} \Leftrightarrow \theta = \frac{1}{E_\theta(X_1)}$$

\Rightarrow La moyenne empirique des observations pourra être un bon candidat.

Comment faire cette moyenne empirique ?

\rightarrow supprimer la dernière colonne.

$$\hat{\theta}_2 = \frac{93}{\sum_{k=1}^{12} k N_k}$$

$$\hat{\theta}_2 = \frac{100 - N_{13}}{\sum_{k=1}^{100} k N_k} = \frac{\sum_{i=1}^{100} \mathbf{1}_{\{X_i \leq 12\}}}{\sum_{i=1}^{100} X_i \mathbf{1}_{\{X_i \leq 12\}}}$$

\rightarrow On utilise toutes les observations.

$$P_\theta(N_1=29, N_2=16, \dots, N_{12}=3, N_{13}=7) = C \theta^{93} ((1-\theta)\theta)^{16} (\theta(1-\theta))^{11})^3 ((1-\theta)^3)^7$$

où $P_\theta(X \geq 12) = (1-\theta)^{12}$

$$C \theta^{93} (1-\theta)^{322}$$

$$C = \frac{100!}{29! 16! \dots 7!}$$

$$L(\theta) = C \theta^{93} (1-\theta)^{322}$$

$$L'(\theta) = C [93 \theta^{92} (1-\theta)^{322} - 322 \theta^{93} (1-\theta)^{321}]$$

$$L'(\theta) = 0 \text{ si } \theta = \frac{93}{415},$$

soit $\hat{\theta}_3(w) = 9224$ qui maximise

$P_\theta(N_1=29, \dots, N_{12}=3, N_{13}=7)$ en θ .

 Voir que $\hat{\theta}_3 = \frac{N_1 + \dots + N_{12}}{\sum_{k=1}^{12} k N_k + 12 N_{13}}$

$$\hat{\theta}_3 = \frac{\sum_{i=1}^{100} \mathbf{1}_{\{X_i \leq 12\}}}{\sum_{i=1}^{100} X_i \mathbf{1}_{\{X_i \leq 12\}}}$$

(6 statutaire). $\sum_{i=1}^{100} X_i \mathbf{1}_{\{X_i \leq 12\}} + 12 \sum_{i=1}^{\infty} \mathbf{1}_{\{X_i > 12\}}$

b) Définit

④ La vraisemblance associée à l'observat

$$x_1, \dots, x_m \text{ est } V(\theta, x_1, \dots, x_m) = P_\theta(x_1 = x_1, \dots, x_m = x_m)$$

$$\theta \in \mathbb{R}, \quad (x_1, \dots, x_m) \in \mathbb{R}^m$$

$$(P_\theta(x_1 \in \mathcal{X})) = 1,$$

$V(\theta, x_1, \dots, x_m)$ est la vraisemblance du paramètre θ à la vue de l'observat x_1, \dots, x_m .

On maximise cette vraisemblance pour avoir le paramètre le plus vraisemblable.

⑤ L'estimateur du maximum de vraisemblance est

$$\hat{\theta} = \operatorname{argmax}_{\theta \in \mathbb{R}} V(\theta, x_1, \dots, x_m)$$

Rq:

Modèle de Bernoulli : $(\mathcal{Q}, \mathcal{F}, (P_\theta)_{\theta \in [0,1]})$

$$x_1, \dots, x_m \text{ iid Bern}(\theta), \quad \mathcal{X} = \{0,1\}$$

$$\forall (x_1, \dots, x_m) \in \{0,1\}^m \quad \forall \theta \in [0,1]$$

$$\begin{aligned} V(\theta, x_1, \dots, x_m) &= P_\theta(x_1 = x_1, \dots, x_m = x_m) \\ &= \prod_{i=1}^m P_\theta(x_i = x_i) = \prod_{i=1}^m \theta^{x_i} (1-\theta)^{1-x_i} \\ &= \theta^{\sum_{i=1}^m x_i} (1-\theta)^{m - \sum_{i=1}^m x_i} \end{aligned}$$

$$\hat{\theta}_m = \operatorname{argmax}_{\theta \in [0,1]} V(\theta, x_1, \dots, x_m)$$

à arg-maximiser sur $\theta \in [0,1]$,

$$V(\theta, x_1, \dots, x_m) = \theta^{\sum_{i=1}^m x_i} (1-\theta)^{m - \sum_{i=1}^m x_i}$$

$$\Leftrightarrow L(\theta, x_1, \dots, x_m) = \ln V(\theta, x_1, \dots, x_m)$$

$$\left(\sum_{i=1}^m x_i \right) \ln \theta + (m - \sum_{i=1}^m x_i) \ln (1-\theta)$$

$$L(\theta, x_1, \dots, x_m) = S_m \ln \theta + (m - S_m) \ln (1-\theta)$$

$$\frac{\partial}{\partial \theta} L(\theta, x_1, \dots, x_m) = \frac{S_m}{\theta} - \frac{m - S_m}{1-\theta}$$

$$\text{pour } \frac{S_m}{\theta} = \frac{m - S_m}{1-\theta}, \quad S_m = \sum_{i=1}^m x_i$$

$$\Leftrightarrow (1-\theta) S_m = \theta(m - S_m)$$

$$\Leftrightarrow \theta = \frac{S_m}{m}$$

(P)

$$\hat{\theta}_n = \underset{\theta \in \mathbb{R}, \mathbb{E}}{\operatorname{argmax}} V(\theta, X_1, \dots, X_n) = \underset{\theta \in \mathbb{R}, \mathbb{E}}{\operatorname{argmax}} L(\theta, X_1, \dots, X_n)$$

On dit que X a pr densité f si
 $\forall A \in \mathcal{B}(\mathbb{R})$, $P(X \in A) = \int_A f(x) dx$

$$= \frac{S_n}{m}$$

• Comme $V(\theta, X_1, \dots, X_n)$ est une forme de produit
 on peut utiliser pour faciliter les calculs la log-vraisemblance

$$L(\theta, X_1, \dots, X_n) = \ln V(\theta, X_1, \dots, X_n)$$

\uparrow débord

• Pas f(x) \mathbb{D} , pas t(x) FF explicite.

2/ Lois à densités

(a) aléatoires à densité (Ω, \mathcal{F}, P)

soit X une (a) à valeurs dans \mathbb{R} ,

$$X: (\Omega, \mathcal{F}) \rightarrow (\mathbb{R}, \mathcal{B}(\mathbb{R}))$$

$$\xrightarrow{w} \xrightarrow{X(\omega)} \text{mesurable}$$

La loi est déterminée par la f de répartition


$$F_X: \mathbb{R} \rightarrow [0, 1]$$

$$t \mapsto F_X(t) = P(X \leq t)$$

(18)

f est une f positive sur \mathbb{R} & intégrable sur \mathbb{R} .

$$\int_{\mathbb{R}} f(x) dx = 1$$




• si X a pr densité f alors F_X est cont sur \mathbb{R} .

$$F_X(t) - F_X(t^-) = P(X \leq t) - P(X < t)$$

$$= P(X=t) = 0$$

cällage: cont à droite limite à gauche



$$\lim_{t_n \rightarrow t} P(X \leq t_n) = P(\bigcup_{m \in \mathbb{N}, t_m < t} \{X \leq t_m\}) = P(X < t)$$


$\forall t \in \mathbb{R}, \mathbb{P}(X=t)=0$, si X est à densité

mais $\mathbb{P}(X \in [t-\varepsilon, t+\varepsilon]) = \int_{t-\varepsilon}^{t+\varepsilon} f(x) dx$

(de généralisé à $\mathbb{R}^2, \dots, \mathbb{R}^m$)

► loi exponentielle, $X \sim \text{Exp}(\theta)$,


si X a p.d. $f_\theta(x) = \theta e^{-\theta x} \mathbf{1}_{[0, \infty)}(x)$.




Exemple : \rightarrow loi uniforme sur $[0,1]$
 $X \sim \text{Unif}([0,1])$ si X a p.d.
 $f = \mathbf{1}_{[0,1]}$

$$\mathbb{P}(X \in A) = \int_A \mathbf{1}_{[0,1]}(x) dx$$

$$= \lambda(A \cap [0,1])$$



où λ est la mesure de Lebesgue sur \mathbb{R} .



si $B \in \mathcal{D}(\mathbb{R})$, on dit que $X \sim \text{Unif}(B)$,

$$\text{si } \forall A \in \mathcal{D}(\mathbb{R}), \mathbb{P}(X \in A) = \frac{\lambda(A \cap B)}{\lambda(B)}$$





$$\mathbb{P}(X \geq 0) = \int_0^\infty \theta e^{-\theta x} dx = 1.$$

► loi normale:

$$X \sim \mathcal{N}(m, \sigma^2)$$

si X a p.d.

$$f_{m, \sigma}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-m)^2}$$



$$f_{0,1}(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}$$

$$\int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = 1.$$

Statistique $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \Theta})$

X_1, \dots, X_m iid tq X_i est à densité f_θ .

$$\mathbb{P}_\theta(X_1 = x_1, \dots, X_m = x_m) = 0.$$

Heuristique: si $\epsilon > 0$, $(x_1, \dots, x_m) \in \mathbb{R}^m$, $\theta \in \Theta$


$$\mathbb{P}_\theta(X_1 \in [x_1 - \epsilon, x_1 + \epsilon], \dots, X_m \in [x_m - \epsilon, x_m + \epsilon]) =$$

$$= \prod_{i=1}^m \mathbb{P}_\theta(X_i \in [x_i - \epsilon, x_i + \epsilon])$$

$$= \prod_{i=1}^m \int_{x_i - \epsilon}^{x_i + \epsilon} f_\theta(x) dx$$

$$\approx \prod_{i=1}^m (2\epsilon) f_\theta(x_i)$$

$$\approx (2\epsilon)^m \prod_{i=1}^m f_\theta(x_i)$$



⑤ La vraisemblance associée à un échantillon x_1, \dots, x_m de loi à densité f_θ est donnée par $\forall \theta \in \Theta$,

$$\forall (x_1, \dots, x_m) \in \mathbb{R}^m,$$

$$V(\theta, x_1, \dots, x_m) = \prod_{i=1}^m f_\theta(x_i) \text{ et}$$

l'estimateur du max de vrais. est

$$\hat{\theta}_m = \operatorname{argmax}_{\theta \in \Theta} V(\theta, x_1, \dots, x_m) = \operatorname{argmax}_{\theta \in \Theta} \prod_{i=1}^m f_\theta(x_i)$$

Exemples Estimateur du max de vraisemblance par des lois à densité.

1) Loi uniforme sur $[0, \theta]$

Sur $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in [0, \infty[})$, on observe un échantillon x_1, \dots, x_m où $X_i \sim \text{Unif}([0, \theta])$.

(R*) $X \sim \text{Unif}([0, \theta])$


$$\text{si } \mathbb{P}(X \in B) = \frac{\lambda(B \cap [0, \theta])}{\theta} \quad \forall B \in \mathcal{D}(\mathbb{R})$$

où λ : mesure de Lebesgue sur $(\mathbb{R}, \mathcal{D}(\mathbb{R}))$.
 $f_{dR^\theta}: \mathcal{S} = [-\infty, t] \quad \forall t \in \mathbb{R}$.

⑩

$$F_\theta(t) = \mathbb{P}(X \leq t) = \frac{\lambda(-\infty, t] \cap [0, \infty]}{\theta}$$

$$= \begin{cases} 0 & \text{si } t < 0 \\ \frac{t}{\theta} & \text{si } 0 \leq t < \theta \\ 1 & \text{si } t \geq \theta. \end{cases}$$



Densité

$$f_\theta(x) = \frac{1}{\theta} \mathbb{1}_{[0, \theta]}(x)$$



$$\text{Ry: } F_\theta(t) = \int_{-\infty}^t f_\theta(x) dx$$


La vraisemblance \hookrightarrow à l'observation X_1, \dots, X_n est

$$V(\theta, X_1, \dots, X_n) = \prod_{i=1}^n f_\theta(X_i) = \prod_{i=1}^n \left(\frac{1}{\theta} \mathbb{1}_{[0, \theta]}(X_i) \right)$$


$$V(\theta, X_1, \dots, X_n) = \frac{1}{\theta^n} \prod_{i=1}^n \mathbb{1}_{[0, \theta]}(X_i)$$

$$\mathbb{1}_{[0, \theta]}(X_i) = \mathbb{1}_{[X_i, \infty]}(\theta).$$


$$\prod_{i=1}^n \mathbb{1}_{[0, \theta]}(X_i) = \prod_{i=1}^n \mathbb{1}_{[X_i, \infty]}(\theta) = \mathbb{1}_{[\max_{1 \leq i \leq n} X_i, \infty]}(\theta)$$



$$V(\theta, X_1, \dots, X_n) = \frac{1}{\theta^n} \mathbb{1}_{[\max_{1 \leq i \leq n} X_i, \infty]}(\theta)$$




$$\hat{\theta}_m = \underset{\theta > 0}{\operatorname{argmax}} V(\theta, X_1, \dots, X_n) = \max_{1 \leq i \leq n} X_i$$



Rechercher la loi de $\hat{\theta}_m$ via la Fdfr.

Autre estimateur si $X \sim \text{Unif}([0, \theta])$.

$$P_{\theta}(\hat{\theta}_m \leq t) = P_{\theta}(\max_{1 \leq i \leq n} X_i \leq t)$$





$$= P_{\theta}\left(\bigcap_{i=1}^n \{X_i \leq t\}\right) = \prod_{i=1}^n P_{\theta}(X_i \leq t) = (F_{\theta}(t))^n$$

$$\mathbb{E}(X) = \int_{\mathbb{R}} x f_{\theta}(x) dx = \int_{\mathbb{R}} x \frac{1}{\theta} \mathbf{1}_{[0, \theta]}(x) dx = \int_0^{\theta} \frac{x}{\theta} dx = \frac{\theta}{2}$$

$$\Rightarrow P_{\theta}(\hat{\theta}_m \leq t) = \begin{cases} 0 & \text{si } t < 0 \\ \left(\frac{t}{\theta}\right)^n & \text{si } 0 \leq t < \theta \\ 1 & \text{si } t \geq \theta \end{cases}$$

$$\Rightarrow \theta = 2\mathbb{E}(X)$$


$$\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i \Rightarrow \tilde{\theta}_m = 2\bar{X}_m \text{ est un estimateur de } \theta.$$



On le comparera par la suite.


2) Loi normale

Q) $X \sim \mathcal{N}(m, \sigma^2)$ si X a pr. densité $f_{m, \sigma^2}(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(x-m)^2}$



si σ petit

$$\int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{x^2}{2\sigma^2}} dx = 1$$




$$\Rightarrow \mathbb{E}(X) = m$$

$$\text{Var}(X) = \sigma^2.$$

On montrera que $\hat{\theta}_m \xrightarrow[m \rightarrow \infty]{P_{\theta}} \theta$.

Densité de $\hat{\theta}_m$: $m \frac{t^{m-1}}{\theta^n} \mathbf{1}_{[0, \theta]}(t)$

• $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \mathbb{R}})$ sur lequel on observe ,
 X_1, \dots, X_m iid : $X_i \sim \mathcal{N}(\theta, 1)$.



si $m = \bar{x}$: l'estimateur de θ b+ vraisemblable est \bar{x} .

$$V(\theta, X_1, \dots, X_m) = \prod_{i=1}^m f_{\theta, 1}(X_i) = \prod_{i=1}^m \frac{1}{\sqrt{2\pi}} e^{-\frac{(X_i-\theta)^2}{2}}$$

$$= \left(\frac{1}{\sqrt{2\pi}} \right)^m e^{-\frac{1}{2} \sum_{i=1}^m (X_i-\theta)^2}, \text{ on cherche } \hat{\theta}_n \text{ qui maximise } V(\theta, X_1, \dots, X_m) \text{ en } \theta.$$

$$\Leftrightarrow \text{minimiser } \theta \mapsto \sum_{i=1}^m (X_i - \theta)^2.$$

$$\text{Or } \sum_{i=1}^m (X_i - \theta)^2 = \sum_{i=1}^m X_i^2 - 2\theta \sum_{i=1}^m X_i + m\theta^2$$

admet un minimum en $\hat{\theta}_n = \bar{X}_m$

$$\bullet \theta = (m, \sigma^2) \in \mathbb{R} \times \mathbb{R}_{>0}$$

$$(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in \mathbb{R}_{[0, \infty[}})$$

X_1, \dots, X_m iid tq $X_i \sim \mathcal{N}(m, \sigma^2)$

$$\begin{aligned} \text{Vraisemblance : } V(m, \sigma^2, X_1, \dots, X_m) &= \prod_{i=1}^m \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{1}{2\sigma^2}(X_i-m)^2} \\ &= \left(\frac{1}{\sqrt{2\pi}\sigma} \right)^m e^{-\frac{1}{2\sigma^2} \sum_{i=1}^m (X_i-m)^2} \end{aligned}$$

$$\ln(V(m, \sigma^2, X_1, \dots, X_m)) = -\frac{m}{2} \ln(2\pi\sigma^2) - \frac{1}{2\sigma^2} \sum_{i=1}^m (X_i-m)^2$$

$$\frac{\partial}{\partial m} \ln V(m, \sigma^2, X_1, \dots, X_m) = \frac{1}{2\sigma^2} 2 \sum (X_i-m)^2$$

$$\frac{\partial}{\partial \sigma^2} \ln V(m, \sigma^2, X_1, \dots, X_m) = -\frac{m}{2\sigma^2} + \frac{1}{2\sigma^4} \sum (X_i-m)^2$$

$$\frac{\partial}{\partial m} \ln V(m, \sigma^2, X_1, \dots, X_m) = 0 \text{ si } m = \bar{X}_m = \hat{m}_m.$$

$$\frac{\partial}{\partial \sigma^2} \ln V(m, \sigma^2, X_1, \dots, X_m) = 0 \text{ si } \sigma^2 = \sigma^2(m) = \frac{1}{m} \sum_{i=1}^m (X_i-m)^2$$

\Rightarrow l'estimation du maximum de vraisemblance de (m, σ^2) est $(\hat{m}_m, \hat{\sigma}^2_m)$; $\hat{m}_m = \bar{X}_m$, $\hat{\sigma}^2_m = \frac{1}{m} \sum_{i=1}^m (X_i - \bar{X}_m)^2$
 (variance empirique)

(R) $X \sim \text{Unif}(\{x_1, \dots, x_m\})$;

$$\text{Var}(X) = E[(X - E(X))^2]$$

$$E(X) = \sum_{i=1}^m \frac{x_i}{m} = \bar{x}_m$$

$$\text{Var}(X) = \sum_{i=1}^m \frac{1}{m} (x_i - \bar{x}_m)^2 = \frac{1}{m} \sum_{i=1}^m (x_i - \bar{x}_m)^2$$

III / Propriétés des estimateurs

($\Omega, \mathcal{F}, P_\theta$) un modèle statistique munie d'observables X_1, \dots, X_m iid soit $\hat{\theta}_m$ un estimateur de θ .

② Biass & risque quadratique

Le biass de l'estimateur est $b_m(\theta) = \theta - E_\theta(\hat{\theta}_m)$ et l'estimateur $\hat{\theta}_m$ est sans biass si $E_\theta(\hat{\theta}_m) = \theta$.

• ③ Risque quadratique de l'estimateur $\hat{\theta}_m$ est

$$R_m(\hat{\theta}_m) = E_\theta[(\hat{\theta}_m - \theta)^2]$$

(R) Si $\hat{\theta}_m$ est sans biass alors $R_m(\hat{\theta}_m) = \text{Var}_\theta(\hat{\theta}_m)$

84

1 Décomposition "biass-variance"

$$\begin{aligned} R_m(\hat{\theta}_m) &= E_\theta[(\hat{\theta}_m - E_\theta(\hat{\theta}_m) + E_\theta(\hat{\theta}_m) - \theta)^2] \\ &= E_\theta[(\hat{\theta}_m - E_\theta(\hat{\theta}_m))^2 + (E_\theta(\hat{\theta}_m) - \theta)^2 \\ &\quad + 2(E_\theta[(\hat{\theta}_m - E_\theta(\hat{\theta}_m))(E_\theta(\hat{\theta}_m) - \theta)])] \\ &= b_m^2(\theta) + \text{Var}_\theta(\hat{\theta}_m) + 2(E_\theta(\hat{\theta}_m) - \theta) E_\theta[(\hat{\theta}_m - E_\theta(\hat{\theta}_m))] \\ &= b_m^2(\theta) + \text{Var}_\theta(\hat{\theta}_m) \end{aligned}$$

$$R_m(\hat{\theta}_m) = b_m^2(\theta) + \text{Var}_\theta(\hat{\theta}_m)$$

→ Le risque quadratique est un critère pour comparer des estimateurs entre eux.

Exemples:

- modèle de Bernoulli

\bar{X}_m est un estimateur sans biass de θ .

$$E_m(\bar{X}_m) = \text{Var}_\theta(\bar{X}_m) = \frac{\theta(1-\theta)}{m} \xrightarrow[m \rightarrow \infty]{} 0$$

• loi Uniforme

X_1, \dots, X_m iid $\text{Unif}([0, \theta])$

$$\hat{\theta}_m = \max_{1 \leq i \leq m} X_i, \quad \widetilde{\theta}_m = 2\bar{X}$$

$$\mathbb{E}_\theta(\bar{x}_n) = \mathbb{E}_\theta\left(\frac{1}{n} \sum_{i=1}^n x_i\right) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta(x_i) = \frac{\theta}{2}$$

$\Rightarrow \tilde{\theta}_n$ est un estimateur sans biais de θ . On dit que $\hat{\theta}_n$ est un estimateur faiblement consistant

• $\hat{\theta}_m$ a la densité $\frac{n^{n-1}}{\theta^n} \mathbf{1}_{[0,\theta]}(x)$. $\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P_\theta(|\hat{\theta}_m - \theta| > \varepsilon) = 0$.

$$\mathbb{E}_\theta(\hat{\theta}_m) = \int_{\mathbb{R}^n} x \cdot n \frac{x^{n-1}}{\theta^n} \mathbf{1}_{[0,\theta]}(x) dx.$$

$$\mathbb{E}_\theta(\hat{\theta}_m) = \frac{n}{\theta^n} \left[\frac{x^{n+1}}{n+1} \right]_0^\theta = \frac{n}{n+1} \theta$$

$$\tilde{\theta}_m = \max_{1 \leq i \leq m} x_i < \theta \quad P_\theta \text{ ps.}$$

$\rightarrow \hat{\theta}_m$ n'est pas un estimateur sans biais de θ mais il est asymptotiquement sans biais.

Calculer les RQ quadratiques de $\tilde{\theta}_n$ et $\hat{\theta}_m$. $\hat{\theta}_m$ a un RQ quad bien + petit que $\tilde{\theta}_n$. en $\frac{1}{m}$ et $\frac{1}{n^2}$.

2 Consistance

On dit que $\hat{\theta}_n$ est un estimateur P_θ -probablement consistant si $\hat{\theta}_n \xrightarrow[m \rightarrow \infty]{P_\theta \text{-prob}} \theta$.

$\forall \varepsilon > 0$, $\lim_{n \rightarrow \infty} P_\theta(|\hat{\theta}_n - \theta| > \varepsilon) = 0$.

On dit que $\hat{\theta}_m$ est un estimateur fortement consistant de θ si $\hat{\theta}_m \xrightarrow[n \rightarrow \infty]{P_\theta \text{-prob}} \theta$.

$\Leftrightarrow P_\theta(\text{jeu } \omega : \hat{\theta}_m(\omega) \xrightarrow[m \rightarrow \infty]{P_\theta \text{-prob}} \theta) = 1 \quad \forall \omega \in \Omega$.

Critères probabilités

$\hat{\theta}_m$ fortement consistant de $\theta \Rightarrow$ faiblement consistant de θ .

Réciproquant: Condition suffisante si $\sum_{n=1}^{\infty} P_\theta(|\hat{\theta}_n - \theta| > \delta) < \infty$ alors $\hat{\theta}_n \xrightarrow[n \rightarrow \infty]{P_\theta \text{-prob}} \theta$

Exemple: loi uniforme sur $[0, \theta]$, $\hat{\theta}_m = \max_{1 \leq i \leq m} x_i$. la consistance faible.

$$\forall \varepsilon > 0 \quad P_\theta(|\hat{\theta}_m - \theta| > \varepsilon) = P(\theta - \hat{\theta}_m > \varepsilon) \quad \begin{matrix} \text{cas} \\ \hat{\theta}_m < \theta \\ P_\theta \text{ ps} \end{matrix}$$

$$= P_\theta(\hat{\theta}_m < \theta - \varepsilon) = (F_\theta(\theta - \varepsilon))^m$$

$$= \left(\frac{\theta - \varepsilon}{\theta}\right)^m \quad \begin{matrix} \text{si } \varepsilon > 0 \\ \text{ou } 0 \text{ si } \varepsilon \geq \theta. \end{matrix}$$

65

$$\text{Dc } \lim_{n \rightarrow \infty} \left(\frac{\theta - \varepsilon}{\theta} \right)^n = 0$$

$$\Rightarrow \forall \varepsilon > 0, P_\theta(|\hat{\theta}_m - \theta| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0$$

• De plus, $\sum_{n=1}^{\infty} \left(\frac{\theta - \varepsilon}{\theta} \right)^n < \infty \quad \varepsilon < 0.$

$$\Rightarrow \hat{\theta}_m \xrightarrow[n \rightarrow \infty]{\text{P.P.S}} \theta$$

et $\hat{\theta}_m$ est un estimateur fortement consistant de θ .

La forte des grands n

si $(X_n)_{n \in \mathbb{N}^*}$ est une suite d'@ iid tq

$$\mathbb{E}(|X_i|) < \infty \text{ alors } \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\text{P.S}} \mathbb{E}(X)$$

• Loi uniforme sur $[0, 1]$.

$$\hat{\theta}_m = 2\bar{X}_m, \quad \bar{X}_m \xrightarrow[n \rightarrow \infty]{\text{P.P.S}} \frac{\theta}{2} \Rightarrow \hat{\theta}_m \xrightarrow[n \rightarrow \infty]{\text{P.P.S}} \theta$$

$\hat{\theta}_m$ est un estimateur fortement consistant de θ .

③ Loi asymptotique

Intro $\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i$

La loi exacte de la loi somme peut être difficile à calculer & la loi asymptotique est plus accessible & universelle.

Convergence en loi

④ Une suite de var $(X_n)_{n \in \mathbb{N}^*}$ converge en loi vers une var X pd $n \rightarrow \infty$ si



$$\lim_{n \rightarrow \infty} F_{X_m}(x) = F_X(x) \text{ au tt point } x \text{ de continuité de } F_X$$

où F_{X_m} est FdR de X_m .

$$F_X \xrightarrow{\text{lois}} X$$

$$\text{si } (\mathcal{E}, \mathcal{F}, \mathbb{P})$$

$$\textcircled{a} \quad X_n \sim \text{Unif}\left(\left\{ \frac{k}{m} \right\}, \quad 1 \leq k \leq m \right)$$



$$X \sim \text{Unif}([0, 1]).$$

A Mq $F_{X_m}(x) \xrightarrow{n \rightarrow \infty} F_X(x)$

$X \in \mathcal{R}$

② $X_i \sim \text{Unif}([\underline{\theta}, \bar{\theta}])$, $T_m = \max_{1 \leq i \leq m} X_i$ ($\leq \bar{\theta}$ ps) ④ • $\mathbb{E}(X_1^2) < \infty \Rightarrow \mathbb{E}(|X_1|) < \infty$
 et $\text{Var}(X_1) < \infty$.
 On pose $Z_m = m(\bar{\theta} - T_m)$.
 On pt montr $Z_m \xrightarrow[n \rightarrow \infty]{\text{loi}} Z$ où $Z \sim \text{Exp}\left(\frac{1}{\bar{\theta}}\right)$

Consequence de la ② en loi si $X_m \xrightarrow[n \rightarrow \infty]{\text{loi}} X$.

$\forall (a, b) \in \mathbb{R}^2$, $a < b$,

$$\mathbb{P}(X_m \in [a, b]) \xrightarrow[n \rightarrow \infty]{\text{loi}} \mathbb{P}(X \in [a, b])$$

$$\text{car } \mathbb{P}(X_m \in [a, b]) = F_{X_m}(b) - F_{X_m}(a) \xrightarrow[m \rightarrow \infty]{} F_X(b) - F_X(a)$$

③ TL de limite centrale (TLC) $\mathbb{P}(X \in [a, b])$

sont $(X_m)_{m \in \mathbb{N}^*}$ une suite de variables iid & de
carac intégrables $\mathbb{E}(X_1^2) < \infty$,
 (définies sur l'espace de proba) (Q, F, P).

$$\text{On pose } S_m = \sum_{i=1}^m X_i$$

$$Z_m = \frac{S_m - \mathbb{E}(S_m)}{\sqrt{\text{Var}(S_m)}} \xrightarrow[n \rightarrow \infty]{\text{loi}} Z \text{ où } Z \sim \mathcal{N}(0, 1). \quad \text{④} \quad Z \sim \mathcal{N}(0, 1) \text{ a pr densité :}$$

④ conseil d'après null ridante: $m \geq 1$

- $\text{Var}(S_m) = \sum_{i=1}^m \text{Var}(X_i)$ car les $(X_i)_{1 \leq i \leq m}$ sont indép
- $= m \text{Var}(X_1)$ car de \hat{m} loi.
- $\mathbb{E}(S_m) = m \mathbb{E}(X_1)$.

$$\frac{S_m - \mathbb{E}(S_m)}{\sqrt{\text{Var}(S_m)}} = \frac{S_m - m \mathbb{E}(X_1)}{\sqrt{m \text{Var}(X_1)}} = \sqrt{\frac{1}{m}} \frac{X_m - \mathbb{E}(X_1)}{\sqrt{\text{Var}(X_1)}}$$

④ TLC fournit une vitesse de convergence de $\mathbb{E}(X_1)$ de $\sqrt{\frac{1}{m}}$.

$$\bar{X}_m = \mathbb{E}(X_1) + \sqrt{\frac{\text{Var}(X_1)}{m}} Z_m$$

• si $a < b$:

$$\mathbb{P}\left(a \leq \sqrt{\frac{1}{m}} \frac{X_m - \mathbb{E}(X_1)}{\sqrt{\text{Var}(X_1)}} \leq b\right) \xrightarrow[m \rightarrow \infty]{} \mathbb{P}(a \leq Z \leq b)$$



$$f_{0,1}(x) = \frac{1}{\sqrt{2\pi}} e^{-x^2/2} \text{ sur } \mathbb{R}, \text{ sa}$$

Fonction Φ est def: $\Phi(z) = \mathbb{P}(Z \leq z) = \int_{-\infty}^z \frac{1}{\sqrt{2\pi}} e^{-x^2/2} dx$

Table des val^{pro}s de $\Phi(t)$, $t \geq 0$. $P(-z \geq -t) = P(z \leq t)$ car Z est m. loi.

(val^{pro} $\geq 1/2$)

si $t < 0$

$\Phi(t) = P(Z \leq t) = P(Z \geq -t)$

$= 1 - P(Z \leq -t)$

$= 1 - \Phi(-t)$

Consequence : Intervalle de fluctuation


$P_{\theta}(-t \leq Z_n \leq t) = P_{\theta}\left(\frac{Z_n - \theta}{\sqrt{\theta(1-\theta)}} \leq \frac{t - \theta}{\sqrt{\theta(1-\theta)}}\right) \xrightarrow{n \rightarrow \infty} P_{\theta}(t \leq Z) = \Phi(t)$

$\Leftrightarrow P_{\theta}\left(\frac{|Z_n - \theta|}{\sqrt{\theta(1-\theta)}} \leq t\right) \xrightarrow{n \rightarrow \infty} P_{\theta}(|Z| \leq t)$

or $P_{\theta}(|Z| \leq t) = P_{\theta}(Z \leq t) - P_{\theta}(Z \leq -t)$

Values utiles t tq $\Phi(t) = 0,95$.

$t = 1,645$.



t tq $\Phi(t) = 0,975$

$t = 1,96$.

Application: M de Bernoulli.

M statistique $(\Omega, \mathcal{F}, (\mathbb{P}_{\theta})_{\theta \in [0,1]})$.

X_1, \dots, X_n iid Bern (θ) suiv \mathbb{P}_{θ} .

TLC $(\mathbb{E}(X_i))_{1 \leq i \leq n}$ st de cours intégrables.

$\Rightarrow \sqrt{n} \frac{\bar{X}_n - \theta}{\sqrt{\theta(1-\theta)}} \xrightarrow[n \rightarrow \infty]{\mathbb{P}_{\theta} - \text{loi}} Z$ où $Z \sim \mathcal{N}(0,1)$.

Consequence : Intervalle de fluctuation

$P_{\theta}(-1,96 \leq \frac{\bar{X}_n - \theta}{\sqrt{\theta(1-\theta)}} \leq 1,96) \xrightarrow{n \rightarrow \infty} 0,95$

$\Leftrightarrow 2\Phi(1,96) - 1 = 0,95$

$\Leftrightarrow \Phi(1,96) = 0,975$

$\Leftrightarrow t = \Phi^{-1}(0,975) = 1,96$.

$P_{\theta}\left(\theta - 1,96 \sqrt{\frac{\theta(1-\theta)}{n}} \leq \bar{X}_n \leq \theta + 1,96 \sqrt{\frac{\theta(1-\theta)}{n}}\right) \xrightarrow{n \rightarrow \infty} 0,95$

② int'glibage = int. stricte sur la densité.

$$\text{On note } \theta(1-\theta) < \frac{1}{4},$$

$$\lim_{n \rightarrow \infty} P_\theta \left(\theta - \frac{1,96}{\sqrt{n}} \leq \bar{X}_n \leq \theta + \frac{1,96}{\sqrt{n}} \right) \geq 0,95$$

$$P_\theta \left(\bar{X}_n \in \left[\theta - \frac{1,96}{\sqrt{n}}, \theta + \frac{1,96}{\sqrt{n}} \right] \right) \geq 0,95.$$

si n est assez grand.

Contrôle de l'approximation gaussienne.

TH (Berry-Essen)

soit $(X_n)_{n \in \mathbb{N}^*}$ suite de variables indépendantes

$$\mathbb{E}(|X_1|^3) < \infty.$$

$$\text{On note } \sigma^2 = \text{Var}(X_1), \rho^3 = \mathbb{E}[|X_1 - \mathbb{E}(X_1)|^3]$$

$$\sigma^2 > 0 \text{ et } \rho^3 > 0.$$

$$\text{alors si } Z_m = \frac{s_m - \mathbb{E}(s_m)}{\sqrt{\text{Var}(s_m)}} \text{ où } s_m = \sum_{i=1}^m X_i.$$

$$\sup_{x \in \mathbb{R}} |\mathbb{P}(Z_m \leq x) - \mathbb{P}(Z \leq x)| \leq c \frac{\rho^3}{\sigma^3} \frac{1}{\sqrt{m}}.$$

$$\frac{1}{2}$$

$$\text{ex: } n=1942: c=1,59 \quad \text{②}$$

Application: $X_i \sim \text{Bern}(\theta)$.

$$\sigma^2 = \theta(1-\theta) \text{ et } \rho^3 = \theta(1-\theta)(\theta^2 + (1-\theta)^2)$$

$$\frac{\rho^3}{\sigma^3} = \frac{\theta^2 + (1-\theta)^2}{\sqrt{\theta(1-\theta)}} \leq \frac{1}{\sqrt{\theta(1-\theta)}}$$

• 3600 fois un K & S nb de 6 obtenu.
 $S \sim \text{Bin}(3600, \frac{1}{6})$.

$$\mathbb{P}(540 \leq S \leq 660) = \mathbb{P}\left(\left|\frac{S-600}{\sqrt{500}}\right| \leq \frac{6}{\sqrt{5}}\right)$$

$$\approx \Phi\left(\frac{6}{\sqrt{5}}\right) - \Phi\left(-\frac{6}{\sqrt{5}}\right) = 2\Phi\left(\frac{6}{\sqrt{5}}\right) - 1 \approx 0,993$$

erreur d'approximation.

$$\left| \mathbb{P}\left(\frac{S-600}{\sqrt{500}} \leq \frac{6}{\sqrt{5}}\right) - \Phi\left(\frac{6}{\sqrt{5}}\right) \right| \leq c \frac{6}{\sqrt{5}} \frac{1}{\sqrt{3600}} = c/\sqrt{60\sqrt{5}}.$$

$$\left| \Phi\left(\frac{S-600}{\sqrt{500}} \leq -\frac{6}{\sqrt{5}}\right) - \Phi\left(-\frac{6}{\sqrt{5}}\right) \right| \leq \frac{c}{10\sqrt{5}}$$

$$\Rightarrow \left| \mathbb{P}\left(\left|\frac{S-600}{\sqrt{500}}\right| \leq \frac{6}{\sqrt{5}} - \left(\Phi\left(\frac{6}{\sqrt{5}}\right) - \Phi\left(-\frac{6}{\sqrt{5}}\right)\right) \right| \leq \frac{2c}{10\sqrt{5}} \approx 0,045.$$

$$\mathbb{P}(540 \leq S \leq 660) \geq 0,993 - 0,045.$$

(Rq) Par Bienaymé - Pebitchev :

$$\begin{aligned} P(540 \leq S \leq 660) &= P(|S - 600| \leq 60) \\ &= 1 - P(|S - 600| > 60) \\ &\geq 1 - \frac{5}{60^2} = 1 - \frac{5}{36} = 0.86. \end{aligned}$$

Vocab statistiq

① Un estimat^R est asymptotiquement normal.
soit $\hat{\theta}$ en loi (de un chgt d'échelle au préalable) vers une loi $\mathcal{N}(0,1)$. On parle de normalité asymptotiq de l'estimat^R.

IV Intervalle de confiance ($\mathbb{Q}, \mathbb{P}, (P_\theta)_{\theta \in \Theta}$)

⑤ Un intervalle de confiance pour θ de niveau de confiance $1-\alpha$ ($\alpha \in [0,1]$) et un intervalle aléatoire \hat{I}_m f de X_1, \dots, X_m (indép de θ) tq $P(\theta \in \hat{I}_m) \geq 1-\alpha$.

(Rq) $P_\theta(\theta \in \hat{I}_m) = P_\theta(\hat{I}_m \ni \theta)$

Généralisé : $\hat{\theta} \in \mathbb{R}^d$.

Région de confiance $\hat{D}_m \subset \mathbb{R}^d$.

$$P_\theta(\theta \in \hat{D}_m) \geq 1-\alpha$$

② M de Construc

\hat{I}_m (ou \hat{D}_m) est obt basé sur estimat de θ

$$\hat{I}_m = [\hat{\theta}_m - \varepsilon, \hat{\theta}_m + \varepsilon] \quad \& \quad \varepsilon \geq 0 \text{ (dep de } n \& \alpha, \text{ mais pas de } \theta)$$

$$\text{ou } \hat{I}_m = [\frac{1}{c} \hat{\theta}_m, c \hat{\theta}_m] \quad c > 1.$$

a) Calcul exact

si on connaît la loi d'un estimat^R de θ .

@ (Estim nbre tirages all des 2GM à matricules chancs détruit).

n tirages de remise de carte q contient N cartes numérotées de 1 à N, N est inconnu.

X_i résultat du i^e tirage $1 \leq i \leq n$.

$$(e, \mathcal{F}, P_N)_{N \in \mathbb{N}^*}, \quad X_i \sim \text{Unif}(\{1, \dots, N\}) \quad (\text{iid})$$


$$P_N(X_i = k) = \frac{1}{N} \quad 1 \leq k \leq N.$$

Estimateur du max de l'ensemble.

$$\forall (x_1, \dots, x_m) \in (\mathbb{N}^*)^m.$$

$$\begin{aligned} V(N, x_1, \dots, x_m) &= \prod_{i=1}^m P_N(X_i = x_i) \\ &= \prod_{i=1}^m \frac{1}{N} \mathbf{1}_{\{x_i \leq N\}} \\ &= \frac{1}{N^m} \mathbf{1}_{\{x_i \leq N : \forall i \in \{1, \dots, m\}\}} \end{aligned}$$

$$\boxed{V(N, x_1, \dots, x_m) = \frac{1}{N^m} \mathbf{1}_{\{N \geq \max_{1 \leq i \leq m} x_i\}}}$$



$\hat{N}_n = \max_{1 \leq i \leq n} X_i$ est l'estimateur du max de l'ensemble de N . Sa loi est la suivante

$$P_N(\hat{N}_n \leq k) = P_N(\max_{1 \leq i \leq n} X_i \leq k)$$

$$\Rightarrow P_N\left(\bigcap_{i=1}^n \{X_i \leq k\}\right) = \prod_{i=1}^n P_N(X_i \leq k) = \left(\frac{k}{N}\right)^n$$

Intervalle de confiance pour N de niveau $1-\alpha$

$$\begin{aligned} \hat{N}_n \leq N \text{ et } P_N(\varepsilon N \leq \hat{N}_n \leq N) &= \\ &= 1 - P_N(\hat{N}_n < \varepsilon N) = 1 - P_N(\hat{N}_n \leq \lceil \varepsilon N \rceil - 1) \\ &= 1 - \left(\frac{\lceil \varepsilon N \rceil - 1}{N}\right)^n \geq 1 - \varepsilon^n \end{aligned}$$

$$\text{Car } \varepsilon - \frac{1}{N} \leq \frac{\lceil \varepsilon N \rceil - 1}{N} < \varepsilon, \quad \varepsilon = e^{-n}, \quad \alpha = e^{-n}$$

$$\Rightarrow P_N\left(N \in \left[\hat{N}_n, \frac{\hat{N}_n}{\sqrt[n]{\alpha}}\right]\right) \geq 1-\alpha$$

⑤ Les inégalités de concentration

soit θ fixé et X_1, \dots, X_n iid ss P_θ .

BT si les $(X_i)_{1 \leq i \leq n}$ sont de carrés intégrables

$$\text{alors } P_\theta \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - E_\theta(X_i) \right| \geq \varepsilon \right) \leq \frac{\text{Var}_\theta(X_i)}{n \varepsilon^2}$$

Hoeffding si les $(X_i)_{1 \leq i \leq n}$ sont bornées

$$a \leq X_i \leq b$$

$$P_\theta(a \leq X_i \leq b) = 1$$

$$\text{alors } P_\theta \left(\left| \frac{1}{n} \sum_{i=1}^n X_i - E_\theta(X_i) \right| > \varepsilon \right) \leq 2 e^{-2(b-a)^2 \frac{n \varepsilon^2}{n}}$$

Plus restrictif que les hypothèses molles des inégalités.

1) asymptotique

Un intervalle de confiance \hat{I}_n pour θ de niveau de

confiance asymptotique $1-\alpha$ si $\lim_{n \rightarrow \infty} P_\theta(\theta \in \hat{I}_n) \geq 1-\alpha$.

Utilis: TLC

si $(X_i)_{i \in \mathbb{N}^*}$ est une suite de iid de carré intégrable

$$\text{alors } \sqrt{n} \frac{\bar{X}_n - E_\theta(X_i)}{\sqrt{\text{Var}_\theta(X_i)}} \xrightarrow[n \rightarrow \infty]{\text{loi de } P_\theta} Z \sim N(0, 1)$$

R^o BT variance finie et bornée


appliquée au modèle de Bernoulli

X_i iid $\text{Bern}(\theta)$, $\theta \in [0, 1]$.

$$\sqrt{n} \cdot \frac{\bar{X}_n - \theta}{\sqrt{\theta(1-\theta)}} \xrightarrow[n \rightarrow \infty]{P_\theta} Z$$

$$\lim_{n \rightarrow \infty} P_\theta \left(\sqrt{n} \frac{|\bar{X}_n - \theta|}{\sqrt{\theta(1-\theta)}} \right) \leq \Phi^{-1}(1 - \frac{\alpha}{2})$$

$$= \Phi(|Z| \leq \Phi^{-1}(1 - \frac{\alpha}{2})) = 1 - \alpha$$



$$\text{R} \Phi(H) = \int_{-\infty}^H \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} dx = P(Z \leq H)$$

$$\text{On cherche } z_\alpha \geq 0 \text{ tq} \\ P(|Z| \leq z_\alpha) = 1 - \alpha$$

$$Z \sim N(0, 1)$$

$$\begin{aligned} \text{or } P(|Z| \leq z_\alpha) &= P(Z \leq z_\alpha) - P(Z < -z_\alpha) \\ &= \Phi(z_\alpha) - (1 - \Phi(z_\alpha)) \\ &= 2\Phi(z_\alpha) - 1 \end{aligned}$$

$$\text{car } \begin{aligned} P(Z < -z_\alpha) &= P(-Z > z_\alpha) = P(Z > z_\alpha) \\ &= 1 - P(Z < z_\alpha) = 1 - \Phi(z_\alpha) \end{aligned}$$

Puis on résoud $\Phi(z_\alpha) - 1 = 1 - \alpha$
 $\Leftrightarrow \Phi(z_\alpha) = 1 - \frac{\alpha}{2}$.
 $\Leftrightarrow z_\alpha = \Phi^{-1}(1 - \frac{\alpha}{2})$.

[RQ] En encadrage analytique on cherche a_α & b_α tq $P(Z \in [a_\alpha, b_\alpha]) = 1 - \alpha$ (\star)

le plus petit intervalle qui vérifie (\star), est centré en 0.

$\Delta \alpha = 0,05$, $\Phi^{-1}(1 - \frac{\alpha}{2}) = \Phi^{-1}(0,975) = 1,96$


Pour un intervalle de niveau asymptotique 95%, on a:

$$P_\theta \left(\sqrt{n} \frac{|\bar{X}_n - \theta|}{\sqrt{\theta(1-\theta)}} \leq 1,96 \right) \xrightarrow{n \rightarrow \infty} 0,95$$

⚠️ La variance dépend de θ .

$$\hat{I}_m(\theta) = \left[\bar{X}_m - 1,96 \sqrt{\frac{\theta(1-\theta)}{n}}, \bar{X}_m + 1,96 \sqrt{\frac{\theta(1-\theta)}{n}} \right]$$

m' est pas IdC au dpd de θ !



(33)

→ Comment se débarrasser de θ (ds la variance) ?
[M2] Résoudre l'inéq (en θ).

$$\sqrt{n} \frac{|\bar{X}_n - \theta|}{\sqrt{\theta(1-\theta)}} \leq 1,96 \Leftrightarrow \sqrt{n} |\bar{X}_n - \theta| \leq 1,96 \sqrt{\theta(1-\theta)}$$

$$\Leftrightarrow n (\bar{X}_n - \theta)^2 \leq 1,96^2 \theta (1-\theta)$$

$$\Leftrightarrow \theta^2 (n + 1,96^2) + \theta (-2n\bar{X}_n - 1,96^2) + n\bar{X}_n^2 \leq 0$$

$$\Leftrightarrow \theta \in [\hat{\theta}_m^1, \hat{\theta}_m^2]$$

$$\Delta_m = (\delta_m \bar{X}_m + 1,96)^2$$

$$\hat{\theta}_m^1 = \frac{\delta_m \bar{X}_m + 1,96^2 - \sqrt{\Delta_m}}{2(n + 1,96^2)}$$

$$- \delta_m \bar{X}_m^2 (n + 1,96^2)$$

$$\hat{\theta}_m^2 = \frac{\delta_m \bar{X}_m + 1,96^2 + \sqrt{\Delta_m}}{2(n + 1,96^2)}$$

$$- 4 \times 1,96^2 \bar{X}_m^2$$

$$= 4 \times 1,96^2 \bar{X}_m (\bar{X}_m + \bar{\delta}_m) + 1,96^4$$

[M2]

On majore la variance :

$$\text{comme } \theta(1-\theta) \leq \frac{1}{4}. \quad \sqrt{\theta(1-\theta)} \leq \frac{1}{2}$$

$$\hat{I}_m(\theta) \subset \hat{I}_m\left(\frac{1}{2}\right) \quad \forall \theta \in]0,1[$$

$$\left[\bar{X}_m - \frac{1,96}{\sqrt{n}}, \bar{X}_m + \frac{1,96}{\sqrt{n}} \right]$$

$$\lim_{m \rightarrow \infty} P_\theta(\theta \in \hat{I}_m(\theta)) = 0,95$$

$$\Rightarrow \lim_{m \rightarrow \infty} P_\theta(\theta \in \hat{I}_m\left(\frac{1}{2}\right)) \geq 0,95$$

M₃ On estime la variance :

OB: Remplace $\sigma(1-\sigma)$ par $\bar{X}_n(1-\bar{X}_n)$
(c'est la variance empirique, estimat^Re fortement
consistant de la variance $\text{Var}_{\mathbb{P}}(X_1) = \sigma(1-\sigma)$).

\rightarrow si g est cont à valeurs ds \mathbb{R} &
 $(Y_n, Z_n) \xrightarrow[n \rightarrow \infty]{\text{loi}} (Y, c)$.
alors $g(Y_n, Z_n) \xrightarrow[n \rightarrow \infty]{\text{loi}} g(Y, c)$.

Centril probabilité

L de Slutsky

soit $(Y_n)_{n \in \mathbb{N}^*}$ & $(Z_n)_{n \in \mathbb{N}^*}$ 2 suites de va.
définies sur le m^e espace $(\Omega, \mathcal{F}, \mathbb{P})$ tq

$$Y_n \xrightarrow[n \rightarrow \infty]{\text{loi}} Y \quad \& \quad Z_n \xrightarrow[n \rightarrow \infty]{\text{proba}} c$$

$$\Rightarrow (Y_n, Z_n) \xrightarrow[n \rightarrow \infty]{\text{loi}} (Y, c).$$

Conse^gie :

$$X_n \xrightarrow[n \rightarrow \infty]{\text{loi}} X \text{ si } Vf \text{ hcont bornée}$$

$$\mathbb{E}(h(X_n)) \xrightarrow[n \rightarrow \infty]{} \mathbb{E}(h(X))$$

\rightarrow permet de définir la CVe en loi
pr des vecteurs aléatoires $(X_n \& X)$
valeurs ds \mathbb{R}^d).

$$\text{et } Y + Z_n \xrightarrow[n \rightarrow \infty]{\text{loi}} Y + c$$

$$Y_n \times Z_n \xrightarrow[n \rightarrow \infty]{\text{loi}} cY$$

Applicat du L au TLC:

III TLC \rightarrow autonormalisat :

si $(X_n)_{n \in \mathbb{N}^*}$ est une suite de Va iid de
variance finie & si V_n est un estimat^R faiblement
consistant de la variance alors

$$\sqrt{n} \frac{X_n - \mathbb{E}_{\mathbb{P}}(X)}{\sqrt{V_n}} \xrightarrow[n \rightarrow \infty]{\text{loi}} Z \sim \mathcal{N}(0, 1)$$

glbt const^t
on prouve

34

Q
CVe = CVe sp de continuité de la f

$$\text{Preuve : } \sqrt{n} \frac{\bar{X}_n - \mathbb{E}_\theta(X_1)}{\sqrt{V_n}} = \frac{\sqrt{n} \frac{\bar{X}_n - \mathbb{E}(X_1)}{\sqrt{V_{\mathbb{E}_\theta}(X_1)}}}{\sqrt{\frac{V_{\mathbb{E}_\theta}(X_1)}{V_n}}} \times \sqrt{\frac{V_{\mathbb{E}_\theta}(X_1)}{V_n}} = \left| \mathbb{E}[f(\bar{Y}_n)g(Z_n)] - \mathbb{E}[f(Y)g(c)] \right|$$

$\bar{Y}_n \xrightarrow[n \rightarrow \infty]{\text{loi}} Y$ où $\bar{Y}_n \sim N(0,1)$

$Z_n = V_n$, $Z_n \xrightarrow[n \rightarrow \infty]{\text{probab}} V_{\mathbb{E}_\theta}(X_1)$

alors $(\bar{X}_n, Z_n) \xrightarrow[n \rightarrow \infty]{\text{loi}} (Y, V_{\mathbb{E}_\theta}(X_1))$

$$g(y, z) = y \times \sqrt{\frac{V_{\mathbb{E}_\theta}(X_1)}{z}}$$

$$g(\bar{Y}_n, Z_n) \xrightarrow{} g(Y, V_{\mathbb{E}_\theta}(X_1)) = Y.$$

$$= \sqrt{n} \frac{\bar{X}_n - \mathbb{E}_\theta(X_1)}{\sqrt{V_n}}$$

$$= \left| \mathbb{E}[f(\bar{Y}_n)[g(Z_n) - g(c)]] + g(c)[f(\bar{Y}_n) - f(Y)] \right|$$

$$\leq \left| \mathbb{E}(f(\bar{Y}_n)(g(Z_n) - g(c))) \right| + \left| \mathbb{E}[g(c)(f(\bar{Y}_n) - f(Y))] \right|$$

$$A \leq \left| \mathbb{E}[|f(\bar{Y}_n)| |g(Z_n) - g(c)|] \right| \stackrel{B \leq |g(c)| / (\mathbb{E}(f(\bar{Y}_n)) - \mathbb{E}(f(Y)))}{\leq \|f\|_\infty \mathbb{E}[|g(Z_n) - g(c)|]}$$

L) (\mathbb{E}_θ dominé en probabilité)

soit $(W_m)_{m \in \mathbb{N}^*}$ une suite de \mathbb{R} t.q.

- $\exists M \in \mathbb{R}_+$, $|W_m(w)| \leq M \quad \forall w \in \Omega$
- $W_m \xrightarrow[n \rightarrow \infty]{\text{probab}} 0 \quad \Rightarrow \mathbb{E}(|W_m|) \xrightarrow[m \rightarrow \infty]{\text{ }} 0$.


Preuve du L) de Slutsky :

$\forall f, h$ cont bornée, $\mathbb{E}[h(\bar{Y}_n, Z_n)] \xrightarrow[n \rightarrow \infty]{} \mathbb{E}(h(Y, c))$

admis il suffit de le faire pr $h(y, z) = f(y)g(z)$.

f & g cont bornées.

$$\mathbb{E}(X) = \int_0^\infty P(X > t) dt.$$



$$\text{Preuve : } E(|W_m|) = \int_0^\infty P(|W_m| \geq t) dt$$

$$= \int_0^M P(|W_m| \geq t) dt$$

$$= \int_0^{\varepsilon} P(|W_m| \geq t) dt + \int_{\varepsilon}^M P(|W_m| \geq t) dt$$

$$\leq \varepsilon + P(|W_m| \geq \varepsilon) (M - \varepsilon)$$

$$\text{car } P(|W_m| \geq t) \leq P(|W_m| \geq \varepsilon) \quad \forall t \geq \varepsilon.$$

$$\Rightarrow \lim_{n \rightarrow \infty} E(|W_n|) \geq \varepsilon \quad \forall \varepsilon > 0$$

$$\rightarrow \lim_{n \rightarrow \infty} E(|W_n|) = 0$$

$$\text{On l'applique à } W_n = g(Z_n) - g(c) \xrightarrow{n \rightarrow \infty} 0$$

Appliqué au \boxed{M} & Bernoulli

$$\text{Voir } \frac{\bar{X}_m - \theta}{\sqrt{\bar{X}_m(1-\bar{X}_m)}} \xrightarrow[n \rightarrow \infty]{P_0 \text{ loi}} Z \text{ sur } \mathbb{R} \text{ et } Z \sim N(0,1).$$

$$P_0 \left(\theta \in \left[\bar{X}_m \pm \Phi^{-1}\left(1 - \frac{\alpha}{2}\right) \sqrt{\frac{\bar{X}_m(1-\bar{X}_m)}{m}} \right] \right) \xrightarrow[m \rightarrow \infty]{\rightarrow 1-\alpha}$$

\Rightarrow Pour Bernoulli : 5 \boxed{M} IDC

• **BT** $\hat{I}_m^{BT} = \left[\bar{X}_m - \frac{1}{2\sqrt{m}\sigma}, \bar{X}_m + \frac{1}{2\sqrt{m}\sigma} \right] \cap [0,1]$

• **Jeffreys** $\hat{I}_m^{J} = \left[\bar{X}_m - \sqrt{\frac{-1}{2m \ln \frac{\alpha}{2}}}, \bar{X}_m + \sqrt{\frac{1}{2m \ln \frac{\alpha}{2}}} \right] \cap [0,1]$

• **TIC** • 4 critères d'invariance

• majoration de la variance \Rightarrow réduire inégalité

$$\hat{I}_m^{TI} = \left[\bar{X}_m - \frac{\Phi^{-1}(1 - \frac{\alpha}{2})}{2\sqrt{m}}, \bar{X}_m + \frac{\Phi^{-1}(1 - \frac{\alpha}{2})}{2\sqrt{m}} \right]$$


• estimation de l'avarage

$$\hat{I}_m^E = \left[\bar{X}_m \pm \Phi^{-1}(1 - \frac{\alpha}{2}) \sqrt{\frac{\bar{X}_m(1 - \bar{X}_m)}{n}} \right]$$

⑨ Les particules des échantillons gaussiens

loi du Chi-deux

$(Z_i)_{1 \leq i \leq d}$ est une suite de ⑧ iid de loi $\mathcal{N}(0,1)$ alors la loi de $U_d = \sum_{i=1}^d Z_i^2 = \|Z\|^2$ où $Z = (Z_1, \dots, Z_d) \in \mathbb{R}^d$ est appelée loi du χ^2 à d degrés de liberté.



U_d est positive.

$$\mathbb{E}(U_d) = \sum_{i=1}^d \mathbb{E}(Z_i^2) = d$$

$$Z_i \sim \mathcal{N}(0,1), \quad \mathbb{E}(Z_i) = 0$$


$$\text{Var}(Z_i) = 1 = \mathbb{E}(Z_i^2)$$

$$\text{Var}(U_d) = \sum_{i=1}^d \text{Var}(Z_i) \quad \text{car les } (Z_i)_{1 \leq i \leq d} \text{ st. indép.}$$

$$\text{Var}(Z_i^2) = \mathbb{E}(Z_i^4) - \mathbb{E}(Z_i^2)^2 = 3 - 1 = 2.$$

~~Montrer~~ Soit $m \in \mathbb{N}^*$, $\mathbb{E}(Z^m)$, $i: Z \sim \mathcal{N}(0,1)$

$$\text{Var}(U_d) = dd$$



densité de U_d .

$$\begin{aligned} \text{densité } \mathbb{E}(\Psi(Z_i^2)) &= \int \Psi(z^2) \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz \\ &= 2 \int_0^\infty \Psi(z^2) \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} dz \\ &= \int_0^\infty \Psi(u) \frac{1}{\sqrt{2\pi u}} e^{-\frac{u}{2}} du \end{aligned}$$

(u = z², z = √u, $dz = \frac{1}{2\sqrt{u}} du$).

⑩ Ψ measurable borné: $\mathbb{E}[\Psi(z)] = \int \Psi(z) f_z(z) dz$.

$$f_z(x) = \frac{1}{\sqrt{2\pi n}} e^{-\frac{x^2}{2}} \mathbf{1}_{[0, \infty]}(x)$$

densité de U_d (de Z_i^2).


$$f_d(x) = \frac{1}{2^{d/2} \Gamma\left(\frac{d}{2}\right)} x^{\frac{d}{2}-1} e^{-\frac{x}{2}} \mathbf{1}_{[0, \infty]}(x)$$

$$\Gamma\left(\frac{d}{2}\right) = \int_0^\infty t^{\frac{d}{2}-1} e^{-t} dt$$

) par récurrence de $\Gamma(n+1)$

Loi de Student

$n \geq 2 \sim N(0,1)$ & $U_d \sim \chi^2(d)$
 & si Z & U_d st indépendantes alors la
 loi de $V_d = \frac{Z}{\sqrt{U_d}}$ est appellée loi de Student
 à d degrés de liberté



$$E(T_d) = 0, \quad \text{Var}(T_d) = \frac{d}{d-2}, \quad d \geq 2.$$

Th de Student

X_1, \dots, X_n iid de loi $N(\mu, \sigma^2)$

alors • $\bar{X}_n \sim N(\mu, \frac{\sigma^2}{n})$

cad $\frac{V_n}{\sigma} \sim N(0,1)$

• $\frac{n V_n}{\sigma^2} = \sum_{i=1}^n \frac{(X_i - \bar{X}_n)^2}{\sigma^2} \sim \chi^2(n-1)$

$$\bullet \quad \frac{\bar{X}_n - \mu}{\sqrt{\frac{\sigma^2}{n}}} \sim N(0,1), \quad V_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

$$V_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$$

(estimation sans biais de la variance).

RG3

• si $X_1 \sim N(\mu_1, \sigma_1^2)$ et $X_2 \sim N(\mu_2, \sigma_2^2)$,
 X_1, X_2 indépendants
 alors $X_1 + X_2 \sim N(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2)$.

Consequence : $X_1 + \dots + X_m \sim N(m\mu, m\sigma^2)$
 $\frac{1}{m}(X_1 + \dots + X_m) \sim N(\mu, \frac{\sigma^2}{m})$.

$$\bullet \sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 \sim \chi^2(n)$$

$$Z_i = \frac{(X_i - \mu)}{\sigma} \sim N(0,1)$$

\bar{X}_n & V_n st indép. On perd un deg de liberté en remplaçant μ par \bar{X}_n

88

Intervalles de confiance de niveau $1-\alpha$


• Pour la moyenne m

→ si variance σ^2 connue

$$\sqrt{n} \frac{\bar{X}_n - m}{\sigma} \sim N(0, 1)$$

Donc $P\left(\sqrt{n} \frac{|\bar{X}_n - m|}{\sigma} \leq \Phi^{-1}(1 - \frac{\alpha}{2})\right) = 1 - \alpha$

\hat{I}_m est FdR² de $N(0, 1)$.



$$\text{d'où } P_m(m \in [\bar{X}_n \pm \Phi^{-1}(1 - \frac{\alpha}{2}) \frac{\sigma}{\sqrt{n}}]) = 1 - \alpha$$

$$\hat{I}_m = \left[\bar{X}_n \pm \Phi^{-1}(1 - \frac{\alpha}{2}) \frac{\sigma}{\sqrt{n}} \right] = 1 - \alpha$$

→ à variance σ^2 inconnue


$\sqrt{n} \frac{\bar{X}_n - m}{\sigma} \sim t_{n-1}$ est int d'anc prem de niveau $1 - \alpha$.

$$\sqrt{n} \frac{\bar{X}_n - m}{\sqrt{V_n}} = \sqrt{n-1} \frac{\bar{X}_n - m}{\sqrt{V_n}} \sim \text{Student}(n-1)$$

$q_{n-1}(1 - \frac{\alpha}{2})$ le quantile d'ordre $1 - \frac{\alpha}{2}$ de la

loc de Student $(n-1)$ si $T_{n-1} \sim \text{Student}(n-1)$,

$$P(T_{n-1} \leq q_{n-1}(1 - \frac{\alpha}{2})) = 1 - \frac{\alpha}{2}.$$



• $f(m, \sigma^2) \in \mathbb{R} \times \mathbb{R}^+$,

$$P_{m, \sigma^2}\left(\sqrt{n} \frac{|\bar{X}_n - m|}{\sigma} \leq q_{n-1}(1 - \frac{\alpha}{2})\right) = 1 - \alpha.$$

$$P_{m, \sigma^2}\left(m \in \left[\bar{X}_n \pm q_{n-1}(1 - \frac{\alpha}{2}) \frac{\sigma}{\sqrt{n}}\right]\right) = 1 - \alpha.$$


$$\text{Donc } \hat{I}_m = \left[\bar{X}_n \pm q_{n-1}(1 - \frac{\alpha}{2}) \frac{\sigma}{\sqrt{n}} \right]$$

• Pour la variance σ^2

→ à moyenne m connue

Intervalle bilatéral

$$\sum_{i=1}^n \left(\frac{X_i - m}{\sigma} \right)^2 \sim \chi^2(n)$$



$$P_m(a_\alpha \leq \sum_{i=1}^n \left(\frac{X_i - m}{\sigma} \right)^2 \leq b_\alpha) = 1 - \alpha$$

→ a_α quantile d'ordre $\frac{\alpha}{2}$ de la loi $\chi^2(n)$

$$a_n(\frac{\alpha}{2}), \quad P(U_n \leq a_n(\frac{\alpha}{2})) = \frac{\alpha}{2}$$

où $U_n \sim \chi^2(n)$

→ b_α quantile d'ordre $1 - \frac{\alpha}{2}$ de la loi $\chi^2(n)$

$$b_n(1 - \frac{\alpha}{2})$$

$$\text{et } b_n(\frac{\alpha}{2}) \leq \sum_{i=1}^n \frac{(X_i - m)^2}{\sigma^2} \leq b_n(1 - \frac{\alpha}{2})$$

$$\Leftrightarrow \frac{\sum_{i=1}^n (x_i - m)^2}{c_m(1 - \frac{\alpha}{2})} \leq \sigma^2 \leq \frac{\sum_{i=1}^n (x_i - m)^2}{c_m(\frac{\alpha}{2})}$$

D'où l'intervalle de confiance σ^2 de niveau $1-\alpha$

$$\hat{I}_m = \left[\frac{\sum_{i=1}^n (x_i - m)^2}{c_m(1 - \frac{\alpha}{2})}, \frac{\sum_{i=1}^n (x_i - m)^2}{c_m(\frac{\alpha}{2})} \right]$$

Intervalle unilatéral

$$P_m(c_m(\alpha) < \frac{\sum_{i=1}^n (x_i - m)^2}{\sigma^2}) = 1 - \alpha$$

$$\Leftrightarrow P_m\left(\sigma^2 < \frac{\sum_{i=1}^n (x_i - m)^2}{c_m(\alpha)}\right) = 1 - \alpha$$

$$\hat{I}_m^{\text{uni}} = \left[0, \frac{\sum_{i=1}^n (x_i - m)^2}{c_m(\alpha)} \right].$$

→ a moyenne inconnue

$$\frac{mV_m}{\sigma^2} = \sum \frac{(x_i - \bar{x}_m)^2}{\sigma^2} \sim \chi^2(m-1) \text{ sous } P_m, \sigma^2$$

$$P_{m, \sigma^2}(\sigma^2 \in \left[\frac{\sum (x_i - \bar{x}_m)^2}{c_{m-1}(1 - \frac{\alpha}{2})}, \frac{\sum (x_i - \bar{x}_m)^2}{c_m(\frac{\alpha}{2})} \right]) = 1 - \alpha$$

$$P_{m, \sigma^2}(\sigma^2 \in \left[0, \frac{\sum (x_i - \bar{x}_m)^2}{c_{m-1}(\alpha)} \right]) = 1 - \alpha \quad \text{Int. unilat}$$


© Pour χ^2 , $m=10$, $\alpha = 5\%$.
 $c_m(\frac{\alpha}{2}) = 3,247$

$$P(U_{10} \geq 3,247) = 0,975$$


$$\Leftrightarrow P(U_{10} \leq 3,247) = 0,025$$

$$c_m(1 - \frac{\alpha}{2}) = 20,483$$

$$P(U_{10} \geq 20,483) = 0,025$$



ou $U_{10} \sim \chi^2(10)$



③

Simulations

OB: Simuler va ayant une certaine loi.

Outil de base: ordinateur "simule des réalisations de loi uniforme sur $[0,1]$ "


Générateur de nbr aléatoires ou pseudo aléatoires (voir article Jean-Paul Delaya : aleas du hasard informatique pour la science).

I / M Héberg pour simuler var basée sur l'inverse de la f d' R^D .

Soit X une var de F_{dR} F .

② Si F est bijective

2



$$U \sim U_{[0,1]}$$

④

Si $Y = F^{-1}(U) \Rightarrow X$ et Y ont la m^e loi.
En effet $\forall t \in \mathbb{R}$,

$$\mathbb{P}(Y \leq t) = \mathbb{P}(F^{-1}(U) \leq t) = \mathbb{P}(U \leq F(t))$$

$$= F(t)$$

$$\text{ou } F(t) \in [0,1]$$

Donc Y & X ont la m^e F_{dR} .

Exemple: loi de Cauchy

$$f(x) = \frac{1}{\pi(1+x^2)}$$

$$F(x) = \frac{1}{\pi} \arctan(x) + \frac{1}{2}$$

$$F(x) = y \Leftrightarrow \frac{1}{\pi} \arctan(x) + \frac{1}{2} = y$$


$$y \in]0, 1[$$

$$\Leftrightarrow \arctan(x) = \pi(y - \frac{1}{2})$$

$$\Leftrightarrow x = \tan(\pi(y - \frac{1}{2}))$$

$$x = \tan(\pi(U - \frac{1}{2}))$$

sont une loi de Cauchy.




② Inverse généralisé

On va construire l' inverse généralisé F^{-1}
de t.q $P(F^{-1}(U) \leq x) = P(U \leq F^{-1}(x))$

Preuve : $P(F^{-1}(U) \leq x) \stackrel{?}{=} P(U \leq F(x)) = F(x)$

ob Mq $\forall u \in]0,1[$, $u \leq F(x) \Leftrightarrow F^{-1}(u) \leq x$.
 $I_u = \{x \in \mathbb{R}, F(x) \geq u\}$, $F^{-1}(u) = \inf I_u$.

③ L'inverse généralisé d'un FdR F est def
 $\forall u \in]0,1[$, $F^{-1}(u) = \inf \{t \in \mathbb{R} \mid F(t) \geq u\}$.



$I_u \neq \emptyset$ car $\lim_{n \rightarrow \infty} F(n) = 1$.

I_u est un intervalle de la forme $[b, \infty[$ ou $]b, \infty[$.

En effet, si $x \in I_u$, $F(x) \geq u$ & si x' tel que $F(x') \geq F(x) \geq u$ alors $x' \in I_u$.
 F est ↑ $\Rightarrow [x, \infty[\subset I_u$.

$I_u \neq \mathbb{R}$ car $\lim_{n \rightarrow -\infty} F(n) = 0$

I_u est fermé : $\inf I_u \in I_u$.

soit $b = \inf I_u$, $\forall x > b : x \in I_u$ & $F(x) \geq u$.

soit $(x_n)_{n \in \mathbb{N}}$ une suite de I_u q. ① $x_n \rightarrow b$ ($x_n > b$).

$F(x_n) \geq u \Rightarrow F(b) \geq u \Rightarrow b \in I_u$

car F est cont à droite.

$I_a = [b, \infty[$, $b = F^{-1}(a)$

④ si F est cont & ST, on retrouve le résultat.
 On pt mq $F^{-1} \uparrow$ & F^{-1} est cont à gauche.

Th si U ~ Uniforme $[0,1]$ & si F^{-1} est l'inverse généralisé d'un FdR F alors $F^{-1}(U)$ a pr FdR F.

⑤

42

$C_{m-1}(x) \rightarrow$

$$b \in I_u, F(b) \geq u$$

$$\Leftrightarrow F(F(u)) \geq u.$$

& on a misé que $F(x) \geq u \Leftrightarrow x \in I_u$.
 $\Leftrightarrow x \geq b \Leftrightarrow x \geq F^{-1}(u)$

Consequence : $\forall a \in \mathbb{R}$

$$P(F^{-1}(U) \leq x) = P(U \leq F(x)) = F(x)$$

③ Exemples :


- Loi exponentielle: $\text{Exp}(a)$

$$F(t) = (1 - e^{-at}) \mathbf{1}_{[0, \infty]}(t)$$

$$F^{-1}(u) = -\frac{\ln(1-u)}{a}, u \in [0, 1]$$

$$F^{-1}(u) = -\frac{\ln(1-u)}{a} \sim \text{Exp}(a)$$

$$\text{ou } -\frac{\ln(u)}{a} \sim \text{Exp}(a)$$



(43)

• Loi de Weibull:

Fonction de survie :

$$S_{a,b,c}(u) = \exp\left(-\left(\frac{u-b}{c}\right)^a\right)$$

$X \sim \text{Weib}(a, b, c)$

$$\Leftrightarrow \frac{X-b}{c} \sim \underbrace{\text{Weib}(a, 0, 1)}_{Y_a}$$

$$Y_a = (-\ln U)^{1/a} \sim \text{Weib}(a, 0, 1).$$

$$\begin{matrix} x > b \\ \Leftrightarrow \\ b \geq 0, a > 0 \end{matrix}$$

$$\begin{matrix} z_a = b + c Y_a \\ \sim \text{Weib}(a, b, c) \end{matrix}$$

II / M spécifiques pour les urnes

① Lois discrètes à support fini


• Loi de Bernoulli

$n X \sim \text{Bern}(p)$ et $U \sim \text{Unif}([0, 1])$ alors

$$\mathbf{1}_{[0, p]}(U) \stackrel{\text{loi}}{=} X \text{ car si } Y = \mathbf{1}_{[0, p]}(U)$$

$$P(Y=1) = P(U \in [0, p]) = p.$$


(RQ) Inverse généralisée de la f de répartitio.




$$F^{-1}(u) = \mathbf{1}_{[1-p, 1]}(u) \sim \text{Bern}(p)$$

Généralisation: $X(\Omega) = \{x_m, m \in \mathbb{N}\}$

X prend nbtz ① de valeurs, $p_m = P(X=x_m)$ $\forall m \in \mathbb{N}^*$



$$\text{En posant } x_i = \sum_{k=1}^m p_k$$



$$\text{en posant } x_0 = 0.$$

$$J_{0,1} = \bigcup_{i=0}^{\infty} J_{x_i, x_{i+1}} \quad \text{car } \lim_{i \rightarrow \infty} x_i = 1 \Leftrightarrow \sum_{k=1}^{\infty} p_k = 1.$$

$$Y = \sum_{i=0}^{\infty} x_{i+1} \mathbf{1}_{J_{x_i, x_{i+1}}} (U)$$

$$P(Y = x_{i+1}) = P(U \in J_{x_i, x_{i+1}}) = x_{i+1} - x_i = p_{i+1}$$

$$\Rightarrow Y \sim X.$$

② Loi Binomiale (n, p) données.

si U_1, U_2, \dots, U_n iid de loi $Unif(J_{0,1})$.

alors on pose $Y_i = \mathbf{1}_{J_{0,p}}(U_i) \quad 1 \leq i \leq n$

$Y_i \sim \text{Bin}(p)$ & $(Y_i)_{1 \leq i \leq n}$ iid

$$\Rightarrow Y = \sum_{i=1}^n Y_i$$

$$Y = \sum_{i=1}^n Y_i = \sum_{i=1}^n \mathbf{1}_{J_{0,p}}(U_i) = \text{card}(\{i \in \{1, \dots, n\} \mid U_i \in J_{0,p}\})$$

$$Y \sim \text{Bin}(n, p)$$

③ Conséquence intéressante: $p \mapsto P_p(S_n \geq k)$ est ↗
si $S_n \sim \text{Bin}(n, p)$ sous P_p . $k \in \mathbb{N}$

Car sur (Ω, \mathcal{F}, P) si tel que on définit U_1, \dots, U_n :

$$P_p(S_n \geq k) = P_p\left(\sum_{i=1}^n \mathbf{1}_{J_{0,p}}(U_i) \geq k\right), \text{ et si } p \leq p' \text{ alors } \sum_{i=1}^n \mathbf{1}_{J_{0,p}}(U_i) \leq \sum_{i=1}^n \mathbf{1}_{J_{0,p'}}(U_i)$$

$$\text{alors } \left\{ \sum_{i=1}^n \mathbf{1}_{J_{0,p}}(U_i) \geq k \right\} \subset \left\{ \sum_{i=1}^n \mathbf{1}_{J_{0,p'}}(U_i) \geq k \right\}$$

$$\& de P_p\left(\sum \mathbf{1}_{J_{0,p}}(U_i) \geq k\right) \leq P_p \mathbf{1}_{J_{0,p}}(U_i) \geq k$$

$\Rightarrow P_p$ croissante en p .

49

L^oi multinomiale : $\text{mult}(n, p_1, \dots, p_d)$

Répartir en n boules \Leftrightarrow d'cases.

$N = (N_1, \dots, N_d) \sim \text{mult}(n, p_1, \dots, p_d)$ où

p_i : prob d'aller de i° cas, N_i : nbre boule de i° cas ($i \in \{1, \dots, d\}$)

$\sum N_i = n$, $X_k \in \{0, 1\}^d$ représente ($1 \leq k \leq n$) le n° de la case de l'arr^e à tirer de la $k-i^{\circ}$ boule.

$X_{ik}(w) = (0, 0, \dots, 0, \underset{j}{1}, 0, \dots, 0)$ d-uplet $\leftarrow X_k(w)$ proba j

alors $N = \sum_{k=1}^n X_k \in \mathbb{N}^d$, $e_i = (0, 0, \dots, 1, 0, \dots, 0)$

$\delta_k = \sum_{i=0}^{d-1} e_{i+1} \mathbf{1}_{[s_i, s_{i+1}[} (U_k)$ P où $s_i = \sum_{j=1}^i p_{ij}, s_0 = 0$.

On simule de $U_1, \dots, U_m \sim \text{Uniform}(0, 1)$

$N = \sum_{k=1}^n \sum_{i=0}^{d-1} e_{i+1} \mathbf{1}_{[s_i, s_{i+1}[} (U_k)$

Alors $N \sim \text{mult}(n, p_1, \dots, p_d)$.

③ L^oi de Poisson (Pois ($\theta > 0$)).

④ $X(\theta) = \text{IV}, P(X=k) = \frac{\theta^k}{k!} e^{-\theta}$.

⑤ si $(E_i)_{i \in \mathbb{N}^*}$ est une suite de ② de loi Exp de param θ , si l'on pose $S_n = E_1 + \dots + E_n$ alors $P(S_n \leq 1 \dots \leq S_{n+1}) = \frac{\theta^n}{n!} e^{-\theta}$ $\forall n \in \mathbb{N}^*$.

Preuve $P(S_n \leq 1 \dots \leq S_{n+1}) = \mathbb{E}(\mathbf{1}_{\{E_1 + \dots + E_n \leq S_{n+1}\}})$
 $= \mathbb{E}(\Psi(E_1, \dots, E_{n+1}))$

Une f compliquée.

Si X a pr densité f & est indep $\Rightarrow (X, Y)$ a pr
 Y a pr densité g densité sur \mathbb{R}^2 .

h tq $h(x, y) = f(x)g(y)$; Q vect^{RE} (E_1, \dots, E_{n+1}) a
 pr densité $f_{n+1}(x_1, \dots, x_{n+1}) = \prod_{i=1}^{n+1} f_0(x_i)$ sur \mathbb{R}^{n+1} .

si $f_0(n) = \theta e^{-\theta n} \mathbf{1}_{[0, \infty]}(n)$

$\Rightarrow f_{n+1}(x_1, \dots, x_{n+1}) = \theta^n e^{-\theta \sum_{i=1}^{n+1} x_i} \prod_{i=1}^{n+1} \mathbf{1}_{[0, \infty]}(x_i)$ (↑)

où $A_{n+1} = \{x_1, \dots, x_{n+1}\} \subset \mathbb{R}$

d'où $P(S_n \leq 1 \dots \leq S_{n+1})$

$$= \int_{\mathbb{R}^{m+2}} \mathbb{1}_{A_{m+1}}(x_1, \dots, x_{m+2}) f_{m+2}(x_1, \dots, x_{m+2}) dx_1 \dots dx_{m+2}$$

$$= \int_{A_{m+1}} f_{m+2}(x_1, \dots, x_{m+2}) dx_1 \dots dx_{m+2} = \int_{\Omega^m} e^{-\theta \sum_{i=1}^{m+1} x_i} \mathbb{1}_{(\mathbb{R}^+)^{m+2}}(x_1, \dots, x_{m+2}) dx_1 \dots dx_{m+2}$$

Chgt de var bijectif $y_1 = x_2, y_2 = x_1 + x_2, \dots, y_m = x_1 + \dots + x_m, y_{m+1} = x_1 + \dots + x_m + x_{m+2}$

$$= \int_{\Psi(A_{m+1})} \theta^m \cdot e^{-\theta y_{m+1}} \mathbb{1}_{(\mathbb{R}^+)^{m+1}}(y_1, y_2, \dots, y_{m+1}) dy_1 \dots dy_{m+1}$$

$$\text{et } \Psi(A_{m+1}) = \{(y_1, \dots, y_{m+1}) \in \mathbb{R}^{m+1} \mid y_{m+1} \leq 1, y_1 \geq 0\}$$

$$= \theta^m \int_{\mathbb{R}^{m+1}} \mathbb{1}_{\{(y_1, \dots, y_{m+1}) \in \mathbb{R}^{m+1} \mid 0 \leq y_1 \leq \dots \leq y_m \leq y_{m+1}\}} e^{-\theta y_{m+1}} dy_1 \dots dy_m dy_{m+1}$$

$$= \theta^m \int_{\mathbb{R}^m} \mathbb{1}_{B_m}(y_1, \dots, y_m) \cdot \mathbb{1}_{[0, \infty]}(y_{m+1}) e^{-\theta y_{m+1}} dy_1 \dots dy_m dy_{m+1}$$

où $B_m = \{(y_1, \dots, y_m) \in \mathbb{R}^m \mid 0 \leq y_1 \leq \dots \leq y_m \leq 1\}$ simplex

$$= \theta^m V_m(B_m) \int_0^1 e^{-\theta y_{m+1}} dy_{m+1} \quad \& \quad V_m(B_m) = \frac{1}{m!}$$

$m!$ simplexes en permutant (cf. exerc)



$$= \frac{\theta^m}{m!} e^{-\theta} \quad \leftarrow \text{valide pour } m=0 \text{ aussi}$$

$$\underline{\text{alors}} \quad P(X=m) = P(S_m \leq z < S_{m+1}).$$

$$\text{Or on peut définir } Y = \sum_{n=0}^{\infty} n \cdot \mathbb{1}_{\{S_n \leq z < S_{n+1}\}}$$

$$\text{ou on le appelle } S_m = E_1 + \dots + E_m$$

Algé de simulation

Simulation des $(E_i)_{i \in \mathbb{N}}$, $E_i = -\frac{1}{\theta} \ln(U_i) \sim \text{Exp}(\theta)$.

$$S_m \leq z < S_{m+1} \Leftrightarrow -\sum_{i=1}^m \frac{\ln(U_i)}{\theta} \leq z < -\sum_{i=1}^{m+1} \frac{\ln(U_i)}{\theta}$$

$$\Leftrightarrow \sum_{i=1}^{m+1} \ln(U_i) < -\theta \leq \sum_{i=1}^m \ln(U_i)$$

$$\Leftrightarrow \prod_{i=1}^{m+1} U_i < e^{-\theta} \leq \prod_{i=1}^m U_i$$

$$\text{de } Y = \inf \{k \in \mathbb{N} \mid \prod_{i=1}^{k+1} U_i < e^{-\theta}\}$$

Consequence: $f: \theta \rightarrow P_\theta(X \geq k)$ n'est pas borné

$$\text{En effet si } Y(\theta) = \inf \{k \in \mathbb{N} \mid \prod_{i=1}^{k+1} U_i < e^{-\theta}\}$$

$$P_\theta(X \geq k) = P_\theta(Y(\theta) \geq k).$$

$$\text{si } \theta < 0', \quad \{k \in \mathbb{N}, \prod_{i=1}^{k+1} U_i < e^{-\theta}\} \subset \{k \in \mathbb{N} \mid \prod_{i=1}^{k+1} U_i < e^{-\theta}\}$$

$$\Rightarrow \inf(2) \geq \inf(1) \quad \text{d'où la croissance rapide}$$

⚠ si $(U_i)_{i \in \mathbb{N}}$ suite de va iid de loi $\text{Unif}(0, 1)$

16) $M_q M_m = \prod_{i=1}^m U_i$ ⚡ pas vrai

④ Loi géométrique

$$Y = \inf \{ k \in \mathbb{N}^* \mid U_k \leq p \} \sim \text{Geom}(p)$$

Etudier monotonie de $\theta \mapsto P_\theta (X \geq k)$

si $X \sim \text{Geom}(\theta)$ alors P_θ .

Autre M de simulation

$$\text{Si } E \sim \text{Exp}(0) \Rightarrow \lfloor E \rfloor \sim \text{Geom}(1-e^{-\theta})$$

$$Y = \left\lceil \frac{\ln U}{\ln(1-p)} \right\rceil \sim \text{Geom}(p)$$

change de var
en param auton

⑤ Loi Gaussienne

M Bon-Mélanger

① si $U_1, \dots, U_2 \sim \text{Unif}([0,1])$ alors si

$$X = \sqrt{-2 \ln U_1} \cos(2\pi U_2) \quad Y = \sqrt{-2 \ln U_1} \sin(2\pi U_2) \Rightarrow (X, Y) \sim \mathcal{N}(0, J_\theta)$$

$$\Rightarrow X \sim \mathcal{N}(0, 1) \quad \text{et} \quad X, Y \text{ indép}$$

$$\begin{aligned} \text{NB } (x, y) &= g(u_1, u_2) \\ (u_1, u_2) &= g^{-1}(x, y) \end{aligned}$$

$$du_1 du_2 = J_{g^{-1}}(x, y) dx dy$$

$$\text{Preuve : } \mathbb{E}(\varphi(x, y)) = \int_{\mathbb{R}^2} \varphi(x, y) \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}} \frac{1}{\sqrt{2\pi}} e^{-\frac{y^2}{2}} dx dy$$

$$\text{ou } \mathbb{E}(\varphi(x, y)) = \mathbb{E}(\varphi \circ g(u_1, u_2)) \quad \text{donc}$$

$$= \int_{[0,1]^2} \varphi(\sqrt{-2 \ln U_1} \cos(2\pi U_2), \sqrt{-2 \ln U_1} \sin(2\pi U_2)) dU_1 dU_2$$

Reprendons la preuve :

② ça va bien

soit $\varphi : \mathbb{R}^2 \rightarrow \mathbb{R}$ mesurable bornée.

$$\text{OB : Mg } \mathbb{E}(\varphi(x, y)) = \int_{\mathbb{R}^2} \varphi(x, y) f(x, y) dx dy$$

$$\mathbb{E}[\varphi(x, y)] = \mathbb{E}\left[\varphi\left(\sqrt{-2 \ln U_1} \cos(2\pi U_2), \sqrt{-2 \ln U_1} \sin(2\pi U_2)\right)\right]$$

$$= \int_{[0,1]^2} \varphi(\sqrt{-2 \ln U_1} \cos(2\pi U_2), \sqrt{-2 \ln U_1} \sin(2\pi U_2)) dU_1 dU_2$$

$$= \int_{[0,1]^2} \varphi(g(u_1, u_2)) du_1 du_2 = \int_{\mathbb{R}^2 \setminus \{(0,0)\}} \varphi \circ g \circ g^{-1}(u, y) J_{g^{-1}}(u, y) du dy$$

où $g : [0,1]^2 \rightarrow \mathbb{R}^2 \setminus \{(0,0)\}$

$$(u_1, u_2) \mapsto (\sqrt{-2 \ln U_1} \cos(2\pi U_2), \sqrt{-2 \ln U_1} \sin(2\pi U_2))$$

g est un C^1 difféomorphisme. $J_{g^{-1}}(u, y) = \frac{1}{J_g(g^{-1}(u, y))}$

$$= \int_{\mathbb{R}^2} \varphi(x, y) \frac{1}{2\pi} e^{-\frac{1}{2}(x^2+y^2)}$$

④ P

III / Algorithme du rejet

Idee: On suppose qu'on sait simuler un certain vect^R aléatoire M . On va simuler plus M_1, \dots, M_n jusqu'à ce qu'une certaine condition soit réalisée
 $\Rightarrow M_T \sim T$ aléatoire et $M_T \sim \text{loi}$ qu'on cherche à simuler.


1) Simulation d'un vect^R aléatoire de loi uniforme

$$B \in \mathcal{B}(\mathbb{R}^d)$$

OB: Simuler un vect^R de loi unif sur B .
 On sait simuler des vect^Rs de loi uniforme sur $[0,1]^d$.

$$(U_1, \dots, U_d) \text{ où } U_i \sim \text{Unif}(\mathbb{R}^d)$$

$(U_i)_i$ iid.



Sur un paré qq :

$$\prod_{i=1}^d [a_i, b_i]$$

$$V_i = a_i + (b_i - a_i) U_i \sim \text{Unif}([a_i, b_i])$$

Principe:

soit $c \in \mathbb{Q}$ $B \subset C$ (B est borné on peut prendre un paré pour C) tq on suppose qu'on sait simuler une uniforme sur C

\Rightarrow on simule M_1, \dots, M_n des vect^Rs de loi uniforme sur C jusqu'à avoir un vect^R $M_i \in B$.
 $\Rightarrow M_T \sim \text{Unif}(B)$.

Prop:

soit $(M_n)_{n \in \mathbb{N}^*}$ une suite de vect^Rs aléa. à val^Rs de \mathbb{R}^d indépendants & de m^e loi μ .

soit $B \in \mathcal{B}(\mathbb{R}^d)$, $\mu(B) > 0$

$$\forall w \in \Omega, T(w) = \inf\{n \in \mathbb{N}^*, M_n(w) \in B\}.$$

On définit $M_T(w) = \begin{cases} M_{T(w)}(w) & \text{si } T(w) < \infty \\ 0 & \text{si } T(w) = \infty \end{cases}$

④ le vect^R aléat^R

alors a) $\mathbb{P}(T < \infty) = 1$ et si $T^1 = T \mathbf{1}_{\{T < \infty\}}$
 alors $T^1 \sim \text{Geom}(\mu(B))$.

b) M_T est un vecteur aléatoire de \mathbb{R}^d dont la loi
 ν est $\mu(A \cap B)$.
 i.e. $\forall A \in \mathcal{D}(\mathbb{R}^d), \nu(A) = \mathbb{P}(M_T \in A) = \frac{\mu(A \cap B)}{\mu(B)}$


Considérez :

si μ est la loi uniforme sur C alors
 $\nu(A) = \frac{\mu(A \cap B)}{\mu(B)} = \frac{\lambda_d(A \cap B \cap C)}{\lambda_d(B \cap C) / \lambda_d(C)}$
 $= \frac{\lambda_d(A \cap B)}{\lambda_d(B)}$ car $B \subset C \Rightarrow \nu$ est la loi uniforme sur B .

$\Rightarrow M_T \sim \text{Unif}(B)$ si $M_1, \dots, M_n \dots$ st iid $\text{Unif}(C)$
 et $T = \inf \{i \in \mathbb{N}^*, M_i \in B\}$.

@ $B = \{(x, y) \in \mathbb{R}^2, x^2 + y^2 \leq 1\}$.

$$M_i = (x_i, y_i)$$



$$\begin{aligned} M_1, \dots, M_n \\ \text{Unif}([-1, 1]^2) \\ T = \inf \{i \in \mathbb{N}^*, M_i \in B\} \\ = \inf \{i \in \mathbb{N}^*, x_i^2 + y_i^2 \leq 1\} \quad T \sim \text{Geo}(p) \end{aligned}$$

(4.9)

Rq $U_1 \sim \text{Unif}([0, 1])$, idem U_2 .

$$X = U_2 \cos(2\pi U_1) \quad Y = U_2 \sin(2\pi U_1)$$

Calculer la loi de (X, Y)

Preuve Prop:

• Mesurabilité de T & T'

$$\{T=k\} = \{\inf \{i \in \mathbb{N}^*, M_i \in B\} = k\}$$

$$= \bigcap_{i=1}^{k-1} \{M_i \notin B\} \cap \{M_k \in B\}.$$

$$= \bigcap_{i=1}^{k-1} M_i^{-1}(B^c) \cap M_k^{-1}(B) \in \mathcal{F} \text{ car les } (M_i) \text{ st vtrna aléa}$$

$$\mathbb{P}(T=k) = \mathbb{P}\left(\bigcap_{i=1}^{k-1} \{M_i \notin B\} \cap \{M_k \in B\}\right)$$

$$= \prod_{i=1}^{k-1} \mathbb{P}(M_i \notin B) \mathbb{P}(M_k \in B) \text{ P indépend des } (M_i) \text{ iid}$$

$\mathbb{P}(M_k \in B) = \mu(B)$ car μ est la loi de M_k

$$\Rightarrow \mathbb{P}(T=k) = \mu(B^c)^{k-1} \mu(B) = \mu(B)(1 - \mu(B))^{k-1}$$

$$= p^{(1-p)^{k-1}} \quad p = \mu(B).$$

$T \sim \text{Geo}(p)$

$$\{T' = 0\} = \{T = \infty\} = \bigcap_{i=1}^{\infty} \{M_i \notin B\}$$

$$= \{w \in \Omega : \exists k \in \mathbb{N}^* \text{ tq } T(w) = k \text{ & } M_k(w) \in A\}$$

$$= \bigcup_{k \in \mathbb{N}^*} \{T = k, M_k \in A\}$$

$$\{w \in \Omega : T(w) = k, M_k(w) \notin A\}$$

$$\{w \in \Omega, T(w) = k, M_k(w) \in A\} :$$

$$= \{w \in \Omega, M_1(w) \notin B, M_{k-1}(w) \notin B, M_k(w) \in B\}$$

$$\text{et } M_k(w) \in A\}$$

$$\bigcap_{i=1}^{\infty} \{M_i \notin B\} \subset \bigcap_{i=1}^n \{M_i \notin B\} \quad \forall n \in \mathbb{N}^*$$

$$P\left(\bigcap_{i=1}^{\infty} \{M_i \notin B\}\right) \leq P\left(\bigcap_{i=1}^n \{M_i \notin B\}\right)$$

$$= (\mu(B^c))^n \quad \forall n \in \mathbb{N}^*$$

$$\Rightarrow P\left(\bigcap_{i=1}^{\infty} \{M_i \notin B\}\right) = 0$$

al

$$P(T=T') = 1. \text{ & } T' \text{ est } \mathbb{N}^* \text{ ob } \mathbb{N} \text{ (finie)}$$

$$\text{& } T \text{ et } T' \text{ suivent } \text{Geo}(p) \quad p = \mu(B)$$

b) mesureabilité & loi de M_T , soit $A \in \mathcal{B}(\mathbb{R}^d)$

$$M_T^{-1}(A) = \{M_T \in A\} = \{w \in \Omega : M_T(w) \in A\}$$

$$= \{w \in \Omega : \exists k \in \mathbb{N}^* \text{ tq } T(w) = k \text{ & } M_k(w) \in A\}.$$

(58)

$$\bigcap_{i=1}^{\infty} \{M_i \notin B\} \cap \{M_k \in A \cap B\}$$

$$\text{or } k = \infty, M_\infty = 0$$

$$\{w \in \Omega : T(w) = \infty, M_\infty(w) \in A\}$$

$$= \begin{cases} \bigcap_{i=1}^{\infty} \{M_i \notin B\} & \text{si } 0 \in A \\ \emptyset & \text{si } 0 \notin A \end{cases}$$

$$\text{et } P(M_T \in A) = \sum_{k \in \mathbb{N}^*} P(T=k, M_k \in A)$$


$$= \sum_{k \in \mathbb{N}^*} P\left(\bigcap_{i=1}^{k-1} \{M_i \notin B\} \cap \{M_k \in A \cap B\}\right)$$

$$= \sum_{k=1}^{\infty} (\mu(B^c))^{k-1} \mu(A \cap B) = \frac{\mu(A \cap B)}{\mu(B)} = \mu(A|B).$$

2) Simuler la densité

Idée: Se servir de l'hypographie de la densité & appliquer la M précédente.
Densité f .

$$G = \{(x, y) \in \mathbb{R}^2, 0 \leq y \leq f(x)\}$$




Prop 1: si $(Z, Y) \sim U_{\text{hyp}}(G)$ alors
 Z a pr densité f .

$$\text{R} \quad \mathcal{I}_2(G) = 1.$$

Preuve: soit $A \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}(Z \in A) = \mathbb{P}(Z \in A, Y \in \mathbb{R}) = \mathbb{P}(Z, Y) \in A \times \mathbb{R})$$

$$= \frac{\mathbb{P}_Z(A \times \mathbb{R} \cap G)}{\mathcal{I}_2(G)} = \int_a^b f(t) dt$$



(57)

Prop 2: soit X une \mathbb{R} de densité g .

$$\text{Posons } M = (X, c \cdot g(X), U)$$

où $U \sim U_{[0,1]}$ indépendante de X alors

M suit une loi U_{hyp} sur $H = \{(x, y) \in \mathbb{R}^2, 0 \leq y \leq c g(x)\}$


Preuve: soit $\varphi: \mathbb{R}^2 \rightarrow \mathbb{R}$ mesurable bornée

$$\mathbb{E}[\varphi(M)] = \int_{\mathbb{R} \times [0,1]} \varphi(x, c \cdot g(x) u) g(x) dx du$$

$$= \int_{\mathbb{R}} \left(\int_0^2 \varphi(x, c \cdot g(x) u) c g(x) du \right) \frac{1}{c} dx$$

$$= \int_{\mathbb{R}} \int_0^2 \varphi(x, y) dy \frac{1}{c} dx \quad y = c g(x) u$$

$$= \iint_H \varphi(x, y) \frac{1}{c} dxdy \quad \text{où } c = \mathcal{I}_d(H)$$




$$\mathcal{I}_d(H) = c \int_{\mathbb{R}} g(x) dx.$$

$$= \iint_H \varphi(x, y) \frac{1}{c} \underbrace{\mathbf{1}_H(x, y)}_{\text{densité de }(X, Y)} dxdy$$

$$M \sim U_{\text{hyp}}(H)$$

Application: $(X_i)_{i \in \mathbb{N}^*}$ de densité g .
 (ii) liens $\text{Unif}(0,1)$.

$$M_i = (x_i, c g(x_i) U_i) \sim \text{Unif}(G) \quad (\text{p. prop})$$



On applique l'algorithme du rejet

$$T = \inf \{ i \in \mathbb{N}^* \mid M_i \in G \}$$

$$M_i = (x_i, c g(x_i) U_i) \in G \Leftrightarrow c g(x_i) U_i \leq f(x_i)$$

$$\rightarrow T = \inf \{ i \in \mathbb{N}^* \mid c g(x_i) \leq f(x_i) \}$$

alors $M_T \sim \text{Unif}(G) \Rightarrow X_T$ a p. densité f . (p. prop).

② Loi gamma

Loi de densité

$$f_{a,b}(t) = \frac{\beta^a}{\Gamma(a)} t^{a-1} e^{-bt} \mathbf{1}_{[0, \infty]}(t)$$



⑤ 2

Idée: g densité d'une loi de Weibull.
 $g_a(t) = a t^{a-1} e^{-ta} \mathbf{1}_{[0, \infty]}(t)$

Exemple d'application:

$$\bullet \text{ loi gamma: } f_a(t) = \frac{1}{\Gamma(a)} t^{a-1} e^{-t} \mathbf{1}_{[0, \infty]}(t)$$

$a < 1$ la non bornée, $f_a(t) \approx \frac{1}{\Gamma(a)} t^{a-1}$.

OBz appliquer M.T de Rejet, majora la p. de g_a où g_a est facile à simuler.

On use la loi de Weibull dont la densité est

$$g_a(t) = a t^{a-1} e^{-ta} \mathbf{1}_{[0, \infty]}(t)$$

$$\text{Sa } f \text{ de survie est } G_a(t) = e^{-ta} \mathbf{1}_{[0, \infty]}(t) + \mathbf{1}_{(-\infty, 0]}(t)$$

$$F_a(t) = 1 - e^{-ta}, \quad t \geq 0.$$

$$F_a(u)^{-1} = [-\ln(1-u)]^{1/a}, \quad \text{si } U \sim \text{Unif}(0,1)$$

$$\text{alors } F_a^{-1}(U) = [-\ln(1-u)]^{1/a} \text{ a p. densité } g_a$$

$$X = [-\ln(U)]^{1/a} \text{ a p. densité } g_a.$$

Trouver c tq $f_a(t) \leq c g_a(t) \quad \forall t \in \mathbb{R}$.

$$t > 0, \quad \frac{f_a(t)}{g_a(t)} = \frac{1}{a \Gamma(a)} e^{-t+t^a} = \frac{1}{a \Gamma(a)} e^{-t(1-t^{a-1})}$$

Le cas où on $t \in]0, \infty[$ est atteint

$$t_a = \left(\frac{1}{a}\right)^{\frac{1}{a-1}} \Rightarrow c_a = \frac{1}{\Gamma(a)} e^{-ta(1-t_a^{a-1})}$$

$$c_a = \frac{e^{a\frac{a}{a-1}(1-a)}}{\Gamma(a+1)} \quad (a \Gamma(a) = M(a+1))$$

Algorithm du Rejet:

On simule $X_i = (-\ln U_i)^{\frac{1}{a}}$
indép. $U_i \sim \text{Unif}([0,1])$.

On s'arrête à i_0 tq $c_a g_a(X_{i_0}) V_0 \leq f_a(X_{i_0})$
alors X_{i_0} a pr. densité f_a .

Autre exemple:

→ loi normale : $f(t) = \frac{1}{\sqrt{2\pi}} e^{-t^2/2}$

Majoyer (à constante près) f par la densité g d'une loi de Cauchy (qu'on sait simuler en inversant la fct).

3) Simulation d'une loi discrète :

On cherche à simuler Z de loi discrète sur \mathbb{N} et on note
 $f: \mathbb{N} \rightarrow \mathbb{R}$
 $k \mapsto f(k) = P(Z=k)$

On suppose que l'on sait simuler X de la discrète sur \mathbb{N} tq
 $g(k) = P(X=k)$; $0 \leq f(k) \leq c \cdot g(k)$, $c > 1$, $\forall k \in \mathbb{N}$

Prop: soit $(X_i)_{1 \leq i \leq n}$ une rv iid de densité g p à la mesure de comptage ($P_x = \sum_{k \in \mathbb{N}} g(k) S_k$) et $(U_i)_{i \in \mathbb{N}^*}$ une loi uniforme sur $[0,1]$ indépendante des $(X_i)_{i \in \mathbb{N}^*}$. alors si $T = \inf \{i \in \mathbb{N}^* \text{ tq } c \cdot g(X_i) U_i \leq f(X_i)\}$. X_T a pr. densité f p à la mesure de comptage sur \mathbb{N} .


Preuve: m chose que la loi à densité f_R p à \mathbb{R} (adapté)

(R) U_1 & U_2 2 rv ind. de loi $\text{Unif}([0,1])$

$$\begin{cases} X = U_1 \cos(2\pi U_2) \\ Y = U_1 \sin(2\pi U_2) \end{cases}$$

$$\mathcal{D} = \{(x,y) \in \mathbb{R}^2 : x^2 + y^2 \leq 1\}$$

MT de Box-Muller



1) $(x, y) \in D$ mais ne suit pas une loi uniforme
sur D .

$$\text{P}(X, Y) \in B(0, \epsilon) = \text{P}(U_1 \cos(2\pi U_2), U_1 \sin(2\pi U_2))$$

$$B(0, \epsilon) = \{(x^*, y^*) \in \mathbb{R}^2; x^* + y^* \leq \epsilon^2\}$$

$$= \text{P}(U_1 \in [0, \epsilon]) = \epsilon$$

Or si (X, Y) suivait une loi uniforme sur D ,
on aurait $\text{P}((X, Y) \in B(0, \epsilon)) = \frac{\lambda_2(B(0, \epsilon) \cap D)}{\lambda_2(D)}$

$$= \frac{\lambda_2(B(0, \epsilon))}{\lambda_2(D)} = \frac{\pi \epsilon^2}{\pi} = \frac{\pi \epsilon^2}{\pi}$$

2) Mg la densité de (X, Y) est $f(x, y) = \frac{1}{\pi \sqrt{x^2 + y^2}} \mathbf{1}_D(x, y)$

3) Trouver M de simulate de loi uniforme sur D :

$$\begin{cases} X = g(U_1) \cos(2\pi U_2) \\ Y = g(U_1) \sin(2\pi U_2) \end{cases} \text{ Trouver } g. \quad (54)$$

Correc du Partiel DS₁

Q^o de cours 12.

Ex 2 15: $n = 200$ personnes ds 2 sites Univ.

$S_m^{(1)}$: nbr de personnels RU Barrois
 $S_m^{(2)}$: Sully.

On cherche $P(S_m^{(1)} \leq N) \geq 0,9$

Si on met N places ds chq RU, l'évènent
 $A =$ "chq personnel trouve une place".

$$A = \{S_m^{(1)} \leq N\} \cap \{S_m^{(2)} \leq N\}$$

$$A^c = \{S_m^{(1)} > N\} \cup \{S_m^{(2)} > N\}.$$

$$P(A) \geq 0,9 \Leftrightarrow P(A^c) \leq 0,1.$$

$$\Leftrightarrow P(\{S_m^{(1)} > N\} \cup \{S_m^{(2)} > N\}) \leq 0,1,$$


si on choisit N tq $P(S_m^{(1)} > N) \leq 0,05$
et $P(S_m^{(2)} > N) \leq 0,05 \Rightarrow P(A^c) \leq 0,1$.

$$S_m^{(1)} + S_m^{(2)} = n.$$

$$P(S_m^{(2)} > N) = P(n - S_m^{(1)} > N) = P(S_m^{(1)} < n - N)$$

$$P(S_m^{(1)} > N) \leq 0,05, \quad P(S_m^{(1)} < n - N) \leq 0,05$$

$$S_m^{(1)} \sim Bin(n, \frac{1}{2}).$$



$$N = \frac{m}{2} + m\epsilon \quad (= 350 + 700\epsilon)$$

$$\textcircled{1} \Leftrightarrow \begin{cases} P(S_m^{(1)} > \frac{m}{2} + m\epsilon) \leq 0,05 \\ P(S_m^{(1)} < \frac{m}{2} - m\epsilon) \leq 0,05 \end{cases}$$

$$\Leftrightarrow P\left(\left|S_m^{(1)} - \frac{m}{2}\right| > m\epsilon\right) \leq 0,1.$$

Par Hoeffding,

$$P\left(\left|S_m^{(1)} - \frac{m}{2}\right| > m\epsilon\right) \leq e^{-2m\epsilon^2}$$

On cherche $\epsilon > 0$ tq $e^{-2m\epsilon^2} \leq 0,1$.

$$\epsilon \geq \sqrt{\frac{1}{2m} \ln(0,1/2)}$$

$$n=700 : \epsilon = 0,04626.$$

$$\underline{N = 383 = 350 + 700\epsilon}$$

(36)

2) Test: si θ est la proba de choisir Barrois

Ho: "— Sully" $\theta \leq \frac{1}{2}$

Hs: "Le RU Barrois est le préféré des personnels" $\theta > \frac{1}{2}$

$S_n^{(1)}$ est le nbr de personnels q vont à Barrois.

$$\mathcal{R}_0 = \{S_n^{(1)} \geq k\}.$$

où k est tq $\sup_{\theta \leq \frac{1}{2}} P_\theta(\mathcal{R}_0) \leq 0,05$

$$\text{or } \sup_{\theta \leq \frac{1}{2}} P_\theta(S_n^{(1)} \geq k) = P_{\frac{1}{2}}(S_n^{(1)} \geq k).$$

$$k = \min \{l \in \{0, \dots, n\} : P_{\frac{1}{2}}(S_n^{(1)} \geq l) \leq 0,05\}$$

Or $P_{\frac{1}{2}}(S_n^{(1)} \geq k) \leq 0,05$ conduit p. Hoeffding à $k = 383$.

$$\mathcal{R}_0 = \{S_{700}^{(1)} \geq 383\} \text{ or } S_{700}^{(1)}(10) = 399$$

$\Rightarrow 10 \in \mathcal{R}_0$ de on conclut que le Barrois est le RU préféré des personnels.

6. Ex3 "Les stats expliquées à mon chat"

p : proba d'opinion "oui"
 q : proba de répondre "oui" à l'issue du lancer
 $A =$ "le lancer tombe à 6".

2) $B =$ "répondre oui"

$$\begin{aligned} \mathbb{P}(B) &= q = \mathbb{P}(B|A) \cdot \mathbb{P}(A) + \mathbb{P}(B|A^c) \cdot \mathbb{P}(A^c) \\ &= p \frac{1}{6} + (1-p) \frac{5}{6} = \frac{5}{6} - \frac{2}{3} p. \end{aligned}$$

3) $(X_i)_{1 \leq i \leq n}, X_i \sim \text{Bern}(q)$

$$3) \hat{q}_m = \frac{1}{n} \sum_{i=1}^n X_i$$

sans biais $\mathbb{E}_p(\hat{q}_m) = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_p(X_i) = q$

faire constat: LFGN $\rightarrow \hat{q}_m \xrightarrow[m \rightarrow \infty]{\text{PP PS}} q$.

Rq quadratique

$$\begin{aligned} \mathbb{E}_p((\hat{q}_m - q)^2) &= \text{Var}_p(\hat{q}_m) = \frac{1}{n^2} \text{Var}_p\left(\sum_{i=1}^n X_i\right) \\ &= \frac{1}{n^2} \sum_{i=1}^n \text{Var}_p(X_i) = \frac{q(1-q)}{n}. \end{aligned}$$

57

$$4) q = \frac{5}{6} - \frac{2}{3} p \Leftrightarrow p = \frac{5}{4} - \frac{3}{2} q$$

$$\text{Empirique } \hat{q}_m = \frac{5}{4} - \frac{3}{2} \hat{q}_m$$

(RQ) \hat{q}_m n'est pas une moyenne empirique de la loi de Bernoulli.

$$\hat{q}_m = \frac{1}{n} \sum_{i=1}^n \left(\frac{5}{4} - \frac{3}{2} X_i \right) = \frac{1}{n} \sum_{i=1}^n Y_i$$

$$Y_i = \frac{5}{4} - \frac{3}{2} X_i$$

$$\begin{aligned} \mathbb{E}_p(\hat{q}_m) &= \frac{5}{4} - \frac{3}{2} \mathbb{E}_p(Y_i) = \frac{5}{4} - \frac{3}{2} \left(\frac{5}{6} - \frac{2}{3} q \right) = p \\ \text{donc } \underline{\text{sans biais}}. \end{aligned}$$

objectivement constant:

$$\begin{aligned} \hat{q}_m &\xrightarrow[n \rightarrow \infty]{\text{PP PS}} q \\ \Rightarrow \frac{5}{4} - \frac{3}{2} \hat{q}_m &\xrightarrow[n \rightarrow \infty]{\text{PP PS}} \frac{5}{4} - \frac{3}{2} q \end{aligned}$$

doit

$$\begin{aligned} \mathbb{E}_p((\hat{q}_m - p)^2) &= \mathbb{E}_p \left[\left(\frac{5}{4} - \frac{3}{2} \hat{q}_m - \left(\frac{5}{4} - \frac{3}{2} q \right) \right)^2 \right] \\ &= \mathbb{E}_p \left[\frac{9}{4} (\hat{q}_m - q)^2 \right] \\ &= \frac{9}{4} \frac{q(1-q)}{n}. \end{aligned}$$

H

F

5) Intervalle de confiance pour q à 90% , Appli Numér : $\hat{q}_{1000}(w) = 0,642$
 $m = 1000$ $\hat{q}^2_{1000}(w) = \frac{5}{4} - \frac{3}{2} \hat{q}_{1000}(w) = 0,287$.

$$\hat{q}_{1000}(w) = \frac{642}{1000} = 0,642.$$

$$\hat{I}_{1000}(w) = [0,228; 0,346].$$

$$P_p(|\hat{q}_n - q| > \varepsilon) \leq 2e^{-2n\varepsilon^2} \leq 0,1.$$

$$\text{On choisit } \varepsilon > 0 \text{ t.q. } \varepsilon \geq \sqrt{\frac{-1}{2n} \ln(\frac{1}{2})}$$

$$m = 1000, \varepsilon \geq 0,039.$$

Intervalle de confiance pour q à 90%

$$P_p(q \in [\hat{q}_{1000} - 0,039, \hat{q}_{1000} + 0,039]) \geq 0,9$$

$$\Leftrightarrow P_p\left(|\frac{5}{6} - \frac{2}{3}\hat{p}_n - \left(\frac{5}{6} - \frac{2}{3}\mu\right)| > \varepsilon\right) \leq 0,1.$$

$$\Leftrightarrow P_p\left(\frac{2}{3}|\hat{p}_n - \mu| > \varepsilon\right) \leq 0,1$$

$$\Leftrightarrow P_p(|\hat{p}_n - \mu| > \frac{3}{2}\varepsilon) \leq 0,1.$$

Intervalle de confiance pour p à 90%

$$P_p\left(p \in \underbrace{[\hat{p}_n - \frac{3}{2}\varepsilon, \hat{p}_n + \frac{3}{2}\varepsilon]}_{\hat{I}_m}\right) \geq 0,9$$

\hat{I}_m

⑤ Ex9
 $S_{m,a} = \sum_{i=1}^m \mathbb{1}_{\{X_i = a\}}$

1) $S_{m,a} \sim \text{Bin}(m, \frac{1-\theta}{2})$

$S_{m,b} \sim \text{Bin}(m, \frac{1}{2}), S_{m,c} \sim \text{Bin}(m, \frac{\theta}{2})$

$$P(S_{m,a}) + P(S_{m,b}) + P(S_{m,c}) = 1.$$

2) $\frac{1}{n} \sum S_{m,c}$ d'espérance 0 ⑥ P_θ pr rev d. cf. TD

3) $S_{m,a} + S_{m,b} + S_{m,c} = m$

on $\mathbb{1}_{\{X_i=a\}} + \mathbb{1}_{\{X_i=b\}} + \mathbb{1}_{\{X_i=c\}} = 1$

et $X_i \in \{a, b, c\}$

$$4) \sum_{n \in \mathbb{N}^*} P_\theta(S_{m,b} = n) < \infty \text{ car}$$

$$P(S_{m,b} = n) = P\left(\bigcap_{i=1}^n \{X_i = b\}\right) = \prod P(X_i = b)$$

$$5) \Omega' = \{\omega \in \Omega, \exists N(\omega) \in \mathbb{N}^*, \forall n \geq N(\omega), S_{m,a}(\omega) + S_{m,c}(\omega) > 0\}$$

$$\Omega'^c = \{\omega \in \Omega, \forall N \in \mathbb{N}^*, \exists n \geq N, S_{m,a}(\omega) + S_{m,c}(\omega) = 0\}$$

$$= \{\omega \in \Omega, \forall N \in \mathbb{N}^*, \exists n \geq N, \omega \in \{S_{m,a} + S_{m,c} = 0\}\}$$

$$= \bigcap_{N \in \mathbb{N}^*} \bigcup_{m \geq N} \{S_{m,a} + S_{m,c} = 0\} \xrightarrow{\text{utilise Borel-Cantelli}}$$

$$6) \text{ On } \{S_{m,a} + S_{m,c} = 0\} = \{S_{m,b} = m\}.$$

$$\begin{aligned} & \text{P(BC)}: \sum P_\theta(S_{m,a} + S_{m,c} = 0) < \infty \\ & \Rightarrow P_\theta(\Omega'^c) = 0 \Rightarrow P_\theta(\Omega') = 1. \end{aligned}$$

(59)

$$6) T_m(\omega) = \begin{cases} \frac{S_{m,c}(\omega)}{S_{m,a}(\omega) + S_{m,c}(\omega)} & \text{si } S_{m,a}(\omega) + S_{m,c}(\omega) > 0 \\ 0 & \text{sinon.} \end{cases}$$

$\Omega' \subset \Omega$, $\exists N(\omega) \in \mathbb{N}^*, \forall n \geq N(\omega)$,

$$T_m(\omega) = \frac{S_{m,c}(\omega)}{S_{m,a}(\omega) + S_{m,c}(\omega)}$$

$$\frac{S_{m,c}}{m} \xrightarrow[m \rightarrow \infty]{P_\theta \text{ ps}} \frac{\theta}{2} \text{ et } \frac{S_{m,a} + S_{m,c}}{m} \xrightarrow[m \rightarrow \infty]{P_\theta \text{ ps}} \frac{1}{2}$$

$$\exists \Omega_c \in \mathcal{F}^P, P_\theta(\Omega_c) = 1 \text{ tq } \forall \omega \in \Omega_c,$$

$$\frac{S_{m,c}(\omega)}{m} \xrightarrow[m \rightarrow \infty]{} \frac{\theta}{2}.$$

$$\exists \Omega_{a,c} \in \mathcal{F}^P, P_\theta(\Omega_{a,c}) = 1 \text{ tq}$$

$$\forall \omega \in \Omega_{a,c} \xrightarrow[m \rightarrow \infty]{S_{m,a}(\omega) + S_{m,c}(\omega)} \frac{1}{2}$$

de $\omega \in \Omega' \cap \Omega_a \cap \Omega_{a,c}$

$$T_m(\omega) = \frac{S_{m,c}}{m} \xrightarrow[\text{de proton } \omega]{(S_{m,a}(\omega) + S_{m,c}(\omega)) \xrightarrow[m \rightarrow \infty]{} \frac{1}{2}} = \frac{\theta}{2}$$

$$\begin{aligned}
 & V(\theta, x_1, \dots, x_m) = \prod_{i=1}^m P_\theta(X_i = x_i) \\
 & = \prod_{i=1}^m \left[\left(\frac{1-\theta}{2} \right)^{\mathbb{1}_{\{X_i=a\}}} \left(\frac{1}{2} \right)^{\mathbb{1}_{\{X_i=b\}}} \left(\frac{\theta}{2} \right)^{\mathbb{1}_{\{X_i=c\}}} \right] \\
 & = \left(\frac{1-\theta}{2} \right)^{\sum_{i=1}^m \mathbb{1}_{\{X_i=a\}}} \left(\frac{1}{2} \right)^{\sum_{i=1}^m \mathbb{1}_{\{X_i=b\}}} \left(\frac{\theta}{2} \right)^{\sum_{i=1}^m \mathbb{1}_{\{X_i=c\}}} \\
 & = \left(\frac{1-\theta}{2} \right)^{n_a} \left(\frac{1}{2} \right)^{n_b} \left(\frac{\theta}{2} \right)^{n_c}
 \end{aligned}$$

(60)

$$F_{a,b,c}' = f_{a,b,c} = \frac{d}{dx} (1 - e^{-\frac{x-a}{c}}) = \frac{d}{dx} (1 - e^{-\frac{(x-b)}{c}})^a = + \frac{a}{c} \frac{(x-b)^{a-1}}{e^{-\frac{(x-b)}{c}}}^a$$

$$= \frac{a}{c} (x-b)^{a-1} \left(\frac{(x-b)}{c} \right)^a = - \left(\frac{a}{c} \left(\frac{(x-b)}{c} \right)^{a-1} \right)$$

$$\frac{d}{dx} \left(- \left(\frac{(x-b)}{c} \right)^a \right) = - \frac{1}{c^a} \frac{d}{dx} (x-b)^a = - \frac{a}{c^a} (x-b)^{a-1}$$

Statistiques Mathématiques M66
TP n° 2

Nous utilisons dans ce TP les bibliothèques `numpy` et `matplotlib`. On fait donc figurer en en-tête de notre code

```
import numpy as np
import matplotlib.pyplot as plt
```

Exercice 1 - Simulation par inversion de la fonction de répartition Le but de cet exercice est d'illustrer la partie du cours sur la simulation de variables aléatoires. On suppose que l'on sait simuler des variables aléatoires de loi uniforme sur l'intervalle $[0, 1]$. En particulier, avec Python, le code suivant permet de simuler un vecteur de $n = 1000$ variables aléatoires indépendantes et de loi uniforme sur $[0, 1]$.

```
n = 1000
U = np.random.uniform(size=n)
```

Soit X une variable aléatoire réelle et $F(x) = P(X \leq x)$ sa fonction de répartition. On définit l'inverse généralisée de F par $F^{-1}(u) := \inf\{x \in \mathbb{R} : F(x) \geq u\}$ pour $u \in]0, 1[$. Si U est une variable de loi uniforme sur $[0, 1]$ alors

$$F^{-1}(U) \stackrel{\text{(loi)}}{=} X.$$

Nous avons donc une méthode pour simuler une variable aléatoire, si l'on sait inverser sa fonction de répartition. Donnons un exemple : la simulation d'une variable de loi exponentielle de paramètre égal à $a > 0$. Dans ce cas la variable aléatoire X a une densité

$$f(x) = ae^{-ax} 1_{[0, +\infty]}(x),$$

la fonction de répartition s'écrit

$$F(x) = (1 - e^{-ax}) 1_{[0, +\infty]}(x),$$

et pour $u \in [0, 1[$

$$F^{-1}(u) = -\frac{1}{a} \log(1 - u).$$

Le code suivant permet ainsi de simuler une variable aléatoire de loi exponentielle de paramètre égal à 1.

```
U = np.random.uniform()
X = - np.log(1 - U)
```

Si l'on veut simuler efficacement plusieurs variables aléatoires de loi exponentielle, on doit penser à utiliser des *vecteurs*. Par exemple le code suivant est celui d'une fonction qui prend en entrée `a` et `n`, et qui retourne un vecteur de `n` variables aléatoires indépendantes de loi exponentielle de paramètre égal à `a`.

```
def expo(a,n):
    U = np.random.uniform(size=n)
    X = - np.log(1-U)/a
    return(X)
```

Pour vérifier que nous simulons la loi souhaitée, on peut tracer l'histogramme d'un échantillon et lui superposer la densité de la loi exponentielle correspondante.

```
X = expo(1,1000)

plt.hist(X, bins= 20, density=True)

xx = np.linspace(0, np.max(X), 2**10)
plt.plot(xx, np.exp(-xx), 'r-')

plt.show()
```

1. Reprendre le code de simulation de variables exponentielles ci-dessus et tester différentes valeurs du paramètre a .
2. La loi de Gumbel de paramètres $b \in \mathbb{R}$ et $c > 0$ est la loi de sur \mathbb{R} de fonction de répartition

$$F_{b,c}(x) = \exp\left(-\exp\left(-\frac{x-b}{c}\right)\right).$$

Cette loi apparaît lorsque l'on étudie des maxima de variables aléatoires. Écrire une fonction `gumbel` qui les deux paramètres `b` et `c`, un entier `n` et qui retourne un vecteur de `n` variables aléatoires indépendantes qui suivent la loi de Gumbel de paramètres `b` et `c`. Vérifier votre fonction à l'aide d'histogrammes.

3. La loi de Weibull de paramètres $a > 0$, $b \geq 0$ et $c > 0$ est la loi sur \mathbb{R} de fonction de répartition

$$F_{a,b,c}(x) = \begin{cases} 1 - \exp\left(-\left(\frac{x-b}{c}\right)^a\right) & \text{si } x \geq b, \\ 0 & \text{sinon.} \end{cases}$$

Cette loi apparaît également lorsque l'on étudie des maximums de variables aléatoires. Écrire une fonction `weibull` qui prend en entrée les deux paramètres `a`, `b`, et `c`, un entier `n` et qui retourne un vecteur de `n` variables aléatoires indépendantes qui suivent la loi Weibull de paramètres `a`, `b`, et `c`. Vérifier votre fonction à l'aide d'histogrammes.

4. On souhaite simuler des variables aléatoires de densité

$$f(x) = \begin{cases} x & \text{si } x \in [0, 1], \\ 1/2 & \text{si } x \in]1, 2] \\ 0 & \text{sinon.} \end{cases}$$

$$F(t) = \int_{-\infty}^t \frac{1}{2} x^n dx = \frac{1}{2} \left[x^{n+1} \right]_{-\infty}^t = \frac{1}{2} t^{n+1}$$

Écrire une fonction **mixte** qui prend en entrée un entier n et qui retourne un vecteur de n variables aléatoires indépendantes de densité f . Vérifier votre fonction à l'aide d'histogrammes.

5. On définit la loi « double exponentielle » de paramètre $a > 0$ comme la loi sur \mathbb{R} de densité

$$\frac{P(X \leq 0)}{P(X \geq 0)} = \frac{1}{2}.$$

Écrire une fonction `double_exp` qui prend en entrée le paramètre a , un entier n et qui retourne un vecteur de n variables aléatoires indépendantes de loi double exponentielle de paramètre a . Vérifier votre fonction à l'aide d'un test.

6. Dans un exercice de TD, on s'intéressait à une variable aléatoire X de fonction de répartition

$$F_{a,b}(x) = \begin{cases} 1 - a \exp(-bx) & \text{si } x \geq 0, \\ 0 & \text{sinon,} \end{cases}$$

avec $a \in]0, 1[$ et $b \geq 0$. On avait alors vu qu'avec probabilité $1 - a$, $X = 0$ et avec probabilité a , X suit une loi exponentielle de paramètre égal à b . Cela implique que si U et V sont deux variables aléatoires de loi uniforme sur $[0, 1]$, alors

$$-\frac{1}{b} \log(1-U) \, 1_{[0,a]}(V) \stackrel{\text{(loi)}}{=} X.$$

Utiliser cette remarque pour écrire une fonction `pluvio` qui prend en entrée les deux paramètres `a` et `b`, un entier `n` et qui retourne un vecteur de `n` variables aléatoires indépendantes qui suivent la même loi que X . Vérifier votre fonction à l'aide d'histogrammes.

Exercice 2 - Méthode de Box Muller La fonction de répartition de la loi normale (centrée, réduite) n'admet pas d'inverse généralisée explicite. Différentes méthodes permettent de palier ce problème, celle de Box-Muller s'appuie sur la propriété suivante. Si X et Y sont deux variables indépendantes de même loi $\mathcal{N}(0, 1)$ et (R, θ) les coordonnées polaires de (X, Y) , alors R et θ sont deux variables aléatoires indépendantes et de lois respectives $\text{Exp}(1/2)$ et $\text{Unif}([0, 2\pi])$. On peut ainsi simuler R et θ .

En utilisant la méthode de Box-Muller, écrire une fonction `normal_BM` qui prend en entrée deux paramètres `mu` et `sigma`, un entier `n`, et qui retourne un vecteur de `n` variables aléatoires indépendantes de loi normale d'espérance `mu` et d'écart-type `sigma`. Vérifier votre fonction à l'aide d'histogrammes.

Exercice 3 - Méthode de Monte Carlo et réduction de variance La méthode de Monte Carlo permet de calculer des intégrales en utilisant l'aléatoire. Illustrons sur un exemple simple où l'on souhaite évaluer

$$F(t) = \int_{-\infty}^t \frac{1}{2} \mathbf{1}_{[1,2]}(x) dx = \frac{1}{2} \left(\int dx + \int \frac{1}{x} dx \right) = \frac{1}{2} t + \frac{1}{2} \ln(t+1)$$

4 Parmi les trois estimateurs précédents, lequel semble être le meilleur ?
 Estimer I à l'aide de l'estimateur I_{center} et donner l'intervalle de confiance de niveau 95% correspondant.

$$\text{Estimer } I \text{ à l'aide de l'estimateur } I_{\text{center}} = \frac{1}{n} \sum_{k=1}^n (e^{U_k} - U_k + 1/2).$$

Dans notre cas, on peut choisir $Z_k = U_k - 1/2$, et le nouvel estimateur Monte Carlo

$$\text{Var}(e^{U_k} - Z_k) \leq \text{Var}(e^{U_k}).$$

3 Variable de contrôle Il s'agit d'une variable centrale Z_k que l'on sait facilement simuler avec U_k et telle que
 Vraie variable de contrôle. Vraie variable centrale Z_k que l'on sait facilement
 niveau 95% correspondant.

$$\text{Estimer } I \text{ à l'aide de l'estimateur } I_{\text{ctrl}} = \frac{1}{n} \sum_{k=1}^n \frac{e^{U_k}}{e^{U_k} + e^{1-U_k}}.$$

unitaire sur $[0, 1]$. Le nouvelle estimateur Monte Carlo est alors donné par

La simulation. On remarque que $1 - U_k$ donne une autre variable aléatoire de loi est continue en temps de calcul. Il peut alors parfois être intéressant de « renverser » 2 Échantillonage anti-héritage Généralement, c'est l'opération de simulation qui succède de certaines de ces méthodes.
 ou parallèles de réduction de variance. La fin de l'exercice consiste en une présentation du nombre de simulations n ou trouver une méthode pour avoir un écart-type σ_n plus petit, de l'intervalle de confiance, donc du rapport σ_n/\sqrt{n} . Pour le rendre, on peut augmenter le corrépondant.

1. Estimer I à l'aide de l'estimateur I_n et donner l'intervalle de confiance de niveau 95% où σ_n est l'écart-type empirique de l'échantillon $(e^{U_k})_{1 \leq k \leq n}$.

$$\left[I_n - 1.96 \frac{\sqrt{n}}{\sigma_n}, I_n + 1.96 \frac{\sqrt{n}}{\sigma_n} \right]$$

On peut alors donner un intervalle de confiance de niveau 95% pour I

$$I_n = \frac{1}{n} \sum_{k=1}^n e^{U_k} \xrightarrow[n \rightarrow +\infty]{\text{P.s.}} I.$$

Si U suit une loi uniforme sur $[0, 1]$, alors $E(e^U) = I$, en déduit que si $(U_k)_{1 \leq k \leq n}$ sont des variables aléatoires indépendantes de loi uniforme sur $[0, 1]$, alors par la loi forte des grands nombres

H.66

Ex 1: $\{A_m\}_{m \in \mathbb{N}^*}$ suite d'événements
 (Ω, \mathcal{F}, P) . $\sum_{m \in \mathbb{N}^*} P(A_m) < \infty$

$$\Delta \quad P\left(\bigcup_{m=N}^{\infty} A_m\right) = \sum_{m=N}^{\infty} P(A_m)$$

$$P\left(\bigcup_{m=N}^{\infty} A_m\right) \leq \sum_{m=N}^{\infty} P(A_m) < \sum_{m=0}^{\infty} P(A_m) = 0$$


de ~~limite~~ $\lim_{N \rightarrow \infty}$ de limite nulle étant le reste d'une suite \textcircled{Q} .

$$\rightarrow C_m = \bigcup_{k=m}^{\infty} A_k \neq \emptyset$$

$$\text{d'où } 0 \leq P\left(\bigcup_{m=N}^{\infty} A_m\right) \leq \sum_{m=N}^{\infty} P(A_m) \xrightarrow{N \rightarrow \infty} 0$$

Passage à la limite.

$$P\left(\bigcap_{N \in \mathbb{N}^*} \bigcup_{m=N}^{\infty} A_m(\varepsilon)\right) = \lim_{N \rightarrow \infty} P\left(\bigcup_{m=N}^{\infty} A_m(\varepsilon)\right) \text{ or}$$



$$b) d \quad P\left(\bigcap_{N \in \mathbb{N}^*} \bigcup_{m=N}^{\infty} A_m\right) = 0$$

$$B_m = \bigcup_{k=m}^{\infty} A_k \rightarrow m \rightarrow, \quad P(B_N) = P\left(\bigcup_{m=1}^{\infty} A_m\right) \leq \sum_{m=1}^{\infty} P(A_m) < \infty$$

$$\text{Il s'en suit que } P\left(\bigcap_{m \in \mathbb{N}^*} B_N\right) = \lim_{m \in \mathbb{N}^*} P(B_N) = \lim_{m \in \mathbb{N}^*} P\left(\bigcup_{n=N}^{\infty} A_n\right) = 0$$

$$2) (\Omega, \mathcal{F}_0(P_0), \omega \in [0, 1])$$

$X_i \sim D(a, b)$ pour P_0

$$A_m(\varepsilon) = \{(x_1, \dots, x_m) \mid |x_m - a| \geq \varepsilon\}$$

$$a) \text{ signification } A(\varepsilon) = \bigcap_{N \in \mathbb{N}^*} \bigcup_{m=N}^{\infty} A_m(\varepsilon)$$

La moyenne empirique ~~s'approche~~ de a de ε ~~se rapproche~~ de a .

b) Mo

$$P_0(A(\varepsilon)) = 0 \quad \forall \varepsilon > 0$$

$$P\left(\bigcup_{m=N}^{\infty} A_m(\varepsilon)\right) \leq \sum_{m=N}^{\infty} P_0(A_m(\varepsilon)) = \sum_{m=N}^{\infty} P_0(|X_m - a| > \varepsilon)$$

$$\leq \sum_{m=N}^{\infty} 2e^{-2m\varepsilon^2} = 2e^{-2N^2} \frac{1}{1-e^{-2\varepsilon^2}} \xrightarrow{N \rightarrow \infty} 0$$

①

$\overline{X_m} \xrightarrow[m \rightarrow \infty]{\text{prob}} \theta$

$\lim_{m \rightarrow \infty} P_\theta(|\overline{X_m} - \theta| > \epsilon) = 0.$

Pris sur tout niveau $m \in \mathbb{N}$ $\sum_{n \in \mathbb{N}} P_\theta(|\overline{X_n} - \theta| > \epsilon) < \infty$.
On a mis à pris pris de b), cette que l'état majorité

$\overline{X_m} \xrightarrow[m \rightarrow \infty]{\text{prob}} \theta$

$\Rightarrow \overline{X_m} \xrightarrow[m \rightarrow \infty]{\text{P.s.}} \theta.$

$\sum_{n \in \mathbb{N}} P_\theta(|\overline{X_n} - \theta| > \epsilon) < \infty$

$\overline{X_m} \xrightarrow[m \rightarrow \infty]{\text{P.s.}} \theta \Rightarrow \overline{X_m} \xrightarrow[m \rightarrow \infty]{\text{prob}} \theta$

Ex 2: Soit $\theta \leftarrow \sigma$.

$X_i \sim \text{Bin}(n)$

$P_\theta(A(\epsilon)) = 0 \Rightarrow P_\theta\left(\bigcap_{N \in \mathbb{N}} \bigcup_{m=N}^{\infty} A_m(\epsilon)\right) = 0.$

$\Rightarrow \lim_{N \rightarrow \infty} P_\theta\left(\bigcup_{m=N}^{\infty} A_m(\epsilon)\right) = 0.$

$\xrightarrow[500 \times 200]{\text{soit } N=500} = 1 - P_\theta\left(\left|\frac{S}{3600} - \frac{1}{6}\right| \geq \frac{101}{3600}\right) \geq 1 - e^{-2 \times 3600 \left(\frac{101}{3600}\right)^2} \approx 0,993.$

Or $A_N(\epsilon) \subseteq \bigcup_{m=N}^{\infty} A_m(\epsilon) \Rightarrow P_\theta(A_N(\epsilon)) \leq P_\theta\left(\bigcup_{m=N}^{\infty} A_m(\epsilon)\right).$

\Rightarrow QED on pris sur $\lim_{N \rightarrow \infty} P_\theta(A_N(\epsilon)) = 0.$

$\xrightarrow[N \rightarrow \infty]{\text{soit } N=500}$

$-a \leq S \leq a$

$(S \geq a - 4 \times 200 > 500)$

$4 \times 200 \leq 500$

$P(S_n - \theta > \epsilon)$

$X_n = \frac{S_n}{m}, S_n = \sum X_i$

$\sum P(A_m(\epsilon)) < \infty$

iid: indépendant
identique
différents

$\#(A_m(\epsilon)) \leq 2e^{-3m\epsilon^2}$

$$2) \text{ IDC' } \varphi \text{ Hoeffding}$$

$$1-\alpha = 0,05.$$

$$\mathbb{P}(\bar{X}_m > \theta) \leq 1-\alpha ?$$

$$\mathbb{P}(|\bar{X}_m - \theta| > \epsilon) \leq 2e^{-2m\epsilon^2} \leq 0,05$$

$$e^{-2m\epsilon^2} \leq \frac{0,05}{2} : \quad \frac{-2m\epsilon^2 \cdot \ln(0,05)}{2m\epsilon^2} \geq \ln\left(\frac{0,05}{2}\right)$$

$$\alpha \epsilon^2 \geq \sqrt{\frac{1}{2m} \ln\left(\frac{0,05}{2}\right)}.$$

$$\hat{I}_m = \bar{X}_m - \sqrt{\frac{1}{2m} \ln\left(\frac{1}{0,05}\right)} \cdot \bar{X}_m + \sqrt{\frac{1}{2m} \ln\left(\frac{2}{0,05}\right)} \cdot \alpha \hat{J}_{11} \quad \text{oder}$$

$$\hat{I}_m = \bar{X}_m - 0,0226 \cdot \bar{X}_m + 0,0226 \cdot \frac{x}{3600} \quad \text{oder}$$

$$\bar{X}_m = \frac{1}{n} \sum_{i=1}^n X_i$$

Seit $\sigma \in \mathbb{J}_{0,1} \subset \text{on derde } \mathcal{H}$

$$\mathbb{P}_0(\mathcal{H}) \leq 0,05$$

$$\Leftrightarrow \mathbb{P}_0(|\bar{X}_m - \theta| > \epsilon) \leq 0,05$$

$$\Leftrightarrow 2e^{-200\epsilon^2} \leq 0,05.$$

$$\exists n \text{ Bsp., stets } 640 \rightarrow 6.$$

$$\mathcal{H}_0: \text{"die sqrt"} \frac{1}{6} \quad \mathcal{H}_1: \text{"d mod gr. 0 f. } \mathcal{G}'$$

$$\mathbb{P}(\text{amide } \mathcal{H}_1) \leq 0,05.$$

$$\mathbb{P}_{\mathcal{H}_0}(\text{amide } \mathcal{H}_1) \leq 0,05. \quad \text{da } \mathcal{H}_0 = \{k \mid k \geq 6\} \quad \text{und } \mathcal{H}_1 = \{k \mid k \leq 5\}$$

$$\text{die r.v. } k_0(\text{gr. } \mathcal{G} \geq k_0) \leq 0,05. \quad k_0 = \arg\min_{0 \leq k \leq m} \mathbb{P}_{\mathcal{H}_0}(k \geq k) \leq 2.$$

$$\left| \frac{\partial \mu}{\partial x} \right| \leq 1$$

$$\hat{B}_1 \hat{J}_{10}$$

$$\frac{640}{3600} \quad \text{OB}$$

$$n = 1$$

3) $H_0: \theta = \frac{1}{6}$ contre $H_1: \theta \neq \frac{1}{6}$. Pour k_2 :

$$R_{3600}^{0,05} = \left\{ S_{3600} \leq k_1^{0,05} \right\} \cup \left\{ S_{3600} \geq k_2^{0,05} \right\}.$$

on $k_1^{0,05}, k_2^{0,05}$ vérifient $P_{1/6}(R_{3600}^{0,05}) \leq 2$

$$\Rightarrow k_1^{0,05} = \max(k \mid P_{1/6}(S_{3600} \leq k) \leq 0,025)$$

$$k_2^{0,05} = \min(k \mid P_{1/6}(S_{3600} \geq k) \leq 0,025)$$

Pour le premier: $P_{1/6}(S_{3600} \leq k) \leq 0,025$ multiplie \downarrow pm-1

~~$\Leftrightarrow P_{1/6}\left(\frac{S_{3600}}{3600} - \frac{1}{6} \geq \frac{k+1}{3600} - \frac{1}{6}\right) \leq 0,025$~~

$$\Leftrightarrow P_{1/6}\left(\frac{S_{3600}}{3600} - \frac{1}{6} \geq \frac{-k+1}{3600} + \frac{1}{6}\right) \leq 0,975.$$

$$\Leftrightarrow e^{-7200} \left(\frac{\ln(2)}{3600} \right)^2 \leq 0,975$$

$$\frac{1}{6} - \frac{k}{3600}$$

$$\Leftrightarrow 600 - 360 \sqrt{\frac{\ln(2)}{7200}} > k$$

et $k=302$

$$k \geq 599 + 360 \sqrt{\ln(0,975)/7200}$$

④

$$(3) \quad (\Omega, \mathcal{F}(P_{\theta})_{\theta \in \mathcal{J}_{0,1}})$$

$$V(\theta, x_1, \dots, x_m) = \prod_{i=1}^m P_{\theta}(X_i = x_i)$$

$$\begin{aligned} 2) \quad \prod_{i=1}^m P_{\theta}(X_i = x_i) &= \prod_{i=1}^m \theta^{x_i} (1-\theta)^{1-x_i} \\ &= \theta^{\sum x_i} (1-\theta)^{m - \sum x_i} \\ &= \theta^{\sum x_i} (1-\theta)^{m - \sum x_i}. \end{aligned}$$

3) pour $\mu = \theta^2$.

$$\tilde{V}(\mu, x_1, \dots, x_m) = \sqrt[m]{\prod_{i=1}^m (1 - \sqrt{\mu})^{m - x_i}} = V(\theta, x_1, \dots, x_m)$$

4) L? Mo estima^{re} du maximum de vraisemblance

$$\begin{aligned} \text{de } \mu \text{ et } \hat{\mu}_n &= \arg \max_{\mu \in \mathbb{R}, 1 \leq i \leq n} \tilde{V}(\mu, x_1, \dots, x_n) \\ &= \arg \max_{\mu \in [0, 1]} \tilde{L}(\mu, x_1, \dots, x_n) \end{aligned}$$

$$= \bar{x}_m^2 \quad \text{ou} \quad \bar{x}_m = \frac{1}{n} \sum x_i.$$

$$P(X=x) = p^x (1-p)^{1-x}, \quad x \in \{0, 1\}$$

Estimat^R du max de l'ensemble de θ et $\hat{\theta}_n = \arg \max_{\theta} V(\theta, x_1, \dots, x_m)$.

On a $\arg \max_{\theta \in \mathcal{J}_{0,1}} (\tilde{f}(n)) = \arg \max_{\theta \in \mathcal{J}_{0,1}} (\ln(\tilde{f}(\theta)))$

$$\begin{aligned} \tilde{f}(\theta, x_1, \dots, x_m) &\stackrel{\text{ln}}{=} \left(\mu^{\sum x_i} (1 - \sqrt{\mu})^{m - \sum x_i} \right) \\ &= \frac{1}{2} \left(\sum x_i \right) \ln(\mu) + (m - \sum x_i) \cdot \ln(1 - \sqrt{\mu}). \end{aligned}$$

$$\text{On dérive en } \mu: \frac{\partial}{\partial \mu} \tilde{f}(\mu, x_1, \dots, x_m) = \frac{\sum x_i}{2\mu} + \frac{(m - \sum x_i)}{1 - \sqrt{\mu}}$$

Cette dérivée ^{est nulle} on cherche qd la dérivée s'annule
pour trouver le maximum.

$$\frac{1}{2\mu} (\sum x_i) + (m - \sum x_i) \frac{-\frac{1}{2\sqrt{\mu}}}{1 - \sqrt{\mu}} = 0$$

$$\Leftrightarrow \sum x_i - (m - \sum x_i) \frac{\mu}{\sqrt{\mu} - \mu} = 0$$

$$\Leftrightarrow \sum x_i - (m - \sum x_i) \frac{1}{\frac{1}{\sqrt{\mu}} - 1} = 0$$

$$\begin{aligned} \Leftrightarrow \frac{\sum x_i}{m - \sum x_i} &= \frac{1}{\frac{1}{\sqrt{\mu}} - 1} \Rightarrow \frac{\frac{1}{\sum x_i}}{m - \sum x_i} + 1 = \sqrt{\mu} \\ \Leftrightarrow \frac{1}{\sum x_i} &= \frac{1}{m - \sum x_i} \end{aligned}$$

(5)

$$\Leftrightarrow \frac{1}{n-\sum x_i + 1} = \sqrt{\mu} \Leftrightarrow \frac{\sum x_i}{n-\sum x_i + \sum x_i} = \sqrt{\mu}$$

$$\Leftrightarrow \frac{\sum x_i}{n} = \sqrt{\mu} \Leftrightarrow \mu = (\bar{x}_m)^2$$

6) Calculer $E_0(\bar{x}_m) = E_0\left(\left(\frac{1}{n} \sum x_i\right)^2\right)$

$$= \frac{1}{n^2} E_0\left(\left(\sum_{i=1}^n x_i\right)\left(\sum_{i=1}^n x_i\right)\right) = \frac{1}{n^2} E_0\left(\sum_{i=1}^n x_i^2 + \sum_{i=1}^n \sum_{k=1, k \neq i}^n x_i x_k\right)$$

$$= \frac{1}{n^2} \left(\sum_{i=1}^n E_0(x_i^2) + \sum_{i=1}^n E_0\left(\prod_{k=1, k \neq i}^n x_k\right) \right)$$

$$= \frac{1}{n^2} \left[\sum \sigma^2 + \sum \prod \sigma \right] = \frac{1}{n^2} [n\sigma^2 + n\sigma^{n-1}]$$

$$= \frac{\sigma^2 + \sigma^{n-1}}{n^2} = \frac{1 + \sigma^{\frac{n-1}{2}}}{n^2}$$

L'estimateur est sans biais si

$$E(\text{estimateur}) = \theta.$$

si n est pas sans biais.

montre

lim

$$\xrightarrow{n \rightarrow \infty}$$

$$\mu = \theta^2$$

7) Proposer un autre estimateur trivial de μ qui est sans biais.

$$\hat{\mu}_m = \frac{1}{n} \sum x_i$$

$$\Rightarrow E_0(\hat{\mu}_m) = \sqrt{\mu}$$

$$Var(\bar{x}_m) = E_0(\bar{x}_m) - E_0(\bar{x}_m)^2$$

$$E_0(\hat{\mu}_m) = Var_0(\bar{x}_m) + E_0(\bar{x}_m)^2$$

$$= \frac{\sigma(1-\theta)}{n} + \theta^2$$

$$\begin{aligned} (\sum x_i)^2 &= (\sum x_i)(\sum x_j) = \sum \sum x_i x_j \\ &= \sum x_i^2 + 2 \sum_{1 \leq i < j \leq n} x_i x_j \end{aligned}$$

C sans biais si
 $E(\text{estimateur}) = \theta$.

1) Faire l'amour vs Ménage

1) Modéliser, p.b.

$$\text{D}\sigma (\Omega, \mathcal{F}, P_0) \in \mathbb{R}_{+}^{[0,1]}$$

on définit la loi de Bernoulli indépendante indiquant (la proba) que celle qui un homme effectuant au moins 30% des

(TQ) d'avoir au moins \bar{q} RD/mois. ($X_i = 1$ si i^e h intangé)

$$\text{la loi } S_m = \sum_{i=1}^m X_i \text{ binomiale } N(\text{Dim}(S_m), q) \text{ avec } P_0.$$

La p.b est de savoir si $\bar{q} \leq 0,6$.

2) Déterminer si $\bar{q} \leq 0,6$. Faire test stat.

Il faut sélectionner les types H_0 & H_1 tq


$$H_0: \bar{q} \leq 0,6$$

y à justific.

$$H_1: \bar{q} > 0,6.$$

minimiser $P(H_1 \text{ conclue } H_0) \leftarrow$ conclure à tort
 H_0 alors que H_0 vraie.

3) Continuer test à niveau 5%.



1-2: fiabilité (E_1)

2: incertitude 0,5 %.

Zone de Rejet $R_m^2 = \{S_m \geq k\} \subseteq I$
 de telle sorte que $\sup_{\theta \in \Theta_0} P_\theta(S_m) \leq 2$,

$$k = \min \{ k \mid \sup_{\theta \in \Theta_0} P_\theta(S_m) \leq 2 \}$$

$$= \min \{ k \mid P_{0,05}(S_m \geq k) \leq 2 \}$$

$$P_{0,05}(S_m \geq k) \leq 0,05 \Leftrightarrow P_{0,05}(S_m > k+1) \leq 0,05$$

$$\Leftrightarrow 1 - P_{0,05}(S_m \leq k+1) \leq 0,05.$$

$$\Leftrightarrow 0,95 \leq P_{0,05}(S_m \leq k+1)$$

→ D'après la table, k + petit entier k+1 vérifiant cette inégalité est 569, soit $k_0 = 563$

On ne rejette pas H_0 . au $\underline{\text{TB}} \leq 563$.

Autre rao: $H_0: \theta > 0,6$

$H_1: \theta \leq 0,6$.

On avait déterminé k_α à stant

$$k_\alpha = \max \left\{ k \mid \sup_{\theta \in \Theta} P_\theta(S_m) \leq \alpha \right\}$$

$$= \max \left\{ k \mid \sup_{\theta \in \Theta} P_\theta(S_m \leq k_\alpha) \leq 0,05 \right\}$$

$$= 513$$

$513 \leq 515$ et on rejette H_0 .

atténuer
sup

→ Dans table: ^{user} Hoeffding.

$$P_\theta(S_m \leq k_\alpha) \leq 0,05$$

Asymétrie de la loi

$$P_\theta(-S_m > -k_\alpha) \leq 0,05$$

$$P_\theta(0,6 - \frac{S_m}{900} > 0,6 - \frac{k_\alpha}{900}) \leq 0,05$$

$$\Leftrightarrow e^{-1800 \left(0,6 - \frac{k_\alpha}{900}\right)^2} \leq 0,05$$

on cherche $\epsilon > 0$

$$S_m \leq k_\alpha$$

$$\frac{S_m}{m} - \theta > \epsilon$$

$$e^{k \frac{503}{900}} \leq e^{1800 \epsilon^2} \leq 0,05$$

$$\frac{503}{900} \leq \epsilon^2 \Rightarrow \epsilon \leq \sqrt{\frac{503}{900}}$$

1) **R^R** Consommation carburant. $P(\theta) = p$
1) R^R nombre pour estimer p (en judjant)

$$\text{Moyenne empirique } \hat{p} = \frac{1}{100} \sum_{i=1}^{100} \mathbb{1}_{\{Y_i \geq 73\}} \quad \text{et } n = 100$$

En effet $\hat{p} = \frac{1}{100} \sum_{i=1}^{100} \mathbb{1}_{\{Y_i \geq 73\}}$

$$\hat{p} = \frac{1}{100} \sum_{i=1}^{100} \mathbb{1}_{\{Y_i \geq 73\}}$$

$$1 \leq i \leq 100, Y_i = \mathbb{1}_{\{X_i \geq 73\}}$$

$$(Y_i)_{1 \leq i \leq 100} \text{ st indp, } Y_i \sim \text{Bern}(p)$$

$$\mathbb{E}_p(\hat{p}) = \frac{1}{100} \sum_{i=1}^{100} \mathbb{E}_p(Y_i) = p$$

$\Rightarrow \hat{p}$ est un estimat^R sans biais

$$P_\theta \theta - \mathbb{E}(\cdot) = 0.$$

$$\mathbb{E}(\text{estimat}^R) = g \Rightarrow \text{estimat}^R \text{ est sans biais}$$

2) On cherche un IdC au niveau 95%

M.p. On cherche ε tq $P_p(p \in \bar{I}) > 0,95$

$$p \in \bar{I} \Leftrightarrow |p - \bar{p}| \leq \varepsilon.$$

$$P_p(p \in \bar{I}) \geq 0,95 \Leftrightarrow P_p(|p - \bar{p}| \geq \varepsilon) \leq 0,05.$$

$$\Leftrightarrow P_p(|p - \bar{p}| \geq \varepsilon) \leq 2 \cdot e^{-n\varepsilon^2}$$

Il suffit $\varepsilon \geq 0$ tq $2 \cdot e^{-n\varepsilon^2} \leq 0,05$.

~~$$e^{2n\varepsilon^2} \leq \frac{1}{2} 905$$~~

$$2n\varepsilon^2 \leq \ln\left(\frac{1}{2} 905\right)$$

$$n\varepsilon^2 \geq \ln\left(\frac{2}{905}\right)$$

$$\varepsilon \geq \sqrt{\frac{1}{2n} \ln\left(\frac{2}{905}\right)}$$

$$\varepsilon \geq \sqrt{\frac{1}{200} \ln(40)}$$

et intervalles de confiance à 95% est

$$\Rightarrow \left[\bar{Y}_m \pm \sqrt{\frac{\ln 40}{200}} \right]_{0,1} []$$

$$S_m = \sum Y_i \sim \mathcal{D}_{\text{bin}}(n, p)$$

$\bar{Y}_m = \frac{1}{m} \sum Y_i$: estimateur moyen empirique (9)


1) $X \sim \dots$

(15)

$$X \sim \mathcal{D}_{\text{un}}(n, p)$$

Unbiais

$$\{7, 8, 9, 10\}$$



① zone de rejet : H_0 rejette / H_1 accepté.

2) Taille du test : $\sup_{\theta \in \Theta_0} P_\theta(R)$ i.e. $\Theta = \{0,5\}$

$$= P_{0,5}(R) = P_{0,5}(X > 6) = 1 - P(X \leq 6) \\ = 1 - 0,828 = 0,172$$

Puissance du test : conclude H_2 à raison.
 $P_{1,0}(R)$