

M-66 Pr: Castellan Gwanaëlle

TATISTIQUE MATHÉMATIQUE

Objectifs

1. avoir un premier aperçu de deux problématiques fondamentales en statistique : l'estimation et la prise de décision
2. pour l'estimation, apprendre à construire rigoureusement un intervalle de confiance
3. pour la prise de décision, découvrir le vocabulaire des tests d'hypothèses, savoir construire et interpréter quelques tests simples.

Statistiques

1. Simulation de variables aléatoires : simulation de variables aléatoires discrètes, inverse de la fonction de répartition, méthode du rejet
2. Estimation ; introduction du vocabulaire de l'estimation à partir du modèle de Bernoulli ; intervalles de confiance non asymptotiques.
3. Introduction à la notion de tests statistiques : vocabulaire des tests d'hypothèses (hypothèses, risque, région de rejet, puissance) ; test sur une probabilité inconnue dans le cadre du modèle de Bernoulli (test binomial) ; exemples de tests de comparaison d'échantillons appariés (test du signe) et non appariés (test des longueurs, test de la somme des rangs).
4. Application de la loi des grands nombres et du théorème de la limite centrale (TCL) aux intervalles de confiance et aux tests : rappel de la loi des grands nombres ; rappel du théorème de Moivre et énoncé du TCL ; intervalles de confiance asymptotiques ; propriétés des estimateurs, consistance et normalité asymptotique. Les 36h de TD comportent une dizaine d'heures de TD avec Python

$$P(|\bar{X} - \mu| \leq \alpha)$$

① Démarche statistique à t Bernoulli II / Modélisation

- Observés : n obser. x_1, \dots, x_n . On les modélise à réalisation de ω : $X_1(\omega) = x_1, \dots, X_n(\omega) = x_n$.
- Famille de probas. Les $(X_i)_{1 \leq i \leq n}$ st déf n espace probabilisable (Ω, \mathcal{F}) (& mesurables). On munit (Ω, \mathcal{F}) d'une famille de probabilités $(P_\theta)_{\theta \in \Theta}$.

Modèle statistique : $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ la loi seule des X_i ne suffit pas.

Loi des observés : pr avoir loi des observés (x_1, \dots, x_n) on a sondage $P_\theta(S_n = k) = \frac{\binom{n}{k} \theta^k (1-\theta)^{n-k}}{\binom{n}{k} \theta^k (1-\theta)^{n-k}}$ $S_n = \sum_{i=1}^n X_i$

(N individus, n interrogés) pas indep \Rightarrow rep. tsr. \Rightarrow permet d'avoir la loi de (X_1, \dots, X_n) .

Loi hypergéom \rightarrow loi binom. $\lim_{N \rightarrow \infty} P_\theta(S_n = k) = \binom{n}{k} \theta^k (1-\theta)^{n-k}$ $S_n \sim \text{Hypergéom}(n, N, \theta)$

2° modèle : TAR $(X_i)_{i \geq 1}$ indep, $X_i \sim \text{Bern}(\theta)$ $(P_\theta(S_n = k) = \binom{n}{k} \theta^k (1-\theta)^{n-k})$ $S_n \sim \text{Bin}(n, \theta)$ sous P_θ .

② Vers l'as (non ①) qd $n \rightarrow \infty$, $\Omega = \{0, 1\}^{\mathbb{N}}$ ens de ttes suites à val^{rs} de $\{0, 1\}$, \mathcal{F} ? P_θ sur (Ω, \mathcal{F}) pt 2 construit pr coincider 4 p. $\rightarrow (\Omega, \mathcal{F}, (P_\theta)_{\theta \in [0, 1]})$ d'un n -échantillon (X_1, \dots, X_n) tq $X_i \sim \text{Bern}(\theta)$ est appelé modèle de Bernoulli.

III / $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ d (X_1, \dots, X_n) le n échant. obtenu θ q observé de (X_1, \dots, X_n) ?

④ Estimation ① Un estimat^r de θ est f mesurable de (X_1, \dots, X_n) q ne dpt pas de θ .

\rightarrow Un estimat^r $\hat{\theta}_n$ de θ est ② : $\hat{\theta}_n = \varphi(X_1, \dots, X_n)$ où φ mesurable.

③ f mesurable si $f: (E_1, \mathcal{F}_1) \rightarrow (E_2, \mathcal{F}_2)$, $\forall B \in \mathcal{F}_2, f^{-1}(B) \in \mathcal{F}_1$.

• $\hat{\theta}_n(\omega)$ est le param θ q maximise $\theta \mapsto P_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n))$

• $\hat{\theta}_n$ est le param le plus vraisemblable.

Estimat^r & Interv^r de confiance

Généralisation : $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta, \Omega})$, X_1, \dots, X_n iid $\text{Bern}(\theta)$ sous P_θ . $\forall \theta \in [0, 1]$ $\forall (x_1, \dots, x_n) \in \{0, 1\}^n$, $\forall (\theta, x_1, \dots, x_n) = P_\theta((X_1, \dots, X_n) = (x_1, \dots, x_n)) = \theta^{\sum x_i} (1-\theta)^{n - \sum x_i}$ $V(\theta, x_1, \dots, x_n)$ f de vraisemblance. $\ln(V(\theta, x_1, \dots, x_n)) = \sum x_i \ln \theta + (n - \sum x_i) \ln(1-\theta)$ $\varphi'(\theta) = \frac{1}{\theta} \sum x_i - \frac{1}{1-\theta} n - \sum x_i$; $\varphi'(\theta) \geq 0 \Leftrightarrow \theta \leq \frac{\sum x_i}{n}$

Estimateur du max de vraisemblance : $\hat{\theta}_n = \arg \max_{\theta \in [0, 1]} V(\theta, x_1, \dots, x_n) = \frac{1}{n} \sum_{i=1}^n x_i$ $\Leftrightarrow V(\theta, x_1, \dots, x_n) \leq V(\hat{\theta}_n, x_1, \dots, x_n)$.

Moyenne Empirique $\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$ des (X_i) .

⑤ estimat^r ? \rightarrow est maximise vraisbl^e : le param le + vraisbl^e à la vue des observés x_1, \dots, x_n \rightarrow a bonne ppte $E_\theta(\bar{X}_n) = E_\theta(\frac{1}{n} \sum_{i=1}^n X_i) = \frac{1}{n} E_\theta(\sum_{i=1}^n X_i)$ $E_\theta(\bar{X}_n) = \theta$, \bar{X}_n est un estimat^r sans biais de θ . (+ n grd, + \bar{X}_n se rapproche θ)

Comment évaluer ⑤ de \bar{X}_n vers θ : évaluer $P_\theta(|\bar{X}_n - \theta| \geq \epsilon)$.

1) Bien-Aymé-Chebitch $P_\theta(|\bar{X}_n - \theta| \geq \epsilon) \leq \frac{\theta(1-\theta)}{n\epsilon^2} \leq \frac{1}{4n\epsilon^2}$

2) Moment d'ordre 4 $P_\theta(|\bar{X}_n - \theta| \geq \epsilon) \leq \frac{1}{4n^2\epsilon^4}$

3) Hoeffding (meille^r) $P_\theta(|\bar{X}_n - \theta| \geq \epsilon) \leq 2e^{-2n\epsilon^2}$ pr loi ⑥

⑥ Pr généraliser : \rightarrow ⑦ valable pr ⑧ de carré intégrable. \rightarrow ⑨ valable pr ⑩ bornée.

$\forall \epsilon > 0$, $\lim_{n \rightarrow \infty} P_\theta(|\bar{X}_n - \theta| \geq \epsilon) = 0$, on dit \bar{X}_n ⑪ vers θ sous P_θ , $\theta \in [0, 1]$, $\bar{X}_n \xrightarrow[n \rightarrow \infty]{\text{moka}} \theta$.

• CV ce simple ? $\bar{X}_n(\omega) \xrightarrow[n \rightarrow \infty]{} \theta \forall \omega \in \Omega$? $\Omega = \{0, 1\}^{\mathbb{N}}$ (as non ①)

\mathcal{F} , P tq E_i = "pile au i° lancer", $P_\theta(E_i) = \theta$ et les $(E_i)_{i \in \mathbb{N}^*}$ st indép^{ts}.

$X_i(\omega) = \omega_i$ si $\omega = (\omega_m)_{m \in \mathbb{N}^*} \in \Omega$ (résultat du i° lancer)

$P_\theta(X_i = 1) = P_\theta(E_i) = \theta = 1 - P_\theta(X_i = 0)$, $X_i \sim \text{Bern}(\theta)$ et $(X_i)_{i \geq 1}$ indep.

④ M66 stat^s $\bar{X}_n(\omega) \xrightarrow[n \rightarrow \infty]{} \theta$ n'est pas vraie $\forall \omega \in \Omega$

@ $\omega = (0, \dots, 0, \dots)$ $\bar{X}_m(\omega) = 0$ et $\omega = (1, \dots, 1, \dots)$ $\bar{X}_m(\omega) = 1$
 $\exists \Omega' \in \mathcal{F}$, $P_\theta(\Omega') = 1$, $\forall \omega \in \Omega'$, $\bar{X}_m(\omega) \xrightarrow{m \rightarrow \infty} \theta$

DM $\Omega' = \{\omega \in \Omega, \lim_{m \rightarrow \infty} \bar{X}_m(\omega) = \theta\}$

$\lim_{m \rightarrow \infty} \bar{X}_m(\omega) = \theta$, $\forall \varepsilon > 0$, $\exists m \in \mathbb{N}^*$, $\forall p \geq m$,

$|\bar{X}_p(\omega) - \theta| \leq \varepsilon$, se traduit en termes d'événements :

$A_p(\varepsilon) = \{\omega \in \Omega, |\bar{X}_p(\omega) - \theta| \leq \varepsilon\} = \{|\bar{X}_p - \theta| \leq \varepsilon\} \Rightarrow P_\theta(\bigcap_{m \in \mathbb{N}^*} B_m(\varepsilon)) = \lim_{m \rightarrow \infty} P_\theta(B_m(\varepsilon))$

$\rightarrow \omega \in \Omega'$ si $\forall \varepsilon > 0$, $\exists m \in \mathbb{N}^*$ $\forall p \geq m$, $\omega \in A_p(\varepsilon)$

si $\forall \varepsilon > 0$, $\omega \in \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\varepsilon)$

si $\omega \in \bigcap_{\varepsilon > 0} \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\varepsilon)$

Rq On se ramène à une intersection @ en mq

$\bigcap_{\varepsilon > 0} A(\varepsilon) = \bigcap_{m \in \mathbb{N}^*} A\left(\frac{1}{m}\right)$

en notant $A(\varepsilon) = \bigcup_{m \in \mathbb{N}^*} \bigcap_{p \geq m} A_p(\varepsilon)$

On va mq $P_\theta(\Omega'^c) = 0$

$\Omega'^c = \bigcup_{\varepsilon > 0} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon) = \bigcup_{m \in \mathbb{N}^*} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c\left(\frac{1}{m}\right)$

(2)

On mq $P_\theta\left(\bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon)\right) = 0 \quad \forall \varepsilon > 0$ (*)

$P_\theta(A_p^c(\varepsilon)) = P_\theta(|\bar{X}_p - \theta| > \varepsilon) \leq 2e^{-2p\varepsilon^2} \xrightarrow{m \rightarrow \infty} 0$

$B_m(\varepsilon) = \bigcup_{p \geq m} A_p^c(\varepsilon)$, la suite $(B_m(\varepsilon))$ est \downarrow :

$B_{m+1}(\varepsilon) \subset B_m(\varepsilon) = A_m^c(\varepsilon) \cup B_{m+1}(\varepsilon)$

$\Rightarrow P_\theta(\bigcap_{m \in \mathbb{N}^*} B_m(\varepsilon)) = \lim_{m \rightarrow \infty} P_\theta(B_m(\varepsilon))$

$P_\theta(B_m(\varepsilon)) = P_\theta\left(\bigcup_{p \geq m} A_p^c(\varepsilon)\right) \leq \sum_{p=m}^{\infty} P_\theta(A_p^c(\varepsilon))$

Hoeffding : $P_\theta(B_m(\varepsilon)) \leq \sum_{p=m}^{\infty} 2e^{-2p\varepsilon^2} = 2 \frac{e^{-2m\varepsilon^2}}{1 - e^{-2\varepsilon^2}}$

Reste d'une série @, $\lim_{m \rightarrow \infty} P_\theta(B_m(\varepsilon)) = 0 \Rightarrow$ on a (*)

$\Omega'^c = \bigcup_{m \in \mathbb{N}^*} \bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon)$, $P_\theta(\Omega'^c) \leq \sum_{m \in \mathbb{N}^*} P_\theta(\bigcap_{m \in \mathbb{N}^*} \bigcup_{p \geq m} A_p^c(\varepsilon))$

$\Rightarrow P_\theta(\Omega') = 1$

Qd $\exists \Omega' \in \mathcal{F}$, $P_\theta(\Omega') = 1$, $\forall \omega \in \Omega'$, $\lim_{m \rightarrow \infty} \bar{X}_m(\omega) = \theta$

On dit que \bar{X}_m @, presque sûrement vers θ .

Rq \bar{X}_m @ p.s. vers $\theta \Rightarrow \bar{X}_m$ @ en proba vers θ .

\bar{X}_m @ en proba vers θ

$\Rightarrow \bar{X}_m$ @ p.s. vers θ .

$\sum_{m \in \mathbb{N}^*} P_\theta(|\bar{X}_m - \theta| > \varepsilon) < \infty$

- Risque quadratique: $E_0((\bar{X}_n - \theta)^2) = \text{Var}(\bar{X}_n)$
 $= \text{Var}_0\left(\frac{1}{n} \sum X_i\right) = \frac{1}{n^2} \text{Var}_0(\sum X_i) = \frac{1}{n^2} \sum \text{Var}_0(X_i)$
 par indep des (X_i) $= \frac{1}{n^2} n \theta (1-\theta) = \frac{\theta(1-\theta)}{n}$

Un IdC est intervalle aléat. où se trouve vrai param inconnu
se gde proba.

• \square de Bernoulli

$$\boxed{BT} \quad P_{\theta}(|\bar{X}_n - \theta| \geq \epsilon) \leq \frac{1}{4n\epsilon^2} \Leftrightarrow P_{\theta}(\theta \notin [\bar{X}_n - \epsilon, \bar{X}_n + \epsilon])$$
$$\hat{I}_m^\alpha = \int \bar{x}_m - \frac{1}{2\sqrt{m\alpha}}, \bar{x}_m + \frac{1}{2\sqrt{m\alpha}} [0, 1]$$
$$P_{\theta}(\theta \in \hat{I}_m^2) \geq 1 - \alpha.$$

H $P_{\theta}(|\bar{X}_m - \theta| \geq \epsilon) \leq 2e^{-2m\epsilon^2}$, il suffit de prendre $\epsilon = \epsilon(n, m)$ tq

$$2e^{-2m\epsilon^2} \leq \alpha \Leftrightarrow \epsilon \geq \sqrt{\frac{1}{2m} \ln \frac{2}{\alpha}}$$

$$\hat{I}_m^2 = \left[\bar{x}_m - \sqrt{\frac{1}{2n} \ln \frac{2}{\alpha}}, \bar{x}_m + \sqrt{\frac{1}{2n} \ln \frac{2}{\alpha}} \right] \cap]0, 1[$$

③

@ on a $n=10$, IdC de niveau 90%, $\alpha=10\%$
 $\bar{X}_{10}(20) = \frac{3}{10}$, $\hat{I}_{10}^{10\%} =]0; 0,8[$; $\hat{I}_{10}^{\hat{10}\%} =]0; 0,687[$

$$n=1000, \alpha=10\% \quad (B) \frac{1}{2\sqrt{\ln 2}} = \frac{1}{20} = 0.05 \quad (R) \sqrt{\frac{1}{3m} \ln \frac{e}{\alpha}} = 0.0387.$$

IV / tests stat
 @ médicament : on teste mvs H_0^t or H_0^{tt} mvs H_0^t est-il mvt^R?
 Exemple : H_0^t est mvt^R alors q ce n'est pas le cas. Ex: H_0^t m^t pas mvt^R \Rightarrow applot.

On ne pourra pas minimiser les ϵ en \mathbb{R} : on privilégie \mathbb{E}_s .

Orienté le choix (dysymétrique) des types :

H_0 : hypo nulle (hypo d défaut) | H_1 : hypo alternative.

→ Le test H_0 contre H_1 est const^t dsq la proba de se tromper
qd on conclut H_1 est faible & contrôlée.

@ H_0 : "tt⁺ m' est ps mill^k" | H_1 : "tt⁺ est mail^k"

↳ chr dissymétriq, dépend pt de vue : @ confinement.

θ_0 : proba question d'ancien H^t (comm) / θ : -- " (in comm)

@ m'ides, on vt tester $H_0: \theta \leq \theta_0$ contra $H_1: \theta > \theta_0$, à la
vue de l'observat^r X_1, \dots, X_m (i.i.d de n pat. au mod θ)
 X_1, \dots, X_m i.i.d Bern(θ): $X_i = \begin{cases} 1 & \text{si } i^{\text{o}} \text{ pat guérit} \\ 0 & \text{sinon} \end{cases}$

θ_0 known, or a estimate \bar{X}_m
 θ_0 known \Rightarrow Comment conclude H_1 ?

"Réponse naïve" si $\bar{x}_m > \theta_0$.

(pb) On veut contrôler proba de se tromper P_{H_0} ("conclure H_1 ")

Erreur: $\sup_{\theta \leq \theta_0} P_{\theta}(\bar{X}_n \geq \theta_0) = P_{\theta_0}(\bar{X}_n \geq \theta_0)$
 $= P_{\theta_0}(\sum_{i=1}^n X_i \geq n\theta_0) \approx \frac{1}{2}$

car la médiane d'une $\text{Bin}(n, \theta_0)$ est $\lfloor n\theta_0 \rfloor$ ou $\lfloor n\theta_0 + 1 \rfloor$.

→ On se donne une marge d'erreurs $\alpha \in]0, 1[$, appelé niveau de test. On cherche un seuil t_α

tq on conclut H_1 si $\bar{X}_n \geq t_\alpha$. (\bar{X}_n suffisamment grand θ_0)

dsq $\sup_{\theta \leq \theta_0} P_{\theta}(\bar{X}_n \geq t_\alpha) \leq \alpha$.

→ Zone de rejet: $R_n^\alpha = \{\bar{X}_n \geq t_\alpha\}$ (event en tq l'on rejette H_0 , on conclut H_1)

Règle de décision: Si on observe $\bar{X}_n(w) \geq t_\alpha$ alors on rejette H_0 (à err^r contrôlée $\leq \alpha$) sinon on ne rejette pas H_0 . (mais l'err^r n'est pas contrôlée).

Généralisation: $(\Omega, \mathcal{F}^n(P_\theta)_{\theta \in \Theta})$, $\Theta =]0, 1[$ (Bernoulli)

X_1, \dots, X_n iid $\text{Bern}(\theta)$.

$\Theta_0 \subset \Theta$, $\Theta_1 \subset \Theta$, $\Theta_0 \cap \Theta_1 = \emptyset$.

(D) Construire un test de H_0 contre H_1 au niv^o α , c'est construire une zone de rejet (f de X_1, \dots, X_n) R_n^α tq $\sup_{\theta \in \Theta_0} P_{\theta}(R_n^\alpha) \leq \alpha$.

Règle de décision:

→ si $w \in R_n^\alpha \Rightarrow$ on conclut H_1 .

→ si $w \notin R_n^\alpha \Rightarrow$ on ne rejette pas H_0 .

t_α ? p-value ou $\mathbb{E}[P]$ ou $\mathbb{P} \cdot \mathbb{Q}$ lin.

(4)

Vocab: taille du test $\sup_{\theta \in \Theta_0} P_{\theta}(R_n^\alpha)$

Erreur de 1^{re} espèce (E_1): conclure H_1 à tort

" " (E_0): " " H_0 " " si $\theta \in \Theta_1$, $\beta(\theta) = P_{\theta}(R_n^\alpha)$

Proba de conclure H_0 à tort: $\sup_{\theta \in \Theta_1} P_{\theta}(R_n^\alpha)$

Puissance du test: proba conclure H_1 à raison. si $\theta \in \Theta_1$, $\pi(\theta) = P_{\theta}(R_n^\alpha) = 1 - \beta(\theta)$.

f puissance $\Theta_1 \rightarrow \mathbb{R}$
 $\theta \mapsto P_{\theta}(R_n^\alpha)$

Test convergent: si $\forall \theta \in \Theta_1$, $\lim_{n \rightarrow \infty} P_{\theta}(R_n^\alpha) = 1$

Test sans biais: si $\forall \theta \in \Theta_1$, $\pi(\theta) > \alpha$ ou $\forall \theta \in \Theta_1$, $1 - \beta(\theta) > \alpha \Leftrightarrow \beta(\theta) < 1 - \alpha \Leftrightarrow \beta = \sup_{\theta \in \Theta_0} \beta(\theta) \leq 1 - \alpha$

→ Voir exemples (croisem^t de fleurs) (hypo simple)

(R9) Une va X est dite stochastiq^t + grd qu'une va Y si $\forall x \in \mathbb{R}$: $F_X(x) \leq F_Y(x)$

(R9) si on \searrow niv^o $\alpha \Rightarrow$ puissance $\nearrow \Leftrightarrow E_2 \nearrow$ (hypo multiple: @ médicament)

si $S_n \sim \text{Bin}(n, \theta)$ vs $H_0 \Rightarrow \theta \mapsto P_{\theta}(S_n \geq k) \nearrow$ si $\theta \nearrow$

↳ [H1] mq $f(\theta) \geq 0$ où $f(\theta) = P_{\theta}(S_n \geq k) = \sum_{i=k}^n \binom{n}{i} \theta^i (1-\theta)^{n-i}$

↳ [H2] simuler loi binom & U va uniforme sur $]0, 1[$

→ U on: $X = 1\{U \leq \theta\}$, $P(X=1) = P(U \leq \theta) = \theta$
 loi de Bern: $P(X=0) = 1 - \theta$

Hypothèse simple: Θ_0 ou Θ_1 st singletons.

Test unilatéral: $H_0: \theta = \theta_0$ Zone de Rejet: $R_n^\alpha = \{S_n > k_\alpha\}$
 $H_1: \theta = \theta_1$ où k_α vérifie $P_{\theta_0}(S_n > k_\alpha) \leq \alpha$.

$$k_\alpha = \operatorname{argmin}_{0 \leq k \leq n} \{P_{\theta_0}(S_n \geq k) \leq \alpha\}.$$

Test bilatéral: $H_0: \theta = \theta_0$ | $R_n^\alpha = \{S_n \leq k_\alpha^1\} \cup \{S_n \geq k_\alpha^2\}$ tq $\sup_{\theta \in \Theta_0} P_\theta(R_n) \leq \alpha$
 $H_1: \theta \neq \theta_0$

k_α^1, k_α^2 vérifient $P_{\theta_0}(\{S_n \leq k_\alpha^1\} \cup \{S_n \geq k_\alpha^2\}) \leq \alpha$.

$$k_\alpha^1 = \max(k \mid P_{\theta_0}(S_n \leq k) \leq \frac{\alpha}{2})$$

$$k_\alpha^2 = \min(k \mid P_{\theta_0}(S_n \geq k) \leq \frac{\alpha}{2})$$

$$H_0: \theta \leq \theta_0$$

$$H_1: \theta > \theta_0 : k_\alpha = \min_{\theta \leq \theta_0} \{k \mid \sup P_\theta(S_n \geq k) \leq \alpha\}$$

$$\bar{X}_n \xrightarrow[n \rightarrow \infty]{\text{probab}} \theta \quad \forall \varepsilon > 0 \quad \lim_{n \rightarrow \infty} P(|\bar{X}_n - \theta| \geq \varepsilon) = 0$$

$$\begin{cases} \bar{X}_n \xrightarrow[n \rightarrow \infty]{\text{probab}} \theta \\ \sum_{n \in \mathbb{N}} P(|\bar{X}_n - \theta| \geq \varepsilon) < \infty \end{cases} \Rightarrow \bar{X}_n \xrightarrow[n \rightarrow \infty]{\text{p.s.}} \theta$$

Estimateur sans biais si $E(\bar{X}_n) = \theta$ sous θ .
 Puissance du test: conclure H_1 à raison.

$$B_m = \bigcup_{k=m}^{\infty} A_k \searrow, \quad C_m = \bigcap_{k=m}^{\infty} A_k \nearrow$$

de limite nulle
 étant le reste d'une
 suite (C.V.).

$$P\left(\bigcup_{m=N}^{\infty} A_m\right) = \sum_{m=N}^{\infty} P(A_m); \quad P\left(\bigcap_{m=N}^{\infty} A_m\right) \leq \sum_{m=N}^{\infty} P(A_m) \leq \sum_{m=0}^{\infty} P(A_m) = 0$$

$$\sum_{n=0}^N q = q \frac{1-q^{N+1}}{1-q}, \quad \sum_{n=0}^{\infty} q = \frac{1}{1-q} \times q_0$$

Ce Généraliser

I / Modéliser

• **Modèle statistique**: $(\Omega, \mathcal{F}, (P_\theta)_{\theta \in \Theta})$ où
 (Ω, \mathcal{F}) : espace probabilisable, $(P_\theta)_{\theta \in \Theta}$ famille de probas sur l'espace.
 $\rightarrow \Theta$ espace de param, qqs $\Theta \subset \mathbb{R}^d \Rightarrow$ stat un param.

• **Observables**: (X_1, \dots, X_n) un n échantillon de la loi P_θ
 sous P_θ (loi commune des $(X_i)_{1 \leq i \leq n}$); va. i.i.d.
 \Rightarrow OB estimer θ sous $g(\theta)$ & tester, \Rightarrow outils: raisonnement.

II / Raisonnement

① **Lois discrètes**: P_θ la loi de X_1 sous P_θ , spps discrète.

$$\text{soit } \mathcal{B} \quad P_\theta(X \in \mathcal{B}) = 1$$

au plus ①

(taille N inconnue)

② **2 exemples** \rightarrow Capture / Recapture: OB estimer p^θ poissons du lac.

capture \rightarrow Démarche: on pêche 20 poissons \rightarrow marqués & on les remet au lac.

recapture \rightarrow pêche 50 & on compte mbr de poissons marqués.

Modéliser: $(\Omega, \mathcal{F}, (P_p)_{p \in]0,1[})$, $p = \frac{20}{N}$: proba pêcher poisson marqué.

X_1, \dots, X_{50} i.i.d. $\text{Bern}(p)$
 $X_i = \begin{cases} 1 & \text{si } i^\circ \text{ poisson pêché est marqué} \\ 0 & \text{sinon} \end{cases}$

$$P_p(S_{50}=4) = \binom{50}{4} p^4 (1-p)^{46}$$

Idee pe estimer p : choisir $\hat{p}(w)$ q maximise p ,

$p \in]0,1[$: $P_p(S_{50}=4)$. (en dérivant $p \in]0,1[$):

$$\hat{p}(w) = \underset{p \in]0,1[}{\operatorname{argmax}} P_p(S_{50}=4) = \frac{4}{50} = \frac{S_{50}(w)}{50} \quad (5)$$

le q correspond à une estimation de N , $\hat{N}(w) = \frac{20}{\hat{p}(w)} = 250$

+ général^t, si on observe $S_{50}(w)=s \Rightarrow \underset{p \in]0,1[}{\operatorname{argmax}} L(p,s) = \frac{s}{50}$.

$$\text{où } L(p,s) = P_p(S_{50}=s) = \binom{50}{s} p^s (1-p)^{50-s}$$

$$\hat{p} = \frac{S_{50}}{50} \quad \& \quad \hat{N} = \frac{1000}{S_{50}}$$

\rightarrow Loi géom: Modélise mbr cycles avt tomber encinte. θ proba (TE) un mois donné.

X va = mbr cycles pe (TE) . $P_\theta(X=k) = \theta(1-\theta)^{k-1}$, $X \in \mathbb{N}^*$,

cf H0: mbr cycles/mbr ps. On ne dispose pas données indi $(X_i)_{1 \leq i \leq 100}$ mais de $(N_k)_{1 \leq k \leq 13}$: $N_k = \sum_{i=1}^{100} \mathbb{1}_{\{X_i=k\}} = \sum_{i=1}^{100} \mathbb{1}_{\{X_i \geq 12k\}}$

Comment estimer θ ?

$$\rightarrow P_\theta(X_1=1) = \theta, \quad \hat{\theta}_1 = \frac{1}{100} \sum_{i=1}^{100} \mathbb{1}_{\{X_i=1\}}$$

$$E_\theta(\hat{\theta}_1) = \frac{1}{100} \sum_{i=1}^{100} P_\theta(X_i=1) = \theta \quad (*) \text{ car } \hat{\theta}_1 \text{ est estimat sans biais de } \theta.$$

$$\frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{X_i=1\}} \xrightarrow[n \rightarrow \infty]{P_\theta \neq 1} \theta, \quad \hat{\theta}_1(w) = \frac{39}{100}$$

De fait \rightarrow n'utilise pas ttes données, $E_\theta(X_1) = \frac{1}{\theta} \Leftrightarrow$

\Rightarrow la moyenne empirique des observables $\theta = 1/E_\theta(X_1)$.
 peut être un bon candidat.

\rightarrow Comment pe cette moyenne empirique? (supra 3° donne)

$$\hat{\theta}_2 = \frac{93}{100} = \frac{100 - N_{13}}{100} = \frac{\sum_{i=1}^{100} \mathbb{1}_{\{X_i \leq 12\}}}{\sum_{i=1}^{100} X_i \mathbb{1}_{\{X_i \leq 12\}}}$$