

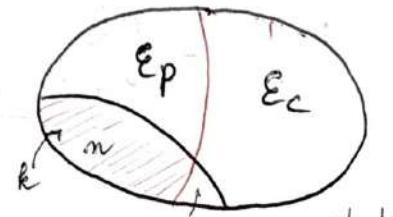
TD - M66

Statistique

(à l'instant précis. Probabilités discrètes)

Ex 1
Sondage

1) Loi de $X_{m,N}$?



Sondage de n individus parmi N

{ espace de probabilité

$$\Omega = \{(w_1, \dots, w_n) : w_i \in \{0, 1\}, 1 \leq i \leq n\}$$

$X_{m,N}$ (ra) représentant le nbr de "pour" parmi les n individus

► $P(\Omega)$

► $P(\{w_1, \dots, w_n\})$???

(i)

$\Omega = \{A \subset \{1, \dots, n\}, \text{card}(A) = m\} \rightarrow$ ensemble des parties de $\{1, \dots, N\}$ à m élts.

enfin

$$\text{card}(\Omega) = C_N^m \quad P(\Omega) = P(\Omega) \quad \text{P équiproba}$$

→ Tableau: $P(\Omega)$

au bien

de Ω , munie de l'équiprobabilité.

$$\Omega = \{(w_1, \dots, w_n) \in \{0, 1\}^n, w_1 < \dots < w_m\}$$

(l'ordre dans lequel on ne compte pas). Les personnes ont été interrogées

$$E = \{1, \dots, N\} = E_p \cup E_c$$

(ii) $X_{m,N} : \Omega \rightarrow \mathbb{R}$

$$A \mapsto \text{card}(A \cap E_p)$$

$$X_{m,N}(A) = \text{card}(A \cap E_p)$$

$$E_p = \{1, \dots, d_N\}$$

$$\forall (w_1, \dots, w_n) \in \Omega$$

$$X_{m,N}(w) = \text{card} \{i \in \{1, \dots, n\}, w_i \leq d_N\}$$

⇒ $X_{m,N}$ (ra) discrète à valeurs de $\{0, \dots, m\}$.

$$P(X_{m,N} = k) = P(\{A \in \Omega, X_{m,N}(A) = k\})$$

$$P(X_{m,N} = k) = \frac{\binom{d_N}{k} \times \binom{n-k}{N-d_N}}{\binom{n}{m}}$$

Loi hypergéométrique $H(m, N, d_N)$

NB

Si on voulait prendre en compte l'ordre dans lequel on interroge les individus:

$$\Omega = \{(w_1, \dots, w_n) \in \{0, 1\}^n, w_i \neq w_j \text{ pr } i \neq j\}$$

$$\text{card}(\Omega) = A_N^m = \frac{N!}{(N-m)!} = N(N-1)\dots(N-m+1)$$

avec $w_1 < \dots < w_m$

1245

$$2) \text{ On suppose } \frac{d_N}{N} = p + \varepsilon(N), \quad \underset{N \rightarrow \infty}{\longrightarrow} 0$$

$\hookrightarrow \text{CR}, \quad 0 < p < 1$

$\lim_{N \rightarrow \infty} P(X_{m,N} = k) \quad \& \quad k \text{ fixé. Supposons!}$
 $0 \leq k \leq m$

$$P(X_{m,N} = k) = \frac{d_N!}{k!(d_N-k)!} \times \frac{(N-d_N)!}{(m-k)!(N-d_N-m+k)!}$$

$$\times \frac{\frac{N!}{m!(N-m)!}}{}$$

$$= \frac{m!}{k!(m-k)!} \times \frac{d_N!}{(d_N-k)!} \times \frac{(N-d_N)!}{(N-d_N+m-k)!}$$

$\begin{array}{c} \text{Suite 1} \\ \text{de } k \text{ termes} \end{array} \quad \begin{array}{c} \text{Suite 2} \\ \text{de } m-k \text{ termes} \end{array}$

$$= \binom{k}{m} \cdot \frac{d_N(d_N-1)\dots(d_N-k+1)}{N(N-1)\dots(N-m+1)}$$

k termes $\approx (m-k)$ termes

m termes

$$= \binom{k}{m} \cdot \frac{\prod_{i=0}^{k-1} (d_N-i) \cdot \prod_{i=0}^{m-k-1} (N-d_N-i)}{\prod_{i=0}^{m-1} (N-i)}$$

$\begin{array}{c} p^k \\ \downarrow \\ \text{ne bouge pas si } N \end{array} \quad \begin{array}{c} (1-p)^{m-k} \\ \downarrow \\ N \rightarrow \infty \rightarrow 1 \end{array}$

$$\Rightarrow \lim_{N \rightarrow \infty} P(X_{m,N} = k) = \binom{k}{m} p^k (1-p)^{m-k}$$

$$= P(X_m = k) \text{ si } X_m \sim \text{Bin}(m,p)$$

Moralité! Un tirage sans remise $(X_{m,N})$ de une source "infinité" équivaut à un tirage de remise (X_m) .

⑧

$0 \leq k \leq m$

Ex2 Inégalité de Chebichev

$(X_i)_{i \geq 1}$ suite i.i.d. indép de m loi de

$\text{Bin}(n)$ à $\theta \in [0, 1]$. On pose $S_m = \sum_{i=1}^m X_i$
 & $\tilde{X}_m = \frac{S_m}{m}$ (moy. empirique)

1) Q est la loi de S_m ? Espérance? Variance?

$$S_m \sim \text{Bin}(m, \theta); P(S_m=k) = \binom{m}{k} \theta^k (1-\theta)^{m-k}$$

$$\Omega = \{0, 1\}^m$$

$$\mathbb{P} = P(\Omega)$$

$$P(\{(w_1, \dots, w_m)\}) = \theta^{\sum w_i} (1-\theta)^{m - \sum w_i} \quad \forall (w_1, \dots, w_m) \in \Omega;$$

$$S_m(w) = \sum_{i=1}^m w_i = \text{card}(\{i : i \in \{1, \dots, m\}, w_i = 1\})$$

$$\mathbb{E}(S_m) = \mathbb{E}\left(\sum_{i=1}^m X_i\right) = \sum_{i=1}^m \mathbb{E}(X_i) = m\theta$$

$$\text{Var}(S_m) = \text{Var}\left(\sum_{i=1}^m X_i\right) \stackrel{\text{par indépendance}}{=} \sum_{i=1}^m \text{Var}(X_i) = m\theta(1-\theta)$$

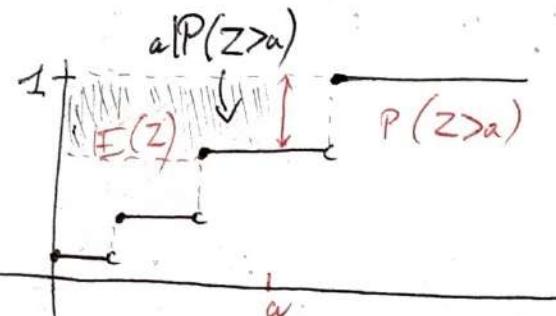
pour

$$\begin{aligned} \text{Var}(X_i) &= \mathbb{E}(X_i^2) - \mathbb{E}(X_i)^2 \\ &= \mathbb{E}(X_i) - \mathbb{E}(X_i)^2 = \theta - \theta^2 \quad \text{③} \end{aligned}$$

i) Soit $\epsilon > 0$, majorer proba $P(|\tilde{X}_m - \theta| > \epsilon)$ en f de m, θ et ϵ .

$$P(|\tilde{X}_m - \theta| > \epsilon) \leq \frac{\mathbb{E}(|\tilde{X}_m - \theta|)}{\epsilon}$$

$$\text{pas simple: } \mathbb{E}(|\tilde{X}_m - \theta|) = \sum_{k=0}^m \left| \frac{k}{m} - \theta \right| k (1-\theta)^{m-k}$$



Markov $P(Z > a) \leq \frac{\mathbb{E}(Z)}{a}$

- Z va > 0
- $a > 0$

$$\text{Var}(\tilde{X}_m) = \text{Var}\left(\frac{S_m}{m}\right) = \frac{1}{m^2} \text{Var}(S_m) = \frac{\theta(1-\theta)}{m}$$

$$\mathbb{E}(\tilde{X}_m) = \mathbb{E}\left(\frac{S_m}{m}\right) = \theta$$

$$Rq: |\tilde{X}_m - \theta| \leq \tilde{X}_m - \theta \leq 1$$

$$\Rightarrow E(|\tilde{X}_m - \theta|) \leq E(\tilde{X}_m) + \theta = 2\theta$$

et $E(|\tilde{X}_m - \theta|) \leq 1$

$$E(|\tilde{X}_m - \theta|) \leq \min(1, 2\theta)$$

$$P(|\tilde{X}_m - \theta| > \varepsilon) \leq \frac{E(|\tilde{X}_m - \theta|)}{\varepsilon} \leq \frac{\min(1, 2\theta)}{\varepsilon}$$

pas intéressant: on peut le faire

~~$$\frac{E(|\tilde{X}_m - \theta|)}{\varepsilon} = \frac{1}{\varepsilon} \sum_{k=0}^m C_m^k \left| \frac{k}{n} - \theta \right| \theta^k (1-\theta)^{n-k}$$~~

~~$$\leq \frac{1}{\varepsilon} \sum_{k=0}^m C_m^k (\theta+1) \theta^k (1-\theta)^{n-k}$$~~

~~$$\leq \frac{\theta+1}{\varepsilon} 1^n$$~~

C'est appliquant Markov à $\varepsilon = n$

~~$$\leq \frac{\theta+1}{n} \rightarrow dc en passant à la limite:$$~~

$$\lim_{n \rightarrow \infty} \frac{\theta+1}{n} = 0$$

$$P(\underbrace{|\tilde{X}_m - \theta|^2}_{m \geq 0} > \varepsilon^2) \stackrel{\text{Markov}}{\leq} \frac{E((\tilde{X}_m - \theta)^2)}{\varepsilon^2}$$

$$= \frac{\text{Var}(\tilde{X}_m)}{\varepsilon^2} = \frac{\theta(1-\theta)}{n \varepsilon^2}$$

$$Rq: P(|\tilde{X}_m - \theta| > \varepsilon) = P(|S_m - m\theta| > n\varepsilon)$$

à θ fixé, $\lim_{n \rightarrow \infty} \frac{\theta(1-\theta)}{n \varepsilon^2} = 0$

$$\lim_{n \rightarrow \infty} P(|\tilde{X}_m - \theta| > \varepsilon) = 0$$

(Rq) $\text{Var}(z) = E(z^2) - E(z)^2 = E[(z - E(z))^2]$

$$\tilde{X}_m \xrightarrow[n \rightarrow \infty]{\text{Probab}} \theta$$

④

Ex 3 Amélioration de l'inégalité de Chebichev

But $P\left(\left|\frac{s_m}{m} - \theta\right| \geq \epsilon\right) \leq \frac{1}{4n^2\epsilon^4}$

soit $(X_i)_{i \geq 1}$ suite \textcircled{a} iid m loi Bern(0), $\theta \in \mathbb{R}, \epsilon$.

$$s_m = \sum_{i=1}^m X_i, \text{ pour } Y_i = X_i - \theta \quad \forall i \in \mathbb{N}^*$$

1) en utilisant identité $\left(\sum_{i=1}^m Y_i\right)^4 = \sum_{i,j,k,l=1}^m Y_i Y_j Y_k Y_l$

Mq $E\left(\sum_{i=1}^m Y_i\right)^4 = mE(Y_i^4) + 3m(m-1)(E(Y_i^2))^2$

$$\{i,j,k,l\} \subset \{1, \dots, m\}^4,$$

$$E(Y_i Y_j Y_k Y_l) ?$$

$$Y_i = X_i - \theta, \quad X_i \sim \text{Bern}(0)$$

- $E(Y_i) = 0$ (car $E(X_i) = E(0)$)

- Y_1, \dots, Y_m m loi + indépendantes.

si (i,j,k,l) st tous distincts.

$$E(Y_i Y_j Y_k Y_l) = E(Y_i) E(Y_j) E(Y_k) E(Y_l)$$

\textcircled{a} Si X est indépendante de Z (pour g & h mesurables) $g(X)$ est indépendante de $h(Z)$.

$(i,j,k,l) \in \{1, \dots, m\}^4$ plusieurs cas :

► i,j,k,l tous distincts : $E(Y_i Y_j Y_k Y_l) = 0$.

► i,j,k,l tous égaux $i=j=k=l$ car $Y_i \sim \text{Bern}(0)$
 $E(Y_i Y_j Y_k Y_l) = E(Y_i^4) = E(Y_1^4)$ car que Y_1 est un triplet (i,j,k,l) de ce type

► 3 égaux & 1 \neq : @ $i=j=k$ & $l \neq i$

$$E(Y_i Y_j Y_k Y_l) = E(Y_i^3 Y_l) = E(Y_i^2) E(Y_l) = 0$$

► 2 égaux : - 2 restants dists
- 2 restants fixés $\Rightarrow E(Y_i Y_j Y_k Y_l) = 0$.

► 2 égaux + 2 égaux : @ $i=j$ et $k=l$ & $i=k$

$$E(Y_i Y_j Y_k Y_l) = E(Y_i^2 Y_k^2) = E(Y_i^2) E(Y_k^2)$$

$$= [E(Y_i^2)]^2 \text{ car } E(Y_i^2) = E(Y_k^2)$$

$$= E(Y_i^2)$$

→ dénombrer le nb de (i,j,k,l)
à 2 indices égaux & les 2 restants égaux
(mais distincts des 2 autres).

@ $(1,1,2,2); (1,2,1,2); (1,1,1,2); (2,2,1,1); (2,1,2,1); (2,1,1,2)$.
6 cas si une fois les 2 indices fixés.

$$\Rightarrow 6 \times C_m^2 = 6 \times \frac{m(m-1)}{2} = 3m(m-1)$$

$x:m$

$\cdot:m-1$

③

$$\begin{pmatrix} (x,x,\dots) \\ (x,\dots,x,\dots) \\ (\dots,\dots,x,x) \end{pmatrix} \Rightarrow \underline{3m(m-1)}$$

$$\Rightarrow \mathbb{E}\left(\left(\sum_{i=1}^n Y_i\right)^4\right) = n \mathbb{E}(Y_1^4) + 3n(n-1) \left[\mathbb{E}(Y_1^2)\right]^2$$

et $\mathbb{E}\left[(S_n - n\theta)^4\right] = n\theta(1-\theta)[3n\theta(1-\theta) + 1 - 6\theta + 6\theta^2]$

$$\sum_{i=1}^n Y_i = \sum_{i=1}^n (X_i - \theta) = S_n - n\theta$$

$$\mathbb{E}(Y_1^4) = \mathbb{E}((X_1 - \theta)^4) \quad \begin{array}{l} \text{moment continu} \\ \text{d'ordre 4 de la} \\ \text{loi de Bernoulli} \end{array}$$

$$\mathbb{E}(Y_1^2) = \mathbb{E}((X_1 - \theta)^2) = \text{Var}(X_1) = n\theta(1-\theta)$$

$$\begin{aligned} \mathbb{E}((X_1 - \theta)^4) &= (1-\theta)^4 \theta + \theta^4 (1-\theta) \\ &= \theta(1-\theta) [(1-\theta)^3 + \theta^3] \\ &= \theta(1-\theta) [1 + 3\theta^2 - 3\theta - \theta^3 + \theta^3] \\ &= \theta(1-\theta) (1 - 3\theta + 3\theta^2) \end{aligned}$$

NB: $Y_1 = (X_1 - \theta)^4 = \begin{cases} (1-\theta)^4 & \text{4 proba } \theta \\ \theta^4 & \text{4 proba } 1-\theta \end{cases}$

$$\mathbb{E}(g(X)) = \sum_{x_k \in V(\mathbb{Z})} g(x_k) \mathbb{P}(X=x_k)$$

$$\Rightarrow \mathbb{E}(Y_1^4) = \mathbb{E}((X_1 - \theta)^4) = \theta(1-\theta)(1 - 3\theta + 3\theta^2)$$

(B)

$$\begin{aligned} \mathbb{E}[(S_n - n\theta)^4] &= n\theta(1-\theta)(1 - 3\theta + 3\theta^2) \\ &\quad + 3n(n-1)\theta^2(1-\theta)^2. \end{aligned}$$

$$= n\theta(1-\theta)[3n\theta(1-\theta) + 1 - 6\theta + 6\theta^2]$$

[2) al $\forall n \in \mathbb{N}^*, \forall \varepsilon > 0, \mathbb{P}\left(|\frac{S_n}{n} - \theta| \geq \varepsilon\right) \leq \frac{1}{4n^2\varepsilon^4}$

$$\mathbb{P}\left(|\frac{S_n}{n} - \theta| \geq \varepsilon\right) = \mathbb{P}(|S_n - n\theta| \geq n\varepsilon) = \mathbb{P}((S_n - n\theta)^4 \geq n^4\varepsilon^4)$$

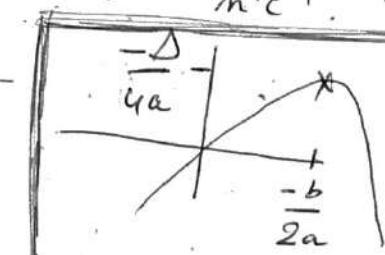
par Markov $\leq \frac{\mathbb{E}((S_n - n\theta)^4)}{n^4\varepsilon^4} = \frac{n\theta(1-\theta)[3n\theta(1-\theta) + 1 - 6\theta + 6\theta^2]}{n^4\varepsilon^4} + \infty$

$$\frac{\frac{n\theta^2(6-3n)}{4} + \theta(3n-6) + 1}{n^4\varepsilon^4}$$

$$\max(\theta^2(6-3n) + \theta(3n-6) + 1)$$

$$= \frac{3}{4}n - \frac{1}{2}$$

$$\leq \frac{3}{16} \frac{n}{n^2\varepsilon^4} \leq \frac{1}{4n^2\varepsilon^4}$$



$$\text{Sur } [0, 1], \theta(1-\theta) \leq \frac{1}{4}$$

En q cela améliore Yebitcher? Vif au $\frac{1}{n^2}$
plutôt que en $\frac{1}{n}$ à Yebitcher.

$$\textcircled{R9} \quad \forall \varepsilon > 0, \quad P\left(\left|\frac{s_m}{m} - \theta\right| \geq \varepsilon\right) \leq \frac{1}{4m\varepsilon^4}$$

$\forall \delta > 0, \exists m_0 \in \mathbb{N}^*, \forall m \geq m_0,$

$$P\left(\left|\frac{s_m}{m} - \theta\right| \geq \varepsilon\right) \leq \delta \Leftrightarrow P\left(\left|\frac{s_m}{m} - \theta\right| \leq \varepsilon\right) \geq 1-\delta$$

On veut exprimer $P(\forall m \geq m_0, |\frac{s_m}{m} - \theta| < \varepsilon) = P(B_{m_0})$
en f de $A_m(\varepsilon) = \left\{ \left|\frac{s_m}{m} - \theta\right| \geq \varepsilon \right\}$

$$\hookrightarrow B_{m_0}(\varepsilon) = \left\{ \omega \in \Omega, \forall m \geq m_0, \left| \frac{s_m(\omega)}{m} - \theta \right| < \varepsilon \right\}$$

et $P(A_m(\varepsilon)) \leq \frac{1}{4m^2\varepsilon^4}$.

$$\omega \in B_{m_0}(\varepsilon) \iff \forall m \geq m_0, \omega \in A_m^c(\varepsilon).$$

$$B_{m_0}(\varepsilon) = \bigcap_{m \geq m_0} A_m^c(\varepsilon)$$

$$\textcircled{R9} \quad \bigcap_{m \in \mathbb{N}^*} A_m$$

$$C_N = \bigcap_{m=1}^N A_m, \quad \bigcap_{m \in \mathbb{N}^*} A_m = \overbrace{\bigcap_{N \in \mathbb{N}^*} C_N}^{\text{intersection décroissante}}$$

$$P\left(\bigcap_{n \in \mathbb{N}^*} A_n\right) = P\left(\bigcap_{n \in \mathbb{N}^*} C_N\right) = \lim_{N \rightarrow \infty} P(C_N)$$

(2)

$$= \lim_{N \rightarrow \infty} \prod_{m=1}^N P(A_m)$$

car les $(A_m)_{m \in \mathbb{N}^*}$ st indépendants.
i.e. les $(A_m^c(\varepsilon))_{m \in \mathbb{N}^*}$ ne st pas indép.

On passe au complémentaire.

$$B_{m_0}^c(\varepsilon) = \bigcup_{m \geq m_0} A_m(\varepsilon)$$

$$P(B_{m_0}^c(\varepsilon)) \leq \sum_{m \geq m_0} P(A_m(\varepsilon)) \leq \sum_{m \geq m_0} \frac{1}{4m^2\varepsilon^4}$$

\rightarrow Trouver $m_0 \in \mathbb{N}^*$ (en f de ε)

$$\text{tg} \sum_{m \geq m_0} \frac{1}{4m^2\varepsilon^4} \leq 0,01.$$

$$\text{Indic: } \sum_{m=N+1}^{\infty} \frac{1}{m^2} \leq \frac{1}{N}.$$

$$\sum_{m=m_0-1}^{\infty} \frac{1}{4m^2\varepsilon^4} \leq \frac{1}{4\varepsilon^4} \times \frac{1}{m_0-1}$$

Il suffit de prendre m_0 tg $\frac{1}{4\varepsilon^4(m_0-1)} \leq 0,01$.

$$\Leftrightarrow m_0 \geq 1 + \frac{100}{4\varepsilon^4}.$$

Exercice 4)

Mq & indication: $\sum_{n=N+1}^{\infty} \frac{1}{n^2} \leq \frac{1}{N}$

$\forall \theta \in]0, 1[$, $g_\theta'(s) = -\theta + \frac{\theta e^s}{\theta e^s + 1 - \theta}$

$g_\theta''(s) = \frac{\theta(1-\theta)e^s}{(\theta e^s + 1 - \theta)^2} \leq \frac{1}{4}$

$\text{On a que } \forall n \geq 1, \forall n \in [n-1, n]$

$\frac{1}{n^2} \leq \frac{1}{n^2}, \frac{1}{n^2} = \int_n^\infty \frac{1}{x^2} dx \leq \int_{n-1}^1 \frac{1}{x^2} dx$

$\Rightarrow \sum_{n=N+1}^{\infty} \frac{1}{n^2} \leq \sum_{n=N+1}^{\infty} \int_{n-1}^n \frac{1}{x^2} dx$

Chaque $\int_N^\infty \frac{1}{x^2} dx = \left[-\frac{1}{x} \right]_N^\infty = \frac{1}{N}$

$g_\theta''(s) \text{ est de la forme } \frac{ab}{(a+b)^2} \cdot a = \theta e^s, b = 1 - \theta$

$a b \leq (a+b)^2 \Leftrightarrow \frac{a^2 - 2ab + b^2}{(a+b)^2} \geq 0$

Ex 1) Inégalité de Hoeffding.

Mq $\forall s > 0$, $X \sim \text{Dom}(\theta)$, $s \in]0, 1[$.

$$\Rightarrow g_\theta''(s) \leq \frac{1}{4}, g_\theta'(0) = 0$$

$$\Rightarrow g_\theta'(s) \leq \frac{s}{4} \quad \& \quad g_\theta(0) = 0$$

$$\Rightarrow g_\theta(s) \leq \frac{s^2}{8}$$

$\text{si } X \sim \text{Dom}(\theta), \mathbb{E}(\varphi(X)) = \varphi(1)\theta + \varphi(0)(1-\theta)$

$$g_\theta(s) = \ln(\mathbb{E}(e^{s(X-\theta)}))$$

$$\mathbb{E}(e^{s(X-\theta)}) = \theta e^{s(1-\theta)} + (1-\theta)e^{-s\theta}$$

$$g_\theta(s) \leq \frac{s^2}{8} \Leftrightarrow \mathbb{E}(e^{s(X-\theta)}) \leq e^{s^2/8}$$

$$g_\theta(s) = \ln \left[\theta e^{s(1-\theta)} + (1-\theta)e^{-s\theta} \right]$$

(8)

2) et $S_m \sim \mathcal{D}_{\text{Bin}}(n, \theta)$ alors $\mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) \leq e^{-2n\varepsilon^2}$

et $\mathbb{P}\left(|\frac{S_m}{m} - \theta| > \varepsilon\right) \leq 2e^{-2n\varepsilon^2}$

indie une τ dans \mathbb{Z} & $\forall x \in \mathbb{R}, s > 0$:

$$\mathbb{P}(Z \geq x) \leq e^{-sx} \mathbb{E}(e^{sZ})$$

$$= \prod_{i=1}^n \mathbb{E}\left(e^{\frac{s}{m}(X_i - \theta)}\right) = \left[g_\theta\left(\frac{s}{m}\right)\right]^n$$

$$\leq \left[e^{\left(\frac{s}{m}\right)^2 \cdot \frac{1}{8}}\right]^n = e^{\frac{s^2}{8m}}$$

$$\mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) \leq e^{-s\varepsilon} \mathbb{E}(e^{s(\frac{S_m}{m} - \theta)}) \leq e^{-s\varepsilon + \frac{s^2}{8m}}$$

$s > 0$
à optimiser

Pour $\mathbb{P}\left(\underbrace{\frac{S_m}{m} - \theta}_{\text{pas positive}} > \varepsilon\right)$ mais $\mathbb{P}\left(\underbrace{e^{\frac{S_m}{m} - \theta}}_{\text{va. positive}} > e^{s\varepsilon}\right) \Rightarrow \mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) \leq \inf_{s > 0} e^{-s\varepsilon + \frac{s^2}{8m}}$

$$= e^{-4n\varepsilon + \frac{(4n\varepsilon)^2}{8m}} = e^{-2n\varepsilon^2}$$

$$\Rightarrow \boxed{\mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) \leq e^{-2n\varepsilon^2}}$$

$\forall \varepsilon > 0$ et $S_m \sim \mathcal{D}_{\text{Bin}}(n, \theta)$; $S_m = \sum_{i=1}^n X_i$
et $\{X_i\}_i$ indép.

$$\& X_i \sim \mathcal{D}_{\text{Bin}}(\theta)$$

Par Markov:

$$\mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) \leq e^{-s\varepsilon} \mathbb{E}\left(e^{s\left(\frac{S_m}{m} - \theta\right)}\right)$$

$$\& e^{s\left(\frac{S_m}{m} - \theta\right)} = e^{\frac{s}{m} \sum_{i=1}^n (X_i - \theta)} = e^{\sum_{i=1}^n \frac{s}{m}(X_i - \theta)}$$

$$\mathbb{E}\left(e^{s\left(\frac{S_m}{m} - \theta\right)}\right) = \mathbb{E}\left(e^{\sum_{i=1}^n \frac{s}{m}(X_i - \theta)}\right)$$

$$= \mathbb{E}\left(\prod_{i=1}^n e^{\frac{s}{m}(X_i - \theta)}\right)$$

X_i indépend.

On a $\mathbb{P}\left(|\frac{S_m}{m} - \theta| > \varepsilon\right) = \mathbb{P}\left(\frac{S_m}{m} - \theta > \varepsilon\right) + \mathbb{P}\left(\frac{S_m}{m} - \theta < -\varepsilon\right)$

$$S_m \sim \mathcal{D}_{\text{Bin}}(n, \theta) \text{ et } n - S_m \sim \mathcal{D}_{\text{Bin}}(n, 1-\theta)$$

et on applique l'inégalité précédente à $n - S_m = S'_m$

$$\left\{ \frac{S_m}{m} - (1-\theta) \geq \varepsilon \right\} = \left\{ \frac{n - S_m}{m} - (1-\theta) \geq \varepsilon \right\} = \left\{ -\frac{S_m}{m} + \theta \geq \varepsilon \right\} \sim \mathcal{D}_{\text{Bin}}(n, 1-\theta)$$

$$\mathbb{P}\left(\frac{S_m}{m} - (1-\theta) \geq \varepsilon\right) \leq e^{-2n\varepsilon^2} = \left\{ \frac{S_m}{m} - \theta \leq -\varepsilon \right\}$$

$$\text{alp: } \mathbb{P}\left(|\frac{S_m}{m} - \theta| > \varepsilon\right) \leq 2e^{-2n\varepsilon^2} \Leftrightarrow \mathbb{P}\left(\frac{S_m}{m} - \theta \leq -\varepsilon\right) \leq e^{-2n\varepsilon^2}$$

⑨

Applications des inégalités de concentration

Ex5 Un C¹ téléphonique dessert 5000 abonnés. à un instant donné, chaque abonné a une proba à 2% d'utiliser son téléphone & les appels des abonnés sont supposés indépendants. Quel nbr minimal d'appels doit pouvoir traiter simultanément le central pour que sa proba d'être saturé à un instant donné soit inférieure à 25%?

$N = 5000$, chq abonné a une proba $p = 0,02$ d'appeler. Si on voulait spécifier $\underline{\Omega}$.

$$\omega = (\omega_1, \dots, \omega_{5000}) ; \quad \omega_i = \begin{cases} 1 & \text{si la } i^{\text{e}} \text{ personne appelle} \\ 0 & \text{sinon} \end{cases}$$

$$\underline{\Omega} = \{0, 1, \dots, 5000\}$$

$$X_i = \begin{cases} 1 & \text{si la } i^{\text{e}} \text{ pers appelle} \\ 0 & \text{sinon} \end{cases}$$

Le nbr d'appels sur le central téléphonique est la variable aléatoire

$S_m \sim \text{Bin}(m, p)$ car les $(X_i)_i$ sont i.i.d. de loi $\text{Bin}(p)$.

$$(X_i(\omega) = \omega_i)$$

On cherche N tq $\mathbb{P}(S_m \geq N) \leq 0,025$

minimum suffisant
valeur exacte de \mathbb{P} : $\sum_{k=N}^m \binom{k}{m} p^k (1-p)^{m-k}$

$$\text{Rq: } \mathbb{P}(S_m \geq m\epsilon + m\theta) \leq e^{-2m\epsilon^2}$$

$$= \mathbb{P}(S_m \geq m\epsilon + m\theta) = \sum_{k=m\epsilon + m\theta}^m \binom{k}{m} \theta^k (1-\theta)^{m-k}$$

$$mp = 100$$

$$0 \xrightarrow[m\epsilon]{} N \xrightarrow[m]{} 5000$$

$$N = mp + m\epsilon.$$

$$\mathbb{P}(S_m \geq mp + m\epsilon) = \mathbb{P}\left(\frac{S_m}{m} - p \geq \epsilon\right) \leq e^{-2m\epsilon^2}$$

Il suffit de prendre ϵ tq $e^{-2m\epsilon^2} \leq 0,025$

$$\epsilon \geq \sqrt{-\frac{1}{2m} \ln(0,025)}$$

$$m = 5000,$$

$$\epsilon \approx 0,019.$$

$$N = \lceil m(p+\epsilon) \rceil \quad p = 0,02$$

$$\boxed{N=196} \quad \text{si } k \geq 196 : \mathbb{P}(S_m \geq k) \leq 0,025$$

(N n'est pas optimal)

(et vrai $\inf_{k \in \Omega_{[0, \dots, m]}} \mathbb{P}(S_m \geq k) \leq 0,025 \Rightarrow N=121$)

Ex6: Sucessions d'absences.

Nbr réservés > nbr passagers effectifs

pour chq vol: $n > 300$ réservés.

$$\begin{aligned} p \leq 300 &\leftarrow \text{vol} \\ \downarrow p+k \} &\text{d'indemnité} \\ k \in \mathbb{N}. & \end{aligned}$$

1) Passagers mutuellement indépendants.

• $P(D) = 0,8$ où $D = \text{"désistement"}$. ($\theta = 0,8 \leftarrow \frac{\text{nbr abs.}}{\text{nbr réservés}}$)

• nbr réservés prisés par la compagnie pour un vol.

• S_n : nbr aléatoires de passagers se présentant à l'embarquement.

$$\rightarrow S_n \sim \mathcal{B}(n, p)$$

→ ed sans calcul: $E(S_n)$ et $\text{Var}(S_n)$.

$$m \cdot \overset{(1)}{P(D)}$$

$$\underset{n}{0,2n}$$

$$m \cdot \overset{(2)}{P(D)} (1 - \overset{(1)}{P(D)})$$

$$\underset{n}{0,2n(0,8)} = 1,6n$$

2) Valeur max n ? $P(S_n \leq 300) \geq 0,95$.

$$1 - P(S_n \geq 300) \geq 0,95$$

$$1 - P\left(\frac{S_n}{n} \geq \frac{300}{n}\right) \geq 0,95$$

$$1 - P\left(\frac{S_n}{n} - \theta \geq \frac{300}{n} - \theta\right) \geq 0,95$$

$$\text{On revient } P\left(\frac{S_n}{n} - \theta \geq \varepsilon\right) \leq e^{-2n\varepsilon^2}$$

$$1 - P\left(\frac{S_n}{n} - \theta \geq \frac{300}{n} - \theta\right) \geq 0,95$$

$$- P\left(\frac{S_n}{n} - \theta \geq \frac{300}{n} - \theta\right) \geq -0,05$$

$$P\left(\frac{S_n}{n} - \theta \geq \frac{300}{n} - \theta\right) \leq 0,05$$

↓ Par l'inégalité de Hoeffding

$$P\left(\frac{S_n}{n} - \theta \geq \varepsilon\right) \leq e^{-2n\varepsilon^2}$$

$$P\left(\frac{S_n}{n} - \theta \geq \frac{300 - 0,8n}{n}\right) \leq \exp(-2n \left(\frac{300 - 0,8n}{n}\right)^2)$$

Il suffit de prendre ε tq $e^{-2n\varepsilon^2} \leq 0,05$

$$\begin{aligned} \varepsilon &\geq \sqrt{\frac{1}{2n} \ln(0,05)} : \quad \varepsilon = ? \quad m = 300 \\ \varepsilon &\approx 0,0707. \end{aligned}$$

$$P\left(\frac{S_n}{n} - \theta \geq \varepsilon\right) \Leftrightarrow P(S_n \geq m\varepsilon + m\theta)$$

$$\begin{aligned} N &= m\theta + m\varepsilon \\ N &= m(\theta + \varepsilon) \end{aligned}$$

$$\exp\left(-2n \left(\frac{300 - 0,8n}{n}\right)^2\right) \leq 0,05.$$

$$\left(\frac{300 - 0,8n}{n}\right)^2 \geq \sqrt{-\frac{1}{2n} \ln(0,05)}$$

$$\begin{aligned} \min\left(\frac{\varepsilon}{1 + \theta + (\theta - \varepsilon)}\right) &= \frac{\varepsilon}{1 + \theta + (\theta - \varepsilon)} \\ 1 - P(S_n \geq 300) &= 1 - P(S_n \geq 300) \times R(S_n = 300) \\ 1 - P(S_n \geq 300) &\geq 0 \end{aligned}$$

$$N = \sqrt{300 \left(0,8 + \frac{300 - 0,8 \times 300}{300}\right)}$$

$$N = 300$$

$$N = \sqrt{300 (0,8 + 0,0707)}$$

$$N = 262$$

[346]

Rq int On pourra faire de Markov, Yebitcher, on trouve des valeurs de k trop grande (≈ 4000).

on a tout

Ex 8: Moyenne empirique & autre.

• $(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in [0, 1]})$; (X_1, \dots, X_m) iid $\mathcal{D}_{\text{Bin}}(\theta)$

• 2 estimateurs: $\hat{\theta}_m^1 = \frac{1}{n} \sum_{i=1}^m X_i$

$$\hat{\theta}_m^2 = \min \{X_1, \dots, X_m\}$$

1) Ces estimateurs st-ils des estimateurs sans biais de θ ?

(ie calculer $\mathbb{E}(\hat{\theta}_m^i)$) linéarité de l'espérance

$$\mathbb{E}(\hat{\theta}_m^1) = \mathbb{E}\left(\frac{1}{n} \sum_{i=1}^m X_i\right) = \frac{1}{n} \mathbb{E}\left(\sum_{i=1}^m X_i\right) \\ = \frac{1}{n} \sum_{i=1}^n \mathbb{E}_\theta(X_i) = \theta.$$

$$\Delta \mathbb{E}(\min(A)) \neq \min \mathbb{E}(A).$$

$\hat{\theta}_m^2 = \min \{X_1, \dots, X_m\}$ prend les valeurs $0, \pm 1$.

$$\mathbb{P}_\theta(\hat{\theta}_m^2 = 1) = \mathbb{P}_\theta\left(\bigcap_{i=1}^m \{X_i = 1\}\right) = \prod_{i=1}^m \mathbb{P}_\theta(X_i = 1) = \theta^n \\ \mathbb{P}_\theta(\hat{\theta}_m^2 = 0) = 1 - \theta^n.$$

$$\mathbb{E}_\theta(\hat{\theta}_m^2) = 1 \times \mathbb{P}_\theta(\hat{\theta}_m^2 = 1) + 0 \times \mathbb{P}_\theta(\hat{\theta}_m^2 = 0) = \theta^n$$

$\rightarrow \hat{\theta}_m^2$ n'est pas un estimateur sans biais de θ . (sauf pour $n=1$). (1)

2) Pour $i \in \{1, 2, 3\}$, calculer le risque $\mathbb{E}_\theta[(\hat{\theta}_m^i - \theta)^2]$

$$\mathbb{E}_\theta((\hat{\theta}_m^1 - \theta)^2) = \text{Var}(\hat{\theta}_m^1) \text{ car } \mathbb{E}_\theta(\hat{\theta}_m^1) = \theta \\ = \text{Var}_\theta\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \text{Var}_\theta\left(\sum_{i=1}^n X_i\right) \\ = \frac{1}{n^2} \sum_{i=1}^n \text{Var}_\theta(X_i) = \frac{\theta(1-\theta)}{n}.$$

Rq $X \sim \mathcal{D}_{\text{Bin}}(\theta)$: $\text{Var}(X) = \mathbb{E}(X^2) - \underbrace{\mathbb{E}(X)^2}_{\theta} = \theta - \theta^2$
 $X^2 = X$ $= \mathbb{E}((X - \mathbb{E}(X))^2) / \theta = \theta(1-\theta)$.

$$\mathbb{E}_\theta((\hat{\theta}_m^2 - \theta)^2) = (1-\theta)^2 \mathbb{P}_\theta(\hat{\theta}_m^2 = 1) + \theta^2 \mathbb{P}_\theta(\hat{\theta}_m^2 = 0) \\ = (1-\theta)^2 \theta^n + \theta^2 (1-\theta^n) = (1-2\theta+\theta^2) \theta^n + \theta^2 - \theta^{n+2} \\ \text{ou bien} \\ = -2\theta^{n+1} + \theta^{n+2} + \theta^2$$

$$\mathbb{E}_\theta((\hat{\theta}_m^3 - \theta)^2) = \mathbb{E}_\theta((\hat{\theta}_m^2)^2) - 2\theta \mathbb{E}_\theta(\hat{\theta}_m^2) + \theta^2 \\ = \theta^{n+1} - 2\theta^{n+2} + \theta^2.$$

3) Quel de ces 2 estimateurs est le meilleur qd $n=2$.

$$\mathbb{E}_\theta[(\hat{\theta}_m^1 - \theta)^2] = \frac{\theta(1-\theta)}{2}, \mathbb{E}_\theta[(\hat{\theta}_m^2 - \theta)^2] = -\theta^{n+1} + \theta^2$$

Le meilleur estimateur: c'est celui q a le plus petit risq quadratique

$$n=2: \mathbb{E}_\theta[(\hat{\theta}_2^1 - \theta)^2] = \frac{\theta(1-\theta)}{2}, \mathbb{E}_\theta[(\hat{\theta}_2^2 - \theta)^2] = \theta^2 - 2\theta^3 + \theta^2 \\ = 2\theta^2(1-\theta)$$

$$\mathbb{E}_\theta[(\hat{\theta}_2 - \theta)^2] < \mathbb{E}_\theta[(\hat{\theta}_1 - \theta)^2]$$

$$\text{or } \theta \leq \frac{1}{4}.$$

\Rightarrow d'où $\theta \leq \frac{1}{4}$, $\hat{\theta}_2$ est meilleur que $\hat{\theta}_1$.

Ex 9 : Estimateur de la variance

$(\Omega, \mathcal{F}, (\mathbb{P}_\theta)_{\theta \in [0,1]}, (X_1, \dots, X_n) \sim \text{Bern}(\theta))$

$$\bar{X}_m = \frac{1}{n} \sum_{i=1}^n X_i, \text{ On veut estimer la variance } v(\theta) = \theta(1-\theta).$$

1) Méthode valable par loi de Bernoulli

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_m)^2 = \bar{X}_m (1 - \bar{X}_m)$$

$$\begin{aligned} \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_m)^2 &= \frac{1}{n} \sum_{i=1}^n X_i^2 - 2\bar{X}_m \underbrace{\sum_{i=1}^n X_i}_{\bar{X}_m} + \bar{X}_m \\ &= \frac{1}{n} \sum_{i=1}^n X_i^2 - \left(\frac{1}{n} \sum_{i=1}^n X_i \right)^2 \end{aligned}$$

$$\boxed{\text{FF: } \mathbb{E}((X - \mathbb{E}(X))^2) = \mathbb{E}(X^2) - (\mathbb{E}(X))^2}$$

$$\frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_m)^2 = \frac{1}{n} \sum_{i=1}^n X_i^2 - \bar{X}_m^2 \quad \text{tjz vrai}$$

$$\begin{aligned} &= \frac{\bar{X}_m - \bar{X}_m}{\bar{X}_m (1 - \bar{X}_m)} \quad \text{unique par Bernoulli} \end{aligned}$$

D'où $\bar{X}_m (1 - \bar{X}_m)$ est la variance empirique des $(X_i)_n$.

2) L'estimateur $\tilde{v}_m = \bar{X}_m (1 - \bar{X}_m)$ est-il un estimateur sans biais de $v(\theta)$?

$$\begin{aligned} &\hookrightarrow \text{calculer } \mathbb{E}(\tilde{v}_m) = \mathbb{E}(\bar{X}_m (1 - \bar{X}_m)) = \mathbb{E}(\bar{X}_m - \bar{X}_m^2) \\ &= \mathbb{E}(\bar{X}_m) - \mathbb{E}(\bar{X}_m^2) = \theta - \mathbb{E}(\bar{X}_m^2) \\ &= \theta - \mathbb{E}\left[\left(\frac{1}{n} \sum_{i=1}^n X_i\right)^2\right] = \frac{1}{n^2} \mathbb{E}\left[\sum_{1 \leq i, j \leq n} X_i X_j\right] \end{aligned}$$

Autre méthode :

$$\begin{aligned} \mathbb{E}_\theta(\bar{X}_m^2) &= \text{Var}_\theta(\bar{X}_m) + \mathbb{E}(\bar{X}_m)^2 = \frac{\theta(1-\theta)}{n} + \theta^2 \\ &= \frac{n-1}{n} \theta(1-\theta) \end{aligned}$$

L'estimateur est asymptotiquement sans biais de $v(\theta)$.

3) Lequel de ces 2 estimateurs est le meilleur qd $n=2$?

$$\begin{aligned} \tilde{v}_m &= (X_1)(1-X_2), \mathbb{E}_\theta(\tilde{v}_m) = \mathbb{E}_\theta[X_1(1-X_2)] \\ &= \mathbb{E}_\theta(X_1) \mathbb{E}_\theta(1-X_2) \quad \text{car } X_1 \text{ & } X_2 \text{ st indep.} \\ &= \theta(1-\theta) = v(\theta) \end{aligned}$$

$\Rightarrow \tilde{v}_m$ est un estimateur sans biais de $v(\theta)$

$$\textcircled{R} \quad \hat{v}_m = \bar{x}_m (1 - \bar{x}_m)$$

$E_\theta(\hat{v}_m) = \frac{m-1}{m} v(\theta)$ et \hat{v}_m est un estimateur asymptotiquement sans biais de $v(\theta)$.
 $(\lim_{m \rightarrow \infty} E_\theta(\hat{v}_m) = v(\theta))$.

4) Quel estimateur préférez-vous ?

\tilde{v}_m utilise peu d'informations : juste x_1 et x_2 , alors \hat{v}_m utilise toute l'échantillon x_1, \dots, x_m .

$$\hat{v}_m \xrightarrow[m \rightarrow \infty]{P_\theta \text{ ps}} \theta(1-\theta) \quad \text{et} \quad \bar{x}_m \xrightarrow[m \rightarrow \infty]{P_\theta \text{ ps}} \theta$$

$$\Leftrightarrow \exists \Omega_1 \in \mathcal{F}^{\theta}, P_\theta(\Omega_1) = 1,$$

$$\text{tq } \forall \omega \in \Omega_1 : \bar{x}_m(\omega) \xrightarrow[m \rightarrow \infty]{} \theta$$

$$\Rightarrow \bar{x}_m(\omega)(1 - \bar{x}_m(\omega)) \xrightarrow[m \rightarrow \infty]{} \theta(1-\theta).$$

$$\text{de } \{ \omega \in \Omega : \hat{v}_m(\omega) \xrightarrow[m \rightarrow \infty]{} v(\theta) \} \supset \Omega_1.$$

$$\text{de } P_\theta(\{ \omega \in \Omega : \hat{v}_m(\omega) \xrightarrow[m \rightarrow \infty]{} v(\theta) \}) = 1.$$

Intervalle de confiance

Ex 10 Échauffement du dé sur des candidats I (extrait partielle)

Mon fils fabrique dé, on se demande si l'est dé est bien équilibré. Il s'arme de patience, lance 3600 fois son dé et recueille le nb X de 6 obtenus. On note θ la probabilité d'obtenir 6 à la dé.

1) si le dé est bien équilibré, donner en justifiant, une minoration de $P(500 \leq X \leq 700)$. ($E_\theta(X) = 3600 \cdot \theta$)

X nb 6 sur 3600 lancers. $\boxed{1} \quad X \sim \text{Bin}(3600, \theta)$,

si le dé est bien équilibré $\theta = \frac{1}{6}$.

$$P(500 \leq X \leq 700) = \sum_{k=500}^{700} P_{3600}^k \left(\frac{1}{6}\right)^k \left(1 - \frac{1}{6}\right)^{3600-k} = F_X(700) - F_X(499)$$

Ré Hoeffding

$$\bar{x}_m = \frac{s_m}{m}, \quad s_m = \sum_{i=1}^m x_i, \quad P_\theta(|\bar{x}_m - \theta| > \varepsilon) \leq e^{-2m\varepsilon^2}$$

$$\begin{aligned} P_{\frac{1}{6}}(500 \leq X \leq 700) &= P_{\frac{1}{6}}(|X-600| \leq 100) \\ &= 1 - P_{\frac{1}{6}}(|X-600| > 100) \end{aligned}$$

$$100 = 3600 \varepsilon \Rightarrow \varepsilon = \frac{1}{36}.$$

$$P_{\frac{1}{6}}(|X-600| > 100) \leq 2e^{-2 \cdot 3600 \times \frac{1}{36^2}} = 2e^{-2 \cdot \frac{100}{36}}$$

$$\textcircled{13} \quad \Rightarrow P_{\frac{1}{6}}(500 \leq X \leq 700) \geq 1 - 2e^{-\frac{100}{36}} \approx 0,9923.$$

X est très concentrée autour de 600.

"Vraie" valeur $0,9999926$

2) On suppose θ non équilibré, donner un intervalle de confiance de niveau de confiance 95% pour θ , à l'aide de l'inégalité de Hoeffding.

$\theta \in]\epsilon, 1[$ inconnu. Intervalle de confiance \hat{I} .

$$P_\theta(\theta \in \hat{I}) > 0,95.$$

$$\text{Estimateur de } \theta : \frac{X}{3600} = \hat{\theta}.$$

$$\hat{\theta} - \frac{X}{3600}$$

$$\hat{I} = [\underline{\theta}, \bar{\theta}]$$

$$\hat{I} = [\hat{\theta} - \varepsilon, \hat{\theta} + \varepsilon]$$

ε à déterminer tq $P_\theta(\theta \in \hat{I}) > 0,95$.

$$\theta \in \hat{I} \Leftrightarrow |\theta - \hat{\theta}| \leq \varepsilon$$

$$P_\theta(\theta \in \hat{I}) > 0,95.$$

$$\Leftrightarrow P_\theta(|\theta - \hat{\theta}| \leq \varepsilon) \geq 0,95$$

$$\Leftrightarrow P_\theta(|\theta - \hat{\theta}| \geq \varepsilon) \leq 0,05$$

$$\Leftrightarrow P_\theta\left(\left|\theta - \frac{X}{3600}\right| \geq \varepsilon\right) \leq e^{-2 \cdot 3600 \cdot \varepsilon^2}$$

Il suffit de prendre $\varepsilon > 0$ tq $e^{-7200 \cdot \varepsilon^2} \leq 0,05$.

$$\varepsilon \geq \sqrt{\frac{1}{7200} \ln \frac{e}{0,05}} \Rightarrow \varepsilon = 0,023.$$

$$\hat{I} = \left[\frac{X}{3600} - 0,023, \frac{X}{3600} + 0,023 \right]$$

3) Sur les 3600 lancers, il observe 640 fois le chiffre 6. A la vue de cette observation, peut-il conclure que θ est mal équilibré à moins de 5% de chances de se tromper? Test statistique? Repondre la qd H_0 et H_1 .

H_0 : "équilibré" $\theta = \frac{1}{6}$ H_1 : "pas équilibré" $\theta \neq \frac{1}{6}$.

$$P_{H_0}(\text{condamne } H_1) \leq 0,05. (\text{i.e. } p_0 = \frac{1}{6}, p_1 \neq \frac{1}{6})$$

$$\text{Zone de Rejet: } P_{0,05} = \{X \geq k\} \text{ tq } P_{\frac{1}{6}}(X \geq k) \leq 0,05$$

$$\text{or } P_{\frac{1}{6}}(X \geq k) \approx P\left(\text{Unif}\left(\frac{1}{6}\right) \geq k\right)$$

$$P_0 =$$

Ex 11 Élections présidentielles

Entre 2 tours, sondage $N=1000$ p. \xrightarrow{A} gagne ?

(H) Ø abstient.

$$S_A : 507 A / 493 B \quad | \quad S_B : 494 A / 506 B.$$

50,7%

49,4%

+ pas
répondre

1) En tant que statisticien, qu'en pensez-vous?

$$\hat{\theta}(w_1) = 0,507$$

$$\hat{\theta}(w_2) = 0,494$$

θ = proba de voter pour A inconnue.

$$P_\theta(\theta \in \hat{I}) \geq 0,95.$$

$$\hat{\theta} = \bar{X}_{1000}, \quad X_i : \text{réponse du } i^{\text{e}} \text{ électeur.}$$

2) Donner un intervalle de confiance pour θ de niveau de confiance 95%.

$$P_\theta(\theta \in \hat{I}) \geq 0,95 \quad (*).$$

$$\hat{I} = [\hat{\theta} - \varepsilon, \hat{\theta} + \varepsilon].$$

$$(*) \Leftrightarrow P_\theta(|\theta - \hat{\theta}| > \varepsilon) \leq 0,05.$$

$$\alpha P_\theta(|\theta - \hat{\theta}| > \varepsilon) \leq \varepsilon e^{-1000 \varepsilon^2}.$$

Il suffit de prendre $\varepsilon > 0$ tq

$$2 e^{-1000 \varepsilon^2} \leq 0,05. \quad \Leftrightarrow \varepsilon \geq \sqrt{\frac{1}{1000} \ln \frac{2}{905}}$$

$$\varepsilon \geq \sqrt{\frac{1}{1000} \ln(40)} \approx 0,043.$$

$$\hat{I} = [\hat{\theta} - 0,043, \hat{\theta} + 0,043]$$

$$\hat{I}(w_1) = [0,507 - 0,043, 0,507 + 0,043]$$

$$\hat{I}(w_2) = [0,494 - 0,043, 0,494 + 0,043].$$

→ P+ on conclut que le candidat A va gagner de moins de 5% d'erreur ?

Bx 12: Conformité de carburant

Conformités au 100 km par 100 chauffeurs sur un trajet.

Conso carburant est \textcircled{v} X de loi inconnue & imprédictible

Tableau par 100 observés $x_1, \dots, x_{100} \geq$ les observables $x_1(w), \dots, x_{100}(w)$ d'une suite de \textcircled{v} indp de \textcircled{m} loi que X .

On a $\underline{p} = P(X > 7)$.

1) Proposez une valeur numérique pour estimateur p en justifiant.

Généralités : $x_i = x_i(w), \dots, x_{100} = X_{100}(w)$

$\frac{1}{100} \sum_{i=1}^{100} x_i$ est estimateur de la consommation moyenne = \textcircled{v} .

$\frac{1}{100} \sum_{i=1}^{100} x_i = \frac{1}{100} \sum_{i=1}^{100} X_i(w)$ est la valeur observée de l'estimateur.

$\underline{p} = P(X > 7)$, Valeur numérique : 47%.

C'est la fréquence d'apparition des $X_i(w) > 7$.

$$\hat{q} = \frac{1}{100} \cdot \text{card} \{ i \in \{1, \dots, 100\} \mid X_i > 7 \}$$

$$\hat{p} = \frac{1}{100} \sum_{i=1}^{100} \mathbf{1}_{\{X_i > 7\}}$$

$$1 \leq i \leq 100$$

$$Y_i = \mathbf{1}_{\{X_i > 7\}}$$

$(Y_i)_{1 \leq i \leq 100}$ st indépendants, $Y_i \sim \text{Bern}(p)$.

$$\mathbb{E}_p(\hat{p}) = \frac{1}{100} \sum_{i=1}^{100} \mathbb{E}_p(Y_i) = p.$$

$\Rightarrow \hat{p}$ est un estimateur sans biais de p .

$$\textcircled{m} \text{ si on note } \hat{p}_m = \frac{1}{m} \sum_{i=1}^m Y_i$$

$$\hat{p}_m \xrightarrow[m \rightarrow \infty]{P_p} p$$

\hat{p}_m est un estimateur consistant.

2) Proposez un intervalle de confiance \textcircled{v} pour p .

On cherche ϵ tq $P_p(p \in I) > 0,95$.

$$p \in I \Leftrightarrow |p - \hat{p}| \leq \epsilon.$$

$$P_p(p \in I) \geq 0,95 \Leftrightarrow P_p(|p - \hat{p}| \leq \epsilon) \geq 0,95$$

$$\Leftrightarrow P_p(|\hat{p} - p| \geq \epsilon) \leq e^{-200\epsilon^2}$$

Il suffit de choisir ϵ tq $2e^{-200\epsilon^2} \leq 0,05$

$$\text{soit } \epsilon \geq \sqrt{\frac{1}{200} \ln \frac{2}{0,05}} \approx 0,136$$

$$I = [\hat{p} - 0,136, \hat{p} + 0,136] \quad (\text{fermé marche aussi})$$

$$P_p(p \in I) \geq 0,95$$

$$\hat{I}(w) = [0,334 ; 0,666]$$

~~Surtout pas $P_p(p \in [0,334 ; 0,666])$~~

Tests Statistiques

Ex 14 Mieux vaut ne pas (trop) se tromper.

Des résultats, décrivez ce q correspondant au choix de l'hypothèse nulle H_0 & de l'hypothèse alternative H_1 .

1) Promenade le long rive jardé, ~~je~~ buit dernière nous.
E q consiste t'en de 1^e espèce ? 2^e espèce ? Laguille est la + grande. Que faites-vous ?

Généralités: Choix de H_0 & H_1 st tq on minimise la proba de se tromper qd on conduit H_1 .

E_1 : Conclure H_1 alors que H_0 q est vraie.

"Un train passe", "pas de train en vue"

H_0

H_1'

* 2 erreurs possibles :

- conclure que le train passe alors que ce n'est pas le cas
⇒ on se décale pour rien.
- conclure que le train ne passe pas alors qu'il y en a un (garaine ⇒ pb ! Hs.)

erreur à privilier : E_1 : (erreur de 1^e espèce)

Conduire Hs alors que c'est H0 q est vraie.

2) Test hypothèse \leftrightarrow jugement. Erreur de 1^e espèce et de condamner l'innocent. Vrai/Faux ?

→ Condamner un coupable n'est pas une erreur.

Erreurs :

- condamner un innocent
- innocenter un coupable.

H_0 : innocent

/ H_1 : coupable.

On conduit Hs si on a suffisamment de preuves.

Consequence si on souhaite rendre l'erreur de 1^e espèce nulle. ⇒ H0 le monde st innocent.

3) Voyage ds l'espace & vs voulez tester si la navette spatiale est sans danger.

H_0 : "la navette est dangereuse"

H_1 : "la navette est sûre"

Ex 15 Les bases

On observe une $\text{v.a. } X \sim \text{Bin}(10, p)$

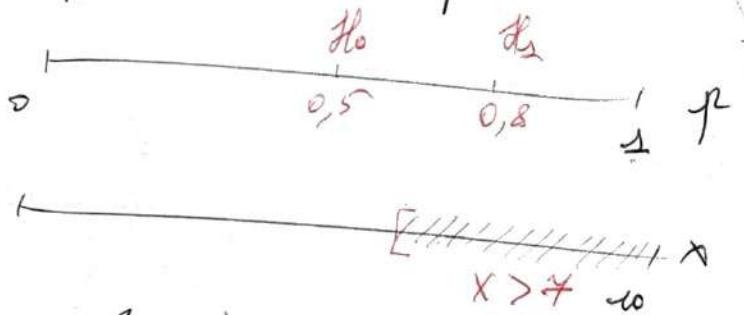
A p ayant n valeurs possibles 0,5 ou 0,8.

On décide que $H_0 : p = 0,5$ est rejettée

& $H_1 : p = 0,8$ est acceptée si la v.a. observée $X \geq 7$.

1) Quelle est la zone de rejet ?

$X \sim \text{Bin}(10, p)$; 2 hypoth. simples
 $H_0 : p = 0,5$ contre $H_1 : p = 0,8$.



$P_{H_0} \{X \geq 7\}$ est l'événement sur lequel on conclut H_1 : zone de rejet.
 On rejette H_0 .

- Les hypo. se traduisent tous en f du param inconnu
- La zone de rejet est un événement f (\textcircled{a}) (observé) X ou x_1, \dots, x_m .

2) Calculer la taille de ce test

$$\alpha_0 = P_{0,5}(R) = P_{0,5}(X \geq 7) = 1 - P_{0,5}(X \leq 6) \\ = 1 - 0,828 = 0,172.$$

3) Calculer la puissance de ce test.

$$P_{0,8}(R) = P_{0,8}(X \geq 7) = 1 - P_{0,8}(X \leq 6) \\ = 1 - 0,181 = 0,879.$$

Taille α_0 , $\theta \in \Theta_0$ ← ici un seul point

sur $P_\theta(R)$

ici $\Theta_0 = \{0,5\}$

4) Quels sont ensembles de 1^e & 2^e espèce ?

Ensemble de 1^e espèce : $\alpha_0 = 0,172$.

2^e espèce : "on dit H_0 alors que c'est H_1 "
 $\beta = P_{0,8}(R^c) = 1 - P_{0,8}(R) = 1 - 0,181 = 0,819$.

5) Construire le test de H_0 contre H_1
 $\Theta \ni \omega \in \Omega = 10\%$.

Donnez la zone de rejet. $S_0 = \{X > k_0\}$.

$$\omega = 10\%$$

$$\omega = 5\% \text{ où } k_0 = \min \{k \in \{0, \dots, 10\} : P_{0,5}(X > k) \leq \omega\}$$

$$P_{0,5}(X > k) = 1 - P_{0,5}(X \leq k-1)$$

$$P_{0,5}(X > k) \leq \omega.$$

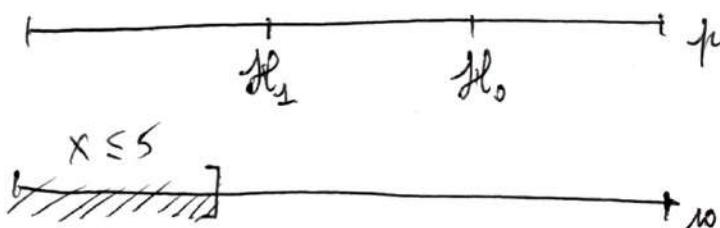
$$\Leftrightarrow P_{0,5}(X \leq k-1) \geq 1-\omega.$$

$$\bullet k_{10\%}-1=7 \Rightarrow k_{10\%}=8, S_0 = \{X \geq 8\}$$

$$\bullet k_{5\%}-1=8 \Rightarrow k_{5\%}=9, R = \{X \geq 9\}$$

NB : $P_{H_0}(R) \leq \omega$ proba de conclure H_1 alors que H_0 est vraie

Autre @ test $H_0: p=0,8$ contre $H_1: p=0,5$



$$k_{10\%} = \max \{k \in \{0, \dots, 10\} : P_{0,8}(X \leq k) \leq 0,1\}$$

(10)

Ex 16 : Un enseignant donne un questionnaire à ses élèves sur l'assassinat. Il teste l'hypothèse H_0 que les élèves répondent au hasard, il adopte la règle de décision :

- si ≥ 7 réponses \oplus : l'étud connaît son cours

- si moins de 7 rép \oplus : l'étud répond au hasard.

1) Déterminer proba de rejeter l'hypothèse (que l'étud joue aux désinfectés) lorsque c'est correcte. C'est la proba de conclure à tort que l'étud connaît son cours

H_0 : "étud répond au hasard" / H_1 : "étud connaît son cours".

X \oplus = nbr réponses correctes.

$X \sim \text{Bin}(10, \theta)$.

$\rightarrow H_0: \theta = 0,5$ contre $H_1: \theta > 0,5$

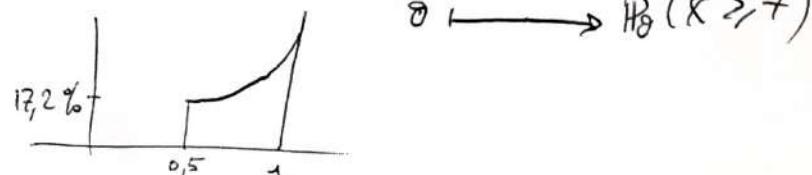
conclut

si $X \geq 7$ alors on conclut $\theta > 0,5$ sinon on $\theta = 0,5$
 $S_0 = \{X \geq 7\}$.

1) $P_{0,5}(X \geq 7) = 0,172$.

2) Tracer la puissance du test

Puissance: $\mathcal{P}: [0,5; 1] \rightarrow [0,1]$



3) Déterminer le + petit nbr de réponses correctes qu'un étud doit avoir pour que le professeur soit sûr au risq de 5% ou 1% que l'étudiant ne joue pas aux devinettes.

$$R_0 = \{X \geq k_2\}$$

$$k_2 = \min \{k \in \{0, \dots, 10\} : P_{0,5}(X \geq k) \leq 2\}$$

$$k_{6\%} = 8, \quad k_{5\%} = 9, \quad k_{1\%} = 10.$$

Ex 18 Élect présidentielle II

A en st, pt-on conclure que le candidat A va gagner de moins de 5% d'erreur.

Sondage sur $N = 1000$.

X_1, \dots, X_N i.i.d Bern(0).

Le candidat A ?

\Rightarrow test statistiq.

① choix hypo

② constuct zone de rejet

③ Cal.

Rq en 5 (Central telephoniq)

à Lehtchev, on obtient un meilleur résultat qu'avec Hoeffding.

① Choix hypo.

H_0 : "A ne gagne pas", H_1 : "A gagne"

$$H_0: \theta \leq \frac{1}{2}$$

$$H_1: \theta > \frac{1}{2}$$

② Construc de la zone de rejet

$$\text{Problème : } S_N = \sum_{i=1}^N X_i, \quad R_0 = \{S_N > 500\}$$

$$\sup_{0 \leq \theta \leq 0,5} P_0(S_N > 500) = P_{0,5}(S_N > 500) \approx \frac{1}{2}$$

$$\text{or sous } P_{0,5}, \quad S_N \sim \text{Bin}(N, \frac{1}{2})$$

$$N - S_N \sim \text{Bin}(N, \frac{1}{2})$$



si on affirme que A gagne si $S_N > 500$,
alors on a une chance de se tromper.

$$R = \{S_N \geq k\} \text{ tq } \sup_{\theta \leq 0,5} P_\theta(S_N \geq k) \leq 0,05.$$

car $\theta \mapsto P_\theta(S_N \geq k)$ est croissante.

$$\text{Koeffeling : } P_\theta(S_m - m\theta \geq m\epsilon) \leq e^{-2m\epsilon^2}$$

$$= P_\theta\left(\frac{S_m}{m} - \theta \geq \epsilon\right) \leq e^{-2m\epsilon^2}$$

$$k = N \cdot \frac{1}{2} + N\epsilon, \epsilon = \sqrt{\frac{1}{1000} \ln\left(\frac{1}{0,05}\right)}, N = 1000$$

$$e^{-2N\epsilon^2} \leq 0,05.$$

$$R_F = \{S_{1000} > 539\}.$$

$$\textcircled{3} \quad \text{cel : } S_{1000}(w_1) = 507, w_1 \notin R$$

$$(w_2) = 494, w_2 \in R.$$

Ex 13 Un nouveau traitement ?

Tumeurs à cellules géantes. Nouveauté. Étude n° 35 pat.

\Rightarrow dépend de θ au tt sur 30 pat.

On affirme que le tt est efficace à 85%.

1) Mettant en doute les propos de son médecin, elle effectue un test stat.

Pt de vue de la patiente ?

H_0 : "Le tt n'est pas efficace" $\theta \leq 0,85$

H_1 : "Le tt est efficace" $\theta > 0,85$

2) Pt de vue médecin

H_0 : "Le tt est efficace" $\theta \geq 0,85$

H_1 : "Le tt n'est pas efficace"

d'avoir une ipat.

3) Constante de tests.

α_{35} : nb pers ayant resp \oplus à tt. Opération inconnue

$R_\theta = \{S_{35} \geq k_\theta : k_\theta = \min \{k \in \{0, \dots, 35\}, P_{0,85}(S_{35} \geq k) \leq \alpha\}$

On va prendre un niveau α tel que $\sup_{\theta \leq 0,85} P_\theta(R^\alpha) \leq \alpha$

ou $\theta \mapsto P_\theta(S_{35} \geq k_\theta) \rightarrow$ de $\sup_{\theta \leq 0,85} P_\theta(S_{35} \geq k_\theta)$

$\alpha = 5\%$.

$\sup_{\theta \leq 0,85} P_\theta(S_{35} \geq k_\theta) = P_{0,85}(S_{35} \geq k_\theta)$

Fiche n°2 : Variables aléatoires discrètes

Ex 1 : Contrôle qualité

mon plume

On souhaite contrôler qualité f_t d'une usine produisant des ampoules. p : proba deampoule défectueuse. On considère que la fabrique à un régime normal qd $p = 10^{-3}$.

1) On préleve au hasard 500 ampoules indép & on note X le nbr d'ampoules défectueuses de ce lot. Loi de $\textcircled{a} X$? Approx loi qd régime est normal.

$X \sim \text{Bin}(500, p)$ (sous P_H).

p la proba inconnue de produire une ampoule défectueuse.

→ si le régime est normal sous P_{H_0} : $X \sim \text{Bin}(500, 10^{-3})$, la loi de X pt être approchée par la loi de Poisson $\mathcal{P}\left(\frac{1}{2}\right)$. " $\text{Bin}(n, p)$ approchée par $\mathcal{P}(np)$ qd n grande".

(*)

2) $\textcircled{a} X$, construire un test permettant de déterminer si fabrique à un régime normal ou si elle est déterioré, sachant que l'on souhaite que la proba de condamne à tort que le régime est déterioré soit inférieure à 5%. Quelle est la taille du test? Que conclut si on observe $X(10) = 3$? Obtient-on m'a tel^e qd nro 18 "régime déterioré": H_1 / "rég. normal": H_0

P_{H_0} ("condamne H_1 ") ≤ 2 .

$H_0: p = 10^{-3}$ contre $H_1: p > 10^{-3}$ où $m \leq \textcircled{a}$

⇒ Construire le test à l'aide de statmox :

Zone de rejet: $R_{0.05} = \{X \geq k\}$

tg $P_{10^{-3}}(X \geq k) \leq 0.05$.

(ou

\textcircled{a} sup $P_p(X \geq k) \leq 0.05$
 $p \leq 10^{-3}$

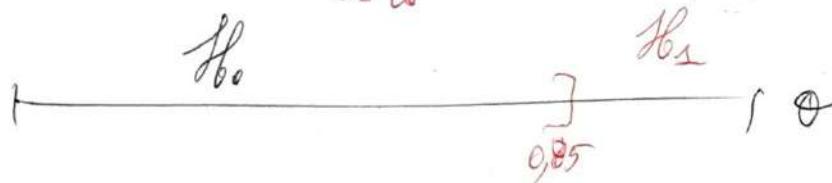
Retour en 19: $\alpha = 0,05$.

$$P_{0,85}(S_{35} > k_{5\%}) \leq 0,05.$$

$$\Leftrightarrow P_{0,85}(S_{35} \leq k_{5\%} - 1) \geq 0,95$$

$k_{5\%} = 34$

33%

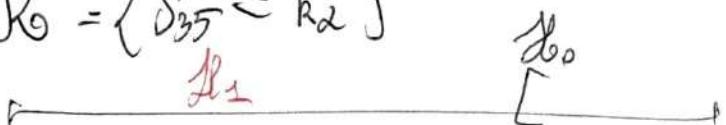


On observe $S_{35}(\omega) = 30$, $\omega \notin R^{5\%}$

On ne peut pas conclure que H_1 est efficace à +85%.
→ si on inverse:

$H_0: \theta \geq 0,85$ contre $H_1: \theta < 0,85$.

$$R^2 = \{S_{35} \leq k_2\}$$



$\cancel{H_0}$

$\{S_{35} \leq \frac{25}{35}\}$

(21)^b

$k_x = \max \{k \in \{0, \dots, 35\} : \sup_{\theta > 0,85} P_\theta(S_{35} \leq k) \leq \alpha\}$

or $\theta \mapsto P_\theta(S_{35} \leq k) = 1 - P_\theta(S_{35} \geq k+1)$ et

en 0. Donc $\sup_{\theta > 0,85} P_\theta(S_{35} \leq k) = P_{0,85}(S_{35} \leq k)$

$\alpha = 0,05$, $k_{5\%} = 25$

$$R_{5\%} = \{S_{35} \leq 25\}.$$

$\text{cl} \sim S_{35}(\omega) = 30$. $\omega \notin R_{5\%}$.
On ne peut pas conclure que H_1 est efficace.
(au moins de 85%).

[Dans les 2 cas, on conclut H_0 sans contrôler la proba de se tromper.]

$$\text{or } P_{10^{-3}}(X \geq k) \approx P(S_{2k}(\frac{1}{2}) \geq k)$$

$$R_0 = \{X \geq 3\} \quad P(S(\frac{1}{2}) \geq k) \leq 0,05 \\ P(S(\frac{1}{2}) \leq k-1) \geq 0,95$$

$$k-1=2, \quad k=3$$

Taille du test: $P_{10^{-3}}(X \geq 3) = 1 - 0,986 = 0,14$.
si on observe $X(w) = 3, \quad w \in \mathbb{R}$.

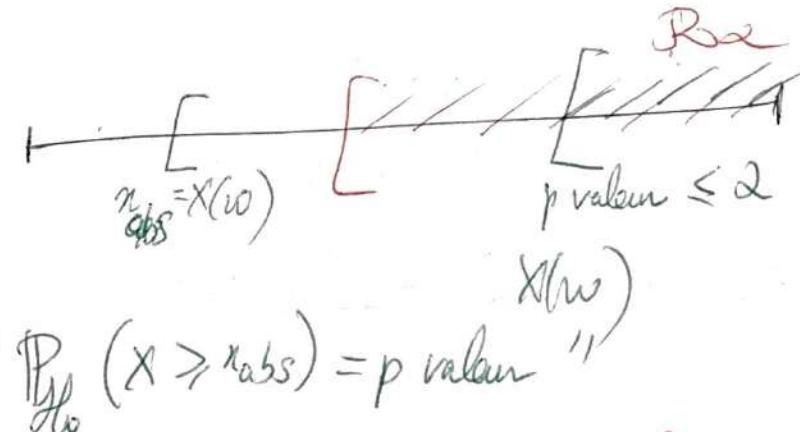
\Rightarrow on rejette H_0 & on conclut que le régime est déterioré.

\rightarrow la p-valeur est $P_{10^{-3}}(X \geq 3) = 1,4\% \leq 5\%$

• Pour un test à 1% :

p-valeur $>$ niv 1%

$w \notin R_0$, on ne peut pas conclure que le régime est déterioré : $R_{0,01} = \{X \geq 9\}$



$$\text{"}P_{H_0}(X \geq x_{\text{abs}}) = \text{p valeur}"$$

3) Supposons que p soit en réalité $2 \cdot 10^{-3}$.
Quelle est la proba de déclarer ce qu'il, à l'issue du test de niv 0,5%, que le régime de fabrication est normal?

$$p = 2 \cdot 10^{-3}, \quad P_{2 \cdot 10^{-3}}(R^c) = P_{2 \cdot 10^{-3}}(X \leq 2) \\ \text{erreur de grande espèce} = 92\%.$$

- an m. 7. -

Exo : Attente aux guichets.

Nbr pers. de file d'attente donnée et $\textcircled{1}$ de loi de Poisson
et param. θ $\xrightarrow{\text{bien}}$ date. On a dénombré 8 dates \rightarrow ville A,
tq $\textcircled{2}$ X_1, \dots, X_{10} st indép & n° loi Pois(θ) $\theta > 0$.

1) Calculer l'estimateur du max de vraisemblance du param θ ?

Qelle est la loi sous P_0 ?

$\rightarrow f$ de vraisemblance: pr $\theta > 0$: $f(x_1, \dots, x_n) \in \mathbb{R}^*$

$$V(\theta, x_1, \dots, x_m) = \prod_{i=1}^m P_\theta(X_i = x_i) = \prod_{i=1}^m \left(\frac{\theta^{x_i}}{x_i!} e^{-\theta} \right)$$

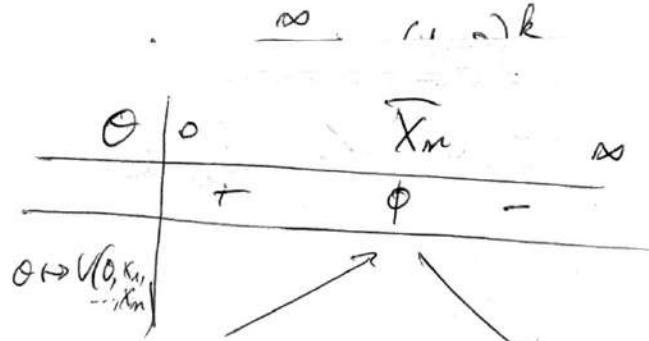
$$= \frac{\theta^{\sum x_i}}{\prod_{i=1}^m x_i!} e^{-m\theta}$$

$$\rightarrow \hat{\theta}_m = \operatorname{argmax}_{\theta > 0} V(\theta, x_1, \dots, x_m) = \operatorname{argmax}_{\theta > 0} \ln V(\theta, x_1, \dots, x_m)$$

$$\rightarrow \ln V(\theta, x_1, \dots, x_m) = \ln \left(\frac{\theta^{\sum x_i}}{\prod_{i=1}^m x_i!} e^{-m\theta} \right) = \ln \left(\frac{\theta^{\sum x_i}}{\prod_{i=1}^m x_i!} \right) - m\theta$$

$$= \ln(\theta^{\sum x_i}) - m\theta - \ln(\prod_{i=1}^m x_i!) = \sum_{i=1}^m x_i (\ln \theta) - m\theta - \ln(\prod_{i=1}^m x_i!)$$

$$\text{or } \frac{\partial}{\partial \theta} \ln V(\theta, x_1, \dots, x_m) = \sum_{i=1}^m x_i - m$$



$$\hat{\theta}_m = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}_m$$

$$\text{Résoudre } \frac{\sum x_i}{\theta} - n = 0$$

Quelle est la loi sous P_0 ?

loi de $\hat{\theta}_m$ sous P_0 , $P_0(\hat{\theta}_m = \theta) = 0$

$\hat{\theta}_m$ prend des valeurs dans $\{ \frac{k}{10}, k \in \mathbb{N} \}$

$$\text{pr } n=10, \hat{\theta}_{10} = \frac{1}{10} \sum_{i=1}^{10} x_i$$

$\hat{\theta}_{10}$ à valeurs dans $\{ \frac{k}{10}, k \in \mathbb{N} \}$

$$P_0(\hat{\theta}_{10} = \frac{k}{10}) = P_0\left(\sum_{i=1}^{10} X_i = k\right) = \frac{(100)^k}{k!} e^{-100}$$

car $\sum_{i=1}^{10} X_i \sim \text{Pois}(100)$.

(somme de $\textcircled{1}$ indép. de la de Poisson)

si $X \sim \text{Pois}(\alpha)$, $Y \sim \text{Pois}(\beta)$, X & Y indép

$\Rightarrow X+Y \sim \text{Pois}(\alpha+\beta)$.

L'estimation du max de vraisemblance est

$$\hat{\theta}_{10}(\Omega) = \left\{ \frac{k}{10}, k \in \mathbb{N} \right\}, \quad \forall x \in \hat{\theta}_{10}(\Omega). \quad \text{Zone de Rejet}$$

$$P_\theta(\hat{\theta}_{10} = n) = \frac{(10\theta)^{10n}}{(10n)!} e^{-10\theta}$$



2) les valeurs observées sont : 3, 0, 2, 4, 2, 5, 1, 4, 3, 8. Puisque on accepte l'hypothèse nulle si il ya en moy. moins d'une personne attendante au guichet au niveau 5% ?

Test statistique: Choisir des hypothèses

$$P_\theta(X=n) = \frac{\theta^n}{n!} e^{-\theta}, \quad \theta = E_\theta(X_i)$$

"Il y a en moyenne moins d'une personne q' attend" $\Leftrightarrow \theta \leq 1$

Pf de vue des clients: $H_0: \theta \geq 1$

Pf de vue de la banque: $H_1: \theta < 1$

Admis $\theta \mapsto P_\theta(X \geq k)$,

si $X \sim \text{Pois}(\theta)$ sous P_θ est croissante (en θ)

Seuil est déterminé par: $\sup_{\theta \leq 1} P_\theta\left(\sum_{i=1}^{10} X_i \geq k\right) \leq 0,05$

$$\text{Or } \sup_{\theta \leq 1} P_\theta\left(\sum_{i=1}^{10} X_i \geq k\right) = P_1\left(\sum_{i=1}^{10} X_i \geq k\right)$$

et sous P_1 , $\sum_{i=1}^{10} X_i \sim \text{Pois}(10)$.

$$P_1\left(\sum_{i=1}^{10} X_i \geq k\right) \leq 0,05 \Leftrightarrow P_1\left(\sum_{i=1}^{10} X_i \leq k-1\right) \geq 0,95$$

$$k-1=15, \quad k=16$$

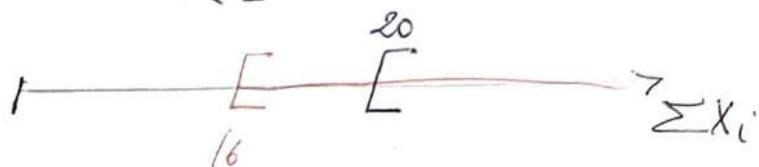
$$P_0 = \left\{ \sum_{i=1}^{10} X_i \geq 16 \right\} = \left\{ \hat{\theta}_{10} \geq 1,6 \right\}$$

Crit Test On observe $\sum_{i=1}^{10} X_i(10) = 20$, $\hat{\theta}_{10}(10) = 2$

De $w \in P_0 \Rightarrow$ dc on rejette H_0 .

On conclut qu'il ya + d'une personne en moyenne q' attend au guichet.

• p-valeur: $\sup_{\theta \leq 1} P_\theta \left(\sum_{i=1}^{10} X_i \geq 20 \right) = 0,003$



On aurait aussi rejété par un test à 1%.

$$P_1 \left(\sum_{i=1}^{10} X_i \geq 20 \right) = 1 - P_1 \left(\sum_{i=1}^{10} X_i \leq 19 \right)$$

$$= 1 - 0,997 = 0,003.$$

E8.3: Estimation du paramètre d'une loi géométrique.

• la géométrique $\theta \in [0,1[$ est celle du temps d'attente du 1^{er} succès
• Dans les épreuves répétées on a une épreuve de probabilité de succès θ .

Une $\forall k \in \mathbb{N}^*$, $P_\theta(X=k) = (1-\theta)^{k-1} \theta$.

1) Vérifier $E_\theta(X) = \frac{1}{\theta}$, $V_{\theta}(X) = \frac{1-\theta}{\theta^2}$

• $\sup_{\theta \in [0,1]} P_\theta \left(\sum_{i=1}^{10} X_i \geq k \right)$

• $(\Omega, \mathcal{F}, P_\theta)$ où $\Omega = \{x_1, \dots, x_m\}$ associé à l'échantillon x_1, \dots, x_m . X_i est P_θ -indép & indép de P_θ . où $S_n = \sum_{i=1}^n X_i$.

a) Donner la vraisemblance associée à l'échantillon x_1, \dots, x_n

$$V(\theta, x_1, \dots, x_n) = \prod_{i=1}^n P_\theta(X_i = x_i) = \prod_{i=1}^n [\theta(1-\theta)^{x_i-1}]$$

$$= \theta^m (1-\theta)^{\sum_{i=1}^n x_i - m}$$

à maximiser en θ .

$$\ln V(\theta, x_1, \dots, x_n) = m \ln(\theta) + \left(\sum_{i=1}^n x_i - m \right) \ln(1-\theta)$$

$$\frac{\partial L(\theta, x_1, \dots, x_n)}{\partial \theta} = \frac{m}{\theta} + \frac{\sum_{i=1}^n x_i - m}{1-\theta} = \frac{m(1-\theta) - \theta(\sum_{i=1}^n x_i - m)}{\theta(1-\theta)}$$

s'annule en $\hat{\theta}_m = \frac{m}{S_m}$ où $S_m = \sum_{i=1}^m X_i$

$\hat{\theta}_m = \frac{m}{S_m}$ est l'estimateur de maximum de vraisemblance.

$$\hat{\theta}_m = \frac{m}{S_m}$$

c) L'estimateur est-il sans biais ? Fais-t-il consensus ?

$\hat{\theta}_m$ fait consensus de θ . $P_\theta(\hat{\theta}_m \xrightarrow{m \rightarrow \infty} \theta) = 1$.

• LFGN ←

• Définition (condition suffisante de LFGN p.s.).

$$\text{si } \sum_{n \geq 1} P_\theta(|\hat{\theta}_n - \theta| \geq \varepsilon) < \infty \Rightarrow \hat{\theta}_n \xrightarrow[m \rightarrow \infty]{P_\theta \text{ p.s.}} \theta$$

(R) LFGN: si $(X_i)_{i \in \mathbb{N}}$ st iid $E(X_1) < \infty$

$$\text{alors } \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{P_\theta \text{ p.s.}} E(X_1)$$

$$(LFGN) \quad \frac{S_n}{n} \xrightarrow[n \rightarrow \infty]{P_\theta \text{ p.s.}} E_\theta(X_1) = \frac{1}{\theta}$$

$$\Rightarrow \frac{m}{S_m} \xrightarrow[m \rightarrow \infty]{P_\theta \text{ p.s.}} \theta$$

Ouv en proba: $\forall \varepsilon > 0, P\left(\liminf_{n \rightarrow \infty} |\hat{\theta}_n - \theta| \geq \varepsilon\right) = 0$

$$\{\hat{\theta}_n \xrightarrow{n \rightarrow \infty} \theta\} = \bigcap_{\varepsilon > 0} \bigcap_{N \in \mathbb{N}} \{|\hat{\theta}_n - \theta| \leq \varepsilon \text{ pour } n \geq N\}$$

(R) $\hat{\mu}_m$ fortement constant de μ si $\hat{\mu}_m \xrightarrow[\mu \rightarrow \infty]{P_\theta \text{ p.s.}} \mu$

$$\hat{\mu}_m = \bar{X}_m^2, \quad \bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i$$

$$\bar{X}_m \xrightarrow[n \rightarrow \infty]{P_\theta \text{ p.s.}} \theta$$

$$P_\theta(\Omega') = 1:$$

$$\bar{X}_m \xrightarrow[n \rightarrow \infty]{P_\theta \text{ p.s.}} E_\theta(X_1) = \theta \quad \text{LFGN}$$

$$\forall w \in \Omega' \quad \bar{X}_m(w) \xrightarrow[n \rightarrow \infty]{} \theta$$

$$\bar{X}_m^2(w) \xrightarrow[n \rightarrow \infty]{} \theta^2$$

Ex 20 Charlatan

Médicament efficace à 90% (fabriquant)

Si 200 p., 160 guéris. Fab charlatan?

Pf de Vme du fabricant:

$$H_0: \theta \geq 0,9 \text{ contre } H_1: \theta < 0,9$$

Test à 5%: $R_\theta = \{ S_{200} \leq k \}$.

$$X_i = \begin{cases} 1 & \text{si la } i^{\text{e}} \text{ pers. guérit} \\ 0 & \text{sinon.} \end{cases}$$

$$S_{200} = \sum_{i=1}^{200} X_i \sim \text{Bin}(200, \theta) \text{ sous } R_\theta.$$

Avec Hoeffding: $\{ S_{200} \leq 162 \} \rightarrow$ explicat

$$P_{0,9}(S_{200} \leq 162) \leq 0,05$$

$$(Rg: P_{0,9}(S_{200} \leq 173) \leq 0,05)$$

explicat: k est déterminé par $\sup_{\theta \geq 0,9} P_\theta(S_{200} \leq k) \leq 0,05$

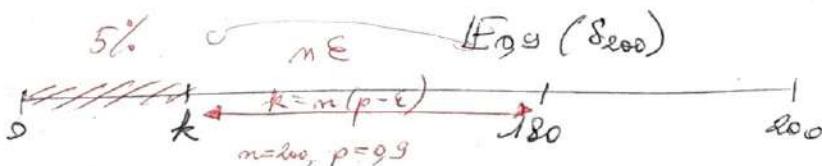
"proba de conclure H_1 "

alors que c'est H_0 qui est vraie"

$$\theta \mapsto P_\theta(S_{200} \leq k) = 1 - P_\theta(S_{200} \geq k+1)$$

est décroissante en θ .

$$\Rightarrow \sup_{\theta \geq 0,9} P_\theta(S_{200} \leq k) = P_{0,9}(S_{200} \leq k)$$



On cherche k : $P_{0,9}(S_{200} \leq k) \leq 0,05$

$$k = 200 \times 0,9 - 200 \epsilon$$

$$P_{0,9}(S_{200} \leq 200 \times 0,9 - 200 \epsilon) = P_{0,9}\left(\frac{S_{200}}{200} - 0,9 \leq -\epsilon\right) \leq e^{-200\epsilon}$$

On choisit $\epsilon > 0$ tq $e^{-200 \times \epsilon} \leq 0,05$

$$\epsilon \geq \sqrt{\frac{1}{200} \ln(0,05)}$$

$$k = \left[200 \times 0,9 - 200 \times \sqrt{\frac{1}{200} \ln(0,05)} \right]$$

Calc On observe $S_{200}(w) = 160$, $w \in R_\theta$ de
on rejette H_0 et on conclut que le tt n'est pas
efficace à 90%. (4-5% de chance de se tromper)

(28) [Annoncer à l'entier inférieur]

p-valeur : val¹⁰ observé

$$P_{0,9} (S_{200} \leq 160) = P_{0,9} (S_{200} - 180 \leq -20)$$

vraie valeur $\leq e^{-400 \left(\frac{1}{10}\right)\varepsilon} = e^{-4} = 0,018$

$1,7 \cdot 10^{-5}$

Autre pt de vue :

$$\mathcal{H}_0: \theta \leq 0,9 \text{ contre } \mathcal{H}_1: \theta > 0,9$$

$$P_0 = P(S_{200} \geq k')$$

$$k' \text{ tel que } \sup_{\theta \leq 0,9} P_\theta (S_{200} \geq k') \leq 0,05 \Leftrightarrow P_{0,9} (S_{200} \geq k') \leq 0,05$$

$$k = 200 \times 0,9 + 100\varepsilon$$

$$P_{0,9} \left(\frac{S_{200} - 180}{\sqrt{200}} \geq \varepsilon \right) \leq e^{-400 \varepsilon^2} \leq 0,05.$$

$$\text{Pour } \varepsilon > \sqrt{\frac{1}{400} \ln(0,05)}, \quad k = 180 + 18 = 198.$$

$$\{S_{200} \geq 197,31\} = \{S_{200} \geq 198\}$$

et $\theta \notin \mathcal{B}_0$, on ne rejette pas \mathcal{H}_0 .

p valeur $P_{0,9} (S_{200} \geq 160) \approx 99\%$.

Ex 21 : Une pièce truquée (Δ test bilatéral)

On lance pièce 6 fois, on obtient 6 "face".

Pt-on conclure au RG de 5% ou 1%

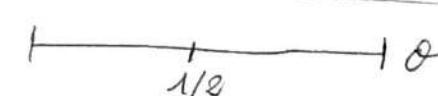
que la pièce n'est pas équilibrée.

On constitue un test unilateral ou bilatéral?

test bilatéral $\mathcal{H}_0: \theta = \frac{1}{2}$ contre $\mathcal{H}_1: \theta \neq \frac{1}{2}$.

test unilateral $\mathcal{H}_0: \theta = \frac{1}{2}$ contre $\mathcal{H}_1: \theta < \frac{1}{2}$.

Test bilatéral :



$$\mathcal{B}_0 = \{S_6 \leq k_1 \text{ ou } S_6 \geq k_2\}$$

Diagram showing a number line from 0 to 1 with tick marks at 0,5%. The region S_6 is divided into three parts: a central region between the two rejection boundaries, and two tail regions labeled k_1 and k_2 at the 0,5% points.

k_1 & k_2 sont déterminés par

$$P_{\frac{1}{2}} (S_6 \leq k_1) + P_{\frac{1}{2}} (S_6 \geq k_2) \leq 0,05.$$

$$k_1: P_{\frac{1}{2}} (S_6 \leq k_1) \leq 0,025$$

$$k_2: P_{\frac{1}{2}} (S_6 \geq k_2) \leq 0,025$$

$$R_0 = \{S_6 \leq 0\} \cup \{S_6 \geq 6\} = \{S_6 \in \{0, 6\}\}$$

On observe $S_6(w) = 0$: $w \in R_0$: on conclut que la pièce n'est pas équilibrée.

$$\left(P_{X_2}(S_6 - 3 \leq -6\varepsilon) \leq e^{-12\varepsilon^2} \right) \text{ comment pas.}$$

$\varepsilon \geq \sqrt{-\frac{1}{12} \ln(0.05)}$, ?

taille du test : $\frac{1}{2^5} = 3,12\%$

$$P_{\frac{1}{2}}(S_6 = 0) = \frac{1}{2^6}, P(S_6 \leq 1) = \frac{1}{2^6}(1+6) \approx 9,1$$

$$= 0,0156 \quad \cancel{P(S_6 \leq 0) = \frac{1}{2^6}}$$

Ex 22 Dé 3600 lancers, 640 fois \rightarrow chiffre 6.
P-t-il conclure que la pièce équilibrée à moins 5% de chances de se tromper? On effectue test stat.

1) $P(300 \leq X \leq 700) \geq 0,9923$ Koeffeling
 $\geq 0,95$ BT.

2) Interv de conf: $X \sim \text{Bin}(3600, \theta)$

$$\hat{I} = \left[\frac{x}{3600} - 0,023; \frac{x}{3600} + 0,023 \right]$$

$$P_\theta(\theta \in \hat{I}) \geq 0,95.$$

3) Test stat: $H_0: \theta = \frac{1}{6}$ contre $H_1: \theta \neq \frac{1}{6}$.
"pt-on de la loi mal équilibrée + $\geq 5\%$ chance de se tromper".
 H_1 : mal équilibré.

$$R_0 = \{X \leq 500\} \cup \{X \geq 700\}$$

On observe $X(w) = 640$.

On a $w \notin R_0$; on ne rejette pas H_0 , on ne pt pas conclure que la loi est mal équilibrée.

$$\text{Résultat: } \left\{ \frac{P_{\text{ops}}}{X_n} \right\} \text{ LF6N.}$$

Proba: $g: \mathbb{R} \rightarrow \mathbb{R}$ est cont en ℓ & si $X_n \xrightarrow[n \rightarrow \infty]{P.s} \ell$
alors $g(X_n) \xrightarrow[n \rightarrow \infty]{P.s} g(\ell)$.

Preuve: $\Omega' = \{\omega \in \Omega : X_n(\omega) \xrightarrow[n \rightarrow \infty]{} \ell\}$.
 $P(\Omega') = 1$.

$\forall \omega \in \Omega': g(X_n(\omega)) \xrightarrow{n \rightarrow \infty} g(\ell)$ car g cont en ℓ .
 $\Rightarrow \{\omega \in \Omega : g(X_n(\omega)) \xrightarrow{n \rightarrow \infty} g(\ell)\} \supset \Omega'$
 $\Rightarrow P(g(X_n) \xrightarrow{n \rightarrow \infty} g(\ell)) = 1$.

$$\bullet E_\theta(\hat{\theta}_n) = E_\theta\left(\frac{n}{S_n}\right) = n E_\theta\left(\frac{1}{S_n}\right)$$

$$@ n=2, E(X_1) = \sum_{h \in \mathbb{N} \cup \mathbb{R}} \frac{1}{2} P(X_1 = h)$$

$$= \sum_{k \in \mathbb{N}^*} \frac{1}{k} \theta(1-\theta)^{k-1} = \frac{\theta}{1-\theta} \sum_{k=1}^{\infty} \frac{(1-\theta)^{k-1}}{k}$$

$$\hat{\theta}(\theta)$$

$$f(\theta) = \sum_{k=1}^{\infty} \frac{(1-\theta)^k}{k}$$

$$f'(\theta) = \sum_{k=1}^{\infty} - (1-\theta)^{k-1} = - \frac{1}{1-(1-\theta)} = \frac{-1}{\theta}$$

$$f''(\theta) = -\ln(\theta)$$

$$E_\theta\left(\frac{1}{X_1}\right) = \frac{-\partial \ln \theta}{1-\theta} \neq 0.$$

Rq: On peut faire un développement asymptotique de $E_\theta\left(\frac{n}{S_n}\right)$.

$$\text{Rq: } E_\theta\left(\frac{n}{S_n}\right) = \sum_{k \leq n} \frac{1}{k} P_\theta(S_n = k) \text{ & on}$$

connait pour $k \geq n$:

$$P_\theta(S_n = k) = \binom{n-1}{k-1} \theta^k (1-\theta)^{n-k}$$

loi binomiale négative.

(31)

3) Construire un intervalle de confiance \hat{I}_m au niveau 95% pour θ à l'aide de D(BT).

si on a la certitude que $\theta > \frac{1}{4}$? Peut-on utiliser l'inégalité de Hoeffding?

$P\left(\left|\frac{s_m}{n} - \frac{1}{\theta}\right| \geq \varepsilon\right)$ fournit \hat{I}_m pour $\frac{1}{\theta}$ de niveau 95%

$P\left(\left|\frac{s_m}{n} - \mathbb{E}(X_1)\right| \geq \varepsilon\right) \Rightarrow$ intervalle \hat{I}_m tq $P_\theta(\theta \in \hat{I}_m) \geq 0.95$

(R) BT : $(X_i)_{i \in \mathbb{N}}$ iid de variance finie.

$$P\left(\left|\frac{s_m}{n} - \mathbb{E}(X_1)\right| \geq m\varepsilon\right) \leq \frac{\text{Var}_\theta(X_1)}{m\varepsilon^2}$$

à appliquer aux $(X_i)_{i \in \mathbb{N}}$ iid de loi Géo(θ) dans P_θ .

$$P\left(\left|\frac{s_m}{n} - \frac{1}{\theta}\right| \geq \varepsilon\right) \leq \frac{\text{Var}_\theta(X_1)}{m\varepsilon^2} = \frac{1-\theta}{\theta^2 m \varepsilon^2}$$

$$\leq \frac{1^{1/4}}{(\frac{1}{4})^2} \times \frac{1}{m\varepsilon^2} = \frac{12}{m\varepsilon^2} \leq 0,05.$$

$\theta > \frac{1}{4}$ par hypo de l'énoncé

$$\text{da } f \quad \theta \mapsto \frac{(1-\theta)}{\theta^2}$$

Pour $\varepsilon \geq \sqrt{\frac{12}{0,05m}}$

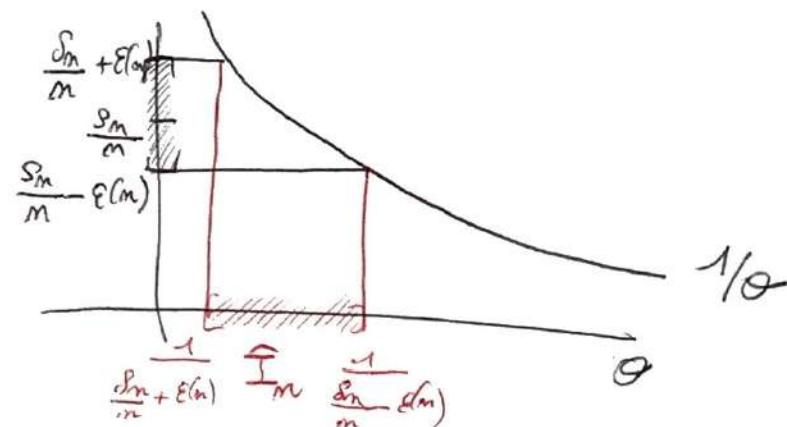
$$\varepsilon(n) = \sqrt{\frac{12}{0,05m}}$$

$$P_\theta\left(\left|\frac{s_m}{n} - \frac{1}{\theta}\right| \geq \varepsilon(n)\right) \leq 0,05$$

\Rightarrow intervalle \hat{I}_m tq $P_\theta(\theta \in \hat{I}_m) \geq 0.95$

$P_\theta\left(\frac{1}{\theta} \in \hat{I}_m\right) \geq 0.95$.

$$\hat{I}_m = \left[\frac{s_m}{n} - \varepsilon(n), \frac{s_m}{n} + \varepsilon(n)\right]$$



$$\hat{I}_m = \left[\frac{1}{\theta(n)} + \frac{s_m}{n}, \frac{1}{\theta(n)} - \frac{s_m}{n}\right] \cap [0, 1] = \left[\frac{\theta(n)}{1 + \varepsilon(n)\theta(n)}, \frac{\theta(n)}{1 - \varepsilon(n)\theta(n)}\right] \cap [0, 1]$$

ou $\frac{s_m}{n} - \varepsilon(n) \leq \frac{1}{\theta} \leq \frac{s_m}{n} + \varepsilon(n)$ ou $\frac{1}{\frac{s_m}{n} + \varepsilon(n)} \leq \theta \leq \frac{1}{\frac{s_m}{n} - \varepsilon(n)}$

(32)

On ne peut pas appliquer Hoeffding à $S_m = \sum_{i=1}^m X_i$ car les $(X_i)_{1 \leq i \leq n}$ ne sont pas bornées.

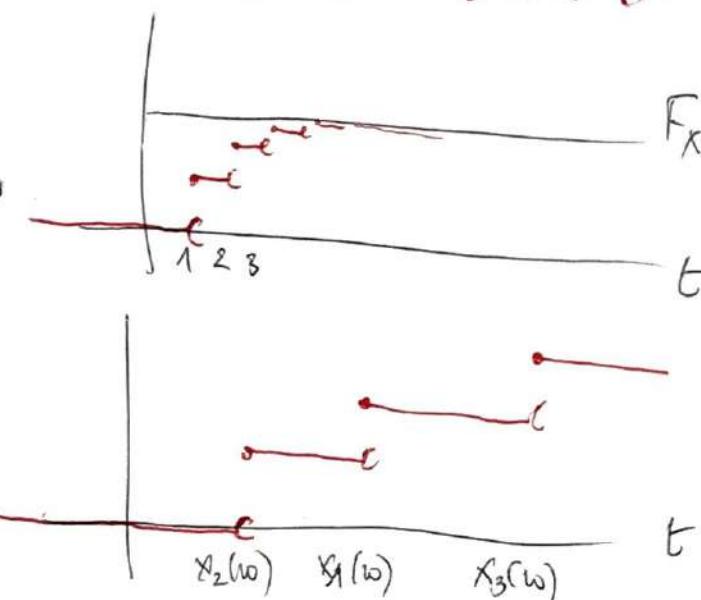
4) a) of table échantillon observé de taille 200.

Reproduisez & complétez le tableau. Utilisez le pour dessiner f de Répartition empirique obtenu à partir d'échantillon. Unité verticale 10 cm

R) Fonction de Répartition empirique

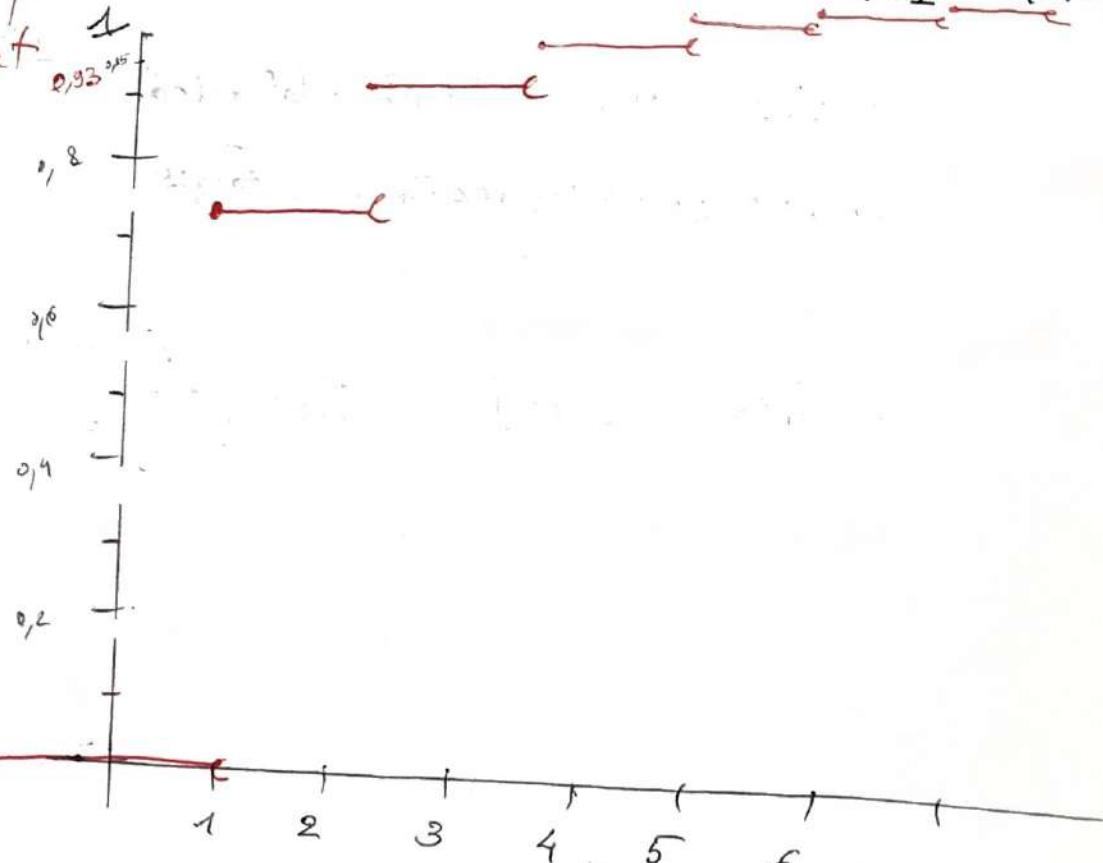
$$F_x(t) = P(X \leq t) = \mathbb{E}[1_{\{X \leq t\}}]$$

$$F_m(t) = \frac{1}{n} \sum_{i=1}^n 1_{\{X_i \leq t\}}$$



Value	1	2	3	4	5	6
Fréquence	0,73	0,2	0,035	0,025	0,005	0,005

$$146 = \sum_{i=1}^{200} \mathbb{1}_{\{X_i(\omega) = 1\}}, 40 = \sum_{i=1}^{200} \mathbb{1}_{\{X_i(\omega) = 2\}}$$



b) Calculez l'estimateur $\hat{\theta}_m$ de θ sur cet échantillon. (Δ c'est une approximation)

$$n=200, X_i(w) \in 1 \leq i \leq 200$$

$$\hat{\theta}_{200}(w) = \frac{200}{S_{200}(w)} \approx 0,72.$$

$$S_{200}(w) = 146 \times 1 + 10 \times 2 + 7 \times 3 + 5 \times 4 + 10.5 + 10.6$$

$$\frac{1}{\hat{\theta}_{200}(w)} = 109.78 + 8 \times 0.055 + 3 \times 0.025 + 4 \dots + 60.05$$

c) Donnez l'IdC I_{200} observé pour cet échantillon.

$$\hat{I}_{200}(w) = [0,402; 3,375], \quad \sigma(w) = \sqrt{\frac{12}{905 \times 200}}$$

5) Autre idée pour estimer θ : (1) param $\text{va. Bernoulli } Y_i$ valant 1 si succès à i^{e} épreuve, 0 sinon.

Comment tableau $X_R(w)$ de 4) permet de reconstituer $Y_i(w)$.

et val $\bar{Y}_n(w)$ des $Y_i(w)$ puis IdC $_{95\%} \mu \theta$
sur l'intervalle de $\bar{Y}_n(w)$. Pj!

$$Y_i, \quad P_\theta(Y_i=1)=\theta$$

$$(y_i), \quad \overbrace{1, 0, 1, 1, 1, \dots}^{x_2 \text{ et } x_3}$$

X_i 1^e succès après $X_i=1$.

$\sum y_i = 200$ nbr de succès.

$$\begin{aligned} \text{Nbr d'échecs : } & 40 + \underbrace{2 \times 7}_{\substack{40 \text{ échecs} \\ \times 3}} + 3 \times 5 + 4 \times 1 + 5 \times 1 = 78 \\ & 2 \times 7 \end{aligned}$$

$$\sum_{i=1}^{278} y_i = 200 \quad \text{nbr de succès}$$

$$\bar{Y}_{278}(w) = \frac{200}{278}$$

Le "278" est le résultat d'une va.

Variables aléatoires à densité

Ex6 Estimation du param d'une loi exponentielle

1) Soit $X \text{ (1)} \sim \text{Exp}(\theta)$, de densité $f_{\theta}(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$, où $\theta \in [0, \infty[$. Vérifia $E(X) = \frac{1}{\theta}$, $V(X) = \frac{1}{\theta^2}$.

Astuce: $\int_{-\infty}^{\infty} (n - \frac{x}{\theta})^2 \theta e^{-\theta x} dx$

$$E_{\theta}(X) = \frac{1}{\theta} = \int_{\mathbb{R}} x f_{\theta}(x) dx = \int_{\mathbb{R}} x \theta e^{-\theta x} dx.$$

$$\text{Var}_{\theta}(X) = E_{\theta}(X^2) - E_{\theta}(X)^2 = \int_{\mathbb{R}} x^2 \theta e^{-\theta x} dx - [E_{\theta}(X)]^2$$

$$\Delta E_{\theta}(\varphi(x)) = \int_{\mathbb{R}} \varphi(x) f_{\theta}(x) dx.$$

2) On se propose d'estimer $\theta > 0$ d'une loi expo $\text{Exp}(\theta)$, au vu d'un échantillon x_1, \dots, x_m de grande taille.

Plus précisément, on considère que x_i est de (2) δ^{e} position, def $m (\Omega, \mathcal{F}, P_0)$ $\theta \in [0, \infty[$ & si $t + \theta \in [0, \infty[$, P_0 -indépendantes & m loi $\text{Exp}(\theta)$ sur P_0 . μ_m , $T_m = \sum_{i=1}^m x_i$ & $\bar{T}_m = \frac{m}{\delta_m}$.

Calculer l'estimateur du max de vraisemblance de vraisemblance $\theta > 0$ $(x_1, \dots, x_m) \in \mathbb{R}$.

$$V(\theta, x_1, \dots, x_m) = \prod_{i=1}^m f_{\theta}(x_i)$$

$$= \prod_{i=1}^m \theta e^{-\theta x_i} \mathbf{1}_{[0, \infty[}(x_i))$$

$$= \theta^m e^{-\theta \sum_{i=1}^m x_i} \mathbf{1}_{[0, \infty[}(\min(x_i)) = \theta^m e^{-\theta \sum_{i=1}^m x_i}$$

$$L(\theta, x_1, \dots, x_m) = m \ln \theta - \theta \sum_{i=1}^m x_i$$

$$\frac{\partial}{\partial \theta} L(\theta, x_1, \dots, x_m) = \frac{m}{\theta} - \sum_{i=1}^m x_i$$

$\theta \mapsto V(\theta, x_1, \dots, x_m)$ atteint son max en $\bar{T}_m = \frac{m}{\delta_m}$.

T_m est l'estimateur du max de maximum biaisé de θ . 4) Justifiez la convergence en loi sous P_0 dans \mathbb{R}^{n+1} ,
 T_m est-il fortement consistant?

$$\frac{\partial S_{m-m}}{\sqrt{m}} \xrightarrow[m \rightarrow \infty]{\text{loi}} Z$$

! Réfère à avoir utilisé la Loi des Grands Nombres

LFGN : si $(X_i)_{i \in \mathbb{N}}$ suit la loi P_0 alors $\mathbb{E}(X_i) = \theta \Rightarrow \sum X_i \xrightarrow{P_0} \mathbb{E}(X)$

$$T_m = \frac{1}{m} \sum_{i=1}^m X_i \xrightarrow[m \rightarrow \infty]{P_0} \theta$$

3) Est-ce que $E_\theta(T_m) = \theta$ (si oui, on dit que T_m est sans biais).

$$E_\theta(T_m) = E_\theta(\frac{1}{m} S_m) = m E_\theta(\frac{1}{m} X_1)$$

$$m=1, S_1 = X_1, E_\theta\left(\frac{1}{m} X_1\right) = \int_{\mathbb{R}} \frac{1}{n} f_\theta(n) dn$$

$$E_\theta\left(\frac{1}{n} X_1\right) = \int_n^\infty \frac{1}{n} \theta e^{-\theta n} dn = \infty$$

T_1 n'est pas sans biais.

FCL

appliquée aux $(X_i)_{i \in \mathbb{N}} \sim i.i.d$ & de certaines intégrales sous P_0 .

$$\frac{1}{\theta} \cdot z_m = \frac{\sqrt{m} \cdot \overline{X}_m - E_\theta(X_1)}{\sqrt{Var_\theta(X_1)}} = \frac{S_m - m E_\theta(X_1)}{\sqrt{m Var_\theta(X_1)}}$$

$$E_\theta(z_m) = 0 \text{ et } Var_\theta(z_m) = 1$$

R) $Var_\theta(S_m) = Var_\theta\left(\sum_{i=1}^m X_i\right) = \sum_{i=1}^m Var_\theta(X_i)$ car les $(X_i)_{i \in \mathbb{N}}$ sont indépendantes

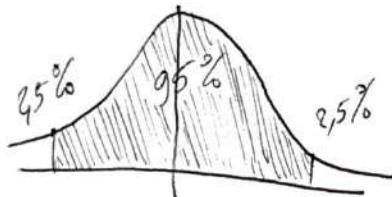
$$= m E_\theta(X_1) = m Var_\theta(X_1)$$

$$\frac{S_m - m E_\theta(X_1)}{\sqrt{m Var_\theta(X_1)}} = \frac{S_m - \frac{m}{\theta}}{\sqrt{\frac{m}{\theta^2}}} = \frac{\frac{1}{\theta} S_m - \frac{m}{\theta}}{\sqrt{\frac{m}{\theta^2}}} = \frac{\frac{1}{\theta} S_m - \frac{m}{\theta}}{\sqrt{m}} \xrightarrow[m \rightarrow \infty]{P_0 \text{ loi}} Z$$

5) En déduire, I_{DC} pour θ à niveau de confiance 0,95 en négligeant l'erreur due à l'approx. gaussienne. (Appli num. si $n=400$, $S_{400}(w) = 1460$)

$$P_0 \left(\left| \frac{\theta S_m - m}{\sqrt{m}} \right| \leq \varepsilon \right) \xrightarrow[m \rightarrow \infty]{} P(|Z| \leq \varepsilon)$$

$$\text{et } \text{tg } P(|Z| \leq \varepsilon) = 0,95, \quad \varepsilon = \Phi^{-1}(0,975) = 1,96.$$



$$\left\{ \left| \frac{\theta S_m - m}{\sqrt{m}} \right| \leq \varepsilon \right\} = \left\{ \theta \in \hat{I}_m(\varepsilon) \right\}$$

$$= \left\{ \theta \in \left[\frac{m - \varepsilon \sqrt{m}}{S_m}, \frac{m + \varepsilon \sqrt{m}}{S_m} \right] \right\}$$

$$\hat{I}_m(\varepsilon) = \left[\frac{m}{S_m} \left(1 - \frac{\varepsilon}{\sqrt{m}} \right), \frac{m}{S_m} \left(1 + \frac{\varepsilon}{\sqrt{m}} \right) \right]$$

$\hat{I}_m(1,96)$ est un intervalle de confiance pour θ de niveau asymptotique 95%.

$$P_0(\theta \in \hat{I}_m(1,96)) \xrightarrow[m \rightarrow \infty]{} 0,95.$$

(37)

Ex5 Estimation de la durée d'une panne.

m ordi; $t=0$: panne ordi, redémarrage au bout de γ . Pour i de 1 à m : quel temps T_i après début panne, l' i^{e} requête ordi i est acceptée par le serveur.

$X_i = T_i - \gamma$ entre redémarrage & 1^e requête ordi i .

$X_i \sim \text{Exp}(\lambda)$ $1 \leq i \leq n$; a supposé connue, $\lambda > 0$

X_i indép.

$\hookrightarrow \frac{1}{n}$ temps moyen entre le redémarrage du serveur & 1^e requête

2) φ est la loi de $\text{V}_n = \inf(X_1, \dots, X_m)$.

⚠ $\hookrightarrow f$ de répartition ou f de densité.

$$F_X(t) = P(X \leq t) \quad f_X(t) = P(X > t)$$

$$\forall t \in \mathbb{R}, \quad P_\varphi(V_n > t) = P_\varphi \left(\bigcap_{i=1}^m \{X_i > t\} \right)$$

$$= \prod_{i=1}^m P_\varphi(X_i > t) = \left[P_\varphi(X_1 > t) \right]^m \text{ car les } (X_i)_{1 \leq i \leq n} \text{ sont indép.}$$

$$\text{a } P_\varphi(X_1 > t) = \int_t^\infty a e^{-ax} dx = e^{-at} \text{ ont la même loi. } \quad a > 0$$

$$P_\varphi(V_n) = \begin{cases} 1 & \text{si } t < 0 \\ e^{-mat} & \text{si } t \geq 0 \end{cases}$$

, $V_n \sim \text{Exp}(ma)$

$$F_{V_n}(t) = (1 - e^{-mat}) \mathbf{1}_{[0, \infty]}(t)$$

(R) f de survie d'une loi $\exp(a)$

$$f_a(t) = \begin{cases} 1 & \text{si } t < 0 \\ e^{-at} & \text{si } t \geq 0 \end{cases}$$

$$= \int_0^\infty \varphi(t) a e^{-a(t-\gamma)} dt.$$

$$= \int_{-\infty}^{\gamma} \varphi(t) a e^{-a(t-\gamma)} \underbrace{1_{[\gamma, \infty]}(t)}_{f_\gamma(t)} dt$$

\Rightarrow Maximalité

$$V(\gamma, T_1, \dots, T_m) = \prod_{i=1}^m f_\gamma(T_i)$$

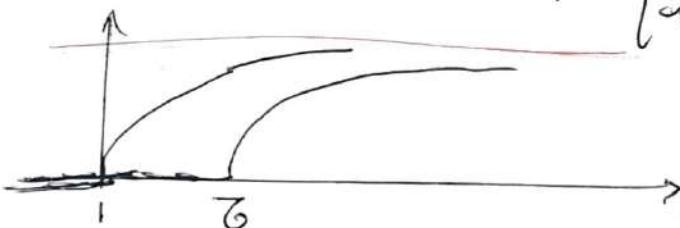
$$= \prod_{i=1}^m a e^{-a(T_i-\gamma)} \underbrace{1_{[\gamma, \infty]}(T_i)}_{f_\gamma(T_i)}$$

$$\cong a^n e^{-a \sum_{i=1}^n T_i} e^{na\gamma} \prod_{i=1}^n \underbrace{1_{[\gamma, \infty]}(T_i)}_{f_\gamma(T_i)}$$

i) Estimer la durée γ de T_1, \dots, T_m en utilisant M max de vraisemblance. On note W_m l'estimateur obtenu.

$$\bullet P(T_i \leq t) = P(X_i + \gamma \leq t) = P(X_i \leq t - \gamma)$$

$$= F_a(t - \gamma) = \begin{cases} 0 & \text{si } t - \gamma < 0 \\ 1 - e^{-a(t-\gamma)} & \text{si } t - \gamma \geq 0. \end{cases}$$



Donc T_i a une densité (durée de $f_d R^*$)

$$f_\gamma(n) = a e^{-a(n-\gamma)} \underbrace{1_{[\gamma, \infty]}(x)}_{f_\gamma(x)}.$$

• Autre M:

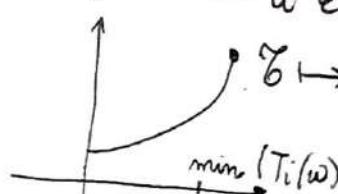
$$E_\gamma(\varphi(T_1)) = \int_{-\infty}^{\infty} \varphi(t) f_\gamma(t) dt = \int_{-\infty}^{\infty} \varphi(x+\gamma) a e^{-ax} \underbrace{1_{[0, \infty]}(x)}_{f_\gamma(x)} dx$$

$$= \int_0^\infty \varphi(x+\gamma) a e^{-ax} dx$$

(38)

$$= \underbrace{1}_{[-\infty, \min_{1 \leq i \leq n} T_i]}(\gamma)$$

$$\cong a^n e^{-a \sum_{i=1}^n T_i} e^{na\gamma} \underbrace{1_{[-\infty, \min_{1 \leq i \leq n} T_i]}(\gamma)}_{f_\gamma(\gamma)}$$



De l'estimateur du maximum de vraisemblance de γ est $W_m = \min_{1 \leq i \leq n} T_i$.

3) Calculer le biais de W_m . est un estimateur sans biais Z_m de la durée de panne. Quelle est la variance de ce nouvel estimateur ?

$$W_m = \min_{1 \leq i \leq m} \{T_i\} \quad \text{et} \quad T_i = \gamma + X_i.$$

$$\min_{1 \leq i \leq m} (T_i) = \gamma + \min_{1 \leq i \leq m} (X_i) \Leftrightarrow W_m = \gamma + V_m$$

$$E_\gamma(W_m) = \gamma + E_\gamma(V_m) = \gamma + \frac{1}{ma}$$

W_m n'est pas un estimateur sans biais de γ .
(il est asymptotiquement sans biais)

→ Z_m sans biais : $Z_m = W_m - \frac{1}{ma}$ car a est connu.

$$E_\gamma(Z_m) = \gamma.$$

$$\text{Var}_\gamma(Z_m) = \text{Var}_\gamma(W_m) = \text{Var}_\gamma(V_m) = \frac{1}{(ma)^2}$$

4) Fabriquer un autre estimateur sans biais de γ , en utilisant cette fois la moyenne empirique \bar{T}_m des T_i . Quelle est sa variance ?

$$\bar{T}_m = \frac{1}{m} \sum_{i=1}^m T_i, \quad E_\gamma(\bar{T}_m) = E_\gamma(T_1) = \gamma + \frac{1}{a}$$

$R_m = \bar{T}_m - \frac{1}{a}$ est un estimateur sans biais & fortement consistant de γ .
¶ la loi forte des grands nombres

$$\begin{aligned} \text{Var}_\gamma(R_m) &= \text{Var}_\gamma(\bar{T}_m) = \frac{1}{m^2} \sum_{i=1}^m \text{Var}_\gamma(T_i) \\ &= \frac{1}{m} \text{Var}_\gamma(T_1) = \frac{1}{m} \text{Var}_\gamma(X_1) = \frac{1}{ma^2}. \end{aligned}$$

④ $\text{Var}_\gamma(Z_m) \ll \text{Var}_\gamma(R_m)$.

↳ Z_m est meilleur que R_m .

On peut aussi montrer Z_m est un estimateur fortement consistant de γ .

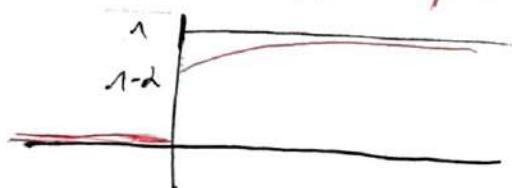
(1a) loi discrète ou à densité

Supposons que X pluie (mm d'eau tombée en 24h) est modélisée par loi dont f de répartition est

$$F_{\alpha, \beta}(x) = (1 - \alpha e^{-\beta x}) \mathbb{1}_{[0, \infty)}(x).$$

où $\alpha \in [0, 1]$ & $\beta > 0$ et paramètres inconnus.

1) tracer $F_{\alpha, \beta}$ ($\beta @ \alpha = \frac{1}{4}$, $\beta = 2$).



2) Probabilité pour pluie = 0: $P_{\alpha, \beta}(X=0)$

$$P_{\alpha, \beta}(X=0) = F_{\alpha, \beta}(0) - F_{\alpha, \beta}(0-) = F_{\alpha, \beta}(0) = 1-\alpha.$$

3) Loi de X discrète ? à densité ?

Si $\alpha = 1$, $F_{\alpha, \beta}$ est continue sur \mathbb{R} dérivable p max de x dc X est à densité.

• Si $\alpha \neq 1$, $F_{\alpha, \beta}$ n'est pas continue dc X n'est pas à densité'.

* X est-elle discrète?

// non car la somme des probas ne vaut pas 1.

$$4) \text{Mq } E_{\alpha, \beta}(X) = \frac{2}{\beta}.$$

X est une variable positive.

$$E_{\alpha, \beta}(X) = \int_0^\infty P_{\alpha, \beta}(X > t) dt = \int_0^\infty 1 - F_{\alpha, \beta}(t) dt$$

$$E_{\alpha, \beta}(X) = \int_0^\infty 1 - (1 - \alpha e^{-\beta t}) \mathbb{1}_{[0, \infty)}(t) dt$$

$$= \int_0^\infty \alpha e^{-\beta t} dt = \alpha \left[-\frac{e^{-\beta t}}{\beta} \right]_0^\infty = \frac{\alpha}{\beta}.$$

5) X_1, \dots, X_n iid tel que X
 $X_1(w), \dots, X_{30}(w)$ observées au mois de mai 2016 en mm et donnés p: cf tableau

Construire un estimateur sans biais & consistant $\hat{\alpha}_m$ du paramètre α . On pourra exprimer ce paramètre en fonction des jours sans précipitation N_m .

$\hat{\alpha}_m$ estimateur de α .

$$N_m^o = \sum_{i=1}^m \mathbb{1}_{\{X_i=0\}} \quad \text{nbr jours sans précipitation}$$

$$\hat{\alpha}_m = \frac{m - N_m^o}{m} = \frac{1}{m} \sum_{i=1}^m \mathbb{1}_{\{X_i>0\}}$$

Estimateur sans biais de α :

$$\text{avec } \mathbb{E}_{\alpha, \beta}(\hat{\alpha}_m) = \frac{1}{m} \sum_{i=1}^m \underbrace{\mathbb{E}_{\alpha, \beta}(\mathbb{1}_{\{X_i>0\}})}_{P_{\alpha, \beta}(X_i > 0) = \alpha} = \alpha$$

Estimateur fortement consistant de α par LFGN (p.s.)

appliquée à $Y_i = \mathbb{1}_{\{X_i>0\}}$

iid intégrables.

$$\frac{1}{m} \sum_{i=1}^m Y_i \xrightarrow[m \rightarrow \infty]{P_{\alpha, \beta} \text{ p.s.}} \mathbb{E}_{\alpha, \beta}(Y_i) = \alpha$$

$$\text{i.e. } \hat{\alpha}_m \xrightarrow[m \rightarrow \infty]{P_{\alpha, \beta} \text{ p.s.}} \alpha$$

6) Donner l'pt asymptotique de la loi de $\hat{\alpha}_m$ et IDC au $\alpha = 95\%$.

par le TLC appliqué aux (Y_i) i.i.d de carres intégrables :

$$\sqrt{n} \frac{\bar{Y}_n - \mathbb{E}_{\alpha, \beta}(Y_i)}{\sqrt{\text{Var}_{\alpha, \beta}(Y_i)}} \xrightarrow[n \rightarrow \infty]{P_{\alpha, \beta} \text{ loi}} \mathcal{Z} \sim \mathcal{N}(0, 1).$$

$$\bar{Y}_n = \hat{\alpha}_m \quad , \quad \mathbb{E}_{\alpha, \beta}(Y_i) = \alpha$$

$$\text{Var}_{\alpha, \beta}(Y_i) = \alpha(1-\alpha) \quad , \quad Y_i \sim \text{Bin}(\alpha)$$

$$\sqrt{n} \frac{\hat{\alpha}_m - \alpha}{\sqrt{\alpha(1-\alpha)}} \xrightarrow[n \rightarrow \infty]{P_{\alpha, \beta} \text{ loi}} \mathcal{Z}$$

$$\text{NB: } Z_m = \sqrt{n} \frac{\hat{\alpha}_m - \alpha}{\sqrt{\alpha(1-\alpha)}} \quad \hat{\alpha}_m \approx \alpha + \sqrt{\frac{\alpha(1-\alpha)}{n}} \mathcal{Z}$$

La loi de $\hat{\alpha}_m$ est approchée par $\mathcal{N}\left(\alpha, \sqrt{\frac{\alpha(1-\alpha)}{n}}\right)$

$$P_{\alpha, \beta} \left(\sqrt{n} \frac{|\hat{\alpha}_m - \alpha|}{\sqrt{\alpha(1-\alpha)}} \leq \varepsilon \right) \xrightarrow{n \rightarrow \infty} P(|\alpha| \leq \varepsilon) \approx 0,95$$

$\mu \varepsilon = 1,96$
 $= \underline{0,975}$.

2 Méthodes

- ① majorant de variance $\alpha(1-\alpha)$
- ② estimation de la variance

(a) $P_{\alpha, \beta} \left(\alpha \in \left[\hat{\alpha}_m - 1,96 \sqrt{\frac{\alpha(1-\alpha)}{m}} ; \hat{\alpha}_m + 1,96 \sqrt{\frac{\alpha(1-\alpha)}{m}} \right] \right) \xrightarrow{n \rightarrow \infty} 0,95$

$$\leq P_{\alpha, \beta} \left(\alpha \in \left[\hat{\alpha}_m - \frac{1,96}{2\sqrt{m}} ; \hat{\alpha}_m + \frac{1,96}{2\sqrt{m}} \right] \right)$$

$$\Rightarrow \liminf_{n \rightarrow \infty} P_{\alpha, \beta} \left(\alpha \in \left[\hat{\alpha}_m - \frac{1,96}{2\sqrt{m}} ; \hat{\alpha}_m + \frac{1,96}{2\sqrt{m}} \right] \right) \geq 0,95.$$

③ Estimation de la variance : TLC & auto-normalisat.:

$$\sqrt{n} \frac{\hat{\alpha}_m - \alpha}{\sqrt{\hat{\alpha}_m(1-\hat{\alpha}_m)}} \xrightarrow[n \rightarrow \infty]{P_{\alpha, \beta} \text{ lim}} Z \sim N(0,1)$$

$$\Rightarrow P_{\alpha, \beta} \left(\alpha \in \left[\hat{\alpha}_m - 1,96 \sqrt{\frac{\hat{\alpha}_m(1-\hat{\alpha}_m)}{m}} ; \hat{\alpha}_m + 1,96 \sqrt{\frac{\hat{\alpha}_m(1-\hat{\alpha}_m)}{m}} \right] \right) \xrightarrow{n \rightarrow \infty} 0,95$$

$$\hat{I}_m^M = \left[\hat{\alpha}_m - \frac{1,96}{2\sqrt{m}} ; \hat{\alpha}_m + \frac{1,96}{2\sqrt{m}} \right]$$

$$\hat{I}_m^E = \left[\hat{\alpha}_m - 1,96 \sqrt{\frac{\hat{\alpha}_m(1-\hat{\alpha}_m)}{m}} ; \hat{\alpha}_m + 1,96 \sqrt{\frac{\hat{\alpha}_m(1-\hat{\alpha}_m)}{m}} \right]$$

$n=30, \hat{\alpha}_{30}(w) = \frac{14}{30}$

$$\hat{\Sigma}_{30}^M(w) =$$

$$\hat{\Sigma}_{30}^E(w) =$$

7) PT- on conclut qu'il ne pleut pas plus d'un jour sur 2 à ray d'erreur d'un plus 5%. On effectuera un test à niv 5%.

$$H_0: \alpha \geq \frac{1}{2} \text{ contre } H_1: \alpha < \frac{1}{2}$$

en justifiant ce choix d'hypothèses.

$$H_0: \alpha \geq \frac{1}{2} \text{ contre } H_1: \alpha < \frac{1}{2}$$

$$1-\alpha \leq \frac{1}{2}$$

$$1-\alpha > \frac{1}{2}$$

"il ne fait pas beau de temps"
 "il fait beau de temps"

"il fait beau de temps"
 "il fait beau de temps"

$$R_{5\%} = \{ \hat{x}_m \leq t_{5\%} \}$$

$$\sup_{\alpha \geq 1/2} P_{\alpha, \beta} (\hat{x}_m \leq t_{5\%}) \leq 0,05$$

$$\alpha \geq \frac{1}{2}$$

$$\sup_{\alpha \geq 1/2} P_{\alpha, \beta} \left(\sum_{i=1}^m \mathbb{1}_{\{x_i > 0\}} \leq k_{5\%} \right)$$

$$= P_{\frac{1}{2}, \beta} \left(\sum_{i=1}^m \mathbb{1}_{\{x_i > 0\}} \leq k_{5\%} \right) \text{ p TLC}$$

Trueur $k_{5\%} = \min \{ k \in \{0, \dots, m\} : P_{\frac{1}{2}, \beta} \left(\sum_{i=1}^m \mathbb{1}_{\{x_i > 0\}} \leq k \right) \leq 0,05 \}$ $P(2 \leq z_{0,05}) = 0,05$

$$P_{\frac{1}{2}, \beta} \left(\sum_{i=1}^m \mathbb{1}_{\{x_i > 0\}} \leq k_{5\%} \right)$$

$$= P_{\frac{1}{2}, \beta} \left(\frac{\sum_{i=1}^m \mathbb{1}_{\{x_i > 0\}} - \frac{m}{2}}{\sqrt{m} \frac{1}{2} (1 - \frac{1}{2})} \leq \frac{k_{5\%} - \frac{m}{2}}{\frac{\sqrt{m}}{2}} \right)$$

en négligeant l'erreur d'approx gaussienne.

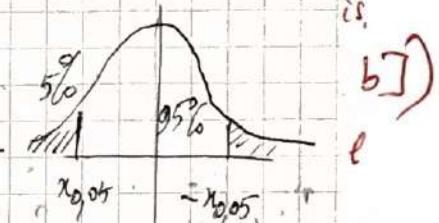
$$\Rightarrow \underset{\frac{\sqrt{m}}{2}}{\approx} P \left(Z \leq \frac{k_{5\%} - \frac{m}{2}}{\frac{\sqrt{m}}{2}} \right) = 0,05$$

$$\Rightarrow \frac{k_{5\%} - \frac{m}{2}}{\frac{\sqrt{m}}{2}} = \Phi^{-1}(0,05)$$

$$\text{NB: } \frac{S_m - \mathbb{E}(S_m)}{\sqrt{\text{Var}(S_m)}} = \frac{S_m - m \mathbb{E}(X_1)}{\sqrt{m} \sqrt{\text{Var}(X_1)}}$$

$$= \sqrt{m} \frac{S_m - \mathbb{E}(X_1)}{\sqrt{\text{Var}(X_1)}}$$

$$\Phi^{-1}(0,05) = z_{0,05} = -1,645$$



b])

en $\sqrt{m} z$

$$k_{5\%} = \left\lfloor \frac{m}{2} - 1,645 \frac{\sqrt{m}}{2} \right\rfloor =$$

$$: m = 30, \quad \left\lfloor 15 - 1,645 \frac{\sqrt{30}}{2} \right\rfloor = 10.$$

$$R_{5\%} = \left\{ \sum_{i=1}^{30} \mathbb{1}_{\{x_i > 0\}} \leq 10 \right\}$$

$w \notin R_{5\%}$: on ne peut pas conclure θ_1 .

i) erreurs intégrables unées.

On définit $\hat{P}_m = \frac{\sum_{i=1}^m \mathbb{I}_{\{X_i \neq 0\}}}{\sum_{i=1}^m X_i}$

(R9) \hat{P}_m est bien défini pour tout grand

$\hat{P}_{2,1}$

8) Par conséquent, $\frac{\sum_{i=1}^m X_i}{\sum_{i=1}^m \mathbb{I}_{\{X_i \neq 0\}}} > 0$

et Mme indic : Calculer $P_{\alpha, \beta}(\sum_{i=1}^m X_i = 0)$

$$\textcircled{a} \quad P_{\alpha, \beta}(\sum_{i=1}^m X_i = 0) = P_{\alpha, \beta}(\cap_{i=1}^m \{X_i = 0\})$$

$\leq \prod_{i=1}^m P_{\alpha, \beta}(X_i = 0)$ car les $(X_i)_{1 \leq i \leq m}$ sont indép.

$\leq \hat{P}_m^m$ car $P_{\alpha, \beta}(X_i = 0)$ est la min de

$\Rightarrow \delta := (1 - \hat{P}_m)^m$

$$\textcircled{b} \quad P_m = \left\{ \sum_{i=1}^m X_i = 0 \right\}$$

$\textcircled{c} \quad \boxed{\text{B.C.}} \quad \text{si } \sum_{m=1}^{\infty} P_{\alpha, \beta}(A_m) < \infty \Leftrightarrow P_{\alpha, \beta}(\bigcap_{m \in \mathbb{N}, m > 0} A_m^c) = 1$

D'après $P_{\alpha, \beta}(\bigcup_{m \in \mathbb{N}, m \geq m_0} A_m^c) = 1$

Donc par minimum + apdng les A_m ne se relâchent plus

$$\Rightarrow \sum_{i=1}^m X_i > 0$$

$\hookrightarrow \exists \Omega' \in \mathcal{F}^0 \text{ tq } P_{\alpha, \beta}(\Omega') = 1 \quad \& \quad \forall w \in \Omega'$

$\exists m(w) \in \mathbb{N}^*$ tq $m > n \Rightarrow P_{\alpha, \beta}(A_m) > 0$
 $\Rightarrow \hat{P}_m(w)$ est borné

plus progressivement

$$\hat{P}_m(w) = \begin{cases} 0 & \text{si } \sum_{i=1}^m X_i(w) = 0 \\ \frac{1}{\sum_{i=1}^m X_i(w)} & \text{sinon} \end{cases}$$

2) Mq \hat{P}_m est un estimateur fortement convergent

de P .

$$\textcircled{d} \quad \hat{P}_m = \frac{\text{card}(\mathcal{I})}{\sum_{i \in \mathcal{I}} X_i} \quad \leftarrow \frac{1}{\sum_{i \in \mathcal{I}} X_i}$$

mais les indices étant aléatoires, on ne peut pas utiliser directement la forte des

grands nbs.

On sait que $P_{\alpha, \beta} \text{ est ps}$

$$\frac{1}{n} \sum_{i=1}^n \mathbb{I}_{\{X_i \neq 0\}} \xrightarrow[n \rightarrow \infty]{\text{LFTG}} P_{\alpha, \beta}(X_1 \neq 0) = \alpha$$

$$\frac{1}{n} \sum_{i=1}^n X_i \xrightarrow[n \rightarrow \infty]{\text{LFTG}} \mathbb{E}_{\alpha, \beta}(X_1) = \frac{\alpha}{\beta}$$

$$\exists \Omega_\alpha \in \mathcal{F}^0 : P_{\alpha, \beta}(\Omega_\alpha) = 1 \text{ et } \forall w \in \Omega_\alpha \quad \frac{1}{\sum_{i=1}^m X_i(w)} \xrightarrow[m \rightarrow \infty]{} \alpha$$

$\exists \Omega_2 \in \mathcal{F} : P_{\alpha, \beta}(\Omega_2) = 1$ et $\forall w \in \Omega_2 : \text{TD.3}$

$$\frac{1}{n} \sum x_i(w) \xrightarrow{n \rightarrow \infty} \frac{\alpha}{\beta}.$$

et $P_{\alpha, \beta}(\Omega_1 \cap \Omega_2) = 1$ car $P_{\alpha, \beta}(\Omega_1^c \cup \Omega_2^c)$

$$P_{\alpha, \beta}(\Omega_1^c \cup \Omega_2^c) \leq P_{\alpha, \beta}(\Omega_1^c) + P_{\alpha, \beta}(\Omega_2^c) = 0$$

(R*) si $(\Omega_i)_{i \in \mathbb{N}}$ est une suite d'événements de proba 1 alors $P(\bigcap_{i \in \mathbb{N}} \Omega_i) = 1$.

$$(R') \bar{X}_{\hat{I}} = \frac{1}{\text{card}(\hat{I})} \sum_{i \in \hat{I}} X_i.$$

$$\sum_{i \in \hat{I}} X_i = \sum_{i=1}^n X_i \mathbf{1}_{\{i \in \hat{I}\}}$$

$$\text{card}(\hat{I}) = \sum_{i=1}^n \mathbf{1}_{\{i \in \hat{I}\}}$$

(Q*) LFGN $Y_i = \mathbf{1}_{\{X_i \neq 0\}} \sim \text{Bern}(P_{\alpha, \beta}(X_i \neq 0))$

$$\frac{1}{n} \sum_{i=1}^n Y_i \xrightarrow{n \rightarrow \infty} \mathbb{E}_{\alpha, \beta}(Y_1).$$

$$\mathbb{E}_{\alpha, \beta}(Y_1) = \mathbb{E}_{\alpha, \beta}(\mathbf{1}_{\{X_1 \neq 0\}}) = P_{\alpha, \beta}(X_1 \neq 0).$$

(Q5)

Application du TCL

Ex 1 : Cumul d'erreurs

Problème : calculer la proba que le cumul d'erreurs soit significatif au seuil $\alpha = \frac{1}{2} \cdot 10^{-5}$ après $n = 10^6$ succès. Erreurs indépendantes $U_i \sim \text{Unif}([-\frac{1}{2} \cdot 10^{-5}, \frac{1}{2} \cdot 10^{-5}])$ et $a = -\frac{1}{2} \cdot 10^{-5}$, $b = \frac{1}{2} \cdot 10^{-5}$ & erreur totale finale est la somme des erreurs commises n chq opér.

1) Evaluer proba qu'en n^{e} finale soit $\leq \frac{1}{2} \cdot 10^{-5}$ en vrac

$U_i \sim \text{Unif}([-\frac{1}{2} \cdot 10^{-5}, \frac{1}{2} \cdot 10^{-5}])$ l'erreur de la i^{e} opér.

L'erreur finale est $U = \sum_{i=1}^n U_i$.

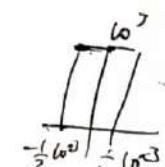
$$P(|U| \leq \frac{1}{2} \cdot 10^{-5})$$

TCL $\frac{S_n - \mathbb{E}(S_n)}{\sqrt{\text{Var}(S_n)}} \xrightarrow[n \rightarrow \infty]{\text{Loi}} Z \sim \mathcal{N}(0, 1)$ car les $(U_i)_{i \in \mathbb{N}}$ sont de variables intégrables et ont des moments finis.

$$\bullet \mathbb{E}(U_1) = 0 = \int_{-\frac{1}{2} \cdot 10^{-5}}^{\frac{1}{2} \cdot 10^{-5}} u \, du$$

$$\bullet \text{Var}(U_1) = \mathbb{E}(U_1^2) - \mathbb{E}^2(U_1) = \mathbb{E}(U_1^2) = \int u^2 \cdot 10^{-5} \mathbf{1}_{[-\frac{1}{2} \cdot 10^{-5}, \frac{1}{2} \cdot 10^{-5}]}(u) \, du$$

$$f(u) = \frac{1}{5 \cdot 10^{-5}} \mathbf{1}_{[0, 1]}(u) : \text{densité} = 10^5$$



$$\textcircled{R} \quad \frac{\delta_m - \mathbb{E}(\delta_m)}{\sqrt{\text{Var}(\delta_m)}} = \frac{\delta_m - m \mathbb{E}(X_1)}{\sqrt{m} \text{Var}(X_1)}$$

$$= \sqrt{m} \frac{\frac{\delta_m - \mathbb{E}(X_1)}{\sqrt{\text{Var}(X_1)}}}{\sqrt{\text{Var}(X_1)}} = \sqrt{m} \frac{\overline{X}_m - \mathbb{E}(X_1)}{\sqrt{\text{Var}(X_1)}}$$

on $\text{Var}(\delta_m) = \text{Var}\left(\sum_{i=1}^m X_i\right)$

$\stackrel{\text{indep}}{=} \sum_{i=1}^m \text{Var}(X_i)$

$= m \text{Var}(X_1)$

$$\begin{aligned} \text{Var}(X_1) &= \mathbb{E}(X_1^2) - \mathbb{E}(X_1)^2 \\ &= 10^5 \int_{-\frac{1}{2}10^{-5}}^{\frac{1}{2}10^{-5}} x^2 dx = 10^5 \left[\frac{x^3}{3} \right]_{-\frac{1}{2}10^{-5}}^{\frac{1}{2}10^{-5}} \\ &= 10^5 \left[\frac{1}{2^{3+3}} 10^{-35} + \frac{1}{2^{3+3}} 10^{-35} \right] = \frac{1}{12} 10^{-25} \end{aligned}$$

P le TOL

$$\frac{\delta_m}{\sqrt{\frac{m}{12}} 10^{-5}} \xrightarrow{\text{loi}} Z \sim \mathcal{N}(0, 1)$$

(46)

$$\begin{aligned} \mathbb{P}(|\delta_m| \leq \frac{1}{2} 10^{-5+3}) &= \mathbb{P}\left(\frac{|\delta_m|}{\sqrt{\frac{m}{12}} 10^{-5}} \leq \frac{\frac{1}{2} 10^{-5+3}}{\sqrt{\frac{m}{12}} 10^{-5}}\right) \\ &\simeq \mathbb{P}(|Z| \leq t) \quad \mu m = 10^6. \end{aligned}$$

$$\mathbb{P}(|\delta_m| \leq \frac{1}{2} 10^{-5+3}) \simeq \mathbb{P}(|Z| \leq \sqrt{3})$$

$$\begin{aligned} &= \Phi(\sqrt{3}) - \Phi(-\sqrt{3}) \\ &= 2\Phi(\sqrt{3}) - 1 \end{aligned}$$

$$= 2 \times 0.9582 - 1 \approx 92\%$$

(comparer Hoeffding)

2) On parle d'accordédi user (T) de Berry-Essen
pe majorer l'erreur commise de approx' fate.

$$|\mathbb{P}(|\delta_{10^6}| \leq \frac{1}{2} 10^{-5+3}) - (2\Phi(\sqrt{3}) - 1)| \leq$$

$$|\mathbb{P}(|\delta_{10^6}^*| \leq \sqrt{3}) - \mathbb{P}(|Z| \leq \sqrt{3})|$$

$$\leq |\mathbb{P}(\delta_{10^6}^* \leq \sqrt{3}) - \mathbb{P}(Z \leq \sqrt{3})|$$

$$- (\mathbb{P}(\delta_{10^6}^* \leq -\sqrt{3}) - \mathbb{P}(Z \leq -\sqrt{3}))|$$

$$\leq 1 \cdot 1 + 1 \cdot 1 \quad \text{et} \quad \delta_{10^6}^* = \frac{\delta_{10^6} \sqrt{12}}{10^{3-5}}$$

$$\textcircled{B} \leq \mathbb{E} \sup_{x \in \mathbb{R}} |\mathbb{P}(S_{100}^* \leq x) - \mathbb{P}(Z \leq x)|$$

$$\leq 2 \times \frac{1}{2} \frac{\rho^3}{c^3 \sqrt{100}} \leq 10^{-3} \frac{\rho^3}{\sigma^3}$$

$$\rho^3 = [\mathbb{E}[|U_1 - \mathbb{E}(U_1)|^3]] = \mathbb{E}[|U_1|^3]$$

$$\sigma^3 = (\rho^2)^{\frac{3}{2}} = \left(\frac{10^{-25}}{12}\right)^{\frac{3}{2}}, \text{ pose } a = 10^{-25}$$

$$= \left(\frac{1}{3^{3/2}} a^3\right)$$

$$\rho^3 = \frac{a^3}{4} = \frac{10^{-75}}{2^5}, \quad \frac{\rho^3}{\sigma^3} = \frac{3^{3/2}}{4}.$$

$$\begin{aligned} \rho^3 &= \mathbb{E}(|U_1|^3) = \int_{-a}^a |x|^3 \frac{1}{2a} dx \\ &= 2 \int_0^a |x|^3 \frac{1}{2a} dx = 2 \int_0^a x^3 \frac{1}{2a} dx \\ &= \frac{1}{a} \left[\frac{x^4}{4} \right]_0^a = \frac{a^3}{4} \end{aligned}$$

$$\leq \frac{3}{4} 10^{-3} = 0,026 = 2,6\%$$

(47)

Ex 2 Contrôle qualité

Une machine dépose pièces \rightarrow longueur $l_0: 20\text{mm}$. En temps normal, pièces ont longueur moyenne 20 mm , d'écart-type σ_0 de 1mm .

Si lot 120 pièces, long may $20,9\text{ mm}$ & comme des erreurs des longs est $52,692,9$.

1) Si on admet σ_0 n'a pas varié, pensez-vous que la machine est déréglée (constitue less than 5%)?

Q^{th} est la proba de conclure que la machine est déréglée si la moyenne du lot des 120 pièces est en réalité 21mm .

Modélisation: X tq $\mathbb{E}(X) = l_0$, $\text{Var}(X) = \sigma_0^2$.
 $n = 120$ pièces. X_1, \dots, X_n sous P_E , $\mathbb{E}(X_i) = l$
 $l \in \mathbb{R}^+$ inconnu.

Test: • Choix des hypothèses:

H_0 : "la machine est bien réglée contre H_1 : "machine est déréglée".

$$l = l_0$$

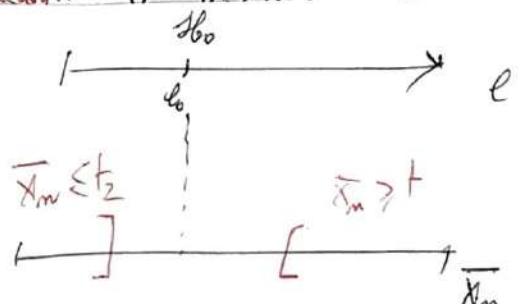
$$l \neq l_0$$

$\bar{X}_m = \frac{1}{m} \sum_{i=1}^m X_i$: estimateur sans biais de l .

→ estimateur fonction constant de l : $\frac{1}{n} \sum_{i=1}^n \bar{X}_i \xrightarrow{\text{PPS}} \mathbb{E}_{P_E}(X_i) = l$

p. CFGN

$$\sigma_0 = 1$$



$$R_{5\%} = \{ \bar{X}_m \leq t_2 \} \cup \{ \bar{X}_m \geq t_3 \} \quad t_1 < t_2 < t_3$$

$P_{P_0}(R_{5\%}) \leq 0,05 \Rightarrow$ on choisit t_1 & t_2 ,

$$P_{P_0}(\bar{X}_m \leq t_2) \leq 0,025 \text{ et } P_{P_0}(\bar{X}_m \geq t_3) \leq 0,025$$

M1 TCL $\sqrt{n} \frac{\bar{X}_m - l_0}{\sigma_0} \xrightarrow[n \rightarrow \infty]{P_{P_0} \text{ loi}} Z \sim N(0,1)$

On fait de $\sqrt{120} \frac{\bar{X}_{120} - l_0}{\sigma_0}$ sous P_{P_0} est approchée par la loi $N(0,1)$

$$\text{et } P_{P_0}\left(\sqrt{120} \frac{|\bar{X}_{120} - l_0|}{\sigma_0} \geq \varepsilon\right) \approx P(|Z| \geq \varepsilon) \underset{\uparrow}{\approx} 0,05$$

$$\begin{aligned} P(Z \geq \varepsilon) &= 0,025 \Leftrightarrow P(Z \leq -\varepsilon) = 0,975 \\ &= 2P(Z \geq \varepsilon) \end{aligned}$$

$$\triangle P(|Z| \geq \varepsilon) = P(Z \geq \varepsilon) + P(Z \leq -\varepsilon)$$

$$\begin{aligned} R_{5\%} &= \left\{ \sqrt{120} \frac{|\bar{X}_{120} - l_0|}{\sigma_0} \geq 1,96 \right\} \\ &= \left\{ \bar{X}_{120} \leq l_0 - 1,96 \sqrt{\frac{\sigma_0^2}{120}} \right\} \\ &\quad \cup \left\{ \bar{X}_{120} \geq l_0 + 1,96 \sqrt{\frac{\sigma_0^2}{120}} \right\} \end{aligned}$$

$$R_{5\%} = \{ \bar{X}_{120} \leq 19,82 \} \cup \{ \bar{X}_{120} \geq 20,18 \}$$

(c) On observe $\bar{X}_{120}(\omega) = 20,9 \text{ mm}$.

$\omega \in R_{5\%}$: on conclut que machine est défaillante.

M2 Uebiicher

$$\begin{aligned} P_{P_0}\left(\sqrt{120} \frac{|\bar{X}_{120} - l_0|}{\sigma_0} \geq \varepsilon\right) \text{ pr } \varepsilon > \frac{1}{\sqrt{0,05}} = 4,47 \\ \leq \frac{1}{\varepsilon^2} \leq 0,05. \end{aligned}$$

$$P_{P_0}(|\bar{X}_{120} - l_0| \geq \varepsilon) \leq \frac{\text{Var}_{P_0}(X_1)}{120 \varepsilon^2} = \frac{\sigma_0^2}{120 \varepsilon^2}$$

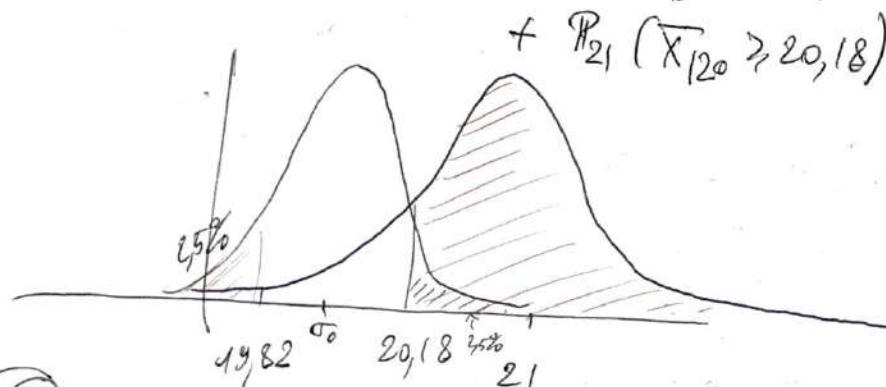
$$R_{5\%} = \{ \bar{X}_{120} \leq 19,59 \} \cup \{ \bar{X}_{120} \geq 20,41 \}$$

de K petite

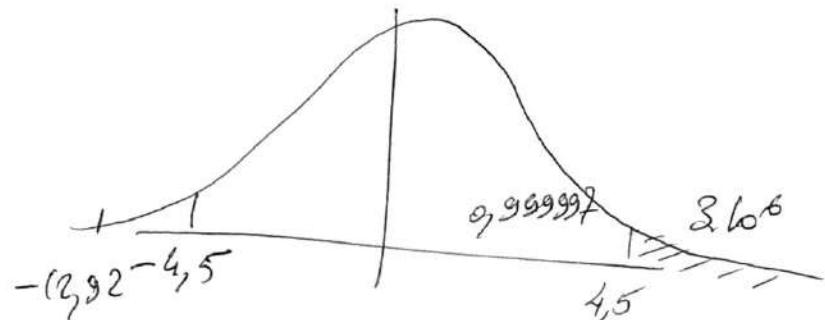
$$\Rightarrow \hat{I}_{100} = \Gamma(\bar{x}_{100} - 1,66, \sqrt{\sigma^2}) \quad \bar{x}_{100} \approx 19,82$$

Q'est la proba de conclure que la machine est déréglée si la moyenne sur le lot des 120 pièces est en réalité 21 mm?

$$l=21, \quad P_{21}(R_{0,5\%}) = P_{21}(\bar{X}_{120} \leq 19,82)$$



$$\dots \text{.} \\ P(Z \leq -12,92) \approx 1,73 \cdot 10^{-38} \\ P(Z \geq -8,98) \approx 1.$$



2) Sans mettre d'hypothèses sur l'écart-type, est-ce que cela modifie les choses?

Dans hyp: $\sigma_0 = 2 \Rightarrow \sigma$ inconnue

$$\text{TLC 4 autonormalisat. } \bar{X}_{120} = \frac{1}{\sqrt{120}} \sum_{i=1}^{120} (x_i - \bar{x}_{120})^2$$

$$\sqrt{120} \frac{\bar{X}_{120} - l}{\sqrt{\sigma^2}} \xrightarrow[n \rightarrow \infty]{\text{P. la.}} Z$$

$$R_{0,5\%} = \left\{ \bar{x}_{120} \leq l - 1,96 \sqrt{\frac{\sigma^2}{120}} \right\} \cup \left\{ \bar{x}_{120} \geq l + 1,96 \sqrt{\frac{\sigma^2}{120}} \right\}$$

Appli Num:

$$\bar{X}_{120}(w) = 2,2975, \quad w \in R_{0,5\%}$$

On rejette encore.

(TCL)

$$\sqrt{n} \frac{\bar{X}_n - 21}{\sigma_0} \xrightarrow[n \rightarrow \infty]{\text{P. la.}} Z \sim N(0,1)$$

La loi de $\sqrt{120} \frac{\bar{X}_{120} - 21}{\sigma_0}$ est approchée par la loi $N(0,1)$,

$$P_{21}(\bar{X}_{120} \leq 19,82) + P_{21}(\bar{X}_{120} \geq 20,18) =$$

$$= P_{21}\left(\sqrt{120} \frac{\bar{X}_{120} - 21}{\sigma_0} \leq \sqrt{120} \frac{19,82 - 21}{\sigma_0}\right) + P_{21}\left(\sqrt{120} \frac{\bar{X}_{120} - 21}{\sigma_0} \geq \sqrt{120} \frac{(20,18 - 21)}{\sigma_0}\right)$$

$$= P(Z \leq -12,92) + P(Z \geq -8,98) \approx 1$$

(49)

$$\sigma_0 = 1$$

Echantillon gaussien

Ex 3 : Consommation de carburant (suite)

Données ex 12 à fiche 1 : $\sum_{i=1}^{100} x_i = 700,51$ et $\sum_{i=1}^{100} x_i^2 = 5043,99$

On suppose $X \sim N(m, \sigma^2)$ inconnues.

1) Donner un intervalle de confiance pour m au niveau de confiance 90 %.

x_1, \dots, x_{100} (ex 12, fiche 1).

Réalisation de X_1, \dots, X_{100} iid de la loi $N(m, \sigma^2)$.

$$\sqrt{n} \frac{\bar{X}_n - m}{\sigma} \sim N(0, 1)$$

$$\bar{X}_n = \frac{1}{n} \sum X_i \sim N\left(m, \frac{\sigma^2}{n}\right); \quad \frac{\bar{X}_n - m}{\sqrt{\sigma^2/n}}$$

$$E(\bar{X}_n) = \frac{1}{n} \sum_{i=1}^n E(X_i) = \frac{1}{n} nm = m.$$

$$\text{et } \sqrt{n} \frac{\bar{X}_n - m}{\sqrt{V_n}} \sim \text{Student}(n-1)$$

$$\text{où } V_n = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x}_n)^2.$$

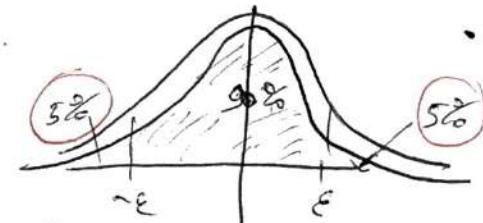
(30)

$$\sqrt{n} \frac{\bar{X}_n - m}{\sqrt{V_n}} \xrightarrow[n \rightarrow \infty]{\text{loi}} Z \sim N(0, 1).$$

(Avec des quantiles de la loi de Student(n) vers les quantiles de la loi normale $n \rightarrow \infty$).

$d = 100$ ds la table.

$n-1 = 99$.



$$P(\text{Student}(99) \leq d) = \alpha$$

$$T_m = \sqrt{n} \frac{\bar{X}_n - m}{\sqrt{V_n}}$$

$$P(|T_m| \leq d) \geq 0,9$$

$$m = 100, \quad T_m \sim \text{Student}(99)$$

à la table, on se contente des quantiles pour $n = 100$,
 $d = 1,66$.

$$\Rightarrow P_{m, \sigma^2} \left(\sqrt{100} \frac{|\bar{X}_{100} - m|}{\sqrt{V_{100}}} \leq 1,66 \right) = 0,90$$

$$P_{m, \sigma^2} \left(m \in \left[\bar{X}_{100} - 1,66 \sqrt{\frac{V_{100}}{100}}, \bar{X}_{100} + 1,66 \sqrt{\frac{V_{100}}{100}} \right] \right) = 0,9$$

$$\Rightarrow \hat{I}_{100} = \left[\bar{X}_{100} - 1,66 \sqrt{\frac{\chi^2_{100}}{100}}, \bar{X}_{100} + 1,66 \sqrt{\frac{\chi^2_{100}}{100}} \right]$$



$$V_n = \frac{1}{n} \sum_{i=1}^n (\bar{X}_i - \bar{X}_m)^2 = \frac{1}{n} \sum X_i^2 - \bar{X}_m^2$$

$$V_n^* = \frac{m}{m-1} V_m = \frac{1}{m-1} \sum X_i^2 - \frac{m}{m-1} \bar{X}_m^2$$

$$\begin{aligned} \chi^2_{100}(20) &= \frac{1}{99} \sum_{i=1}^{100} \bar{x}_i^2 - \frac{100}{99} \left(\frac{1}{100} \sum_{i=1}^m \bar{x}_i \right)^2 \\ &= \frac{1}{99} \times 5043,99 - \frac{100}{99} (7,0055)^2 = 1,38. \end{aligned}$$

$$\bar{X}_{100}(w) = 7,0055.$$

$$\hat{I}_{100}(w) = [6,81 ; 7,20]$$

2) Donner un IdConfiance pour σ^2 de niveau de confiance 90%

• 1 intervalle unilateral : $[0, -] = \hat{I}$.

$$P_{m, \sigma^2}(\sigma^2 \in \hat{I}) \geq 0,9$$

• 1 intervalle bilatéral : \hat{J} .

$$P_{m, \sigma^2}(\sigma^2 \in \hat{J}) \geq 0,9$$

si $U_d \sim \chi^2(d)$, loi asymptotique de U_d

$$U_d \stackrel{\text{loi}}{=} \sum_{i=1}^d Z_i^2 \quad \text{si } Z_i \sim N(0, 1)$$

LFGN

$$\frac{1}{d} \sum_{i=1}^d Z_i^2 \xrightarrow[d \rightarrow \infty]{\text{P.S.}} \mathbb{E}(Z_1^2) = 1.$$

$$\text{Var}(Z_1) = \mathbb{E}(Z_1^2) - \mathbb{E}(Z_1)^2 = \mathbb{E}(Z_1^2).$$

$$\text{TCL} \quad \frac{\sum_{i=1}^d Z_i^2 - d}{\sqrt{2d}} \xrightarrow[d \rightarrow \infty]{\text{loi}} Z \sim N(0, 1).$$

$$\text{Var}(Z_1^2) = \mathbb{E}(Z_1^4) - \mathbb{E}(Z_1^2)^2 = 2.$$

$$\text{Var}(U_d) = \sum_{i=1}^d \text{Var}(Z_i^2) = 2d.$$

$$\frac{U_d - d}{\sqrt{2d}} \xrightarrow[d \rightarrow \infty]{\text{loi}} Z, \text{ la loi de } U_d \text{ pt est approchée}$$

si d est grand par $N(d, 2d)$.

$$\triangle \sqrt{2U_d} - \sqrt{2d-1} \xrightarrow[n \rightarrow \infty]{\text{loi}} Z \text{ se dmy 4 Slutsky.}$$

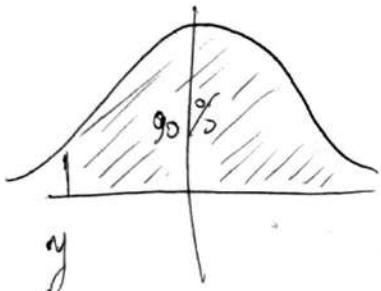
(Permet d'obtenir les quantiles de la loi du $\chi^2(d)$ par des grandes valeurs de d). @ trouver x tq $P(U_d \geq x) = 0,9$

T₁ P 1.11

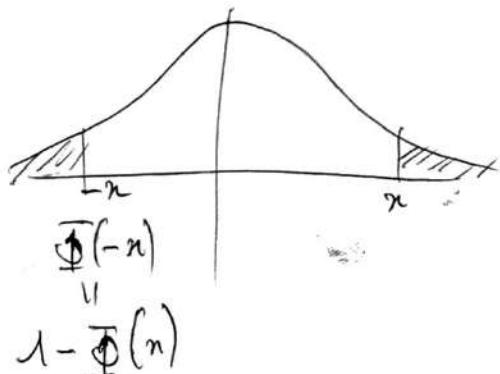
• $P(X_d \geq n) = P(\sqrt{2X_d} - \sqrt{2d-1} \geq \sqrt{n})$
si $d \geq 1$
 $\approx P(Z \geq \sqrt{2n} - \sqrt{2d-1}) = 0,9$

pour $\sqrt{2n} - \sqrt{2d-1} = -1,28$.

$$n = \frac{(\sqrt{2d-1} - 1,28)^2}{2}$$

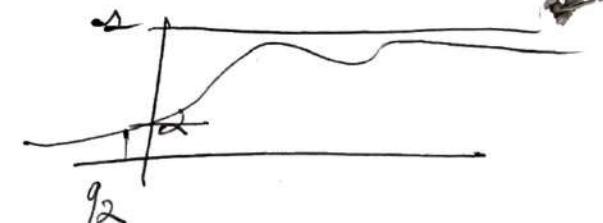


$$\begin{aligned}P(Z > y) &= 0,9 \\P(-z > y) &= 0,9 \\P(z \leq -y) &= 0,9\end{aligned}$$



trouver le quantile d'une loi du $\chi^2(d)$
si $d \geq 30$.

⑤ Le quantile d'ordre α de la loi de X est le réel x_α tq $P(X \leq x_\alpha) = \alpha$.
Pas de pb de définition si X est à densité simon
 $x_\alpha = F^{-1}(\alpha) = \inf \{x \in \mathbb{R}, F(x) \geq \alpha\}$
où F est la loi de X .



$$\begin{aligned}F(x_\alpha) &= \alpha \\P(X \leq x_\alpha) &= \alpha\end{aligned}$$

ici $X_d \sim \chi^2(d)$

$$\sqrt{2X_d} - \sqrt{2d-1} \xrightarrow[d \rightarrow \infty]{\text{loi}} Z$$

$$P(Z \leq 1,28) = 0,9$$

$$= P(\sqrt{2X_d} - \sqrt{2d-1} \leq 1,28) \approx 0,90$$

$$\boxed{P(X_d \leq \left(\frac{(1,28 + \sqrt{2d-1})^2}{2} \right))} = 0,9$$

quantile approché de la loi $\chi^2(d)$ d'ordre 0,9
Quantile d'ordre 0,1 de $\chi^2(d)$
 $P(Z \leq -1,28) = 0,1$

⑤ $\Rightarrow P($

$$\mathbb{P}(Z \leq -1,28) = 0,1$$

$$\Rightarrow \mathbb{P}\left(\chi_d \leq \left(\frac{\sqrt{2d-1}}{2} - 1,28\right)^2\right) \approx 0,1$$

$$\Leftrightarrow \mathbb{P}\left(\chi_d \geq \left(\frac{\sqrt{2d-1}}{2} - 1,28\right)^2\right) \approx 0,9$$

$$\chi_d \rightarrow \frac{nV_n}{\sigma^2},$$

$$\frac{nV_n}{\sigma^2} \geq \left(\frac{\sqrt{2(n-1)} - 1 - 1,28}{2} \right)^2$$

$\underbrace{}_{q_{n-1}(0,1)}$

$$\Leftrightarrow \sigma^2 \leq \frac{nV_n}{q_{n-1}(0,1)}$$

$$\mathbb{P}_{\sigma^2} \left(\sigma^2 \leq \frac{nV_n}{q_{n-1}(0,1)} \right) \geq 0,9$$

(FF)

$$q_d(z) \approx \left(\frac{\sqrt{2d-1} + \Phi^{-1}(z)}{2} \right)^2$$

$$a \leq \frac{nV_n}{\sigma^2} \leq b$$

bilateral

$$\frac{nV_n}{b} \leq \sigma^2 \leq \frac{nV_n}{a}$$

$$\sigma^2 \in [0, \frac{nV_n}{q_{n-1}(0,1)}]$$

Unilateral
(precise on DS).

TD 4 Ex 2 : [M] Monte-Carlo pour le calcul d'intégrals

$f: [0,1] \rightarrow \mathbb{R}$ cont; 1^{re} approche de \int_m

$$m := \int_0^1 f(u) du, (U_i)_{i=1}^m \text{ ind}$$

$U_i \sim \text{Unif}([0,1])$.

$$M_{2m} := \frac{1}{2m} \sum_{i=1}^{2m} f(U_i) + \tilde{M}_{2m} := \frac{1}{2m} \sum_{i=1}^m (f(U_i) + f(1-U_i))$$

1) Explique pourquoi $X_1 := f(U_1)$ et $Y_1 = f(U_1) + f(1-U_1)$ sont intégrables & exprimer l'espérance à l'aide de l'intégration.

$X_1 := f(U_1)$, X_1 est intégrable car f est bornée sur $[0,1]$. (car cont sur un segment).

Donc $\exists M \in \mathbb{R}^+$ tq $|X_1| = |f(U_1)| \leq M \Rightarrow \mathbb{E}(X_1) < \infty$.

De m, $|Y_1| = |f(U_1) + f(1-U_1)| \leq |f(U_1)| + |f(1-U_1)| \leq 2M$.

De Y_1 est une r.v. bornée de intégr.

$$\Rightarrow \mathbb{E}(X_1) = \mathbb{E}(f(U_1))$$

(R) si Z a pr densité h et si $\psi(z)$ est intégrable

$$\Rightarrow \mathbb{E}(\psi(z)) = \int_R \psi(z) h(z) dz$$

$$\mathbb{E}(f(U_1)) = \int_{\mathbb{R}} f(u) \underbrace{\mathbb{1}_{[0,1]}(u)}_{\text{densité de } U_1} du, \quad \mathbb{1}_{[0,1]}(u) = \frac{1}{2} \mathbb{1}_{[0,2]}(u)$$

$$\Rightarrow \mathbb{E}[f(U_1)] = \int_{\mathbb{R}} f(u) \mathbb{1}_{[0,1]}(u) du = \int_{\mathbb{R}} f(u) du = m$$

$$\mathbb{E}(Y_1) = \mathbb{E}[f(U_1) + f(1-U_1)]$$

$$= \int_{\mathbb{R}} (f(u) + f(1-u)) \mathbb{1}_{[0,1]}(u) du$$

$$= \int_0^1 f(u) du + \int_0^1 f(1-u) du = 2m$$

(R) $\mathbb{E}(f(U_1)) = \mathbb{E}(f(1-U_1))$
car $1-U_1 \sim \text{Unif}([0,1])$.

2) En se appuyant sur le cours, montrer que

$$(\bar{M}_{2n})_{n \in \mathbb{N}^*} \text{ et } (\tilde{M}_{2n})_{n \in \mathbb{N}^*} \text{ sont convergents}$$

vers m pdt. $n \rightarrow \infty$.

$$\bar{M}_{2n} = \frac{1}{2n} \sum_{i=1}^{2n} X_i \text{ par LFGN, } (X_i)_{i \in \mathbb{N}^*} \text{ caré intégrable.}$$

$$\bar{N}_{2n} \xrightarrow[n \rightarrow \infty]{\text{P.S.}} \mathbb{E}(X_1) = m$$

$$\tilde{M}_{2n} = \frac{1}{2n} \sum_{i=1}^n Y_i \text{ par LFGN, } (Y_i)_{i \in \mathbb{N}^*} \text{ caré intégrable.}$$

$$\frac{1}{m} \sum_{i=1}^n Y_i \xrightarrow{\text{P.S.}} \mathbb{E}(Y_1) = m$$

$$\Rightarrow \tilde{M}_{2n} \xrightarrow[n \rightarrow \infty]{\text{P.S.}} m$$

3) Expliquer pourquoi X_1 et Y_1 sont de caré intégrables et exprimer leur variance à l'aide de f .

$$|X_1|^2 \leq M^2, \quad M = \sup_{n \in \mathbb{N}^*} |f(n)|$$

$\Rightarrow X_1$ est de caré intégrable idem pour Y_1 .

$\Rightarrow Y_1$ est de caré intégrable

$$\text{Var}(X_1) = \mathbb{E}(f^2(u_1)) - m^2 = \int_0^1 f^2(x) dx - m^2$$

$$\begin{aligned} \text{Var}(Y_1) &= \mathbb{E}(Y_1^2) - \mathbb{E}^2(Y_1) = \mathbb{E}[f(u_1) + f(1-u_1)]^2 \\ &= \mathbb{E}[f^2(u_1) + f^2(1-u_1) + 2f(u_1)f(1-u_1) - \mathbb{E}^2(Y_1)] \\ &= 2 \int_0^1 f^2(x) dx + 2 \int_0^1 f(x)f(1-x) dx - 2m^2 \\ &\quad + \int_0^1 f(x)f(1-x) dx \end{aligned}$$

1) On appelle $\int_A f d\lambda$

a) Montrer que si $(x, y) \in [0, 1]^2$,

$$(f(x) - f(y))(f(1-x) - f(1-y)) \leq 0.$$

$f(x) - f(y)$ est du signe de $x-y$.

$x \mapsto f(1-x)$ est décroissante.

b) De $f(1-x) - f(1-y)$ est du signe opposé de $x-y$.
 $\Rightarrow f(x) - f(y)$ et $f(1-x) - f(1-y)$ à signes opposés.

$$\text{Q) } \mathbb{E}(f(U_1)f(1-U_1)) \leq \mathbb{E}^2(U_1)$$

$$\text{Var}(\tilde{M}_{2n}) = \text{Var}\left(\frac{1}{2n} \sum_{i=1}^m f(U_i) + f(1-U_i)\right)$$

D'après a) $(f(x)-f(y))(f(1-x)-f(1-y)) \leq 0 \quad \forall (x,y) \in [0,1]^2$,
 $f(x)f(1-x) + f(y)f(1-y) \leq f(y)f(1-x) + f(x)f(1-y)$

$$y = 1-x.$$

$$2f(n)f(1-n) \leq f^2(1-n) + f^2(n) \quad \boxed{\text{M1}}$$

$$\Rightarrow 2f(U_1)f(1-U_1) \leq f^2(1-U_1) + f^2(U_1)$$

$$\begin{aligned} & \& \mathbb{E}(f(U_1)f(1-U_1)) \leq \mathbb{E}[f^2(U_1)] + \mathbb{E}[f^2(1-U_1)] \\ & & = 2\mathbb{E}[f^2(U_1)]. \end{aligned}$$

car U_1 et $1-U_1$ ont la m^e loi.

M2 $x = U_1, y = U_2$.
 $\mathbb{E}(-) \leq \mathbb{E}^2(f(U_1))$ (et on utilise la l'indépendance de U_1 & U_2) plus fort.

c) Comparer les variances de M_{2n} et \tilde{M}_{2n} .

$$\text{Var}(M_{2n}) = \text{Var}\left(\frac{1}{2n} \sum_{i=1}^{2n} X_i\right) = \frac{1}{4n^2} \text{Var}\left(\sum_{i=1}^{2n} X_i\right)$$

$$= \frac{1}{4n^2} \sum_{i=1}^{2n} \text{Var}(X_i) \quad \text{car les } (X_i) \text{ sont indép.}$$

$$= \frac{1}{2n} \text{Var}(X_1) = \frac{1}{2n} \left[\int_0^1 f^2(u) du - m^2 \right] \quad \textcircled{55}$$

$$\text{Var}\left(\sum_{i=1}^m Y_i\right) = \frac{1}{4n^2} \sum_{i=1}^m \text{Var}(Y_i)$$

$$= \frac{1}{4n} \text{Var}(Y_1) = \frac{1}{4n} \text{Var}(f(U_1) + f(1-U_1))$$

$$= \frac{1}{4n} (\text{Var}(f(U_1)) + \text{Var}(f(1-U_1)) + 2\text{cov}(f(U_1), f(1-U_1)))$$

$$\begin{aligned} & = \frac{1}{4n} \left[2\text{Var}f(U_1) + 2\left(\mathbb{E}(f(U_1)f(1-U_1)) - \mathbb{E}(f(U_1))^2\right) \right] \end{aligned}$$

$$\leq \frac{1}{2n} \text{Var}(f(U_1)) = \frac{1}{n} \text{Var}(X_1).$$

$$\begin{aligned} & \text{cov}(f(U_1), f(1-U_1)) \leq 0. \\ & = \mathbb{E}[f(U_1)f(1-U_1)] - [\mathbb{E}[f(U_1)]][\mathbb{E}[f(1-U_1)]] \end{aligned}$$

$$= \mathbb{E}[f(U_1)f(1-U_1)] - m^2$$

$$\text{g) } \mathbb{E}[f(U_1)f(1-U_1)] \leq m^2 = [\mathbb{E}(f(U_1))]^2$$

$$\Leftrightarrow \int_0^1 f(u)f(1-u) du \leq m^2.$$

$$\text{cov}(x, y) = \mathbb{E}(xy) - \mathbb{E}(x)\mathbb{E}(y)$$

Comparaison des risques quadratiques:

$$\text{Var}(\tilde{M}_{2n}) \leq \text{Var}(M_{2n}).$$

$$R(\tilde{M}_{2n}) = \mathbb{E}[(\tilde{M}_{2n} - m)^2] = \text{Var}(\tilde{M}_{2n})$$

$$\text{car } m = \mathbb{E}[\tilde{M}_{2n}]$$

al \tilde{M}_{2n} est un estimateur sans biais de m meilleur que M_{2n} au sens du R² quadratique. (lorsq f est ↗)

5) En utilisant TLC, proposer un IIC au n de niveau 95% (en négligeant l'erreur due à l'approx gaussienne) en supposant que l'on connaît un majorant M de $\sup_{x \in [0,1]} |f(x)|$.

$$\tilde{M}_{2n} = \frac{1}{m} \sum_{i=1}^n \frac{Y_i}{2}$$

$$\sqrt{n} \frac{\tilde{M}_{2n} - m}{\sqrt{\text{Var}(\frac{Y_i}{2})}} \xrightarrow[m \rightarrow \infty]{\text{Loi}} Z \text{ où } Z \sim N(0,1)$$

$$= \sqrt{n} \frac{\tilde{M}_{2n} - m}{\sqrt{\text{Var}(Y_1)}} \xrightarrow[m \rightarrow \infty]{\text{Loi}} Z$$

$$\begin{aligned} & P(a \leq Z_n \leq b) \xrightarrow[n \rightarrow \infty]{} P(a \leq Z \leq b) \\ & \Leftrightarrow P(-\varepsilon \leq Z_n \leq \varepsilon) \xrightarrow[n \rightarrow \infty]{} P(-\varepsilon \leq Z \leq \varepsilon) \\ & \Leftrightarrow P(|Z_n| \leq \varepsilon) \xrightarrow[n \rightarrow \infty]{} P(|Z| \leq \varepsilon) \end{aligned}$$

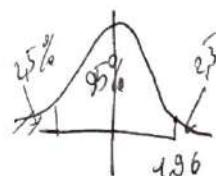
$$\text{Var}(Y_2) \leq 2 \text{Var}(f(U_1))$$

$$2 \left(\mathbb{E}[f^2(U_1)] - [\mathbb{E}(f(U_1))]^2 \right)$$

$$\leq 2 \mathbb{E}[f^2(U_1)] \leq 2M^2.$$

$$\varepsilon = \Phi^{-1}(0,975) = 1,96.$$

$$P(Z \leq 1,96) = 97,5\%$$



$$\begin{aligned} V(\hat{\theta}) &= \mathbb{E}(\hat{\theta}^2) - \mathbb{E}^2(\hat{\theta}) \\ &\leq \mathbb{E}(\hat{\theta}^2) \end{aligned}$$

$$\{ |Z_m| \leq 1,96 \} = \left\{ 2\sqrt{n} \frac{|\tilde{M}_{2n} - m|}{\sqrt{\text{Var}(Y_1)}} \leq 1,96 \right\}$$

$$= \left\{ m \in \left[\tilde{M}_{2n} - 1,96 \frac{\sqrt{\text{Var}(Y_1)}}{2\sqrt{n}} ; \tilde{M}_{2n} + 1,96 \frac{\sqrt{\text{Var}(Y_1)}}{2\sqrt{n}} \right] \right\}$$

$$\subset \left\{ m \in \left[\tilde{M}_{2n} - 1,96 \frac{\sqrt{2} M}{2\sqrt{n}} ; \tilde{M}_{2n} + 1,96 \frac{\sqrt{2} M}{2\sqrt{n}} \right] \right\} \geq 0,95$$

$$\liminf_{n \rightarrow \infty} P\left(m \in \left[\tilde{M}_{2n} - 1,96 \frac{M}{\sqrt{2n}} ; \tilde{M}_{2n} + 1,96 \frac{M}{\sqrt{2n}} \right]\right) \geq 0,95$$

En négligeant l'erreur d'approximation gaussienne.

④ Le Forró

I Intro

⑤ Le forró : music du Nord & Brésil à base d'accordéon, zérumbe & triangle. cf Lille, le Forró existe depuis 2008 par Cacau Moutinho. @ Aqui de Norte.

II P'ties

- TP 1) Si on écoute du forró \Rightarrow on ne peut s'empêcher de danser.
2) Le forró rend heureux.

Preuve Devinette instrument de la prof.

Copie 30 avril / 8 mai / 28 mai
12 bars - 12 ⑨⁹
Aqui de Norte au Relais.

Ex 2 Simulac de la loi de Poisson

$(U_i)_{1 \leq i \leq m}$ iid Uniform $[0, 1]$.

$$M_m = \prod_{i=1}^m U_i$$

1) Montrer $(M_m)_{m \in \mathbb{N}^*}$ converge presque sûrement vers 0.

M1 Penser au log.

$$Z_m = \log M_m = \sum_{i=1}^m \log U_i,$$

si $\log U_1$ est intégrable $\Rightarrow \frac{1}{m} \sum_{i=1}^m \log(U_i) \xrightarrow[m \rightarrow \infty]{\text{P.s.}} \mathbb{E}(\log(U_1))$

est iid car $(\log U_i)_{i \in \mathbb{N}^*}$.

$$\mathbb{E}(\log(U_1)) = \int_{\mathbb{R}} \log x f(x) dx$$

$$= \int_{\mathbb{R}} \log x \mathbf{1}_{[0,1]}(x) dx = \int_0^1 \log x dx$$

$$= [x \log x - x] \Big|_0^1 = -1.$$

$$\frac{1}{m} Z_m \xrightarrow[m \rightarrow \infty]{\text{P.s.}} -1$$

$$M_m = e^{Z_m} = e^{m(\frac{1}{m} Z_m)}$$

$$M_m \xrightarrow[m \rightarrow \infty]{\text{P.s.}} 0$$

Markov.

$$\boxed{\text{M2}} \quad \mathbb{P}(M_m > \varepsilon) \leq \frac{\mathbb{E}(M_m)}{\varepsilon}$$

$$\text{or } \mathbb{E}(M_m) = \mathbb{E}\left(\prod_{i=1}^m U_i\right) = \prod_{i=1}^m \mathbb{E}(U_i) = \frac{1}{2^m}$$

$$\Rightarrow \mathbb{P}(M_m > \varepsilon) \leq \frac{1}{2^m \varepsilon}.$$

$$\Rightarrow \lim_{m \rightarrow \infty} \mathbb{P}(M_m > \varepsilon) = 0.$$

M_m converge en proba vers 0.

$$\Rightarrow \sum \mathbb{P}(M_m > \varepsilon) < \infty$$

De M_m converge presque sûrement vers 0.

$$\boxed{\text{M3}} \quad M_m = \prod_{i=1}^m U_i$$

• $0 \leq M_m \leq 1$ et $M_{m+1} = U_{m+1} M_m \leq M_m$ p.s.

• $(M_m)_{m \in \mathbb{N}^*}$ ↘

• Pour presque tout ω : $(M_m(\omega))_{m \in \mathbb{N}^*}$ ↘ minore de 0 et $M(\omega) \geq 0$

Pour le Th de dominé,

$$\lim_{n \rightarrow \infty} \mathbb{E}(M_n) = \mathbb{E}(M) = 0$$

car $\mathbb{E}(M_n) - \frac{1}{2^n}$.

$\Rightarrow \mathbb{E}(M) = 0 \Rightarrow M=0$ p.s car M est une v.a positive.

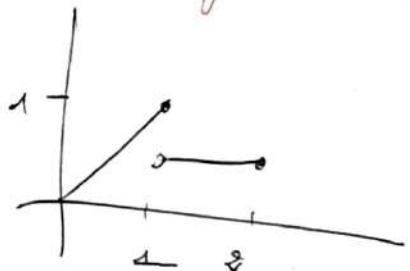
$$\forall t \in \mathbb{R}, \quad F(t) = \int_{-\infty}^t f(u) du$$

$$= \begin{cases} 0 & \text{si } t < 0 \\ \frac{t^2}{2} & \text{si } 0 \leq t < 1 \\ \frac{1}{2} & \text{si } 1 \leq t < 2 \\ 1 & \text{si } t \geq 2 \end{cases}$$

Ex4 Plusieurs méthodes de simulation

On va simuler v.a X de densité f sur \mathbb{R} :

$$f(x) = x \mathbf{1}_{[0,1]}(x) + \frac{1}{2} \mathbf{1}_{[1,2]}(x)$$

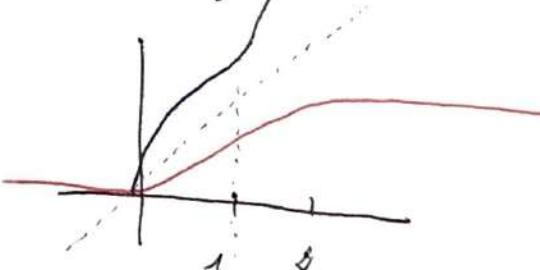


$$\int_{\mathbb{R}} |f(x)| dx = 1 \quad \textcircled{1}$$

et $f \geq 0$ $\textcircled{2}$.

$\rightarrow x \in [0,1]$,

$$F(t) = \int_0^1 x \mathbf{1}_{[0,1]}(x) dx + \int_1^t \frac{1}{2} dx = \frac{1}{2} + \frac{t-1}{2} = \frac{t}{2}$$



1) Expliquer comment simuler X en utilisant la M pour inversion de la f de répartition.

• Calcul de F^{-1} .

• Si $u \in [0, \frac{1}{2}]$:

$$F(t) = u$$

$$\Leftrightarrow \frac{t^2}{2} = u$$

$$\Leftrightarrow t = \sqrt{2u}$$

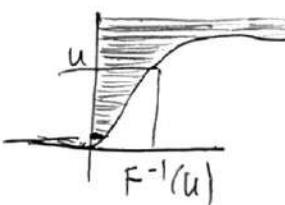
• Si $u \in [\frac{1}{2}, 1]$:

$$\Leftrightarrow F(t) = u$$

$$\Leftrightarrow \frac{t}{2} = u \Leftrightarrow t = 2u$$

(60) $\forall u \in [0,1] \Rightarrow F^{-1}(u) = \sqrt{2u} \mathbf{1}_{[0,\frac{1}{2}]}(u) + 2u \mathbf{1}_{[\frac{1}{2},1]}(u)$

Pour simuler X de densité f , il suffit de simuler $U \sim \text{Unif}([0,1])$ et $X = F^{-1}(U)$



$$= \sqrt{u} \mathbb{1}_{[0, \frac{1}{2}]}(u) + \sqrt{2u} \mathbb{1}_{[\frac{1}{2}, 1]}(u).$$

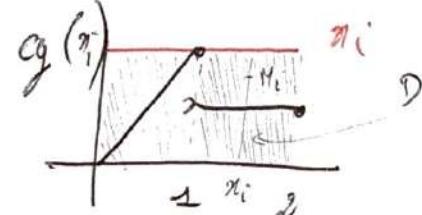
2) Expliquer comment simuler X en utilisant la M de rejet à partir de la loi uniforme sur $[0,2]$.

► Majorer f par $c g$ où g est une densité qu'on sait simuler.

$$g(x) = \frac{1}{2} \mathbb{1}_{[0,2]}(x)$$

$$c g(x) = \mathbb{1}_{[0,2]}(x)$$

$$X_i \sim \text{Unif}([0,2])$$



$$U_i \sim \text{Unif}([0,1])$$

$$M_i = (X_i, c g(x_i) U_i) \sim \text{Unif}(D).$$

$$D = \{(x,y) \in \mathbb{R}^2 : 0 \leq y \leq c g(x)\}$$

$$\sigma(1-T) < 0 \Rightarrow 0.95$$

$$(RQ) cg(x_i) U_i = \prod_{i \in \{0,1\}} (x_i) U_i = U_i.$$

On simule les points $(M_i)_{i \in \mathbb{N}^*}$ jusqu'à la condit : $c g(x_i) U_i \leq f(x_i) \Leftrightarrow U_i \leq f(x_i)$

$T = \inf \{i \in \mathbb{N}^*, U_i \leq f(x_i)\}$ alors $\forall T$ a pr densité f .

3) Soit Y & Z M indép de loi uniforme respectivement sur $[0,1]$ & sur $[0,2]$.

Quelle est la densité de S = max(Y, Z).
et une autre M de simulation de S .

Refine : calculer f de Répartition

$$F_S(t) = P(S \leq t) = P(\max(Y, Z) \leq t)$$

$$= P(\{Y \leq t\} \cap \{Z \leq t\})$$

$$= P(Y \leq t) \times P(Z \leq t) \quad \text{car } Y \perp\!\!\!\perp Z.$$

$$P(Y \leq t) = \begin{cases} 0 & \text{si } t < 0 \\ t & \text{si } t \in [0,1] \\ 1 & \text{si } t \geq 1 \end{cases}$$

$$P(Z \leq t) = \begin{cases} 0 & \text{si } t < 0 \\ t/2 & \text{si } t \in [0,1] \\ 1 & \text{si } t \geq 1 \end{cases}$$

$$(61) F_S(t) = \begin{cases} 0 & \text{si } t < 0 \\ t^2/2 & \text{si } t \in [0,1] \\ 1 & \text{si } t \geq 1 \end{cases}$$

$(f \# R)^l = \text{densité}$

So let X ont la loi de simuler X ,
on simule X , on simule $U_1 \sim \text{Uniform}(0,1)$
 $U_2 \sim \text{Uniform}(0,1)$
 $X = \max(U_1, 2U_2)$.